Appunti di Calcolo Numerico

Tiziano Cazzato

Indice Argomenti

1 Analisi dell'errore

2 Richiami di Algebra Lineare

Introduzione alla materia

Calcolo numerico, è un nome generico a prima vista è tutto quello che riguarda, quantità numeriche da calcolare, una definizione che si potrebbe dare è la seguente:

↳ studio delle proprietà degli algoritmi per problemi di matematica continua con (possibilmente) grandi dati

Con matematica continua si intende che i nostri dati, e risultati intermedi saranno, vettori, numeri complessi, matrici, strutture dati dunque che contengano numeri reali ($\mathbb{R}$) o complessi ($\mathbb{C}$).

Dunque immaginiamo di voler salvare in memoria un numero infinito di cifre ⟶ non è possibile! Dunque sono necessarie delle approssimazioni, e questo introduce degli errori!

↳ Sono necessarie approssimazioni, quando si rappresentano le quantità calcolate (intermedie o finali), non tutti i problemi hanno un'espressione (algoritmo) in forma chiusa! Vedremo soluzioni iterative, che arrivano alla soluzione per passi.

Nella pratica, ci interessano due aspetti:

- Cosa succede con questi errori quando si va avanti con i conti? Dunque ci sono errori che possono provenire da dati iniziali (misurazioni) Ma come interagiscono gli errori di approssimazione e gli algoritmi?
  - Si possono avere algoritmi stabili/instabili
  - condizionamento del problema (avere un risultato molto lontano da quello che si cerca di approssimare)
- Quanto in fretta convergono questi algoritmi? (convergere = man mano che procede si avvicina sempre di più al risultato finale)
  - Costo computazionale
  - Accuratezza

Analisi dell’errore 1

Definizione numeri in virgola mobile

Preso un numero x scalare con $x \in \mathbb{R}$, vogliamo rappresentarlo con un numero finito di parametri interi ($\mathbb{N}$ o $\mathbb{Z}$). Fissata una base $\beta \in \mathbb{N}$, $\beta > 1$ possiamo trovare delle cifre ovvero una successione $\{d_i\}_{i=1,2,3}$ ed un esponente $e \in \mathbb{Z}$, tali che è possibile scrivere x come =

β base
e esponente
d_i cifre rappresentazione

$$x = \text{segno}(x) \cdot \beta^e \sum_{i=1}^{\infty} d_i \cdot \beta^{-i}$$

$$\text{segno}(x) = \begin{cases} 1 & x > 0 \\ -1 & x < 0 \end{cases}$$

Questa è una maniera formale di scrivere un numero come le sue cifre

Esempio (notazione scientifica in base 10)

$x = 0{,}0075 \longrightarrow 75 \times 10^{-4} \longrightarrow 7{,}5 \times 10^{-3}$

Un primo problema è che la rappresentazione non non è unica, nel senso che posso scrivere lo stesso numero in infiniti modi differenti, spostando la virgola

$3{,}14 = 0{,}0034 \cdot 10^{3} = 314 \cdot 10^{-2}$ la rappresentazione di un numero reale non è univoca

$2{,}\overline{9} = 2{,}999\ldots = 3$ anche qui abbiamo due modi per scrivere la stessa cosa

Quindi dato un numero chi è la sua rappresentazione per determinare e ed d in maniera univoca, ciò si può risolvere con alcune proprietà in più sulla rappresentazione, escludendo questi due esempi, attraverso il

Teorema della rappresentazione

sia $1 < B < \mathbb{N}$, $x \in \mathbb{R}$, $x \neq 0$, allora esiste ed è unica $\exists!$ rappresentazione di x in base β tale che

① $d_1 \neq 0$ (la prima cifra non sia zero)

② NON ESISTA $k \in \mathbb{N}$ tale che $d_j = \beta - 1 \quad \forall j > k$

Con queste proprietà la rappresentazione è unica e non ci sono ambiguità

DEFINIZIONE virgola mobile normalizzata

L'unica rappresentazione in base β che verifica le proprietà enunciate sopra, si dice rappresentazione in virgola mobile normalizzata

inoltre la serie $\sum_{J=1}^{\infty} d_J \beta^{-J}$ è detta MANTISSA di $x \in \mathbb{R}$

osservazione

la mantissa pensata come la parte dopo la virgola, vale sempre che (per ogni rappresentazione in virgola mobile normalizzata)

$$\beta^{-1} < \sum_{J=1}^{\infty} d_J \beta^{-J} < 1$$

è più grande di $0,100\ldots$, poichè abbiamo imposto che $d_1 \neq 0$

Ma si ha ancora il problema che le cifre sono infinite, dunque abbiamo infinite cifre, ma in memoria se ne possono tenere solo un numero finito, per risolvere questo troncheremo la mantissa e limiteremo l'esponente, troncando la mantissa scegliamo quante cifre tenere, l'esponente va limitato perchè potrebbe essere arbitrariamente grande.

DEFINIZIONE numeri macchina

dati 4 interi β, m, L, U tali che $\beta > 1$, $L \leq U$ ed $m > 0$ definiamo l'insieme dei numeri di macchina $\mathcal{F}(\beta, m, L, U)$ come:

$$\left\{ x \in \mathbb{R} : x = \text{segno}(x) \cdot \beta^{e} \sum_{i=1}^{m} d_i \beta^{-i},\ L \leq e \leq U,\ d_i \in \{0, \ldots \beta-1\},\ d_1 \neq 0 \right\} \cup \{0\}$$

Questo è l'insieme dei numeri che è possibile rappresentare in maniera esatta, il problema però è che ci sono numeri infiniti che non è possibile rappresentare esattamente

esempio

guardiamo come questi numeri si riescano a rappresentare esattamente nella retta reale

$\beta = 2$ $m = 3$ $L = -1$ $U = 3$ (3 cifre per la mantissa ed esponenti che variano tra -1 e 3)

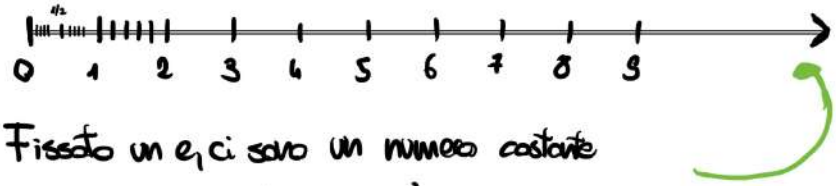

Fissato un e, ci sono un numero costante di elementi in $[\beta^{e-1}, \beta^{e})$, che posso rappresentare, cambiando l'esponente è come se zoomassimo avanti dietro sulla retta

Sono anche equispaziati. Ma quanti sono questi numeri? in questo caso sono 4, tra ogni intervallo scelto dall'esponente. In scala logaritmica questi appaiono così, equispaziati.

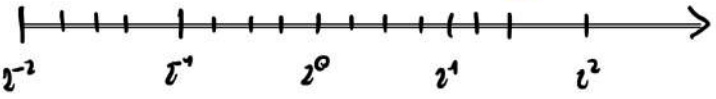

Osservazioni:

① **MINIMO RAPPRESENTABILE >0:** si prende il più piccolo esponente e poi la mantissa più piccola possibile, dove la prima $\neq 0$, e le successive sono zeri $\quad \beta^{L} \cdot d_1 \cdot \beta^{-1} = \beta^{L-1}$

② **MASSIMO RAPPRESENTABILE >0:** discorso opposto, il massimo esponente, e la massima mantissa con cifre massime $(\beta-1)$,

$$\beta^{U}(\beta-1)\sum_{i=1}^{m}\beta^{-i} = \beta^{U}(\beta-1)\left[\frac{1-\beta^{-m-1}}{1-\beta^{-1}} - 1\right] =$$

$$= \beta^{U}(\beta-1)\left[\frac{(1-\beta^{-m-1})\beta}{\beta-1} - 1\right] =$$

$$= \beta^{U}(\beta-1)\left[\frac{\beta-\beta^{-m}-\beta+1}{\beta-1}\right] = \beta^{U}(1-\beta^{-m})$$

Per analisi 1

$$\sum_{j=0}^{n} p^{j} = \frac{1-p^{n+1}}{1-p}$$

③ **QUANTI SONO I NUMERI RAPPRESENTABILI?**

$$2 \cdot (U-L+1)\,(\beta^{m}-\beta^{m-1}) + 1$$

- 2: possibili segni
- $(U-L+1)$: possibili esponenti
- $(\beta^{m}-\beta^{m-1})$: possibili mantisse (tolgo quelle che iniziano con 0)
- 1: il numero 0

Le scelte più comuni nel software sono (IEEE STANDARD):

	β	m	L	U	Memoria
precisione doppia	2	53	-1021	1024	8 byte
precisione singola	2	24	-125	128	4 byte

Parliamo adesso di arrotondamento

DEFINIZIONE arrotondamento (rounding)

dato $x \in \mathbb{R}$ è molto probabile che $x \notin F(\beta, m, L, U)$, ovvero che questo non stia all'interno dei numeri rappresentabili, dunque si distinguono 3 situazioni:

1. $|x| > \beta^U(1-\beta^{-m})$ il numero in modulo è più grande del max rappresentabile (OVERFLOW)
2. $|x| < \beta^{L-1}$ il numero in modulo è minore del più piccolo rappresentabile (UNDERFLOW)
3. qui viene applicato l'arrotondamento e siamo nel seguente range $\beta^{L-1} \leq |x| \leq \beta^U(1-\beta^{-m})$

dunque un'arrotondamento è una funzione $R_D: \mathbb{R} \xrightarrow{\text{va dai reali ai macchina}} F(\beta, m, L, U)$, $R_D(x)$ assegna uno dei due numeri di macchina adiacenti al numero x, le scelte più comuni sono

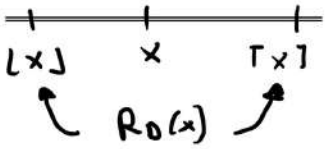

- Troncamento round-down $T_R(x) = \lfloor x \rfloor \ \forall x$
- Troncamento round-up $U_P(x) = \lceil x \rceil \ \forall x$
- Troncamento round-to-nearest $R_N(x) = \begin{cases} \lceil x \rceil & d_{m+1} \geq \beta/2 \\ \lfloor x \rfloor & d_{m+1} < \beta/2 \end{cases}$

Esempio

$x = \text{segno}(x)\,\beta^e \sum_{i=1}^{\infty} d_i \beta^{-i}$ avendo questa rappresentazione con infinite cifre

$T_R(x) = \text{segno}(x)\,\beta^e \sum_{i=1}^{m} d_i \beta^{-i}$ (si ferma ad m)

$U_P(x) = \text{segno}(x)\,\beta^e \left(\sum_{i=1}^{m} d_i \beta^{-i} + \beta^{-m} \right)$ (fermo ad m ma aggiungo una cifra finale)

$$R_N(x) = \begin{cases} T_R(x) & d_{m+1} < \beta/2 \\ U_P(x) & d_{m+1} \geq \beta/2 \end{cases}$$

Valgono le seguenti proprietà

- $|x - T_r(x)| \leq \beta^{e-m}$
- $|x - U_P(x)| \leq \beta^{e-m}$

  L'errore assoluto è minore o uguale ad un'unità nell'ultima cifra significativa

- $|x - R_N(x)| \leq \frac{1}{2}\beta^{e-m}$

  L'errore è dimezzato qui, arrotondando al valore più vicino, non sarò mai più lontano della metà della distanza tra due numeri rappresentabili

  $= \min |z - x|$ dove $z \in F(\beta, m, L, U)$ stiamo cercando la minima distanza!

Considereremo d'ora in poi solo R_N

DEFINIZIONE errore ASSOLUTO E RELATIVO

- L'errore assoluto è la differenza tra il valore esatto e quello arrotondato $\delta x = x - R_N(x)$
- L'errore relativo è il rapporto tra l'errore assoluto ed il valore esatto. È fondamentale perché ci dice quanto l'errore pesi rispetto alla grandezza del numero $\varepsilon_x = \frac{x - R_N(x)}{x} = \frac{\delta x}{x}$

Si ricava facilmente che, l'errore relativo non cresce all'infinito, ma è LIMITATO SUPERIORMENTE, segue questa disuguaglianza dal modello

$$|\varepsilon_x| \leq \frac{|\delta x|}{|x|} \leq \frac{\frac{1}{2}\beta^{e-m}}{\beta^{e-1}} \leq \frac{1}{2}\beta^{1-m}$$

→ Si intuisce che questo risultato non dipende da x, dunque a prescindere dal numero che utilizzo, l'errore relativo massimo è sempre lo stesso.

OSS: l'errore relativo è uniformemente limitato per tutti gli $x \in \mathbb{R}$ dalla quantità $\frac{1}{2}\beta^{1-m}$

ciò che abbiamo appena ricavato si chiama PRECISIONE DI MACCHINA

DEFINIZIONE PRECISIONE DI MACCHINA

La quantità $U = \frac{1}{2}\beta^{1-m}$ è detta precisione di macchina, definisce il limite della risoluzione numerica del sistema

esempio

$\beta = 2 \quad m = 53 \quad U = 2^{-53} \approx 10^{-16}$ (i calcoli hanno una precisione di 16 cifre esadecimali)

FINE LEZ 1

nelle prossime sezioni osserveremo cosa succede quando si svolgono operazioni aritmetiche

Operazioni aritmetiche fra Floating point

precisazione: "floating point" $\longleftrightarrow$ $F(\beta, m, L, U)$

si è notato che la rappresentazione in floting paint, ci da delle limitazioni sui numeri che riusciamo a rappresentare in maniera esatta su di un numero finito di bit

- Problema: anche se prendo due numeri x, y nell'insieme delle cose che è possibile rappresentare senza errori, ovvero $x, y \in F(\beta, m, L, U)$ non è detto (anzi molto spesso non succede) che il risultato di $x \; op \; y$ $(op \in \{+, -, \times, /\})$ sia in $F(\beta, m, L, U)$.
  - Si può finire fuori poichè la rappresentazione del risultato non si scrive con un numero finito di cifre con il sistema numerico che abbiamo definito!

Cosa si deve fare? La cosa più naturale da fare (che viene fatto anche in software) è combinare le operazioni aritmetiche con un arrotondamento sul risultato (per noi $R_N(x)$ Round-to-Nearest)

secondo la seguente definizione

DEFINIZIONE

Se $x, y \in F(\beta, m, L, U)$ definiamo come $x \; \textcircled{op} \; y = R_N(x \; op \; y)$ dove $op \in \{+, -, \times, /\}$

- Così definiamo $\oplus \; \ominus \; \otimes \; \oslash$ intesi in questa aritmetica di macchina

Sorge però un altro problema, adottare questo meccanismo pare semplice, ma in realtà "sporca" o invalida alcune proprietà

Classiche sulle operazioni che conosciamo. Cominciano a non essere più vere, o vere, a meno di errori piccoli, proprietà come: associativa, distributiva della moltiplicazione

⇓

"Un effetto collaterale dell'arrotondamento è che alcune proprietà elementari non valgano più"

⇓

Ad esempio l'associativa può essere valida su alcuni INPUT o essere invalida su altri.

Esempio

$$(x \oplus y) \oplus z \neq x \oplus (y \oplus z)$$

Questa uguaglianza è vera magari su una cosa molto piccola, ma in genere non lo è. Se c'è una catena di operazioni, c'è da tener conto se l'errore si propaga o meno

Esempio

$x, y, z \in F(10, 3, -99, 99)$ si prende $x = 0{,}135 \cdot 10^{-4}$ $y = 0{,}258 \cdot 10^{-2}$
$z = -0{,}251 \cdot 10^{-2}$

Procediamo con i due calcoli

- $x \oplus (y \oplus z) = 0{,}135 \cdot 10^{-4} \oplus (0{,}700 \cdot 10^{-4}) = 0{,}835 \cdot 10^{-4}$ (m=3)

Qui non è stato necessario fare $R_N(x)$ poichè abbiamo tre cifre dopo la virgola!

- $(x \oplus y) \oplus z =$ (devo arrotondarlo secondo $R_N(x)$) $(0{,}259\,35 \cdot 10^{-2}) \oplus (-0{,}251 \cdot 10^{-2}) =$ (posso tenere solo 3 cifre!)

$$= 0{,}259 \cdot 10^{-2} \ominus 0{,}251 \cdot 10^{-2} = 0{,}800 \cdot 10^{-4}$$

Si nota che i due risultati sono differenti!

Similmente si vede che non vale nemmeno la seguente proprietà: $x \otimes (y \oplus z) \neq (x \otimes y) \oplus (x \otimes z)$ ← in generale

Esempio su Matlab

```
>> % Esempio di MATLAB: verifica della (non) distributività
   % Voglio verificare che x * (y + z) ~= (x * y) + (x * z)
   for K = 1:10
       % Generazione di numeri casuali (distribuzione normale standard)
       x = randn;
       y = randn;
       z = randn;

       % Calcolo dei due membri dell'equazione
       S1 = x * (y + z);
       S2 = (x * y) + (x * z);

       % Stampa della differenza (errore di arrotondamento)
       % %d per l'intero K, %.4e per la notazione scientifica (esponenziale)
       fprintf('Tentativo %d, S1 - S2 = %.4e\n', K, S1 - S2);
   end
```

cifre dopo la virgola

```
Tentativo 1, S1 - S2 = -2.7756e-17
Tentativo 2, S1 - S2 = -1.1102e-16
Tentativo 3, S1 - S2 = 2.2204e-16
Tentativo 4, S1 - S2 = 0.0000e+00
Tentativo 5, S1 - S2 = -5.5511e-17
Tentativo 6, S1 - S2 = 0.0000e+00
Tentativo 7, S1 - S2 = -4.4409e-16
Tentativo 8, S1 - S2 = 4.4409e-16
Tentativo 9, S1 - S2 = 1.1102e-16
Tentativo 10, S1 - S2 = 0.0000e+00
```

notiamo che alle volte viene 0 alle volte viene una cosa piccola ma diversa da zero.

Conclusione

Se si ha un'espressione algebrica, e questa si valuta con ordini diversi (ma equivalenti) della stessa formula possono portare a risultati (anche significamente) diversi.

Adesso ci si concentra su cosa succede quando si valuta una certa FUNZIONE su dati input. Si cerca di osservare quali sono le fonti dell'errore e come questo si PROPAGA.
Si vuole spiegare cosa succede per espressioni più complicate di quelle viste fino ad ora (invece di $x \cdot (y+z) != (x \cdot y) + (x \cdot z)$).

Errore nel calcolo di una funzione

Si ha dunque una certa funzione $f: \mathbb{R}^n \to \mathbb{R}$, si hanno dunque n input ed 1 OUTPUT.

$f(x_1 \dots x_n)$ ⟵ funzione di n variabili reale

E si vuole calcolare $f(P_0)$ dove P_0 è un vettore, con delle componenti

$P_0 = (x_1^{(0)} \dots x_n^{(0)}) \in \mathbb{R}^n$ ⟵ vettore di $\mathbb{R}^n$

Quali sono le possibili fonti di errore? Ci sono tre fonti di errori

1. Una prima approssimazione che da una fonte di errore è quando la funzione f (che oltre alle classiche operazioni aritmetiche ne può avere anche di più elaborate esempio può essere un esponenziale) con una funzione razionale (esempio Taylor troncato), ovvero una funzione che coinvolge solo $\pm, x, /$ questa funzione la chiameremo $\tilde{f}$ (ad esempio un polinomio o rapporto tra polinomi!)
2. $\tilde{f}$ deve essere "tradotta" in una formula che coinvolge arrotondamenti (come se fosse un ALGORITMO), quindi che utilizza l'aritmetica floating point e le operazioni $\oplus, \ominus, \otimes, \oslash$. La funzione tradotta la chiamiamo $\tilde{f}_a$
3. P_0, ovvero il vettore, non è detto che sia un numero di macchina quindi rappresentabile, questo infatti va ARROTONDATO al numero di macchina più vicino.
   $P_1 = R_N(P_0)$

In CONCLUSIONE: vorremo valutare $f(P_0)$, ma quello che otteniamo realmente facendo con il SOFTWARE, è $\tilde{f}_a(P_1)$

Esempio

Supponiamo di voler calcolare e^{π}, dunque scriviamo i dati $P_0 = \pi$

$f(x) = e^x \quad (n = 1)$ ⟵ 1 input, 1 output

Per il (1) punto potrei prendere l'approssimazione dell'esponenziale con

il polinomio di Taylor troncato al termine più "basso"

(1) $e^x \approx 1 + x + \frac{x^2}{2}$ $\qquad \tilde{f}(x) = 1 + x + \frac{x^2}{2}$

STOP! Ma come mai Taylor?
Produce un polinomio, che usa solo le operazioni aritmetiche, e approssima bene la funzione vicino lo zero (più son vicino lo zero più l'errore è piccolo)

Poi devo scegliere per il punto (2) un algoritmo che coinvolga arrotondamenti per volotore $\tilde{f}(x)$

(2) $\tilde{f}_a(x) = 1 \oplus x \oplus (x \otimes x) \oslash 2$
ho riscritto $\tilde{f}(x)$ con operazioni floating point

Un'altro modo per descrivere $\tilde{f}_a$ è scrivere cosa succede alle operazioni CON UN GRAFO

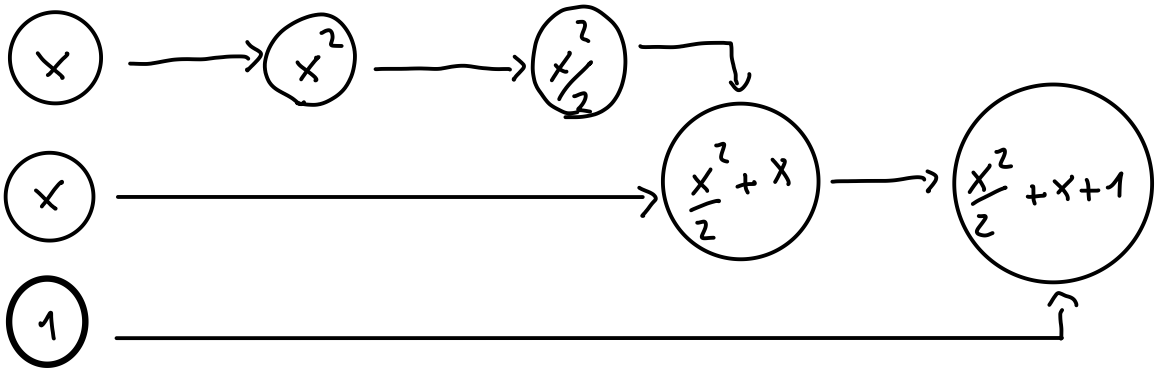

Una descrizione di questo tipo si fa con un cerchietto per ogni input e risultato per le operazioni che vengono svolte con delle frecce che collegano i nodi e indicano le operazioni che si svolgono tra due INPUT

(3) Consideriamo $p_1 = 3{,}1415$ al posto di π
$\tilde{f}_a(p_1) \longrightarrow \tilde{f}_a(3{,}1415)$ che è perfettamente rappresentabile

In questo esempio qua dunque abbiamo approssimato e^{π} con $\tilde{f}_a(3{,}1415)$

Adesso diamo dei nomi agli errori che intervengono

DEFINIZIONE ERRORE TOTALE ASSOLUTO

Si definisce l'errore totale assoluto in $p_0 \in \mathbb{R}^n$, la differenza tra quello che vorremo e quello che calcoliamo davvero questa quantità è definita come segue

$$\delta_f := f(p_0) - \tilde{f}_a(p_1)$$

(DELTA)

DEFINIZIONE ERRORE TOTALE RELATIVO

di quanto pesa l'errore rispetto al problema, definito come segue:

$$\varepsilon_f := \frac{f(p_0) - \tilde{f}_a(p_1)}{f(p_0)}$$

Per il MOMENTO consideriamo per il momento solo funzioni RAZIONALI, funzioni che hanno le operazioni aritmetiche $(f \approx \tilde{f})$, dunque c'è una fonte di errore in meno.

↳ dunque gli unici errori che intervengono sono cominciare ad applicare l'arrotondamento sui dati di input e poi gli errori si accumulano quando si svolgono le operazioni

Funzioni Razionali

in questo caso possiamo dividere l'errore totale assoluto come:

$$\underbrace{f(p_0) - f(p_1)}_{\delta_d} + \underbrace{f(p_1) - \tilde{f}_a(p_1)}_{\delta_a} = \delta f \Rightarrow \delta f = \delta_d + \delta_a$$

$\tilde{f}_a$ *?

δ_d * ERRORE inerente è l'errore causato dal fatto che p_0 è stato arrotondato a p_1.

δ_a * ERRORE ALGORITMICO è l'errore causato dall'aver valutato la mia formula con l'aritmetica floating point, dunque dall'algoritmo (arrotondamenti, troncamenti), la scelta che facciamo nella valutazione della formula

Guardando all'errore totale relativo $\varepsilon_f = \dfrac{f(p_0) - f_a(p_1)}{f(p_0)}$

Possiamo anch'esso scomporlo nella somma dei due termini, come prima sommiamo e sottraiamo qualcosa al numeratore

$$\varepsilon_f = \underbrace{\frac{f(p_0) - f(p_1)}{f(p_0)}}_{\varepsilon_d \text{ errore relativo inerente}} + \frac{f(p_1) - f_a(p_1)}{f(p_0)} =$$

← dobbiamo far comparire al denominatore $f(p_1)$

$$= \varepsilon_d + \underbrace{\frac{f(p_1) - f_a(p_1)}{f(p_1)}}_{\varepsilon_a \text{ errore relativo algoritmico}} \cdot \left(1 + \underbrace{\frac{f(p_1) - f(p_0)}{f(p_0)}}_{-\varepsilon_d} \right)$$

in definitiva l'errore relativo totale $\varepsilon_f = \varepsilon_d + \varepsilon_a(1 - \varepsilon_d) = \varepsilon_a + \varepsilon_d - \varepsilon_a\varepsilon_d$

L'errore relativo è qualcosa di molto piccolo, quindi possiamo approssimare la quantità ignorando il terzo termine in definitiva $\boxed{\varepsilon_f \doteq \varepsilon_d + \varepsilon_a}$

Adesso che abbiamo scomposto l'errore totale in algoritmo e inerente vediamo come dare espressione a queste singole cose

ERRORE INERENTE

Abbiamo detto che l'errore inerente proviene dal fatto che stiamo valutando la funzione invece che nel punto p_0 in p_1 (un pò spostato)

↳ L'idea è che dipende come la funzione si comporta attorno a questo PUNTO, se la funzione è costante, l'errore inerente sarà 0, se si ha una funzione che è variabile, l'errore sarà piccolo o grande sulla base che questa vari molto o poco, e questa è detto dalla DERIVATA che misura quanto CAMBIA la funzione al variare dell'INPUT

Dunque l'errore inerente dipende solo dalla funzione che voglio calcolare (indipendente dal software). sotto l'ipotesi che la funzione sia derivabile $f \in C^1(D)$ dove $D \subseteq \mathbb{R}^n$ (insieme dove prendo gli INPUT, i valori di ingresso della funzione).
Possiamo provare a scrivere l'errore inerente ASSOLUTO usando uno sviluppo al 1° ordine (Taylor).

Sappiamo che:

sostituiamo a $f(p_1)$ lo sviluppo in serie di Taylor attorno al punto p_0, valutato in p_1

$$\delta_d = f(p_0) - f(p_1) = f(p_0) - \left[f(p_0) + (p_1 - p_0)^T \nabla f(\tilde{p}) \right] =$$

$\tilde{p}$ appartiene al segmento $\overline{p_0 p_1}$ $\quad \tilde{p} \in \mathbb{R}^{\sim} \quad \mathbb{R}^2$

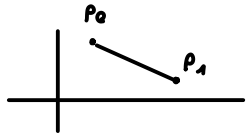

tra p. vero e p. approx.

$$= \sum_{i=1}^{n} \frac{\partial f}{\partial x_i}(\tilde{p}) \cdot \left(x_i^{(0)} - x_i^{(1)} \right)$$

componenti i del vettore $p_0 p_1$

$$p_0 = \begin{bmatrix} x_1^{(0)} \\ \vdots \\ x_n^{(0)} \end{bmatrix} \in \mathbb{R}^n \qquad p_1 = \begin{bmatrix} x_1^{(1)} \\ \vdots \\ x_n^{(1)} \end{bmatrix} \in \mathbb{R}^n$$

Sappiamo poco su $\tilde{p}$, sappiamo solo che sta tra p_0 e p_1, anche qui si fa un ASSUNZIONE che è dovuto al fatto che p_0 e p_1 sono vicini fra di loro, uno è l'arrotondamento dell'altro $\tilde{p} \approx p_0$.

$$\approx \sum_{i=1}^{n} \frac{\partial f}{\partial x_i}(p_0) \cdot (x_i^{(0)} - x_i^{(01)})$$

coefficienti di amplificazione ρ_i^{RO} — si chiamano così perché moltiplicano l'errore di arrotondamento

errore di arrotondamento sulla componente i-esima del vettore p_0. Ogni componente ha il suo errore di arrotondamento inerente δx_i

Questa formula mi sta dicendo che se faccio su un certo INPUT un certo errore di arrotondamento questo viene amplificato in base al valore della derivata parziale in quella direzione.

$$\delta_d \doteq \sum_{i=1}^{n} \rho_i \cdot \delta x_i$$

errore inerente assoluto

Il coefficiente di amplificazione dice "se sbaglio l'input di 1, di quanto sto sbagliando l'output"?

OSS Le quantità δx_i e ρ_i dipendono da p_0, ma se imponiamo che $p \in D$ (insieme di indeterminazione) $D \subseteq \mathbb{R}^n$ allora si possono dare delle limitazioni (p deve stare in un certo insieme D) del tipo:

① $|\delta x_i| \leq \max_{\text{su } D}$ errore assoluto di arrotondamento (nel caso scelore $|\delta x| \leq \frac{1}{2} B^{e-m}$)

* per ogni p!

② $|\rho x_i| \leq \sup_{p \in D} \left| \frac{\partial f}{\partial x_i}(p) \right|$

Ma cosa vuol dire? δx_i e ρx_i dipendono da p_0, ma se invece di un punto fisso consideriamo tutti i possibili punti p in D, possiamo dare dei limiti superiori validi per tutto il dominio.

① "Non so esattamente quanto vale δx_i in quel punto, ma so che non supera mai questo valore su tutto D".

② "Il coefficiente di amplificazione non so esattamente quanto è in p_0, ma so che non supera mai la derivata parziale più grande su tutto D".

È utile perché invece di calcolare l'errore punto per punto ho una stima che vale ovunque su D $\quad \delta_d \leq \varepsilon \cdot \max \text{derivata} \cdot \max \text{errore arrotondamento}$

Errore relativo inerente

voglio far apparire al denominatore $x_i^{(0)}$

L'errore relativo inerente è dato da: $\varepsilon_d = \sum_{i=1}^{n} \frac{\partial f}{\partial x_i}(p_0) \cdot \frac{x_i^{(0)} - x_i^{(1)}}{f(p_0)} =$

$= \sum_{i=1}^{n} \underbrace{\frac{x_i^{(0)}}{f(p_0)} \cdot \frac{\partial f(p_0)}{\partial x_i}}_{\text{coefficiente di amplificazione dell'errore relativo sulla componente } i \text{ } \gamma_i^{\text{gamma}}} \cdot \underbrace{\frac{x_i^{(0)} - x_i^{(1)}}{x_i^{(0)}}}_{\text{errore relativo sull'arrotondamento della componente } i\text{-esima } \varepsilon_x} = \sum_{i=1}^{n} \gamma_i \cdot \varepsilon_i$ (gamma)

- ε_x "Quanto pesa quell'errore sul risultato finale"?
- γ_i "Di che percentuale ho sbagliato x_i?"

L'errore inerente dipende solo dalla funzione, solo dal problema.

DEFINIZIONE DI BEN CONDIZIONATO/MAL CONDIZIONATO

Un problema si dice ben condizionato quando i γ_i sono tali per cui ε_d è della stessa ordine di grandezza degli ε_{x_i} (errori dell'arrotondamento). Se stiamo arrotondando l'errore non è amplificato in maniera disastrosa.

Se gli errori sugli INPUT sono piccoli, l'errore sul risultato deve rimanere piccolo

$\varepsilon_{x_i} \approx 10^{-15} \longrightarrow \varepsilon_d \approx 10^{-15}$ ✓ Ben condizionato

$\varepsilon_{x_i} \approx 10^{-15} \longrightarrow \varepsilon_d \approx 10^{-1}$ × Mal condizionato

Dipende tutto da: quanto amplificano gli γ_i!

Se $|\varepsilon_d| >> \max_{i=1\dots n} |\varepsilon_{x_i}|$ allora il problema si dice MAL CONDIZIONATO

Adesso vediamo gli errori delle 4 operazioni aritmetiche $\mathbb{R}^2 \to \mathbb{R}$, cioè da due input ho 1 output e vedere se queste sono operazioni ben condizionate, oppure mal condizionate

OP	δ_d | errore assoluto inerente	ε_d | errore relativo inerente
$x \oplus y$	$\delta x + \delta y$	$\frac{x}{x+y}\varepsilon_x + \frac{y}{x+y}\varepsilon_y$
$x \ominus y$	$\delta x - \delta y$	$\frac{x}{x-y}\varepsilon_x - \frac{y}{x-y}\varepsilon_y$
$x \otimes y$	$y\,\delta x + x\,\delta y$	$\varepsilon_x + \varepsilon_y$
$x \oslash y$	$\frac{1}{y}\delta x + \frac{x}{y^2}\delta y$	$\varepsilon_x - \varepsilon_y$

OSS Moltiplicazione e divisione sono problemi BEN CONDIZIONATI, ad esempio se $|\varepsilon_x|, |\varepsilon_y| \leq u$ allora $|\varepsilon_d| < 2u$, qualunque siano gli input dati. somma (e sottrazione) possono essere MAL condizionate nel caso in cui $|x+y| << \max(|x|,|y|)$ in questo caso si parla di cancellazione numerica

MOLTIPLICAZIONE e DIVISIONE sono SEMPRE ben condizionate, se gli errori sugli input sono piccoli $\leq u$, allora $|\varepsilon_d| \leq u$;
Somma e sottrazione possono essere mal condizionate, il problema nasce quando $|x+y| << \max(|x|,|y|)$ ovvero quando sommo due numeri quasi uguali ed opposti!

dunque possiamo dire che $|\varepsilon_x|, |\varepsilon_y| < u \Rightarrow |\varepsilon_d| \leq \frac{|x|+|y|}{|x+y|} \cdot u$

Più x ed y si assomigliano, più il denominatore è piccolo, più l'errore viene sparato.

ERRORE ALGORITMICO

Per trovare δ_a (errore algoritmico assoluto) e ε_a (errore algoritmico relativo) dobbiamo fissare una procedura f_a per trovare $f(P_0)$

$$\delta_a = f(P_1) - f_a(P_1), \quad \varepsilon_a = \frac{f(P_1) - f_a(P_1)}{f(P_1)} \qquad P_1 = R_N(P_0) \in \mathbb{F}(\beta, m, L, U)$$

Per fare ciò si usa a rappresentare la procedura scelta con un grafo e si vede come gli errori vengono amplificati, guardando la tabella

Esempio $f(x,y,z,w) = x \cdot \left(\frac{y}{z} - w\right)$ stimiamo l'errore relativo algoritmico

$r_1 = \frac{y}{z}$
$r_2 = r_1 - w$
$r_3 = x \cdot r_2$

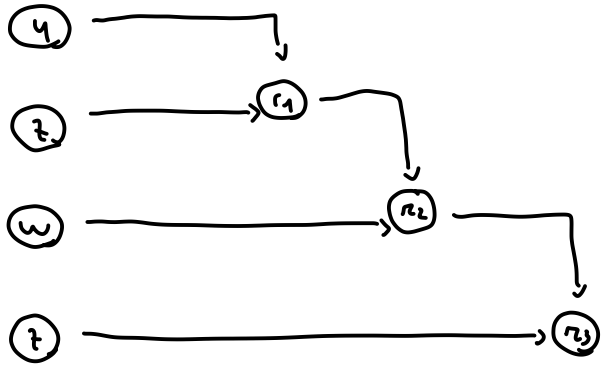

Come funziona l'analisi dell'errore algoritmico?

Ogni volta che si guarda l'input è guardare l'errore che si portano dietro siccome abbiamo assunto che P_1 sto nell'insieme dei numeri macchina, allora questo è zero.

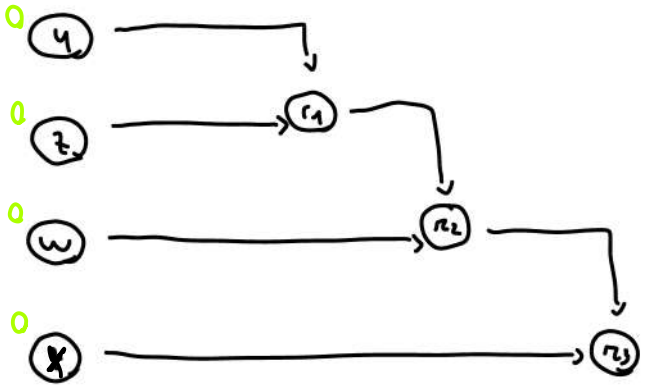

Guardiamo all'operazione che sta tra y e z, supponiamo di voler stimare l'errore relativo algoritmico, facciamo la divisione tra y e z, il coefficiente sulla prima è +1, sulla secondo è -1 $(\varepsilon_y - \varepsilon_z)$

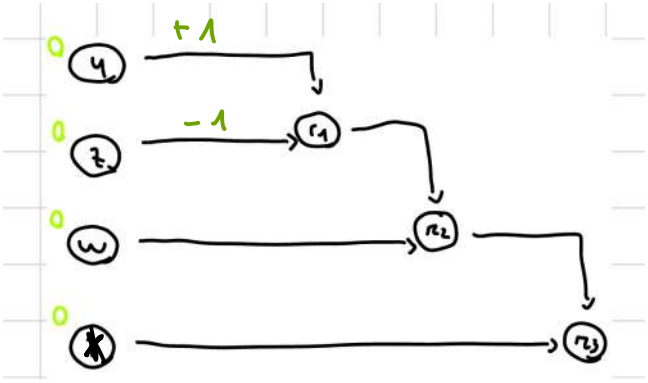

Dunque facciamo la divisione, e facciamo un'arrotondamento, questo arrotondamento porto un errore, chiamato ε_1 (errore dati input + errore ris)

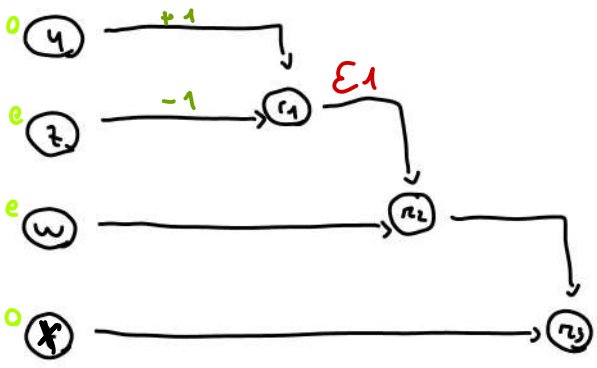

A questo punto ad r1 sottraggo w, quali sono i coefficienti di amplificazione? rifacendoci alla tabella

OP	δ_d | errore assoluto inerente	ε_d | errore relativo inerente
$x \oplus y$	$\delta x + \delta y$	$\frac{x}{x+y}\varepsilon_x + \frac{y}{x+y}\varepsilon_y$
$x \ominus y$	$\delta x - \delta y$	$\frac{x}{x-y}\varepsilon_x - \frac{y}{x-y}\varepsilon_y$
$x \otimes y$	$y\,\delta x + x\,\delta y$	$\varepsilon_x + \varepsilon_y$
$x \oslash y$	$\frac{1}{y}\delta x + \frac{x}{y^2}\delta y$	$\varepsilon_x - \varepsilon_y$

$r_2 = r_1 - w$ dove $r_1 = y/z$

$$\varepsilon_{r_2} = \left(\frac{r_1}{r_1 - w}\right)\varepsilon_{r_1} - \left(\frac{w}{r_1 - w}\right)\varepsilon_w = \left(\frac{\frac{y}{z}}{\frac{y}{z} - w}\right)\varepsilon_{r_1} - \left(\frac{w}{\frac{y}{z} - w}\right)\varepsilon_w$$

$$= \left(\frac{y}{y - 2w}\right)\varepsilon_{r_1} - \frac{2w}{y - 2w}\,\varepsilon_w$$

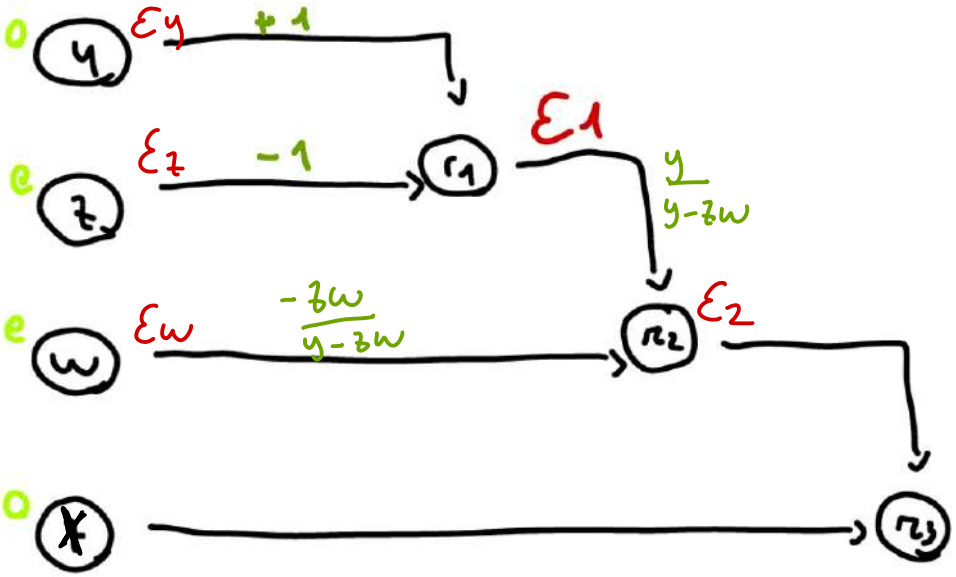

ε_1 ed ε_2 sono errori di arrotondamento dopo l'operazione aritmetica.

Per l'ultima operazione

$r_3 = x \cdot r_2$

OP	δ_d | errore assoluto inerente	ε_d | errore relativo inerente
$x \oplus y$	$\delta x + \delta y$	$\frac{x}{x+y}\varepsilon_x + \frac{y}{x+y}\varepsilon_y$
$x \ominus y$	$\delta x - \delta y$	$\frac{x}{x-y}\varepsilon_x - \frac{y}{x-y}\varepsilon_y$
$x \otimes y$	$y\,\delta x + x\,\delta y$	$\varepsilon_x + \varepsilon_y$
$x \oslash y$	$\frac{1}{y}\delta x + \frac{x}{y^2}\delta y$	$\varepsilon_x - \varepsilon_y$

Rifacendoci alla tabella, i coefficienti sono $+1, +1$ che porteranno ad ε_3

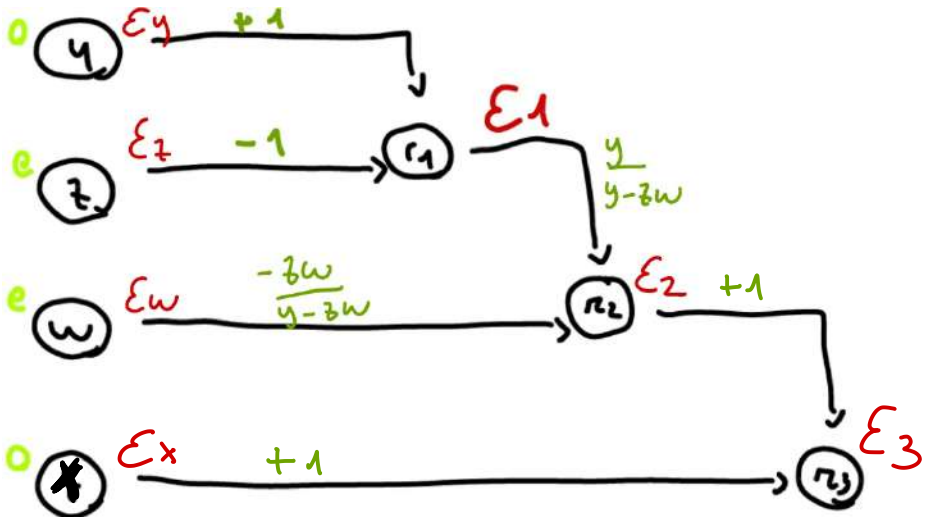

dunque l'errore ε_a sarà come segue

$$\varepsilon_a = \varepsilon_3 + 1 \cdot \varepsilon_x + 1\,\varepsilon_{r_2} =$$
$$= \varepsilon_3 + \left(\varepsilon_2 - \frac{z w}{y - z w}\,\varepsilon_w + \frac{v}{y - z w}\,\varepsilon_{r_1} \right) =$$
$$= \varepsilon_3 + \left(\varepsilon_2 - \frac{z w}{y - z w}\,\varepsilon_w + \frac{v}{y - z w}\,(\varepsilon_1 + \varepsilon_y - \varepsilon_z) \right) =$$

(dove $\varepsilon_w = 0$, $\varepsilon_y = 0$, $\varepsilon_z = 0$)

il trucco sta nel partire dall'ultimo nodo e sommare gli errori insieme ai relativi coefficienti ogni volta che "scopro" un ε_{r_i}!

⚠ ATTENZIONE - differenza sostanziale

$\varepsilon_i \neq \varepsilon_{r_i}$, il primo è l'errore di arrotondamento introdotto dall'operazione, il secondo tutto ciò che r_i porta con sé!

$$\varepsilon_1 \neq \varepsilon_{r_1}$$

$$= \varepsilon_3 + \varepsilon_2 + \frac{x}{y - z w} \cdot \varepsilon_1 = \varepsilon_a$$

Questo è quello con l'errore relativo inerente ma avremmo anche potuto usare l'errore assoluto inerente sarebbero solo cambiati i coefficienti di amplificazione

Se si volesse dare una limitazione ad ε_a, si può usare il fatto che $|\varepsilon_1|, |\varepsilon_2|, |\varepsilon_3| < u$ dunque siccome non conosciamo i valori di $\varepsilon_1, \varepsilon_2, \varepsilon_3$, ma sappiamo che in modulo sono $\leq u$, che è la precisione di macchina ovvero il più piccolo errore relativo che la macchina può introdurre in una singola operazione, possiamo sostituire ogni ε_i con il suo massimo possibile

$$|\varepsilon_a| \leq |\varepsilon_3| + |\varepsilon_2| + \left| \frac{y}{y - z w} \right| \cdot \varepsilon_1$$
$$\leq u + u + \left| \frac{y}{y - z w} \right| u$$
$$\leq 2u + \left| \frac{y}{y - z w} \right| u$$

DEFINIZIONE ALGORITMO STABILE INSTABILE

Se un algoritmo (formula) è tale per cui $|\varepsilon_a| >> u$, allora l'algoritmo si dice INSTABILE. Se $|\varepsilon_a|$ rimane "vicino" alla precisione di macchina, l'algoritmo si dice STABILE

ESERCIZIO

Vediamo $f(x,y) = x^2 - y^2 = (x+y)(x-y)$

Calcoliamo l'errore algoritmico nei due casi e vediamo se c'è una procedura più stabile dell'altra

ALG 1	ALG 2
$r_1 = x \cdot x$	$r_1 = x + y$
$r_2 = y \cdot y$	$r_2 = x - y$
$r_3 = r_1 - r_2$	$r_3 = r_1 \cdot r_2$

1.

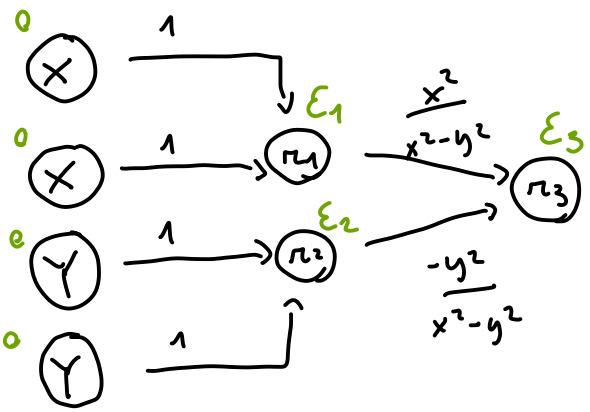

$$\varepsilon_a = \varepsilon_3 + \frac{x^2}{x^2-y^2}\varepsilon_1 - \frac{y^2}{x^2-y^2}\varepsilon_2$$

$$|\varepsilon_a| \leq u\left(1 + \frac{x^2+y^2}{|x^2-y^2|}\right)$$

2.

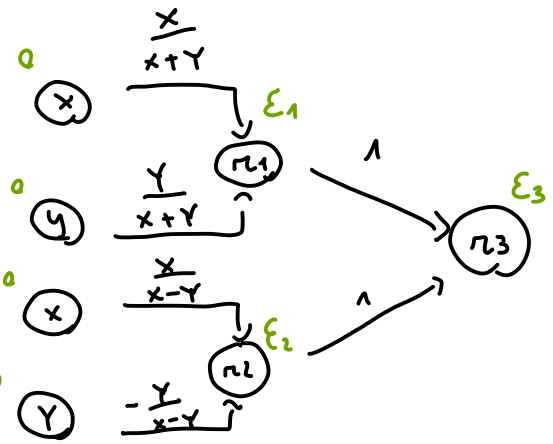

$$\varepsilon_a = \varepsilon_3 + \varepsilon_1 + \varepsilon_2$$

$$|\varepsilon_a| \leq 3u$$

Algoritmo 2 è stabile $\forall$ input, ALG1 potrebbe non esserlo!

LEZ 2

Recap dunque concludendo nel caso di una $f: \mathbb{R}^n \to \mathbb{R}$ con n input ed 1 output scalare, abbiamo analizzato tutte le componenti che intervengono sul RISULTATO FINALE quando questo viene svolto con ARITMETICA FLOATING POINT

Si è visto che volendo la $f: \mathbb{R}^n \to \mathbb{R}$ con $P_0 = \begin{bmatrix} x_1^0 \\ \vdots \\ x_n^0 \end{bmatrix} \in \mathbb{R}^n$ voglio calcolare IDEALMENTE $f(P_0)$ ma mi ritrovo con qualcosa del tipo $f_a(P_1)$:

- $P_1 = RN(P_0)$
- f_a è la versione di f dove si hanno $\oplus, \ominus, \oslash, \otimes$

dunque si hanno due fonti di errore

- inerente ⟶ L'errore dovuto al fatto che valutiamo f su P_1 al posto di P_0 (dunque non dipende dall'algoritmo)
- algoritmico ⟶ dipende dall'ordine e dal tipo di operazioni che si svolgono

In particolare abbiamo caratterizzato l'errore totale assoluto come $\delta_f = \delta_d + \delta_a$ e l'errore totale relativo come $\varepsilon_f = \varepsilon_d + \varepsilon_a$

↓

Per gli errori inerenti

$$\delta_d = \sum_{i=1}^{n} \frac{\partial f}{\partial x_i}(P_0) \cdot \boxed{\delta_i}$$

errori di arrotondamento assoluto su x_i

$$\varepsilon_d = \sum_{i=1}^{n} \frac{\partial f}{\partial x_i}(P_0) \cdot \frac{x_i^{(0)}}{f(P_0)} \cdot \boxed{\varepsilon_i}$$

errori di arrotondamento relativo su x_i

dunque se ho l'espressione ANALITICA (che si può derivare) posso trovarmi l'espressione dell'errore inerente sia assoluto che relativo.

Gli errori algoritmici invece è possibile (che siano relativi o assoluti) Possiamo trovarli con il METODO del grafo, in cui si suppone che i dati di partenza siano esattamente rappresentabili nel sistema numerico scelto (nel nostro caso $\mathbb{F}$), questo perchè quando si fa l'errore algoritmico si è già presupposto di aver fatto $P_1 = RN(P_0)$ dunque l'arrotondamento sui dati di input.

Si deduce dunque L'AMPLIFICAZIONE dell'errore in base alle operazioni che si fanno (quindi usando i coefficienti di AMPLIFICAZIONE delle operazioni) e introducendo gli errori di arrotondamento dopo ogni singola operazione aritmetica

ESERCIZIO $f(x,y) = (x-y)(y^2-x) \quad \mathbb{R}^2 \longrightarrow \mathbb{R}$

Si forniscono le espressioni dell'errore relativo INERENTE ed ALGORITMICO (in termini degli errori di ARROTONDAMENTO RELATIVI su x ed x)

- Inerente: devo svolgere le derivate parziali della mia funzione f, ricordiamo la formula dell'errore inerente

$$\mathcal{E}_d = \sum_{i=1}^{n} \frac{x_i^{(0)}}{f(P_0)} \frac{\delta f(P_0)}{\delta x_i} \varepsilon_{x_i}$$

Vado ad espandere la funzione, ovviamente questa cosa equivale a fare cose in MATEMATICA ESATTA e dunque per il fine di calcolare le DERIVATE PARZIALI non cambia nulla

⚠ Quando invece si fa L'ERRORE ALGORITMICO, mantengo l'errore imposto dalle parentesi, altrimenti sarebbe ovviamente un'altro algoritmo

dunque $f(x,y) = xy^2 - x^2 - y^3 + xy$

$$\frac{\partial f}{\partial x} = y^2 - 2x + y \qquad \frac{\partial f}{\partial y} = 2xy - 3y^2 + x$$

$\mathcal{E}_d$ primo termine = [derivata parziale rispetto a x] · [x su $f(x,y)$] =

$$= \frac{x}{f(x,y)} \cdot y^2 - 2x - y =$$

$$= \frac{x \cdot (y^2 - 2x + y)}{(x-y)(y^2-x)} \varepsilon_x$$

$\mathcal{E}_d$ secondo termine = [derivata parziale rispetto a y] · [y su $f(x,y)$] =

$$= \frac{y}{f(x,y)} \cdot 2xy - 3y^2 + x =$$

$$= \frac{y(2xy - 3y^2 + x)}{(x-y)(y^2-x)} \varepsilon_y$$

Concludendo

$$\varepsilon_d = \frac{x(y^2 - 2x + y)}{(x-y)(y^2-x)} \varepsilon_x + \frac{y(2xy - 3y^2 + x)}{(x-y)(y^2-x)} \varepsilon_y$$

ALGORITMICO

Procediamo con il metodo del grafo

$r_1 = x - y$
$r_2 = y^2$
$r_3 = r_2 - x$
$r_4 = r_1 \cdot r_3$

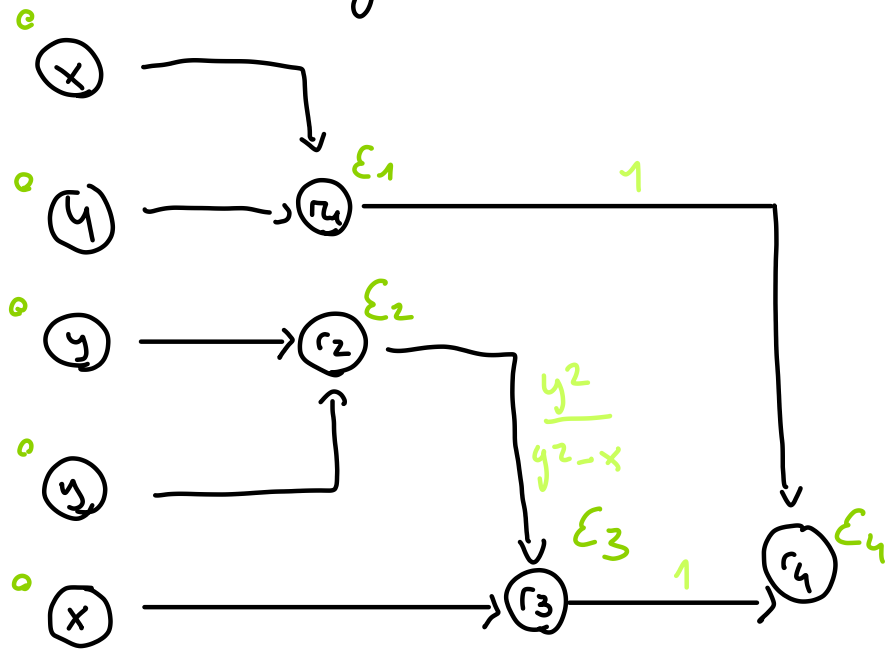

- Non inserisco i coefficienti di amplificazione, in merito alle prime operazioni poiché i dati sono esatti e si porta con $\varepsilon_x, \varepsilon_y = 0$, quindi verrebbero moltiplicati per zero

$$\varepsilon_a = \varepsilon_4 + 1\,\varepsilon_{r_3} + 1\,\varepsilon_{r_1} =$$

$$= \varepsilon_4 + \left(\varepsilon_3 + \frac{y^2}{y^2-x}\varepsilon_{r_2}\right) + \varepsilon_1 =$$

$$= \varepsilon_4 + \left(\varepsilon_3 + \frac{y^2}{y^2-x}\varepsilon_2\right) + \varepsilon_1 =$$

$$= \varepsilon_4 + \varepsilon_3 + \varepsilon_1 + \frac{y^2}{y^2-x^2}\varepsilon_2$$

⚠ questa volta notiamo che c'è una dipendenza dai dati di INPUT, in particolare dagli x ed y che si vanno a valutare

↓

Possiamo dire che quando y e x sono vicini in modulo il denominatore $y^2 - x^2$ sarà piccolo e l'errore relativo sarà GRANDE!

Adesso proviamo a vedere esercizi nei quali si prova a STIMARE, sulla base di dove si va a pescare x ed y, una LIMITAZIONE dell'errore

↳ si può parlare di errore relativo oppure di errore ASSOLUTO (come al solito)

OSS Per ottenere una LIMITAZIONE superiore del modulo dell'errore TOTALE $|\delta f|$ (ASSOLUTO) oppure $|\varepsilon f|$ (relativo), nelle APPLICAZIONI MASSEI chiede di garantire, che queste quantità siano sottocontrollo, si possono usare, le disuguaglianze seguenti (supposto che P_0 varia in un certo insieme D, $P_0 \in D \subseteq \mathbb{R}^n$)

$$|\delta f| \leq |\delta a| + |\delta d| \leq E_a + E_d$$

- E_a = max limitazione dell'errore algoritmico su $P_0 \in D$
- $E_d = \sum_{j=1}^{n} A_{x_j} |\delta x_j|$ dove $A_{x_j} = \max_{P \in D} \left| \frac{\partial f}{\partial x_j}(P) \right|$

massimo modulo della derivata parziale al variare di P su D

Analogamente l'errore totale relativo può essere maggiorato dalla seguente disuguaglianza

$$|\varepsilon f| \leq |\varepsilon a| + |\varepsilon d| \leq H_a + H_d$$

- H_a = max dell'errore relativo algoritmico al variare di p_0, nell'insieme dove vogliamo studiare il PROBLEMA, $p_0 \in D$, quindi POSSIBILI INPUT

- $H_d = \sum_{i=1}^{n} Bx_J \cdot u$ dove $Bx_J = \max_{p \in D} \left| \frac{\delta f(p)}{\delta x_J} \cdot \frac{x_J}{f(p)} \right|$

  u: dovuto al fatto che la precisione di macchina maggiora gli errori di arrotondamento relativi

  Perché sappiamo che l'errore di arrotondamento relativi in modulo sono maggiorati dalla precisione di macchina, per come sono costruiti i numeri in virgola mobile

  $\frac{\delta f(p)}{\delta x_J} \cdot \frac{x_J}{f(p)}$: coefficiente di amplificazione dell'errore relativo

A differenza dei δx_J, quantità che DIPENDONO da dove stanno gli input, se abbiamo un numero grande l'errore di arrotondamento sarà grande, rispetto ad un errore di arrotondamento su un numero piccino, proprio perché DIPENDONO DAL MODULO della cosa che stiamo APPROSSIMANDO.

MA perché si fa tutto ciò? Semplicemente poiché le disuguaglianze forniscono un BOUND GARANTITO! in questo modo posso scegliere l'algoritmo più stabile, capire se i dati di INPUT sono abbastanza precisi, e capire la QUALITÀ del risultato

Si possono quindi considerare DUE TIPI di problema:=

- PROBLEMA DIRETTO: dato $IF(B, m, L, U)$ e un algoritmo ovvero una formula da valutare con un ordine con cui fare le operazioni, stimare (o meglio limitare, dare una limitazione superiore) dall'alto, l'errore TOTALE per valutare $f(p)$ con $p \in D$

Quindi dati i parametri del sistema numerico (numeri di macchina) e una cosa che voglio valutare cercare di maggiorare, l'errore

PROBLEMA INVERSO:

"Potrei anche chiedermi data una certa accuratezza, ovvero voglio che l'errore TOTALE RELATIVO o assoluto sia minore di 10^{-u}, cercare di capire quante cifre mi servono quindi quanto deve essere PRECISO il sistema di numerazione"

↳ Dunque, data una soglia $\gamma > 0$ (piccola) ed i parametri B, L, U e una formula/algoritmo determinare quante sono le cifre della mantissa (m) sono necessarie affinché l'errore totale (assoluto e relativo) su $f(p)$ sia $< \gamma \ \forall p \in D$

Due TIPI di problemi, in uno ha tutti i dati e voglia capire quanto è al massimo l'errore, nel secondo ha tutti i dati tranne il numero di cifre, quindi posso scegliere per rappresentare i numeri in virgola mobile e magari scegliere il minimo m per cui l'errore si trova sotto una certa soglia

ESERCIZIO - errore inerente

$f(x_1, x_2) = \frac{x_1}{x_2}$ ← operazione + arrotondamento $\quad p_0 \in \underbrace{[1,3]}_{x_1} \times \underbrace{[4,5]}_{x_2} = D$

IF(10,3, -99,99)

determinare una maggiorazione per l'errore assoluto totale $|\delta f|$

$$\delta f = \delta d + \delta a$$

Andiamo a vedere chi è δd!

Secondo la formula proposta abbiamo che $\delta d = \frac{\partial f}{\delta x_i}\delta x_1 + \frac{\partial f}{\delta x_2}\delta x_2$ (errori di arrotondamento assoluti)

Andando a fare il conto $\delta d = \frac{1}{x_2} \cdot \delta x_1 - \frac{x_1}{x_2^2}\delta x_2$

Partiamo maggiorando i coefficienti di Amplificazione

- $E_d = \sum_{J=1}^{n} A_{x_J} |\delta x_J|$ dove $A_{x_J} = \max_{P \in D} \left| \frac{\partial f}{\partial x_J}(P) \right|$

massimo modulo della derivata parziale al variare di P su D

Andiamo a trovare questi A_{x_J}

- $A_{x_1} = \max_{(x_1,x_2)\in D} \left| \frac{1}{x_2} \right|$ = questo è massimo quando il den è il minimo possibile = $\frac{1}{4}$
- $A_{x_2} = \max_{(x_1,x_2)\in D} \left| \frac{x_1}{x_2^2} \right|$ = max poss numeratore, minimo possibile denominatore = $\frac{3}{16}$

Adesso maggioriamo gli errori di arrotondamento quest'ultimo dipende da quanto sono grandi x_1, x_2

① $|\delta x_i| \leq \max_{\text{su } D}$ errore assoluto di arrotondamento

* per ogni P!

Osserviamo che $x_1, x_2 \in [1,10] = [10^0, 10^1)$, in particolare se guardo la rappresentazione di x_i è $x_i = \text{segno}(x_i)\, \beta^1 \cdot \sum_{i=1}^{m} d_J \cdot \beta^{-J}$, so che l'esponente è 1, poichè x_1, x_2 vivono nell'insieme definito.

↳ una volta che abbiamo rappresentato il max esponente di β nella rappresentazione sappiamo una maggiorazione per l'errore di arrotondamento poichè

$$|\delta x_i| \leq \frac{1}{2}\beta^{e-m} \text{ (delle scorse sezioni)} = \frac{1}{2}\beta^{1-3} = \frac{1}{2}10^{-2}$$

Questa è una maggiorazione che vale per δx_1 δx_2

in conclusione:

$$|\delta d| \leq \frac{1}{4}\cdot\frac{1}{2}10^{-2} + \frac{3}{16}\cdot\frac{1}{2}\cdot 10^{-2} =$$
$$= \frac{1}{8}10^{-2} + \frac{3}{32}\cdot 10^{-2} = 10^{-2}\left(\frac{1}{8} + \frac{3}{32}\right) = \frac{7}{32}10^{-2}$$

Studiamo adesso δa, L'ERRORE ALGORITMICO

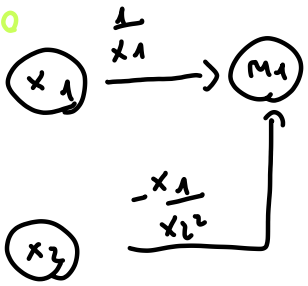

$\delta_a = \delta_1$ errore di arrotondamento assoluto sul risultato di x_1/x_2

Adesse però ho bisogno di una LIMITAZIONE

■ E_a = max limitazione dell'errore algoritmico su $P_0 \in D$

Mi devo chiedere quanto può essere in modulo x_1/x_2
Ricordiamo che il DENOMINATORE in questo caso è più grande del numeratore, la quantità minima che posso avere per x_1, x_2 di x_1/x_2 su D sarà $\left|\frac{x_1}{x_2}\right| = \frac{1}{5}$

dunque $\left|\frac{x_1}{x_2}\right|$ guardandolo come potenze di 10 $\in [0.1, 1] = [\beta^{-1}, \beta^0]$

$$\Rightarrow \frac{x_1}{x_2} = \text{segno}\left(\frac{x_1}{x_2}\right)\beta^0 \cdot \sum_{j=1}^{m} \alpha_j \beta^{-j} \Rightarrow |\delta_i| \le \frac{1}{2}\beta^{e-m} \le \frac{1}{2}\beta^{a-3} \le \frac{1}{2}10^{-3}$$

Vale $\forall x_1, x_2$ in D, poiché questa QUANTITÀ non dipende da essi, quindi vale su TUTTO! l'insieme di indeterminabilità D

Quindi: $|\delta f| \le \frac{1}{2}10^{-3} + \frac{7}{32}10^{-2} = \left(\frac{1}{2} + \frac{70}{32}\right)10^{-3} =$

$= \frac{86}{32}10^{-3} = \frac{43}{16}\cdot 10^{-3}$ ≈ STIMA che posso dare sull'errore totale

ESERCIZIO - PROBLEMA INVERSO $D = [1,2] \times [-2,-1]$, $f(x_1, x_2) = \frac{x_1}{x_2}$

IF $(10, m, -99, 99)$, determinare il minimo m tale per cui l'errore totale $|\delta f| \le 10^{-2}$ $\forall P_0 \in D$

per l'espressione dell'errore inerente applichiamo lo stesso ragionamento dello scorso esercizio, ma con un diverso D

$$|\delta_d| \le \max_D \left|\frac{1}{x_2}\right| \cdot |\delta x_1| + \max_D \left|-\frac{x_1}{x_2^2}\right| \cdot |\delta x_2|$$

- $\frac{1}{x_2}$ minimo denominatore che fa $-1 = 1$
- $\frac{-x_1}{x_2}$ massimo numeratore, minimo denominatore che fa 2

$$|\delta d| \leq 1 \cdot |\delta x_1| + 2|\delta x_2|$$

Adesso maggioriamo δx_1 e δx_2, tenendo conto che $|x_1|, |x_2| \in [10^0, 10^1)$
dunque $|\delta x_i| \leq \frac{1}{2} B^{e-m} \leq \frac{1}{2} 10^{1-m}$

$$|\delta d| \leq \frac{1}{2} 10^{1-m} + 1 \cdot 10^{1-m} \leq \frac{3}{2} 10^{1-m}$$

che è la MAGGIORAZIONE del mio ERRORE INTERNO

Per quanto riguarda δ_1 abbiamo ancora una volta da maggiorare l'errore di arrotondamento su $\frac{x_1}{x_2}$.

↳ Come prima $\min \left|\frac{x_1}{x_2}\right| = \frac{1}{2}$ e quindi $\left|\frac{x_1}{x_2}\right| \in [10^{-1}, 10^1]$

$$\max \left|\frac{x_1}{x_2}\right| = 2$$

$$\Rightarrow |\delta_1| \leq \frac{1}{2} 10^{1-m}$$

Allora $|\delta f| \leq 3/2\, 10^{1-m} + \frac{1}{2} 10^{1-m} = 2 \cdot 10^{1-m}$

vogliamo che questa quantità sia minore di γ

$$|\delta f| \leq 2 \cdot 10^{1-m} \leq 10^{-2}$$

Per gradi
- $m = 3$ $\quad 2 \cdot 10^{1-3} \leq 10^{-2}$ $\quad$ non è $\leq 10^{-2}$
- $m = 4$ $\quad 2 \cdot 10^{1-4} \leq 10^{-2}$ $\quad$ è $\leq 10^{-2}$

dunque per avere $|\delta f| \leq 10^{-2}$ servono $m = 4$ cifre, e garantire questa limitazione dell'errore totale.

FUNZIONI NON RAZIONALI

fino a questo punto abbiamo supposto che la funzione si scriva con una serie di operazioni $(+, -, \times, /)$ vediamo quando non è così, adesso possiamo alle funzioni **non razionali**

↳ un'espressione matematica non razionale può essere $\left(e^{\cos(x+y)}\right)$ dunque cosa viene fatto sulla macchina per VALUTARLA.

Abbiamo detto che si sceglie un'approssimazione razionale di questa funzione chiamata $\tilde{f}(x)$, che $\overset{\text{approssima}}{\approx} f(x)$ e si valuta $\tilde{f}(p_0)$

Come nel caso RAZIONALE a causa dell'uso dell'ARITMETICA floating POINT quello che si ottiene $\tilde{f}_a(p_1)$, ricordiamo che NON si valuta la funzione su p_0 ma su $p_1 = RN(p_0)$ e ovviamente $\tilde{f}$ deve essere "trodotta" nelle versioni arrotondate delle operazioni matematiche, alla fine della fiera come detto negli scorsi paragrafi si ha $\tilde{f}_a(p_1)$

↓

Osservando dunque l'errore possiamo cominciare a scrivere che

sommiamo e sottraiamo delle cose

$$f(p_0) - \tilde{f}_a(p_1) = \underbrace{f(p_0) - f(p_1)}_{\delta_d} + \underbrace{f(p_1) - \tilde{f}(p_1)}_{\delta_{an}} + \underbrace{\tilde{f}(p_1) - \tilde{f}_a(p_1)}_{\delta_a} \Rightarrow$$

δ_d errore inerente: differenza della funzione valutata nel punto esatto e nel punto arrotondato errore inerente su f

δ_{an} errore che corrisponde all'aver sostituito la nostra funzione con la sua appr. razionale valutato nel punto esattamente rappresentabile p_1 si chiama δ_{an} errore analitico dipende da cosa abbiamo scelto per approssimare f

δ_a errore algoritmico su $\tilde{f}$

$$\Rightarrow \boxed{\delta_f = \delta_d + \delta_a + \delta_{an}}$$ (errore inerente, errore algoritmico, errore analitico)

nel caso razionale $f \approx \tilde{f}$ quindi δ_{an} non c'è!

OSS L'errore inerente è calcolato sulla funzione originale (f), mentre l'errore algoritmico è su $\tilde{f}$ (quindi serve un'analisi dell'algoritmo che valuta $\tilde{f}$) dunque per l'errore algoritmico facciamo la solita tecnica con il grafo

Bisogno capire dunque come stimare l'errore analitico, ma cosa succede all'errore relativo?

Con tecniche simili a quanto visto nel caso razionale si dimostra che (a meno di termini trascurabili per l'errore relativo vale:

$$\varepsilon_f := \frac{f(p_0) - \tilde{f}_a(p_1)}{f(p_0)} \quad , \quad \varepsilon_f = \varepsilon_d + \varepsilon_a + \varepsilon_{an}$$

Con $\varepsilon_{an} = \dfrac{f(p_1) - \tilde{f}(p_1)}{f(p_1)}$

Come trovo δ_{an}, ε_{an} errori assoluti e relativi analitici?

δ_{an} ed ε_{an} si stimano con risultati di teoria dell'approssimazione. C'è una teoria della matematica che ci dice quali funzioni razionali approssimano bene date funzioni (esponenziale etc)

↳ L'esempio più semplice e l'unico che vediamo è l'approssimazione con il polinomio di Taylor, per funzioni da $\mathbb{R} \to \mathbb{R}$

Reminder - Come funziona l'approssimazione con il polinomio di Taylor?

ho una funzione che non è razionale ma posso approssimarla con un polinomio che è razionale (moltiplicare, sottrarre, sommare)

data $f: \mathbb{R} \to \mathbb{R}$ derivabile $k+1$ volte $f \in C^{k+1}(\mathbb{R})$, supponiamo di avere un certo punto $x_0 \in \mathbb{R}$, allora possiamo considerare un polinomio di Taylor centrato in x_0 come approssimazione e si scrive

$$f(x) = \underbrace{\sum_{j=0}^{k} \frac{f^{j}(x_0)}{j!}(x - x_0)^j}_{\text{polinomio di grado } k \text{ usato per approssimare la funzione}} + \underbrace{\frac{f^{(k+1)}(\eta_x)}{(j+1)!}(x - x_0)^{k+1}}_{\text{derivata } k+1 \text{ in un certo punto } \eta_x \text{ che non si conosce}}$$

Sarà la funzione $\tilde{f}(x)$ che usiamo per approssimare $f(x)$

il resto di Lagrange ci permette di stimare l'errore analitico, tramite maggiorazioni perché sappiamo che η_x vive nell'intervallo tra x_0 e x, e conosciamo il dominio in cui vive x, possiamo maggiorare $|f^{(k+1)}(\eta_x)|$ con il suo massimo, ottenendo un bound specifico sull'errore

OSS in questo caso l'errore assoluto analitico sarà $\delta_{an(x)} = \frac{f^{(k+1)}(\eta)}{(j+1)!}(x-x_0)^{k+1}$ e quello relativo sarà $\varepsilon_{an(x)} = \frac{f^{(n+1)}(\eta)}{(j+1)!}\frac{(x-x_0)^{k+1}}{f(x)}$

l'idea è che sappiamo che se x varia in un certo insieme D magari si riesce a dare una limitazione all'errore assoluto o relativo algoritmico

ESERCITIO approssimiamo $f(x) = e^x$ con $\tilde{f}(x) = 1 + x + \frac{x^2}{2}$
(polinomio di Taylor per $x_0 = 0$ e $k = 2$)
scelta

↳ riferendoci a $\sum_{j=0}^{k} \frac{f^{(j)}(x_0)}{j!}(x-x_0)^j$

le derivate sono tutte e^x valutate in 0 fanno 1!

La domanda che ci facciamo è, quanto è grande l'errore analitico relativo $|\varepsilon_{an}|$? Posso limitarlo dall'alto per $x \in [-1,1]$

Se prendo un x che varia fra -1 ed 1 qualsiasi e valuto $\tilde{f}(x)$ al posto di valutare e^x, quanto vado vicino, cioè quanto posso dire sull'errore?

$$\delta_{an}(x) = f(P_1) - \tilde{f}(P_1) = e^x - \left(1 + x + \frac{x^2}{2}\right) =$$

$$= \text{resto di Lagrange nella formula} =$$

derivata k-esima, tutte le derivate uguali quindi e^η

$$= \frac{e^\eta}{3!} \cdot x^3 = \frac{e^\eta x^3}{6}$$

$k+1$

$$\varepsilon_{an}(x) = \frac{\delta_{an}(x)}{f(x)} = \frac{e^\eta x^3}{6e^x}$$

Vogliamo maggiorare adesso $|E_{on}(x)| = \left| \frac{e^{\eta} x^3}{6 \cdot e^x} \right|$

il problema è che dentro c'è η, che non conosciamo. Me ne voglio sbarazzare! Perchè non è un valore esatto!!

Per trovare un limite superiore, sostituiamo ogni pezzo con il suo massimo possibile

$$\left| \frac{e^{\eta} \cdot x^3}{6 \cdot e^x} \right| \leq \frac{\max\left(e^{\eta}\right) \cdot \max\left|x^3\right|}{6 \min\left(e^x\right)}$$

Sappiamo che $\eta \in [x, x_0]$ oppure $[x_0, x]$ ma $x_0 = 0$ e $x \in (-1,1]$ dunque

- $\max\limits_{\eta \in [-1,1]} e^{\eta} = e^1 = e$
- $\max\limits_{x \in [-1,1]} |x^3| = 1$
- $\min\limits_{x \in [-1,1]} e^x = e^{-1}$

$$\longrightarrow |E_{on}(x)| \leq \frac{e \cdot 1}{6 \cdot e^{-1}} \leq \frac{e \cdot 1}{6 \cdot e^{-1}} = e \cdot \frac{e}{6} = \frac{e^2}{6} \approx 1.23$$

OSS Se invece di $k=2$ usiamo un polinomio di Tayler di grado k generico

$$\delta_{on}(x) \overset{\text{dal resto di Lagrange}}{=} \frac{e^{\eta} \cdot x^{k+1}}{(k+1)!} \quad \text{per } x_0 = 0 \text{ ragionando come prima}$$

$$\left| E_{on}(x) \right| \leq \frac{e^2}{(k+1)!} \xrightarrow{n \to \infty} 0$$

il fattoriale cresce molto più velocemente di e^2 che è una costante fissa, questo ci dice che più termini aggiungiamo più l'approssimazione diventa precisa

Con $n=4$ $\quad \tilde{f}(x) = 1 + x + \frac{x^2}{2} + \frac{x^3}{6} + \frac{x^4}{24}$ e l'errore relativo scende a

$$|E_{on}(x)| \leq \frac{e^2}{5!} \approx 0.061$$

Richiami di Algebra Lineare

Richiami di ALGEBRA LINEARE

nella prima parte ci siamo concentrati per cose per il quale il valore di uscita era uno scalare

↳ L'oggetto di interesse adesso è spesso un vettore $x \in \mathbb{R}^n$, o si considerano $f: \mathbb{R}^n \to \mathbb{R}^m$

In questo contesto sono importanti le matrici poichè se abbiamo una funzione $f: \mathbb{R}^n \to \mathbb{R}^m$ LINEARE (ovvero che non distingue se prima somma e poi applico f, o applico f e sommo il risultato è lo stesso), dunque

$$f(x+y) = f(x)+f(y) \quad \forall x, y \in \mathbb{R}^n$$

$$f(\lambda x) = \lambda f(x) \quad \forall \lambda \in \mathbb{R}, \forall x \in \mathbb{R}^n$$

Ogni volta che si ha una funzione con queste proprietà quindi esiste una maniera univoca per rappresentarla, che è una MATRICE

Allora $\exists!\ A \in \mathbb{R}^{m \times n}$ (righe, colonne) m(righe - arrivo) $\longrightarrow$ n(colonne - partenza) tale per cui $\forall x$(INPUT) $\in \mathbb{R}^n$ vale $f(x) = Ax$ (MAT VETT)

A è una tabella di $m \times n$ elementi: $A = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & a_{ij} & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix}$

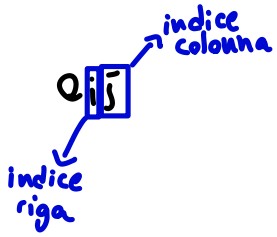

se $m = n$ la matrice si dice QUADRATA

se $m \neq n$ la matrice si dice RETTANGOLARE

dunque $A \in \mathbb{R}^{m \times n}$ (potevo mettere anche $\mathbb{C}$)

DEFINIZIONE presi s vettori in $\mathbb{C}^n$ $x_1 \dots x_s \in \mathbb{C}^n$ si dicono linearmente indipendenti (se generano qualcosa di più piccolo del numero di vettori che sono, se prendiamo due vettori che sono su una retta tutte le loro combinazioni lineari continueranno a darmi una RETTA e non uno spazio 3D, ma uno 2D!)

Se ogni qualvolta prendo una combinazione lineare:

$$\sum_{i=1}^{s} \boxed{\alpha_i} x_i = 0 \qquad \Longleftrightarrow \alpha_1 = \alpha_2 = \dots = \alpha_s = 0$$

scalare $x_i \in \mathbb{C}$ — prendo tutte le costanti pari a 0

Viceversa se questo non accade $x_1 \dots x_s$ si dicono linearmente dipendenti se (almeno un vettore si scrive come combinazione lineare degli altri)

$\exists_J \in \{1 \dots s\}$ tale per cui $x_J = \sum_{i \neq J} \alpha_i x_i$ per qualche scelta di $\alpha_i \in \mathbb{C}$

↳ Ovvero riesco a fare uno di questi vettori come combinazione lineare degli altri, è come se ci fosse un vettore ridondante che potevo generare usando gli altri

Esempio

vettori linearmente indipendenti:

$x_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$ $x_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$ impongo $\alpha_1 x_1 + \alpha_2 x_2 = 0$

$$\alpha_1 \begin{pmatrix} 1 \\ 0 \end{pmatrix} + \alpha_2 \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} \alpha_1 \\ \alpha_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \longrightarrow \text{unica soluzione per } \alpha_1 = \alpha_2 = 0$$

vettori linearmente dipendenti:

$x_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$ $x_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$ $x_3 \begin{pmatrix} 3 \\ 2 \end{pmatrix}$

Posso ottenere 0, anche con coefficienti non tutti 0?

Scegliendo $\alpha_1 = -3$ $\alpha_2 = -2$ $\alpha_3 = 1$

$$-3\begin{pmatrix} 1 \\ 0 \end{pmatrix} - 2\begin{pmatrix} 0 \\ 1 \end{pmatrix} + 1\begin{pmatrix} 3 \\ 2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$ sono dipendenti:

infatti $-3x_1 - 2x_2 + x_3 = 0 \Rightarrow x_3 = 3x_1 + 2x_2$: $3\begin{pmatrix} 1 \\ 0 \end{pmatrix} + 2\begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 3 \\ 2 \end{pmatrix}$

x_3 è ridondante! Può essere scritto come combinazione degli altri!

REGOLA INTUITIVA: ogni vettore aggiunge una direzione nuova? Indipendenti. Uno è già "coperto" appena è possibile coprirlo con gli altri? dipendenti.

DEFINIZIONE un insieme di n vettori linearmente indipendenti in $\mathbb{C}^n$ si dice base (nel senso che con questi vettori pensando alla base come una mappa stradale posso raggiungere qualsiasi posto!)

DEFINIZIONE x, y vettori di n elementi $\in \mathbb{C}^n$ si definisce il prodotto scalare la quantità $\langle x, y \rangle = \sum_{i=i}^{n} x_i \overline{y_i}$ ← coniugato complesso cambia segno alla parte immaginaria

Esempio

$$x = \begin{pmatrix} 1+i \\ 2 \end{pmatrix} \quad y = \begin{pmatrix} i \\ 3 \end{pmatrix}$$

$$\langle x, y \rangle = (1+i)\bar{i} + 2\bar{3} = (1+i)(-i) + 6 = (-i - i^2) + 6 = (-i+1) + 6 = 7 - i$$

Inoltre si definisce norma la quantità

$$\langle x, x \rangle = \sum_{i=1}^{m} x_i \overline{x_i} = \sum_{i=1}^{m} |x_i|^2 = \|x\|_2^2$$

OSS Se contiamo le operazioni di un prodotto scalare queste sono n prodotti e n-1 somme e scriviamo che il suo costo è $O(n)$ (n op.) oppure $O(2n)$ (2n op.) significa che

$$\lim_{n \to +\infty} \frac{\text{costo prodotto scalare}}{n} = \text{costante finita} \neq 0$$

(operazioni per componente; ↑ il costo cresce esponenzialmente con n)

due vettori si dicono ortogonali se $\langle x, x \rangle = 0$

DEFINIZIONE (trasposta coniugata)

$A \in \mathbb{C}^{m \times n}$ si definiscano

$A^T \in \mathbb{R}^{n \times m}$ Trasposta $(A^T)_{ij} = A_{ji}$

$A^H \in \mathbb{R}^{n \times m}$ Hermitiana (trasposta coniugata) $(A^H)_{ij} = \overline{A_{ji}}$

Esempio

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 2 & 9 \\ 5 & 6 & 3 \end{bmatrix} \Rightarrow A^T = \begin{bmatrix} 1 & 4 & 5 \\ 2 & 2 & 6 \\ 3 & 9 & 3 \end{bmatrix}$$

$$A = \begin{bmatrix} 1 & 2 & 3i \\ -i & 1+i & 0 \\ 4 & e & 3 \end{bmatrix} \Rightarrow A^H = \begin{bmatrix} 1 & i & 4 \\ 2 & 1-i & 0 \\ -3i & 0 & 3 \end{bmatrix}$$

in MATLAB

A' ≈ A^{H} (trasposizione con cambio segno complessi)

$A.'$ ≈ A^T (trasposizione senza cambio di segno per Hermitiana)

Se abbiamo la rete facciamo questa

Per definire una matrice su Matlab elemento, elemento

```
A = [ 1  2  3 ; 4  5  6 ];
```
(; = riga)

≈

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}$$ esplicito

Possiamo leggere anche un elemento dalla Matrice come A(righe,colonne)
Ma possiamo anche definirla come A(riga,colonna) = x
A quel punto

≈

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 8 & 0 & 0 \end{bmatrix}$$ ← allarga la matrice

Oppure se vogliamo creare una matrice che non c'è

≈

```
B(10,10) = 1
```

```
>> B(10,10)=1

B =

     0     0     0     0     0     0     0     0     0     0
     0     0     0     0     0     0     0     0     0     0
     0     0     0     0     0     0     0     0     0     0
     0     0     0     0     0     0     0     0     0     0
     0     0     0     0     0     0     0     0     0     0
     0     0     0     0     0     0     0     0     0     0
     0     0     0     0     0     0     0     0     0     0
     0     0     0     0     0     0     0     0     0     0
     0     0     0     0     0     0     0     0     0     0
     0     0     0     0     0     0     0     0     0     1
```

Gli indici nelle matrici partono da 1 e per accedere alle entrate si utilizzano le parentesi tonde

DEFINIZIONE MATRICE DIAGONALE una matrice si dice diagonale quando fuori dalla diagonale principale ha elementi tutti pari a zero, ovvero:

$$a_{ij} = 0 \quad \forall i, j$$

in MATLAB

matlab

```
x = [1, 5, 9];
A = diag(x)
```

Risultato:

$$A = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 5 & 0 \\ 0 & 0 & 9 \end{bmatrix}$$

matlab

```
x = [7, 7];
A = diag(x, 1)
```

Risultato:

$$A = \begin{bmatrix} 0 & 7 & 0 \\ 0 & 0 & 7 \\ 0 & 0 & 0 \end{bmatrix}$$

```
x = [7, 7];
A = diag(x, -1)
```

Risultato:

$$A = \begin{bmatrix} 0 & 0 & 0 \\ 7 & 0 & 0 \\ 0 & 7 & 0 \end{bmatrix}$$

diag(n, k) = matrice con gli elementi tutti pari a 0, tranne sulla diagonale k, dove prende gli elementi da questo

definizione matrice triangolare

matrice triangolare superiore o inferiore se sopra o sotto la diagonale ha elementi pari a 0.

una matrice quadrata (stesso numero righe e colonne) si dice triangolare superiore (o inferiore) se ha elementi uguali a zero, sotto o sopra la diagonale principale

$$U = \begin{bmatrix} u_{11} & \cdots & u_{1m} \\ 0 & \ddots & \vdots \\ 0 & 0 & u_{nm} \end{bmatrix} \qquad L = \begin{bmatrix} l_{11} & 0 & 0 \\ \vdots & \ddots & 0 \\ l_{n1} & \cdots & l_{nm} \end{bmatrix}$$

in Matlab

ci sono i comandi TRIU e TRIL, che estraggono la parte triang SUP o INF di una matrice di input.

```
A = [
    0.3062  -0.2710  -0.5035  -1.6258  -0.9742;
   -1.1723  -0.9000   1.2333  -1.9648  -1.1464;
   -0.9610  -0.2857   0.6103   2.6052   0.5476;
   -0.6537  -0.4624   0.0591   0.9724   1.5651;
   -1.2294  -0.4098  -1.4669   0.2570  -1.6933
];
```

≈

2. Comando tril(A, 2)

Questo comando estrae la parte triangolare inferiore includendo fino alla seconda sovradiagonale (due posizioni sopra la diagonale principale).

Risultato:

matlab

```
ans =
    0.3062  -0.2710  -0.5035        0        0
   -1.1723  -0.9000   1.2333  -1.9648        0
   -0.9610  -0.2857   0.6103   2.6052   0.5476
   -0.6537  -0.4624   0.0591   0.9724   1.5651
   -1.2294  -0.4098  -1.4669   0.2570  -1.6933
```

3. Comando tril(A, -2)

Questo comando estrae la parte triangolare inferiore partendo dalla seconda sottodiagonale (due posizioni sotto la diagonale principale).

Risultato:

matlab

```
ans =
         0         0         0         0         0
         0         0         0         0         0
   -0.9610         0         0         0         0
   -0.6537  -0.4624         0         0         0
   -1.2294  -0.4098  -1.4669         0         0
```

OPERAZIONI FRA MATRICI

SOMMA

- Se ho due matrici di uguale dimensione $B, A \in \mathbb{C}^{m \times n}$ posso definire $C = A + B$ come $C_{ij} = A_{ij} + B_{ij}$

Chi mi dice quanto costa fare la somma tra due matrici?

il costo di $A+B$ è $O(mn)$, si devono fare $m \times n$ addizioni

$n \times m = 2 \times 3 = 6$

Se ho $A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} + B \begin{bmatrix} 7 & 8 & 9 \\ 1 & 0 & 2 \end{bmatrix} = C \begin{bmatrix} 1+7 & 2+8 & 3+9 \\ 4+1 & 5+0 & 6+2 \end{bmatrix}$ = 6 somme $= O(2 \times 3) = O(6)$

PRODOTTO

Se ho invece il prodotto nella moltiplicazione tra matrici, le moltiplicazioni, non devono essere UGUALI, ma devono essere compatibili

Se $A \in \mathbb{C}^{m \times n}$, $B \in \mathbb{C}^{n \times p}$ (per essere compatibili il numero di colonne della prima matrice deve essere UGUALE al numero di righe della seconda)

Allora posso definire la MATRICE PRODOTTO!

Si definisce $C = A \cdot B$ come la matrice che ha $C \in \mathbb{F}^{m \times p}$ (righe prima, colonne seconda) definita da $c_{ij} = \sum_{h=i}^{n} a_{ih} b_{hJ}$

AB rappresenta la funzione (lineare) $(f \circ g)(x)$ (composto) dove g è associata a B, ed f è associata ad A

OSS il prodotto AB corrisponde al prodotto "righe × colonne"

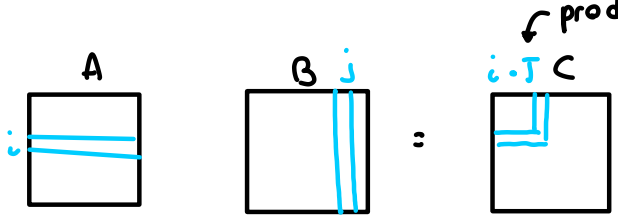

Ma quanto costa il PRODOTTO tra matrici! Quindi calcolare c_{ij} costa come un prodotto scalare tra la riga i di A, e la colonna j di B. Questa cosa costa $O(n)$ per una moltiplicazione!

↓

Ma data C che ha mp entrate il costo di $A \cdot B$ è $O(mnp)$ (prodotto delle 3 dimensioni diverse che appaiono)

Se $m = n$ allora $= p$ (moltiplicazioni di MATRICI QUADRATE) il costo è $O(n^3)$

OSS si può guardare al risultato di $A \times B$, sia per colonne che per righe, questo può essere vantaggioso

$$A = \begin{bmatrix} A^1 \\ \hline \vdots \\ \hline A^m \end{bmatrix} \text{ righe} \quad \text{allora} \quad AB = \begin{bmatrix} A^1 B \\ \hline \vdots \\ \hline A^m B \end{bmatrix} \quad \text{per righe}$$

$$B = \begin{bmatrix} B_1 & | & \dots & | & B_p \end{bmatrix} \text{ colonne} \quad \text{allora} \quad AB = \begin{bmatrix} AB_1 & | & \dots & | & AB_p \end{bmatrix} \quad \text{per colonne}$$

Può essere utile questa cosa quando una delle matrici ha molti zeri

esempio $\begin{bmatrix} 2 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 4 \end{bmatrix} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 2 & 3 \\ 3 & 3 & 3 \\ 4 & 4 & 4 \end{bmatrix}$ moltiplico la prima riga per due, la seconda per tre e così via

$$\begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 4 \end{bmatrix} = \begin{bmatrix} 2 & 3 & 4 \\ 2 & 3 & 4 \\ 2 & 3 & 4 \end{bmatrix}$$ per colonne

OSS in generale in matematica esatta non vale la proprietà commutativa

$AB \neq BA$

Ma vale quella associativa $(A \cdot B) \cdot C = A \cdot (B \cdot C)$

ed anche $(A+B) \cdot C = AC + BC$

Ovviamente queste cose continuano ad essere non esatte in aritmetica floating point.

Però attenzione! nonostante VEDIAMO lo stesso risultato queste cose possono avere costi computazionali diversi.

↓

facciamo il conto! Dunque ANCHE se la moltiplicazione fra MATRICI è associativa, l'ordine con cui si fanno le operazioni può influenzare significamente il costo computazionale!

PERCHÈ? $A \in \mathbb{C}^{m \times n}$, $B \in \mathbb{C}^{n \times p}$, $C \in \mathbb{C}^{p \times q}$ (compatibili, compatibili)

$$(A \cdot B) \cdot C \longrightarrow O(mnp + mpq) = O(mp(n+q))$$
$A \cdot B \in \mathbb{C}^{m \times p}$

$$A \cdot (B \cdot C) \longrightarrow O(npq + mnq) = O(nq(p+m))$$
$B \cdot C \in \mathbb{C}^{n \times q}$

imponiamo dei parametri

Se $n = 1$ (o piccolo) e $m = p = q$ allora il primo metodo costa $O(m^3)$ mentre il secondo $O(2m^2)$ più veloce

DEFINIZIONE determinante il determinante è un numero associato ad una matrice quadrata, e ci fornisce informazioni importanti su di essa!

Data una matrice quadrata $A \in \mathbb{C}^{n \times n}$ si definisce **determinante di A** come la quantità

$$\det(A) = \begin{cases} a_{11} & n=1 \\ a_{11}a_{22} - a_{12}a_{21} & n=2 \\ \sum_{j=1}^{n} (-1)^{i+j} a_{ij} \det(A_{ij}) & \end{cases}$$

dove A_{ij} è la sottomatrice ottenuta cancellando la riga i e la colonna j

esempio

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 0 & 4 & 5 \\ 0 & 0 & 6 \end{bmatrix} \quad \det(A) = 1\det\begin{pmatrix} 4 & 5 \\ 0 & 6 \end{pmatrix} - 2\det\begin{pmatrix} 0 & 5 \\ 0 & 6 \end{pmatrix} + 3\det\begin{pmatrix} 0 & 4 \\ 0 & 0 \end{pmatrix} = 24$$

NOTAZIONE ALTERNATIVA $\det(A) = \begin{vmatrix} a_{11} & \cdots & a_{1m} \\ \vdots & & \vdots \\ a_{m1} & \cdots & a_{mm} \end{vmatrix}$

Casi Particolari Per matrici diagonali e triangolari il determinante è semplicemente il PRODOTTO degli elementi sulla diagonale

$$\det(A) = \prod_{i=1}^{m} a_{ij} = a_{11} \cdot a_{22} \cdots a_{mm}$$

in questo caso il costo di $\det(A)$ è $O(m)$

Proprietà

- $\det(A) = \det(A^T)$ il determinante non cambia se trasporgo la matrice
- $\det(A^H) = \det(A)$
- $\det(\lambda A) = \lambda^m \det(A) \quad (\lambda \in \mathbb{C})$ (m = n righe)

DEFINIZIONE SINGOLARE

Se $\det(A) = 0$ allora A si dice SINGOLARE

in Matlab

```
det(A)
```

Data una matrice A, talvolta è utile "estrarre" A da un'altra matrice selezionando alcune righe e colonne di A $A_{ij} =$ 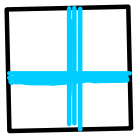

si eliminano righe e colonne

Più in generale se ho $I \subseteq \{1 \dots m\}$, $J \subseteq \{1 \dots n\}$ indici righe e colonne posso definire

$A(I,J)$ = sottomatrice corrispondente alle righe I e alle colonne in J

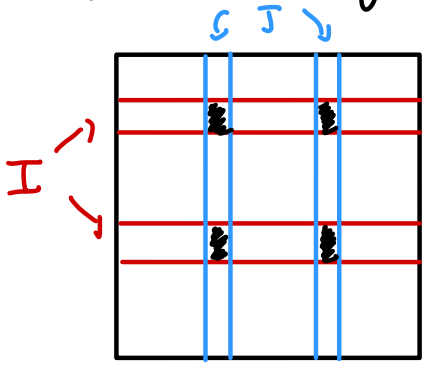

DEFINIZIONE Sottomatrice principale di testa

se $I = \{1 \dots k\}$ $J = \{1 \dots k\}$ allora $A(I,J)$ è detta sottomatrice principale di testa

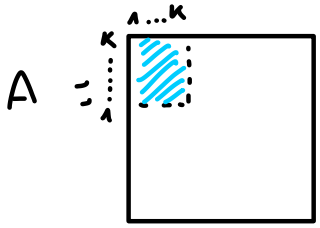

DEFINIZIONE Minore

Si dice minore di ordine k il determinante di una sottomatrice $k \times k$ un minore è detto principale se $I = J$ (coincidono gli indici) (ovvero la sottomatrice di cui si fa il determinante è nella forma $A(I,I)$)

in Matlab

```
A = [
   -0.4494, -0.3909,  1.3018,  0.1203,  0.1807, -1.3933;
   -0.0843,  0.4092, -0.5936, -1.0368,  1.2665, -0.3862;
   -1.9920, -1.1424,  0.4364, -0.8571, -0.2512,  0.5256;
    0.8412, -0.6249, -0.5044, -0.1699, -0.2046,  1.5233;
   -0.4147, -1.1687,  0.1021, -0.1917, -2.2015,  1.7985;
    1.9122,  0.3926,  1.1963, -0.8658, -0.7745, -0.1169
];
```

≈

2. Estrazione della sottomatrice

Nell'immagine vengono creati due vettori indice I e J:

- `I = [1, 2]` (seleziona la riga 1 e la riga 2)
- `J = [1, 2]` (seleziona la colonna 1 e la colonna 2)

matlab

```
I = [1, 2];
J = [1, 2];
A(I, J)
```

Risultato:

Viene restituito il blocco 2×2 in alto a sinistra:

matlab

```
ans =
   -0.4494   -0.3909
   -0.0843    0.4092
```

DEFINIZIONE rango

il rango di una matrice $A \in \mathbb{C}^{m \times n}$ è dato da:

- il numero di colonne linearmente indipendenti (vettori) oppure
- il numero di righe linearmente indipendenti oppure
- la dimensione massima diversa da zero, ovvero la sottomatrice con dim più grande con determinante diverso da zero che posso estrarre oppure

- Oppure la dimensione dello spazio vettoriale immagine di A:

$$\text{Rango}(A) = \dim(\text{Im}(A))$$

$$\text{Im}(A) = \{ y \in \mathbb{C}^m : \exists x : y = Ax \}$$

DEFINIZIONE Immagine di A

L'immagine di una matrice A $(m \times n)$ è l'insieme di tutti i vettori che posso ottenere moltiplicando A per qualche vettore x

Esempio

$$A = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix} \quad x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \quad Ax = x_1 \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} + x_2 \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} = \begin{pmatrix} x_1 \\ x_2 \\ 0 \end{pmatrix}$$

$$\text{Im}(A) \overset{\text{tutti i vettori nella forma}}{=} \left\{ y \in \mathbb{C}^m : \exists x_1, x_2 : \begin{pmatrix} x_1 \\ x_2 \\ 0 \end{pmatrix} = x_1 \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} + x_2 \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} \right\}$$

TEOREMA di Binet-Cauchy

Se $A, B \in \mathbb{C}^{m \times m}$ (matrici quadrate) $\det(A \cdot B) = \det(A) \cdot \det(B)$

Un'idea per calcolare il determinante evitandosi lo sviluppo di laplace è scriversi A come prodotto di matrici che hanno un determinante facile da calcolare (esempio matrici triangolare)

il determinante è collegato ai prodotti di matrici ci dice quando esiste una matrice inversa!

definizione matrice inversa

Se $A \in \mathbb{C}^{n \times n}$ non singolare si definisce $A^{-1} \in \mathbb{C}^{n \times n}$ che verifica $A \cdot A^{-1} = A^{-1} \cdot A = I$
$= diag(1 \dots 1)$ ← matrice diagonale con 1 sulla diagonale principale

in Matlab

$I \in \mathbb{R}^{n \times m} \approx eye(n)$

Proprietà

- A^{-1} esiste $\iff det(A) \neq 0 \iff$ A ha n colonne lin ind $\iff$ A ha n righe lin ind $\iff rango(A) = n$
- Conseguenza di Binet-Cauchy $\longrightarrow det(I)$

$$det(A \cdot A^{-1}) = det(A) \cdot det(A^{-1})$$

dunque $det(A^{-1}) = \frac{1}{det(A)}$

- $(A \cdot B)^{-1} = B^{-1} \cdot A^{-1}$ similmente $(AB)^T = B^T A^T$, $(AB)^H = B^H A^H$

in Matlab

$A^{-1} \approx inv(A)$

Matrici con proprietà particolari

Se $A \in \mathbb{C}^{n \times n}$ (quadrata) A si dice

- Hermitiana se $A = A^H$
- unitaria se $AA^H = A^H A = I$
- normale se $AA^H = A^H A$

Ogni Hermitiana è normale ma esistono matrici normali che non sono Hermitiane

in particolare $\{$Matrici Hermitiane$\} \subsetneq \{$matrici normali$\}$ Ogni Hermitiana è Normale
$\{$Matrici unitarie$\} \subsetneq \{$matrici normali$\}$ Ogni Unitaria è Normale (ma non viceversa)

Se siamo nel caso reale $A \in \mathbb{R}^{n \times n}$

- simmetrica se $A = A^T$
- ortogonale se $A^T A = A A^T = I$

$$\{\text{matrici simmetriche}\} \subsetneq \{\text{matrici Hermitiane}\}$$

$$\{\text{matrici ortogonali}\} \subsetneq \{\text{matrici unitarie}\}$$

Matrici di Permutazione Sono matrici ortogonale particolare $P \in \mathbb{R}^{m \times m}$ è detta di permutazione se è ottenuta dalla matrice identica permutando l'ordine delle righe oppure delle colonne (scambiando)

esempio

$$P = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{bmatrix} \longrightarrow \text{l'ho ottenuta}$$

permutando sulle righe
$\nabla_R = 1 \to 3,\ 2 \to 1,\ 3 \to 2$
permutando sulle colonne
$\nabla_C = 1 \to 2,\ 2 \to 3,\ 3 \to 1$

Proprietà

- ogni matrice di permutazione è ortogonale $P^T P = P P^T = I$
- il prodotto fra una matrice A ed una matrice di permutazione si produce dalle colonne di A (se stiamo calcolando AP) o dalle righe di A (se si sta calcolando PA)

esempio

$$A = \begin{bmatrix} 1 & 4 & 7 \\ 2 & 5 & 8 \\ 3 & 6 & 9 \end{bmatrix}, \quad P = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{bmatrix}$$

* al posto della prima colonna ci mettiamo la terza
* al posto della prima riga ci mettiamo la seconda

$$AP = \begin{bmatrix} 7 & 1 & 4 \\ 8 & 2 & 5 \\ 9 & 3 & 6 \end{bmatrix} \qquad PA = \begin{bmatrix} 2 & 5 & 8 \\ 3 & 6 & 9 \\ 1 & 4 & 7 \end{bmatrix}$$

i SISTEMI LINEARI

questi sistemi sono nella forma

$$\begin{cases} a_{11}x_1 + \dots + a_{1n}x_n = b_1 \\ \vdots \\ a_{m1}x_1 \dots + a_{mn}x_n = b_m \end{cases}$$

m EQUAZIONI
n incognite $x \in \mathbb{C}^n$ vettore incognite $\begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$

① quando esiste la soluzione?
② se esiste è unica?

Il sistema lineare si può anche scrivere come $Ax = b$

$$A = \begin{bmatrix} a_{11} \dots a_{1n} \\ \vdots \\ a_{m1} \dots a_{mn} \end{bmatrix} \quad x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} \quad b = \begin{bmatrix} b_1 \\ \vdots \\ b_m \end{bmatrix} \in \mathbb{C}^m$$

Teorema di Rouche - capelli

Affinche $Ax = b$ ammette soluzioni se e sdo se $\text{Rango}(A) = \text{Rango}(A|b)$ dove $A|b \in \mathbb{C}^{m \times (n+1)}$ è la matrice ottenuta aggiungendo la colonna b in coda alla matrice A

$$A: \begin{bmatrix} a_{11} \dots a_{1n} & b_1 \\ \vdots \quad \vdots & \vdots \\ a_{m1} \dots a_{mn} & b_m \end{bmatrix} = A|b \quad \text{(per l'esistenza ①)}$$

Per l'unicità:

se rango $(A) = n$ (colonne) allora la soluzione è unica
se rango $(A) < n$ (colonne) allora ci sono infinite soluzioni
↳ queste generano uno spazio affine di dimensione n-rango(A)

OSS Se $m = n$ e $\det(A) \neq 0$ allora la soluzione esiste ed è unica

DEFINIZIONE SISTEMA omogeneo

nel caso $b = 0$ si parla di sistema omogeneo, la soluzione esiste sempre!

$Ax = 0$

Qualunque sia la matrice A, moltiplicarlo per 0 da zero, $x_1 = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}$ può essere una soluzione.
Ma, non è detto che sia l'unica che soddisfi $Ax = 0$

DEFINIZIONE

se $m > n$ il sistema si dice **sovradeterminato**

se $m < n$ il sistema si dice **sottodeterminato**

ESERCIZIO

$$\begin{cases} x - 2y - 2z = 0 \\ -2x - y + 4z = 3 \\ x - 2y - 2z = 0 \end{cases} \xrightarrow{\text{-1 in meno}} \Rightarrow \begin{cases} x = 2y + 2z \\ \\ -5y = 3 \end{cases} \Rightarrow \begin{cases} x = -\frac{6}{5} + 2z \\ \\ y = -\frac{3}{5} \end{cases}$$

variabile libera dunque $z = t$

$$A = \begin{bmatrix} -1 & -2 & -2 \\ -2 & -1 & 4 \\ 1 & -2 & -2 \end{bmatrix} \quad b = \begin{bmatrix} 0 \\ 3 \\ 0 \end{bmatrix}$$

scriviamo il vettore soluzione

$$\left\{ \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} -6/5 \\ -3/5 \\ z \end{bmatrix} \longrightarrow \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} -6/5 \\ -3/5 \\ 0 \end{bmatrix} + z \begin{bmatrix} 2 \\ 0 \\ 1 \end{bmatrix} : t \in \mathbb{R} \right\}$$ retta traslata in $\mathbb{R}^3$

Verificare $\text{rango}(A) = \text{rango}(A|b) = 2$

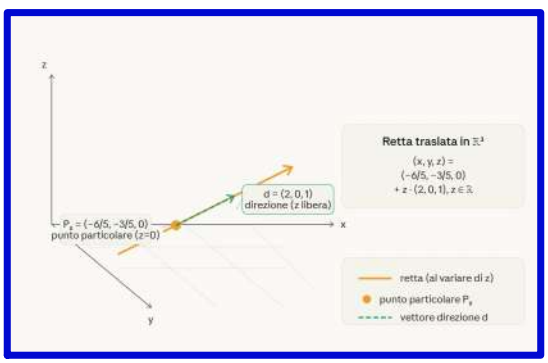

Lez 4

Parliamo di autovalori e autovettori

DEF Presa una matrice $A \in \mathbb{C}^{n \times n}$ e preso uno scalare $\lambda \in \mathbb{C}$ si dice autovalore se $\exists \underset{\text{vettore}}{v} \in \mathbb{C}^n$, $v \neq 0$ per cui vale

$$\boxed{Av = \lambda v}$$

Questa relazione ci dice che la matrice A rappresenta una funzione lineare e questo vettore "v" viene mappato da questa funzione per un multiplo di se stesso, è come se la relazione $Av = \lambda v$ ci dicesse prendi un vettore in INPUT, e restituisce un vettore trasformato, ruotato o scalato.

↳ Quindi λ è un autovalore, il vettore v, associato a λ, per cui vale questa relazione si dice autovettore oppure la coppia (λ, v) si dice AUTOCOPPIA quando verifica la relazione sopra.

Esistono sempre soluzioni a $Av = \lambda v$? La risposta è si.

Si riscrive $Av = \lambda v$ come $(A - \lambda I)v = 0$ ← questo è un sistema omogeneo con $b = 0$ per $Ax = b$

Per Rouche-Capelli, un sistema omogeneo ha sempre almeno la soluzione $v = 0$ (soluzione banale).

Ovvero $v = 0$ è soluzione del sistema omogeneo con matrice $A - \lambda I$

Ma noi vogliamo $v \neq 0$, voglio che questo sistema non abbia una soluzione unica, ma più di una soluzione.

Quando esiste una soluzione non banale? Per Rouche capelli applicato al caso omogeneo, esistono soluzioni non banali se e solo se

$$rk(A - \lambda I) < n \quad \text{che equivale a dire} \quad \det(A - \lambda I)$$

Questa è la equazione caratteristica e i valori λ che soddisfano sono gli autovalori, e per ciascuno di essi il sistema ha infinite soluzioni.

Ma quindi esistano sempre?

Sul campo dei complessi $\mathbb{C}$ sì, sempre, perché il polinomio caratteristico ha n radici, sul campo dei reali $\mathbb{R}$, non necessariamente, poiché le radici potrebbero essere complesse.

Esempio Per trovare gli autovalori serve $\det(A-\lambda I)$ per ruffini Capelli

$$A=\begin{bmatrix}1 & 3\\ 0 & 4\end{bmatrix} \longrightarrow A-\lambda I=\begin{bmatrix}1-\lambda & 3\\ 0 & 4-\lambda\end{bmatrix} \longrightarrow \det(A-\lambda I)=(1-\lambda)(4-\lambda)=\lambda^2-5\lambda+4$$

questo è il polinomio caratteristico indicato con $p_A(\lambda)$

DEF Per una matrice $A^{n\times n}$, il polinomio caratteristico $p_A(\lambda)=\det(A-\lambda I)$ è sempre un polinomio di grado n in λ. Gli autovalori sono le radici di questo polinomio cioè le soluzioni di $p_A(\lambda)$, e anche soluzioni di $Av=\lambda v$

↳ PER IL Teorema fondamentale dell'algebra

"Ogni polinomio di grado n, a coefficienti complessi ha esattamente n radici in $\mathbb{C}$, contate con la loro molteplicità"

$\Big\|$ conseguenza

$p_A(\lambda)$ ha grado n $\longrightarrow$ ha sempre n radici complesse $\longrightarrow$ esistono sempre n autovalori (contati con molteplicità in $\mathbb{C}$)

$p_A(\lambda)$ = polinomio caratteristico della matrice A.

DEF molteplicità algebrica In termini di autovalori si parla di molteplicità algebrica. Se $\tilde{\lambda}$ è un autovalore di A, si dice molteplicità algebrica il numero di volte che $\tilde{\lambda}$ appare come radice del POLINOMIO CARATTERISTICO $p_A(\lambda)$, e si indica con $a(\lambda)$

esempio $p_A(\lambda)=(\lambda-3)^2(\lambda-5)$ $\lambda_1=3$ $a(\lambda)=2$ $\lambda_2=5$ $a(\lambda)=1$

Reminder! Se $\lambda_1 \dots \lambda_m$ sono autovalori di A, il polinomio caratteristico si scrive come prodotto di tutti i fattori $(\lambda - \lambda_i)$

$$p_A(\lambda) = (-1)^n(\lambda-\lambda_1)(\lambda-\lambda_2)\dots(\lambda-\lambda_n)$$ Forma Fattorizzata (prodotto delle radici)

Sviluppando $p_A(\lambda) = (-1)^n \lambda^n + (-1)^{n-1}\sigma_1 \lambda^{n-1} + \dots \sigma_{n-1}\lambda + \sigma_n$

Ma cosa sono gli σ_i? I coefficienti σ_i sono le somme dei MINORI PRINCIPALI di ordine i, della matrice A, ovvero i determinanti delle SOTTOMATRICI principali di ordine i

$$\sigma_i = \sum_{|I|=i} \det(A(I,I))$$

dove $A(I,I)$ indica la sottomatrice ottenuta tenendo solo le righe e le colonne nell'insieme di indici I.

Casi Particolari:

1. $\sigma_1 = tr(A) = \sum_{j=1}^{n} a_{jj} = \sum_{j=1}^{n} \lambda_j$
2. $\sigma_n = \det(A) = \prod_{j=1}^{n} \lambda_j$

La traccia di una matrice è la somma degli elementi sulla diagonale principale

Queste due proprietà sono utili, senza calcolare esplicitamente tutti gli autovalori, so già che devono sommare la traccia e moltiplicarsi al determinante

esempio presa la matrice $A = \begin{bmatrix} 2 & 1 & 0 \\ 0 & 3 & 1 \\ 0 & 0 & 5 \end{bmatrix}$

minori principali di ordine 1 (sottomatrici 1×1)

$\sigma_1 = \det[2] + \det[3] + \det[5] = 2 + 3 + 5 = 10$

$\sigma_3 = \det(A) = 2 \cdot 3 \cdot 5 = 30$

il polinomio caratteristico risultante è

$$p_A(\lambda) = (-1)^3\lambda^3 + (-1)^2\sigma_1\lambda^2 - \sigma_2\lambda + \sigma_3 =$$
$$= -\lambda^3 + 10\lambda^2 - 31\lambda + 30$$

Le radici sono $\lambda_1 = 2$ $\lambda_2 = 3$ $\lambda_3 = 5$ che verificano quanto espresso sopra.

oss se $\det(A) = 0 \longleftrightarrow \exists$ Almeno un autovalore $= 0$

Questo segue direttamente dal fatto che $\det(A)$ = prodotto autovalori.
Se il prodotto è 0, allora per forza uno degli autovalori è 0!

Esempio $A = \begin{bmatrix} 1 & 3 \\ 0 & 4 \end{bmatrix}$ $\approx$ $p_A(\lambda) = \lambda^2 - 5\lambda + 4$ avevamo trovato

ma con le proprietà

$$\text{tr}(A) = 1 + 4 = 5$$
$$\det(A) = 1 \cdot 4 - 3 \cdot 0 = 4$$
$$\longrightarrow p_A(\lambda) = \lambda^2 - \text{tr}(A)\lambda + \det(A)$$

senza andare a calcolare $\det(A - \lambda I)$

Riepilogando

Ogni matrice quadrata ha esattamente n autovalori, ma quanti sono gli autovettori?

Se prendo v che verifica $Av = \lambda v$ e prendiamo θv con $\theta \in \mathbb{C} \setminus \{0\}$
Allora

$$A(\theta v) = \theta(Av) = \theta\lambda v = \lambda(\theta v)$$

θv è autovettore per λ $\forall\, \theta \neq 0$

$\longrightarrow$ gli autovettori associati ad un certo λ sono ∞!

- **Spiegazione** sto scalando v, per un numero complesso qualsiasi non nullo il risultato è ancora un autovettore per lo stesso λ - la direzione è lo stessa, cambia solo lunghezza. Questo ci dice che non ha senso cercare "tutti" gli autovettori, sono infiniti. Ha senso invece trovare una base dello spazio che generano.

↳ Si può dire che formano uno spazio vettoriale se v_1, v_2 sono entrambi autovettori associati ad λ allora

$$A(v_1+v_2) = Av_1 + Av_2 = \lambda v_1 + \lambda v_2 = \lambda(v_1+v_2)$$

non solo dunque i multipli di v sono autovettori, ma anche la somma di due autovettori dello stesse λ è ancora un autovettore per λ. Questo significa che l'insieme degli AUTOVETTORI è chiuso rispetto alla somma e al prodotto per scalare - cioè forma uno spazio vettoriale

DEFINIZIONE AUTOSPAZIO

L'insieme degli autovettori associati a uno specifico λ, autovalore di A, forma un SOTTOSPAZIO VETTORIALE di $\mathbb{C}^n$, chiamato autospazio relativo a λ.
È l'insieme di tutti i vettori v tali che $(A-\lambda I)v = 0$ (nucleo matrice KER)

Ci si può chiedere che dimensione ha questo spazio, questa è la MOLTEPLICITÀ GEOMETRICA dell'autovalore

DEFINIZIONE MOLTEPLICITÀ GEOMETRICA

Sia $\lambda \in \mathbb{C}$ autovalore di $A \in \mathbb{C}^{n \times n}$, si dice molteplicità geometrica la dimensione dell'autospazio relativo a λ, ovvero

$$\gamma(\lambda) = \dim\left(\ker\left(A-\lambda I\right)\right) \quad \leftarrow Av = 0$$

Cioè la dimensione dello spazio delle soluzioni di $(A-\lambda I)v = 0$

"Tale è un pò come dire quanti autovettori linearmente indipendenti sono associati ad λ"

- il ker (nucleo) di $(A-\lambda I)$ è esattamente l'insieme di tutti i vettori v che soddisfano $(A-\lambda I) = 0$, cioè tutti gli autovettori di λ più lo zero. La sua dimensione mi dice quanti autovettori linearmente indipendenti esistono per quel λ.

Proprietà vale sempre $1 \leq \gamma(\lambda) \leq \alpha(\lambda) \leq n$

- $\gamma(\lambda) \geq 1$ perché se λ è autovalore esiste almeno un autovettore per forza
- $\gamma(\lambda) \leq \alpha(\lambda)$ la molteplicità geometrica non supera mai quella algebrica
- $\alpha(\lambda) \leq n$ perché il polinomio caratteristico ha grado n

Per Rouché Capelli $\gamma(\lambda) = n - \text{rango}(A - \lambda I)$, sono il numero di autovettori linearmente indipendenti

Attenzione! Calcolare gli autovalori è costoso, si vuole cercare di ridurre al minimo sforzo, ci si concentra su relazioni fra matrici nei quali non vengano calcolati di fatto gli autovalori

L'idea è che esistono classi di matrici che hanno gli stessi autovalori pur essendo diverse, e studiare queste relazioni ci permette di lavorare con matrici più semplici, senza dover ogni volta risolvere il polinomio caratteristico.

DEFINIZIONE MATRICI SIMILI $A, B \in \mathbb{C}^{n \times n}$ si dicono simili se $\exists S \in \mathbb{C}^{n \times n}$, con $\det(S) \neq 0$ tale che

$$B = S^{-1}AS$$

E si indica con $A \sim B$. (Se conosco gli autovalori di una matrice posso trovarmi quelli dell'altra)

- S è una matrice ($\det(S) \neq 0$ garantisce che S^{-1} esista). L'idea intuitiva è che A e B, rappresentano la stessa trasformazione lineare, ma in due basi diverse. S è il "dizionario" che traduce da una base all'altra.

Se $A \sim B$ allora A e B hanno
- STESSI AUTOVALORI
- STESSO polinomio caratteristico
- stesso determinante
- stessa traccia

dunque se ho una matrice complicata A, posso cercare una matrice simile B più semplice (diagonale ad esempio) e studiare quella sapendo che gli autovalori sono gli stessi.

TEOREMA

$A \sim B \longrightarrow$ A e B hanno gli stessi autovalori, e se v è autovettore di A, allora $S^{-1}v$ è autovettore di B (associato allo stesso autovalore)

DIM L'idea è guardarsi il polinomio caratteristico di B:

$$\det(B-\lambda I) = \det\left(S^{-1}AS - \lambda I\right) =$$
$$= \det(S^{-1}AS - \lambda S^{-1}S) = \det\left(S^{-1}(A-\lambda I)S\right)$$
$$= \det(S^{-1})\cdot\det(A-\lambda I)\cdot\det(S) = \frac{\det(S)}{\det(S)}\cdot\det(A-\lambda I) = \det(A-\lambda I)$$

(per Binet $\det(xy) = \det(x)\det(y)$)

$\longrightarrow$ A e B hanno lo stesso polinomio caratteristico $\longrightarrow$ quindi gli stessi autovalori

DIM PT2, gli autovettori

Sia (λ, v) autocoppia per A, cioè $Av = \lambda v$. Vediamo cosa succede se calcolo $B(S^{-1}v)$
Voglio dimostrare che $S^{-1}v$ è autovettore di B. Per definizione di autovettore dobbiamo verificare che

$$B(S^{-1}v) = \lambda(S^{-1}v)$$

Allora $B(S^{-1}v) = S^{-1}AS(S^{-1}v)$ $\quad B = S^{-1}AS$ per definizione di matrici SIMILI

$$= S^{-1}A(\underbrace{SS^{-1}}_{I})v = S^{-1}Av = S^{-1}(\lambda v) = \lambda S^{-1}v$$

($Av = \lambda v$ v autovettore di A per Hp)

dunque $B(S^{-1}v) = \lambda(S^{-1}v)$. Questa è la definizione di autovettore! Quindi $S^{-1}v$ è autovettore di B, per lo stesso autovalore λ.

dunque queste due matrici sono SIMILI!

Quali sono le matrici che hanno autovalori e autovettori più facili?

Un esempio può essere una matrice diagonale $D = \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix}$ gli autovettori sono i vettori della base CANONICA

$$D\cdot e_1 = \begin{pmatrix} \lambda_1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} = \lambda_1 \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} = \lambda_1 e_1 \quad \text{in generale vale } D\cdot e_i = \lambda_i e_i$$

una matrice diagonale applicata al vettore canonico e_i, restituisce semplicemente λ_i volte e_i, perchè l'unico elemento non zero nella colonna i è proprio λ_i sulla diagonale. Gli autovalori si leggono direttamente dalla diagonale, e gli autovettori sono i vettori canonici $\begin{pmatrix}1\\\vdots\\\cdot\end{pmatrix}$ non c'è nulla da calcolare!

esempio $D = \begin{bmatrix}2&0&0\\0&5&0\\0&0&3\end{bmatrix}$ $\lambda_1 = 2$ $\lambda_2 = 5$ $\lambda_3 = 3$

verificando con i vettori canonici:

e_1 $D \cdot e_1 = \begin{bmatrix}2&0&0\\0&5&0\\0&0&3\end{bmatrix}\begin{pmatrix}1\\0\\0\end{pmatrix} = \begin{pmatrix}2\\0\\0\end{pmatrix} = 2e_1$ ✓

e_2 $D \cdot e_2 = \begin{bmatrix}2&0&0\\0&5&0\\0&0&3\end{bmatrix}\begin{pmatrix}0\\1\\0\end{pmatrix} = \begin{pmatrix}0\\5\\0\end{pmatrix} = 5e_2$ ✓

e_3 $D \cdot e_3 = \begin{bmatrix}2&0&0\\0&5&0\\0&0&3\end{bmatrix}\begin{pmatrix}0\\0\\1\end{pmatrix} = \begin{pmatrix}0\\0\\3\end{pmatrix} = 3e_3$ ✓

Possiamo usare questo, facendo diventare una matrice diagonale con una similitudine! data una matrice qualunque:

DEF - MATRICE DIAGONALIZZABILE Una matrice $A \in \mathbb{C}^{n\times n}$ si dice diagonalizzabile se $\exists S \in \mathbb{C}^{n\times n}$ con $\det(S) \neq 0$ tale che:

$$S^{-1}AS = \begin{pmatrix}\lambda_1 & \cdots & 0\\ \vdots & \ddots & \vdots\\ 0 & \cdots & \lambda_n\end{pmatrix} = \text{diag}(\lambda_1 \dots \lambda_n) = D$$

Diagonalizzare A significa trovare una matrice S invertibile che "cambia base" in modo tale che in quella nuova base la trasformazione diventi una matrice diagonale. Gli elementi sulla diagonale sono gli autovalori di A.

OSS in virtù di quanto detto nel teorema gli n elementi diagonali in $S^{-1}AS$ sono gli autovalori di A, e le colonne di S

$$S = [v_1 | \dots | v_n]$$

sono gli autovettori di A, con v_i associato a λ_i

Attenzione! non tutte le matrici sono diagonalizzabili ad esempio $\begin{bmatrix}\lambda_i & 1 & \cdots & 1\\ 0 & \ddots & \ddots & 1\\ \vdots & & \ddots & \lambda_n\\ 0 & \cdots & 0 & \end{bmatrix}$ non è mai diagonalizzabile!

Esempio $\begin{bmatrix} \lambda & 1 \\ 0 & \lambda \end{bmatrix}$ questa si chiama **Blocco di Jordan** Ha λ ripetuto due volte sulla diagonale principale ($\alpha(\lambda) = 2$) ma ha solo un autovettore indipendente ($\gamma(\lambda) = 1$) poichè $\alpha(\lambda) \neq \beta(\lambda)$ non è mai diagonalizzabile.

Teorema (quando una matrice è diagonalizzabile?)

$A \in \mathbb{C}^{n \times n}$ è diagonalizzabile $\alpha(\lambda) = \gamma(\lambda)$ $\forall \lambda$ autovalore di A

- $\alpha(\lambda)$ mi dice quante volte λ è radice del polinomio caratteristico
- $\gamma(\lambda)$ mi dice quanti autovettori indipendenti esistono per λ
- Se per ogni λ questi due numeri coincidono $\longrightarrow$ ho abbastanza autovettori per formare una base di $\mathbb{C}^n$ $\longrightarrow$ A è diagonalizzabile

Esempio - Blocco di Jordan 4×4

$A = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 1 \end{bmatrix}$ se la matrice è triangolare il determinante è il prodotto della diagonale $\det(A - \lambda I) = (1 - \lambda)^4$

$\lambda_1 = 1$ unico autovalore $\alpha(\lambda) = 4$

Per $\gamma(\lambda) = \dim(\ker(A - \lambda I) = n - \text{rango}(A - \lambda I) = n - \text{rango}(A - \underset{\uparrow}{I})$ "

$\text{rango}(A - I) = \text{rango} \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix} = 3$ (3 righe lin indipendenti, nessuna si può ottenere come combinazione delle altre)

$\gamma(\lambda) = 4 - 3 = 1 \neq \alpha(\lambda) = 4 \longrightarrow$ A non è diagonalizzabile!

OSS 1 Se una matrice ha n autovalori distinti, allora necessariamente

$$\alpha(\lambda_i) = \beta(\lambda_i) = 1 \quad \forall \lambda_i$$

OSS 2 Dire che A è diagonalizzabile significa che posso scegliere $v_1 \dots v_n$ base di $\mathbb{C}^n$, composta da autovettori di A. Ovvero se prendo un vettore qualsiasi $x \in \mathbb{C}^n$, posso scriverlo come $x = \sum_{i=1}^{n} c_i v_i$ dove $c_i \in \mathbb{C}$ (coefficienti)

→ qualsiasi vettore dello spazio si scrive come combinazione lineare dei vettori della base, qui la base è formata da Autovettori. Significa che per capire cosa fa A su qualsiasi vettore x, basta sapere cosa fa A su ciascun autovettore v_i dunque

$$Ax = A\sum_{i=1}^{n} c_i v_i = \sum_{i=1}^{n} c_i A v_i = \sum_{i=1}^{n} c_i \lambda_i v_i$$

esempio se ho $A^{100}x = c_1\lambda_1^{100}v_1 + c_2\lambda_2^{100}v_2 + \dots c_n\lambda_n^{100}v_n$ basta elevare i numeri alla potenza di 100, molto più semplice

La base posso farla ortonormale e unitaria cioè per il

Teorema spettrale:

$A = A^H \iff$ A è diagonalizzabile, ha autovalori reali e si possono prendere autovettori $v_1 \dots v_n$ tali che

$$v_i^H v_j = \begin{cases} 0 & i \neq j \\ 1 & i = j \end{cases} \rightarrow \text{autovettori ortonormali}$$

matrice unitaria, $S^H S = I$

in forma matricide $S^H A S = \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix}$ le colonne di S sono autovettori ortonormali $S = [v_1 | \dots | v_n]$

Matlab

```
A = randn(6)          % crea matrice casuale 6x6

eig(A)                % → restituisce solo gli autovalori

[S, D] = eig(A)       % S = matrice degli autovettori (nelle colonne)
                      % D = matrice diagonale degli autovalori

S * D * inv(S)        % → deve restituire A
```

S = [v1 ... vn]

per $A = S \cdot D \cdot S^{-1}$

Proprietà di autovalori e autovettori

① Traslazione

Se aggiungiamo un multiplo dell'identità ad una matrice, gli autovettori restano gli stessi mentre gli autovalori vengono traslati della stessa quantità

Enunciato: Se (λ, v) è una autocoppia di A, allora $(\lambda+\delta, v)$ è autocoppia per $A+\delta I$ con $\delta \in \mathbb{C}$

DIM $(A+\delta I)v = Av + \delta Iv = \lambda v + \delta v = (\lambda+\delta)v$

② Potenze di una matrice

L'elevamento a potenza di una matrice eleva alla stessa potenza i suoi autovalori

Enunciato: Se (λ, v) è autocoppia per A, allora (λ^k, v) è autocoppia per A^k per ogni $k \in \mathbb{N}$

DIM $A^k v = A^{k-1}(Av) = A^{k-1}(\lambda v) = \lambda A^{k-1} v = \dots = \lambda^k v$

③ Polinomi di matrici

Se applichiamo un polinomio a una matrice, l'autovalore risultante è il polinomio applicato all'autovalore originale

Enunciato: Sia $p(x) = \sum_{j=0}^{d} p_j x^j$ un polinomio. Definiamo $p(A) = \sum_{j=0}^{d} p_j A^j$. Se (λ, v) è autocoppia per A, allora $(p(\lambda), v)$ è autocoppia per $p(A)$

DIM $p(A)v = \left(\sum p_j A^j\right)v = \sum p_j (A^j v) = \sum p_j (\lambda^j v) = \left(\sum p_j \lambda^j\right)v = p(\lambda)v$

! Proprietà aggiuntiva

$\text{rank}(A)$ = n. colonne lin/righe ind = numero autovalori $\lambda \neq 0$

(4) Matrice inversa

Se una matrice è invertibile, allora i suoi autovalori sono gli inversi di quelli della matrice ORIGINALE

Enunciato: Se A è invertibile ($\det(A) \neq 0$) allora (λ, v) è autocoppia per $A \longrightarrow (\lambda^{-1}, v)$ è coppia propria per A^{-1}

DIM $Av = \lambda v \longrightarrow A^{-1}(Av) = A^{-1}(\lambda v) \longrightarrow \underset{Iv = v}{Iv} = \lambda(A^{-1}v) \longrightarrow A^{-1}v = \lambda^{-1}v$

(5) Matrici con stessi autovalori ≠ Matrici Simili

Avere gli stessi autovalori, non garantisce che siano simili.
Se A e B hanno gli stessi autovalori $\not\longrightarrow A \sim B$
Due matrici sono simili solo se hanno la stessa forma canonica di Jordan!

(6) Autovalori complessi e coniugati

Gli autovalori complessi, compaiono sempre in coppie coniugate,
Se un numero complesso è una radice del polinomio caratteristico, allora lo è anche il suo "gemello" con il segno della della parte immaginaria invertito

Enunciato: Sia $A \in \mathbb{R}^{n \times m}$ una matrice a coefficenti reali, se $\lambda \in \mathbb{C}$ è un Autovalore di A, allora anche il suo complesso coniugato $\bar{\lambda}$ è un autovalore di A.

DIM Sia $p_n(\lambda) = \det(A - \lambda I) = (-1)^n \lambda^n + \nabla_1 \lambda^{n-1} + \ldots + \nabla_n$

Perché A è una matrice Reale, i coefficienti sono reali $\nabla_i \in \mathbb{R}$ per ogni $i = 1 \ldots n$

Se $\lambda \in \mathbb{C} \setminus \mathbb{R}$ è autovalore $\longrightarrow p_n(\lambda) = 0$

Consideriamo il complesso coniugato del polinomio

$$\overline{p_n(\lambda)} = \overline{(-1)^n \lambda^n + \sigma_1 \lambda^{n-1} + \dots + \sigma_n = 0}$$

Applicando le proprietà del coniugato

$$(-1)^n \bar{\lambda}^n + \bar{\sigma}_1 \bar{\lambda}^{n-1} + \dots + \bar{\sigma}_n = 0$$

Siccome $\sigma_i \in \mathbb{R} \longrightarrow \bar{\sigma}_i = \sigma_i$ l'espressione diventa

$$(-1)^n \bar{\lambda}^n + \sigma_1 \bar{\lambda}^{n-1} + \dots + \sigma_n = 0$$

Questo per definizione è $p_n(\bar{\lambda})$, in conclusione

$$p_n(\bar{\lambda}) = 0 \longrightarrow \bar{\lambda} \text{ è autovalore di } \lambda$$

DEFINIZIONE RAGGIO SPETTRALE

Sia $A \in \mathbb{C}^{n \times n}$ una matrice quadrata e siano $\lambda_1 \dots \lambda_n$ i suoi autovalori, si definisce raggio spettrale di A, indicato con

$$\rho(A) : \max_{i=1\dots n} |\lambda_i|$$

il raggio spettrale è il modulo dell'autovalore più grande

Proprietà di convergenza

Sia $A \in \mathbb{C}^{n \times n}$, allora

$$\rho(A) < 1 \iff \lim_{k \to +\infty} A^k = 0$$

- Se $\rho(A) < 1$: tutti gli autovalori son piccini, ogni volta che moltiplico per A, i vettori si accorciano, e la matrice si riduce a matrice nulla
- Se $\rho(A) > 1$: c'è almeno un autovalore che "allunga" i vettori. Elevando la matrice a potenze crescenti, i valori degli elementi di A^k, tenderanno a ∞
- se $\rho(A) = 1$ la matrice rimane stabile e i valori oscillano, ma non converge a 0

LEZIONE 5

NORME

in molti casi è necessario definire la grandezza / intensità di un vettore, in termini pratici la norma mi dice quanto è "lungo"

esempio

$x = (3,4)$ $\quad \|x\|_2 = \sqrt{3^2+4^2} = 5$ lunghezza della freccia

Ma come si fa! bisogna considerare queste funzioni chiamate NORME

DEFINIZIONE di NORMA una norma è una funzione $\|\cdot\| : \mathbb{C}^n \to [0, +\infty)$
"Vogliamo definire il concetto di quanto è grande un vettore o la distanza tra due vettori"

Si dice norma, se verifica le seguenti proprietà:

1. L'unico vettore che ha norma pari a 0 è il vettore NULLO!
$\|x\| \longleftrightarrow x = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$ ogni altro vettore ha una norma strettamente positiva

2. se moltiplico un vettore per uno scalare (cambia lunghezza)
$\|\alpha x\| = |\alpha| \cdot \|x\| \quad \forall x \in \mathbb{C}^n, \forall \alpha \in \mathbb{C}$

3. La disuguaglianza triangolare

$$\|x+y\| \leq \|x\| + \|y\| \quad \forall x, y \in \mathbb{C}^n$$

Esempio Si considera spesso la norma EUCLIDEA (norma 2)

$$\|x\|_2 = \sqrt{\sum_{i=1}^{n} |x_i|^2} = \sqrt{\langle x, x \rangle} = \sqrt{x^H x} = \left(\sum |x_i|^2\right)^{1/2}$$

Quali tipi di norme abbiamo?

$\|x\|_1 = \sum_{i=1}^{n} |x_i|$ norma 1, distanza percorsa percorrendo solo orizzontale/verticale

$\|x\|_p = \left(\sum_{i=1}^{n} |x_i|^p\right)^{1/p}$ norma p, al crescere di p il risultato è dominato dalla componente più grande $p \in \mathbb{N}$

$\|x\|_\infty = \max_{i=1\dots n} |x_i|$ norma ∞, valore assoluto massimo fra le componenti

OSS (esempio in $\mathbb{R}^2$) L'insieme dei vettori di norma 1, cambia geometria se si cambia la norma.
Sono tutti vettori $x = (x_1, x_2)$ tali che $\|x\| = 1$

Norma 1

I punti che soddisfano $|x_1| + |x_2| = 1$, formano un rombo con vertici in $(-1,0)$ $(-1,0)$, $(0,1)$, $(0,-1)$

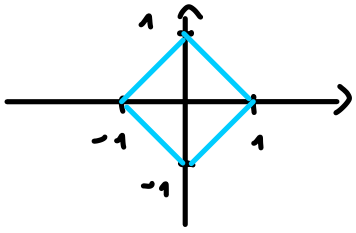

Norma 2

I punti che soddisfano $\|x\|_2 = \sqrt{x_1^2 + x_2^2} = 1$
è sempre un cerchio di raggio 1

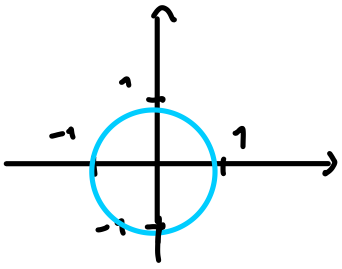

Norma ∞

I punti che soddisfano $\max(|x_1|, |x_2|) = 1$.
Formano un quadrato con lati a distanza 1 dagli assi

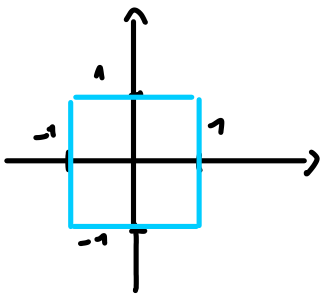

Dunque in generale in $\mathbb{R}^2$

- $\|x\|_1 = c$ è un rombo scalato di c
- $\|x\|_2 = c$ è un cerchio di raggio c
- $\|x\|_\infty = c$ è un quadrato scalato di c

DEFINIZIONE NORME EQUIVALENTI

Due norme $\|\cdot\|_p, \|\cdot\|_q$ su $\mathbb{C}^n$ si dicono equivalenti se $\exists\, \alpha, \beta \in \mathbb{R}^+$ tali che

$$* \quad \alpha\|x\|_p \leq \|x\|_q \leq \beta\|x\|_p \quad \forall x \in \mathbb{C}^n$$

Se vale $*$ vale anche

$$\beta^{-1}\|x\|_q \leq \|x\|_p \leq \alpha^{-1}\|x\|_q$$

Due norme sono equivalenti se una è sempre "schiacciata" tra due multipli dell'altra. Cioè non possono mai differire di troppo, sono confrontabili!

Per le norme più comuni valgono

- $\|x\|_\infty \leq \|x\|_1 \leq n\|x\|_\infty$
- $\|x\|_\infty \leq \|x\|_2 \leq \sqrt{n}\|x\|_\infty$
- $\|x\|_2 \leq \|x\|_1 \leq \sqrt{n}\|x\|_2$

(disuguaglianza cauchy schwartz)

Proviamo ad estendere questo concetto alle matrici

DEFINIZIONE di NORMA MATRICIALE

Si dice NORMA MATRICIALE una funzione $\|\cdot\| : \mathbb{C}^{m \times n} \longrightarrow [0, +\infty)$ (righe, colonne (non necessariamente uguali)) tale che rispetti le seguenti PROPRIETÀ

1. $\|A\| = 0 \iff A = \begin{bmatrix} 0 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 0 \end{bmatrix}$

2. $\|\alpha A\| = |\alpha| \cdot \|A\|$ $\quad \alpha \in \mathbb{C}$

3. $\|A+B\| \leq \|A\| + \|B\|$

4. (nel caso $m = n$ di matrici quadrate) $\|A \cdot B\| \leq \|A\| \cdot \|B\|$

D'ora in poi consideriamo sempre il caso $m = n$

Cosa succede quando una norma matricide viene ricavata da una vettoride? si ha una norma indotta!

DEFINIZIONE norma matricide

Una matricide $\|\cdot\|_m$ si dice indotta (o naturale) se esiste $\exists$ una norma vettoride $\|\cdot\|_v$ se è definita come

$$\|A\|_m = \sup_{x \neq 0} \frac{\|Ax\|_v}{\|x\|_v} = \sup_{\|x\|_v = 1} \|Ax\|_v$$

estremo superiore al variare dei vettori $\neq 0$

sopra applico la matrice A al vettore x, ho un vettore, applico la norma vettoride e divido per la norma di x

"preso un vettore quanto applicarci la matrice A amplifica la sua norma o la diminuisce?"

ESEMPIO Preso $A = \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix}$ e usiamo la norma vettoride $\|\cdot\|_2$, voglio trovare il massimo allungamento che A può fare su un vettore unitario x con $\|x\|_2 = 1$

Ogni vettore unitario si scrive come $x = (\cos\theta, \sin\theta)$ (cerchio)

$$Ax = \begin{pmatrix} 2\cos\theta \\ 3\sin\theta \end{pmatrix} \qquad \|Ax\|_2 = \sqrt{4\cos^2\theta + 9\sin^2\theta}$$

il massimo si raggiunge per $\theta = 90°$ cioè $x = (0, 1)$

$$\|Ax\|_2 = \sqrt{0 + 9} = 3$$

$\|A\|_m = 3$ è il massimo allungamento che posso dare al vettore

Nel caso delle norme 1, 2 e ∞ le norme indotte sono:

- $\|A\|_1 = \max_j \sum_{i=1}^{n} |a_{ij}|$ ← massimo della somma sulle colonne

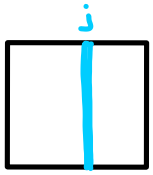

- $\|A\|_\infty = \max_i \sum_{j=1}^{n} |a_{ij}|$ ← massimo della somma sulle righe

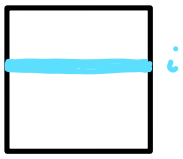

- $\|A\|_2 = \sqrt{\rho(A^*A)} = \sqrt{\max|\lambda|}$ ← max λ autovalore di A^*A
  ↑ raggio spettrale (nel caso reale A^TA)

$\|\cdot\|_2$ è la più ostica da calcolare, perché richiede gli autovalori A^*A

Quali sono i costi?
$\|A\|_1$ e $\|A\|_\infty$ richiedono $O(n^2)$ operazioni

Esempio di norma non indotta $\|A\|_F = \sqrt{\sum_{i,j=1}^{n} |a_{ij}|^2}$ ← norma Frobenius!

Perché non è indotta da nessuna norma vettoriale?
Possiamo guardare che se facciamo la norma di Frobenius della matrice identità $\|I\|_F = \sqrt{n} \neq 1$
Mentre per ogni norma indotta $\|I\| = 1$ perché:

$$\|I\| = \sup_{x \neq 0} \frac{\|I \cdot x\|}{\|x\|} = \sup_{x \neq 0} \frac{\|x\|}{\|x\|} = 1$$

Conclusione, la norma di Frobenius non è una norma indotta poiché $\|I\|_F \neq 1$, mentre ogni norma indotta $\|I\| = 1$!

Un'altra proprietà interessante soprattutto quando si parla di conti e stime è capire come si comportano le norme matriciali con quelle vettoriali quando si guarda PRODOTTI matrice vettore.
(Ad esempio vorrei separare quando ho Ax la norma sulla matrice e la norma sul vettore) ⟶ quando ciò si può fare si parla di NORME COMPATIBILI

DEFINIZIONE NORME COMPATIBILI

Una norma matriciale si dice compatibile con una norma vettoriale $\|\cdot\|_v$ se si ha che

$$\|A \cdot x\|_v \leq \|A\|_m \cdot \|x\|_v$$

($\|A \cdot x\|_v$: risultato vettore; $\|A\|_m$: norma matriciale di A; $\|x\|_v$: norma vettoriale di x)

La norma di A rappresenta il massimo allungamento che A può fare su un vettore. Quindi è naturale che l'allungamento effettivo $\|Ax\|_v$ non superi mai quel massimo moltiplicato per la lunghezza di x

Questa proprietà vale sempre per le NORME INDOTTE!!!

OSS le norme indotte sono sempre compatibili con le rispettive norme vettoriali poichè:

$$\frac{\|Ax\|_v}{\|x\|_v} \leq \|A\|_m \quad \text{(≤ per come è definita la norma indotta)} \quad \text{e allora} \longrightarrow \|Ax\|_v \leq \|A\|_m \cdot \|x\|_v$$

RELAZIONI TRA $\|A\|$ E AUTOVALORI DI A

Diciamo che gli autovalori sono delle quantità che sono difficili da calcolare, dunque se riusciamo a dire cose prima per una matrice queste info ci possono risultare utili

↳ Se ho una norma COMPATIBILE con la norma VETTORIALE, allora posso affermare che la norma maggiore in MODULO TUTTI gli AUTOVALORI $\|A\|_m$ è più grande del modulo di ogni autovalore (più grande del raggio spettrale)

DIM Supponiamo (λ, x) AUTOCOPPIA per A (autovalore autovettore)

$$\|\lambda x\|_v \overset{\text{per definizione}}{=} \|Ax\|_v \overset{(*)}{\leq} \|A\|_m \cdot \|x\|_v$$

$\|\cdot\|$ per le proprietà delle norme: $|\lambda| \cdot \|x\|_v$

$(*)$ perchè $\|\cdot\|_m$ è compatibile con $\|\cdot\|_v$

Avendo questa catena di disuguaglianze posso dividere $\|x\|_v$ in quanto quantità $\neq 0$, perchè x è autovettore e questi non sono mai zero!

$$\longrightarrow \|A\|_m \geq |\lambda| \quad \forall \lambda \text{ autovalore di } A$$

Vale per norme compatibili ($2, 1, \infty$ ad esempio) ma potrebbe non valere per la norma di Frobenius in quanto non indotta

Questo risultato prende il nome di Teorema di Hirsch

Teorema di Hirsch Se $A \in \mathbb{C}^{n \times n}$ (quadrata) allora $\forall \|\cdot\|_m$ (ind. dal fatto che sia indotta a altro), vale la maggiorazione

$$\|A\|_m \geq \rho(A) = \max_{\lambda \text{ autovalori di } A} |\lambda| \qquad \rho \in \mathbb{R}, \ \rho \geq 0$$

(raggio spettrale)

DIM Consideriamo (λ, x) autocoppia di A, e consideriamo una matrice B

$$B = \begin{bmatrix} x & \begin{matrix} 0 \\ \vdots \\ 0 \end{matrix} & \cdots & \begin{matrix} 0 \\ \vdots \\ 0 \end{matrix} \end{bmatrix}$$

quasi 0 tranne su una colonna che ha l'autovettore x

Consideriamo $A \cdot B$ guardato per colonne

$$A \cdot B = \begin{bmatrix} Ax & A\begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix} & \cdots & A\begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix} \end{bmatrix} = \begin{bmatrix} Ax & 0 & \cdots & 0 \end{bmatrix} =$$

$$= \left[\lambda x \,\middle|\, \begin{matrix}0\\ \vdots \\ 0\end{matrix} \,\middle|\, \cdots \,\middle|\, \begin{matrix}0\\ \vdots \\ 0\end{matrix}\right] \overset{\text{scalare}}{=} \lambda \left[x \,\middle|\, \begin{matrix}0\\ \vdots \\ 0\end{matrix} \,\middle|\, \cdots \,\middle|\, \begin{matrix}0\\ \vdots \\ 0\end{matrix}\right] = \lambda B$$

dunque possondo dle norme

$\|A\|\|B\| \geq \|AB\| = \|\lambda B\| = |\lambda|\|B\|$ a questo punto divido per $\|B\|$

(proprietà n delle norme)

che non è zero poiche la prima colonna aveva un autovettore che non sono mai zero. E si ottiene

$$\|A\| \geq |\lambda|$$

OSS Se guardiamo in moniera geometrica gli autovalori e guardiamo il piano in parte reale ed immaginaria
Gli autovalori sono numeri complessi, quindi si possono rappresentare con parte reale(λ) e parte immaginaria(y)

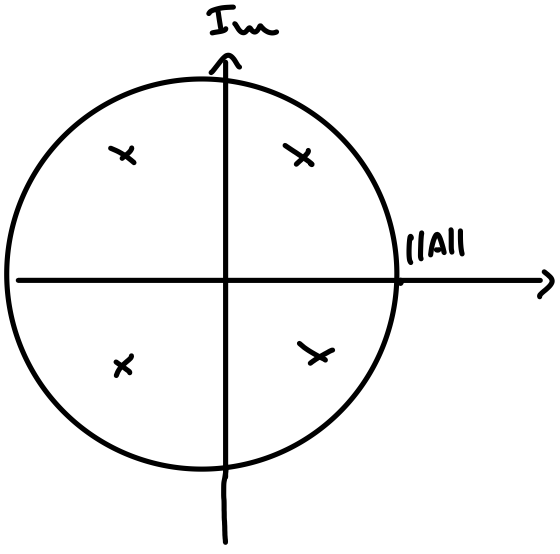

Gli Autovalori di A, sono contenuti in un cerchio che è centrato nell'origine e ha come raggio la norma di A ($\|A\| \geq |\lambda|$)
(nel piano complesso l'insieme di numeri complessi con modulo $\leq r$ è per definizione un cerchio di raggio r)

Se $\|A\| < 1$ per una qualsiasi NORMA MATRICIALE $\longrightarrow$ A è convergente
($\lim_{n\to+\infty} A^k = 0$, $\rho(A) < 1$)

Questa proprietà è sufficiente ma non necessaria!!!

$\rho(A) < 1 \not\Longrightarrow \|A\| < 1$ $\qquad$ $\|A\| > 1 \not\Longrightarrow \rho(A) > 1$

dunque il teorema di Hirsh ci dice che

$$\{\text{AUTOVALORI}\} \subset \{z \in \mathbb{C} : |z| \leq \|A\|\}$$

(cerchio)

Questa però è una STIMA, ci sono dei risultati, i cosi detti teoremi di localizzazione degli AUTOVALORI, che permettono di descrivere delle zone del piano complesso più accurate della stima $|\lambda_i| \leq \|A\|$
Questi Teoremi si chiamano

Teorema di Gershgorin

L'idea è studiare zone del piano complesso, che ci dicono approssimativamente dove si trovano gli autovalori della matrice A

Prima definiamo cosa sono i CERCHI di GERSHGORIN

DEFINIZIONE CERCHI di GERSHGORIN

$A \in \mathbb{C}^{n \times n}$ (quadrata) e definiamo gli insiemi:

è un cerchio ma con centro e raggio differente

$$\mathcal{T}_i(A) = \{\underbrace{z}_{\text{elementi del cerchio}} \in \mathbb{C} : \underbrace{|z - a_{ii}|}_{\text{distanza del centro dove il centro è l'elemento } a_{ii}, \text{ che è un elemento della diagonale}} \leq \underbrace{\rho_i}_{\text{raggio}}\}$$

è come dire tutti i punti z che distano al massimo ρ_i dal centro a_{ii}

dove $\rho_i = \sum_{\substack{j=1 \\ j \neq i}}^{n} |a_{ij}|$

somma dei moduli degli elementi non diagonali della riga i

$\mathcal{T}_i(A)$ viene detto cerchio di GERSHGORIN associato alla riga i di A.

esempio

$$\begin{bmatrix} * & * & * \\ -1 & 1 & i \\ * & * & * \end{bmatrix} = A$$

vediamo chi è $\mathcal{T}_2(A)$ cerchio associato alla riga 2

- ha centro 1 (a_{22})
- raggio $\rho_2 = |-1| + |i| = 2$

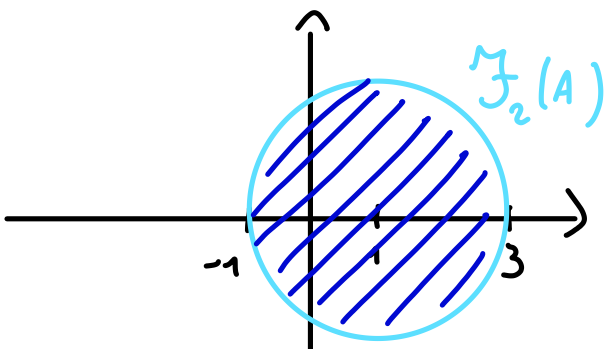

TEOREMA (1ª TEOREMA DI GERSHGORIN)

il teorema dice che tutti gli autovalori di A, non stanno in un singolo cerchio di Gershgorin ma nell'unione di TUTTI i cerchi di Gershgorin

$$\lambda \text{ autovalore di } A \Rightarrow \lambda \in \bigcup_{i=1}^{n} \mathcal{F}_i(A)$$

(su tutte le possibili righe)

(ogni autovalore sta in un cerchio non si ripete come pensavi!)

Si ovranno dunque un certo numero di cerchi nel piano complesso e nella parte interna di questi cerchi ci saranno gli autovalori, una regione più dettagliata rispetto a quella del teorema di Hirsh che ci da un cerchio solo con centro 0 e raggio $\|A\| \longrightarrow$ STIMA più accurata

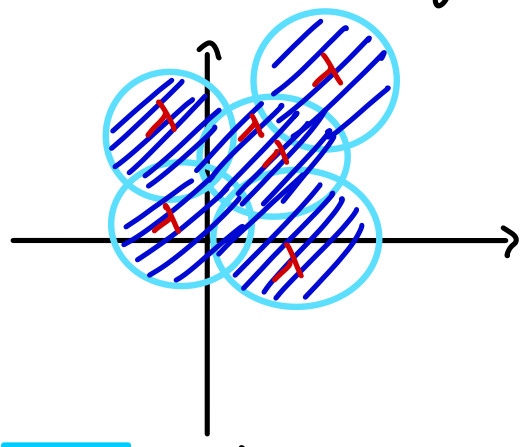

DIM Prendiamo un autocoppia per A (λ, x). L'idea è quella di far vedere che si trova in un preciso cerchio di Gershgorin.

↳ for vedere che c'è un cerchio $\mathcal{F}_K(A)$ per uno specifico K, tale che $\lambda \in \mathcal{F}_K(A)$, per cui se sta in un cerchio sta nell'unione di tutti!

Come scelgo K? Sia K l'entrata di autovettore x con modulo massimo

$$x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_K \\ x_n \end{bmatrix}$$

si ha che è l'entrata più grande in modulo ovvero verifica

$$|x_K| \geq |x_i| \quad \forall i = 1 \dots n$$

Quello che si deve far vedere è che sicuramente λ, sta nel cerchio K-esimo, ovvero associato alla riga K della matrice

Come si fa a vedere? Consideriamo la riga k-esima della relazione $Ax = \lambda x$, questo ci da:

$$a_{k1} \cdot x_1 + a_{k2} \cdot x_2 + \dots + a_{kn} x_n = \lambda \cdot x_k$$

$$\sum_{j=1}^{n} a_{kj} x_j = \lambda x_k \iff \sum_{\substack{j=1 \\ j \neq k}}^{n} a_{kj} x_j = \lambda x_k - a_{kk} x_k = (\lambda - a_{kk}) x_k$$

porto a destra dell'= l'elemento $j=k$

possiamo ai moduli ⟶ $\left| \sum_{\substack{j=1 \\ j \neq k}}^{n} a_{kj} x_j \right|$ (il modulo di un $\cdot$ è uguale a $\cdot$ dei moduli) $= |\lambda - a_{kk}||x_k|$

(Dis. Tri il modulo della somma è $\leq$ della somma dei moduli)

$$\longrightarrow \sum_{\substack{j=1 \\ j \neq k}}^{n} |a_{kj}||x_j| \geq |\lambda - a_{kk}||x_k|$$

perché è qualcosa di più grande di quello scritto sopra.

Adesso voglio dividere per x_k, questa è zero? no, posso fare la divisione perché x_k è il massimo delle componenti di x, e questo è un autovettore che è sempre $\neq 0$

$$\longrightarrow \sum_{\substack{j=1 \\ j \neq k}}^{n} |a_{kj}| \left| \frac{x_j}{x_k} \right| \geq |\lambda - a_{kk}|$$

x_k è sempre $>$ di x_j dunque al massimo è 1 ≤ 1

$$\longrightarrow \sum_{\substack{j=1 \\ j \neq k}}^{n} |a_{kj}| \geq |\lambda - a_{kk}| \longrightarrow \lambda \in \mathcal{J}_k(A)$$

$\mathcal{J}_k$ definizione raggio cerchio di gershgorin

Questa ultima cosa che abbiamo trovato è una cosa ancora più specifica di quello che dice il teorema, il teorema dice che λ sta nell'unione dei cerchi, mentre qui $\lambda \in \mathcal{J}_k(A)$, un cerchio specifico una stima migliore

Però perché il teorema dunque non dice λ_i sta in questo cerchio K_i di Gershgorin?

Perché non è plausibile che noi conosciamo K_i nella pratica, non conosciamo né l'autovalore né l'autovettore! Altrimenti se conoscessimo l'autovettore trovare l'autovalore sarebbe banale.

DEFINIZIONE PREDOMINANZA DIAGONALE FORTE

Consideriamo matrici che hanno elementi abbastanza grandi sulla diagonale
$A \in \mathbb{C}^{n \times n}$ si dice a predominanza diagonale forte se per ogni elemento della diagonale, l'elemento in modulo è maggiore di tutti gli altri sulla stessa riga

$$|a_{ii}| > \sum_{\substack{j=1 \\ j \neq i}}^{n} |a_{ij}|$$

Corollario (dal primo teorema di Gershgorin)

A a predominanza diagonale forte $\longrightarrow$ A è invertibile

DIM Per il 1° Teorema di Gershgorin i cerchi $\mathcal{T}_i(A)$ sono tali per cui il raggio è minore della distanza del centro da 0. In particolare
$0 \notin \cup \mathcal{T}_i(A) \Rightarrow 0$ non può essere autovalore $\Rightarrow \det(A) \neq 0 \Rightarrow A$ invert.
(fatto per questo Corollario)

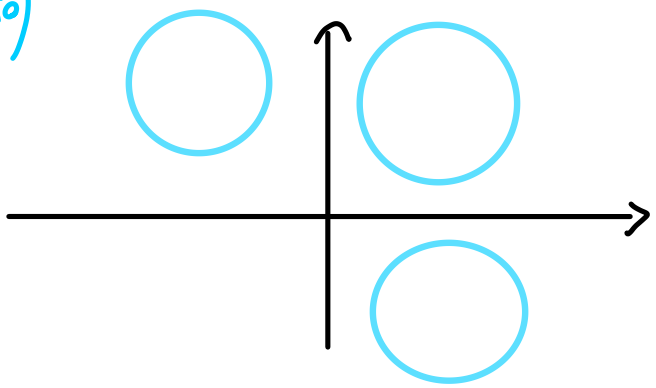

Teorema (2° Teorema di Gershgorin)

Se M_1 è unione di s cerchi di Gershgorin ed M_2 è unione dei restanti $n-s$, e si ha che $M_1 \cap M_2 = \emptyset$ (non si toccano) $\Rightarrow$ M_1 contiene esattamente s autovalori, e M_2 esattamente $n-s$

esempio

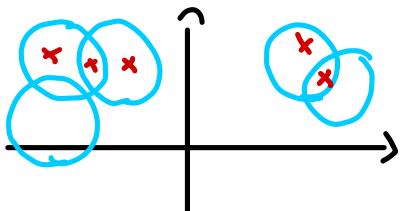

Attenzione! Può succedere che un cerchio non abbia autovalori al suo interno, ma solo se è intersecato con altri, se un cerchio è isolato ha per forza un autovalore

Proprietà derivanti dal teorema

- Se A ha n cerchi disgiunti ⟶ A ha n autovalori distinti
  ⟶ A è diagonalizzabile
- $A \in \mathbb{R}^{n \times n}$, se A ha un cerchio isolato, allora l'autovalore in esso contenuto è sicuramente reale

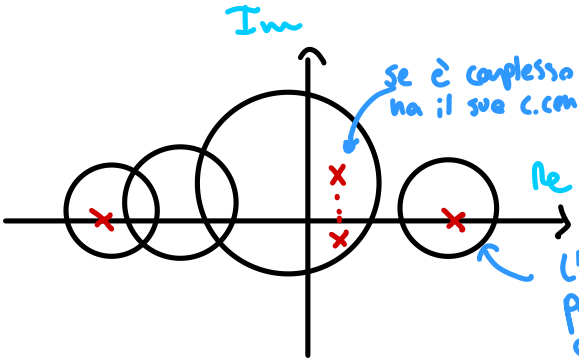

Se A è una matrice reale ha tutti i cerchi centrati sull'asse x

L'autovalore che sta qui deve essere per forza reale poiché se fosse complesso dovrebbe avere anche il suo complesso coniugato e questo viola il 2° teorema di Gershgorin.

M_1 3 cerchi 3 aut!

M_2 1 cerchio 1 aut!

Matlab

- Per fare la norma = norm(x) (norma 2), norm(x,1) (norma 1), norm(x,inf) (norma infinito)
  Identica la sintassi per le matrici.
- Comando PLOT(x, y, '.....')
  x: vettore ascisse stessa lunghezza; y: vettore ordinate; stile: vettori

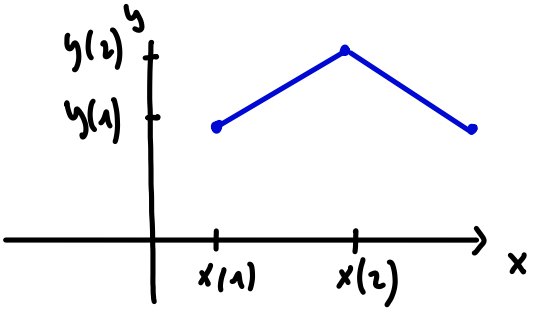

Prende i punti e li unisce, con quello che si è definito nello stile, "o" unisce i punti con delle linee e dei cerchi

Non è necessario che sia una funzione, posso anche disegnare delle figure

esempio Per mostrare il grafico di $\sin(x)$ si può fare $x \in [-5, 10\pi]$

```
% genero un pò di punti fra [-5, 10π]
v = linspace(-5, 10π, 1e4);  % 10.000 punti equispaziati in [-5, 10π]
y = sin(v)  % applica la funzione sin(x) a tutti gli elementi di v
plot(v, y, 'g')   % 'g' = linea solida
```

- Per disegnare un cerchio

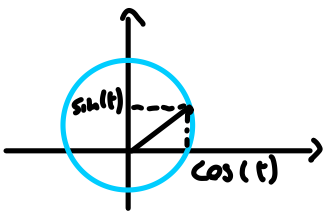

$(\cos(t), \sin(t))$ $t \in [0, 2\pi]$ sono i punti sulla circonferenza di centro 0 e raggio 1. Se voglio un centro generico (x_0, y_0) $(\neq (0,0))$ e raggio r posso considerare i punti $(x_0 + r\cos(t), y_0 + r\sin(t))$ $t \in [0, 2\pi]$

```
t = linspace(0, 2*pi, 1E3)   crea punti
v = x0 + r * cos(t)          crea vettore
y = y0 + r * sin(t)          crea vettore
plot(v, y, 'r')
```

```
end
function circle(c, r, col)
    t = linspace(0, 2*pi, 1000);
    x = r * cos(t);
    y = r * sin(t);
    patch(real(c) + x, imag(c) + y, col, 'EdgeColor', col);
end
```

```
function disegna_gersh(A)
close
% funzione che disegna i cerchi di Gershgorin di una matrice
    n = size(A, 1); numero righe di A
    c = diag(A); % vettore contenente i centri
    r = abs(A - diag(c)) * ones(n, 1); % vettore contenente i raggi
    figure

    hold on
    for j = 1:n
        circle(c(j), r(j), 'b');
    end
    alpha(0.15);
    l = eig(A);
    pp = plot(real(l), imag(l), 'rx', real(c), imag(c), 'ko');
    axis equal;
    legend(pp, 'autovalori', 'centri');

end
```

Evitare i cicli for/while

Matlab è un linguaggio interpretato, non compilato, ogni operazione ha un costo, dunque evitare l'utilizzo di cicli for e while se si possono scrivere le operazioni in forma vettoriale, dunque evito i loop quando possibile, perché aumenta i costi. Meglio su vettori che su matrici

ESEMPIO - CALCOLARE i cerchi di Gershgorin (senza For)

Per ottenere i centri potrei scrivere $C = diag(A) = \begin{bmatrix} a_1 \\ \vdots \\ a_m \end{bmatrix}$ vettore centri

Togliamo adesso la diagonale da A

$$B = A - \underbrace{diag(diag(A))}_{\text{matrice}} = \begin{bmatrix} 0 & a_{12} & \cdots & a_{1n} \\ a_{21} & \ddots & & \vdots \\ \vdots & & \ddots & \\ a_{m1} & \cdots & & 0 \end{bmatrix}$$

vettore

$$\rho_i = \sum_{\substack{j=1 \\ i \neq j}}^{n} |a_{ij}|$$

somma dei moduli degli elementi non diagonali della riga i

Per definizione di raggio, prima di sommare facciamo i valori assoluti degli elementi fuori della diagonale

$$C = ABS(B) = \begin{bmatrix} 0 & |a_{12}| & \cdots & |a_{1n}| \\ |a_{21}| & \ddots & & \vdots \\ \vdots & & \ddots & \\ |a_{m1}| & \cdots & & 0 \end{bmatrix}$$

Come si fa per sommare tutti gli elementi sulle righe?

OPZIONE 1

```
C * ones(n,1);
```

Siccome matrice * vettore restituisce un vettore, moltiplico ogni riga per un vettore di tutti uni, e ogni volta ovvio una somma per elemento come da *

$$\begin{bmatrix} a & \cdots \\ \vdots & \ddots \end{bmatrix} \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} = \begin{bmatrix} a_{11}+a_{12}+a_{13} \\ \vdots \end{bmatrix} = \text{Raggi} = \begin{bmatrix} \rho_1 \\ \vdots \\ \rho_n \end{bmatrix}$$

OPZIONE 2

```
R = SUM(C,2);
```

righe

Somma le righe di C, restituisce un vettore colonna

L'ultima lezione s'è visto

1 teorema di Gershgorin

λ autovalore $\longrightarrow$ $\lambda \in \bigcup \mathcal{F}_i(A)$

$\mathcal{F}_i(A) = \{ z \in \mathbb{C} : |z - a_{ii}| < \sum_{\substack{j=1 \\ j \neq i}}^{n} |a_{ij}| \}$

2 Teorema di Gershgorin se $M_1 = \bigcup_{i=1}^{s} \mathcal{F}_i(A)$ $M_2 = \bigcup_{i=s+1}^{n} \mathcal{F}_i(A)$ e $M_1 \cap M_2 = \emptyset$ allora M_1 contiene esattamente n autovalori, M_2 ne ha $n-s$

Abbiamo costruito i cerchi con centri gli elementi sulla diagonale e raggi la somma dei moduli degli elementi di riga, perché proprio le righe e non le colonne?

OSS Posso farlo anche guardando le colonne! Invece di guardare A guardo A^T!

Dato che A e A^T hanno gli stessi autovalori posso applicare il primo teorema su A^T, e ottenere un nuovo insieme $\bigcup_{i=1}^{n} \mathcal{G}_i(A^T)$ dove si hanno stessi centri di prima ma raggi potenzialmente diversi, perché si guarda la somma sulle colonne

$$\mathcal{G}_i(A^T) = \{ z \in \mathbb{C} : |z - a_{ii}| < \sum_{\substack{j=1 \\ j \neq i}}^{n} |a_{ji}| \}$$

λ è autovalore di A $\longrightarrow$ $\lambda \in \bigcup \mathcal{F}_i(A)$ e $\lambda \in \bigcup \mathcal{G}_i(A^T)$

$\longrightarrow \lambda \in \left[\bigcup_{i=1} \mathcal{F}_i(A)\right] \cap \left[\bigcup_{i=1} \mathcal{G}_i(A)\right]$

Dunque potenzialmente questa cosa qui mi da un'insieme più piccolo

Esempio: Supponiamo di avere i seguenti cerchi di Gershgorin

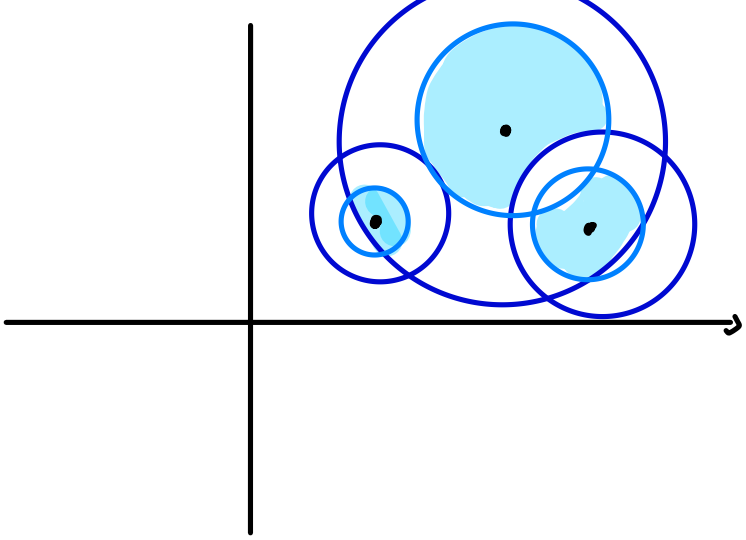

Cerchi relativi ad A

Cerchi relativi ad A^T

Se guardo alle aree di intersezione, avrò aree più ridotte e dunque una stima più accurata

Prima di passare al terzo teorema di Gershgorin, vogliamo definire cosa è il GRAFO DI UNA MATRICE

DEF GRAFO DI UNA MATRICE data una matrice $A \in \mathbb{C}^{n \times n}$ si chiama grafo associato ad A il grafo $G(A) = V, E$ (insieme di vertici e archi), in cui l'insieme dei vertici è l'insieme $V = \{1 \dots n\}$ e invece l'insieme degli archi E è definito dalla relazione

$$(i,j) \in E \iff a_{ij} \neq 0$$

Esempio

$$A = \begin{bmatrix} 1 & 4 & 7 \\ 2 & 5 & 8 \\ 3 & 6 & 9 \end{bmatrix} \Rightarrow G(A) =$$

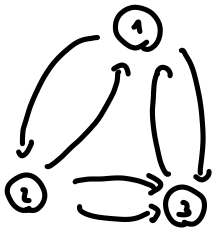

$V = \{1 \dots\}$

$(1,2)$ $(2,1) \in E$

$$A = \begin{bmatrix} 1 & 0 & 1 \\ -1 & -1 & 1 \\ 0 & 0 & 2 \end{bmatrix} \Rightarrow G(A) =$$

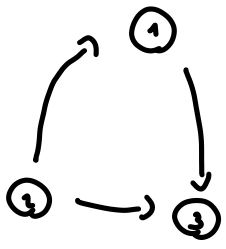

Dunque diciamo che "tiene conto" dove sono gli elementi diversi da zero in una matrice, adesso vediamo perché è rilevante nel contesto di Gershgorin

DEF FORTEMENTE CONNESSO

dato un grafo orientato (V, E) si dice FORTEMENTE CONNESSO se (partendo da un qualsiosi vertice, posso arrivare ad un altro vertice) $\forall$ coppia di vertici (N_i, N_J) esiste un percorso orientato che va da N_i a N_J

Esempio

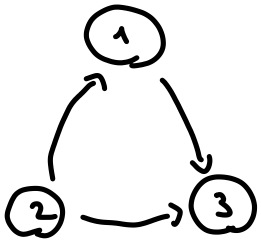

questo grafo non è FORTEMENTE CONNESSO, poichè non posso andare da 3 a 2! Oppure da 3 a 1 o da 1 a 2.

DEF matrice IRRIDUCIBILE

Una matrice $A \in \mathbb{C}^{n \times n}$ si dice IRRIDUCIBILE, se il $G(A)$ (grafo associato ad A) è fortemente connesso.

Dunque l'idea è che in una matrice, ci possono essere degli 0, ma non troppi, più zeri ci sono più probdile che non sia fortemente connesso dunque riducibile

TEOREMA (III° di Gershgorin)

Più che dirci dove si troveranno gli autovalori, mi permette di escludere, Quali valori, non sono autovalori di una MATRICE

Se $A \in \mathbb{C}^{n \times n}$ irriducibile e $\lambda \in \mathbb{C}$ autovalore per A, allora:

Se $\lambda \in \partial\left(\bigcup_{i=1}^{n} \mathcal{F}_i(A)\right)$ se e soltanto se $\Longleftrightarrow \bigcap_{i=1}^{n} \partial \mathcal{F}_i(A)$

$\lambda \in \partial\left(\bigcup_{i=1}^{n} \mathcal{F}_i(A)\right)$: bordo dell'unione dei cerchi di Gershgorin

$\bigcap_{i=1}^{n} \partial \mathcal{F}_i(A)$: sto nell'intersezione del bordo di ogni singolo cerchio

Dunque se sta sul bordo dell'unione, deve stare sull'intersezione del bordo di tutti i cerchi

Esempio $n=3$, A irriducibile $\longrightarrow$ 3 cerchi di Gershgorin

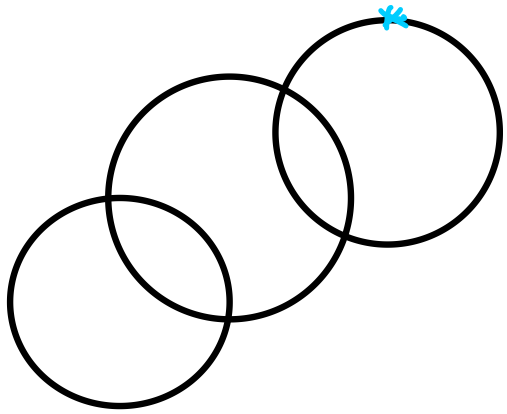

* Può essere autovalore?

Sta sul bordo dell'unione, ma non sta sul bordo del terzo e del secondo. Ma nessun punto dei bordi è un autovalore perché non sta sul bordo dei tre cerchi contemporaneamente

Se abbiamo una situazione dove si toccano tutti

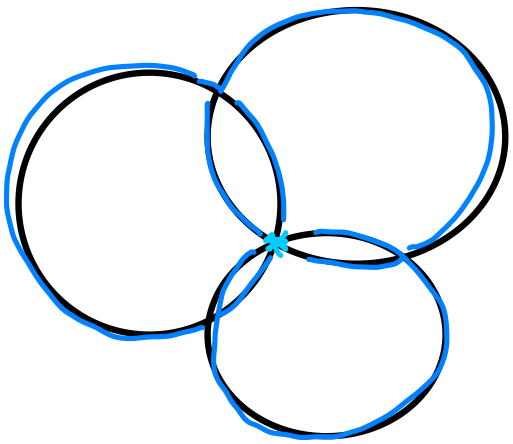

* è autovalore?

Sì, può essere autovalore! Perché sta sul bordo di tutti e 3

Dunque questo teorema più che identificare gli autovalori, mi serve ad escluderli! Tipo tutti i punti —— evidenziati il teorema mi dice che non sono autovalori, stanno sulla frontiera dell'unione ma non dell'intersezione di tutti.

Questo risultato mi aiuta a dire, ad esempio che una matrice sia singolare ovvero che abbia $\det = 0$, ovvero che lo zero sia un'autovalore della matrice

DEF PREDOMINANZA diagonale debole

Una matrice $A \in \mathbb{C}^{n\times n}$ si dice **A PREDOMINANZA DIAGONALE DEBOLE**, se vale

$$|a_{jj}| \geq \sum_{\substack{i=1 \\ i\neq j}}^{n} |a_{ji}|$$

ed esiste almeno un indice $k \in \{1 \dots n\}$ tale che

$$|a_{kk}| > \sum_{\substack{i=1 \\ i\neq k}}^{n} |a_{ki}|$$

Se una matrice **PREDOMINANZA DIAGONALE FORTE** $\Rightarrow$ **PREDOMINANZA diagonale debole**, ma non viceversa.

↳ il primo teorema di Gershgorin ci consentiva di dire che le matrici a predominanza diagonale forte hanno sicuramente $\det(A) \neq 0$, dunque invertibili.

Corollario data $A \in \mathbb{C}^{n\times n}$ IRRIDUCIBILE e a predominanza diagonale debole allora A è invertibile $\Rightarrow$ A non singolare $\Rightarrow \det(A) \neq 0$

DIM Se per assurdo 0 fosse autovalore di A, allora 0 apparterrebbe al bordo dell'unione dei cerchi di Gershgorin.
Tuttavia $0 \notin \partial \mathcal{T}_k(A)$ (dove k è l'indice per cui vale $|a_{kk}| > \sum_{\substack{i=1 \\ i\neq k}}^{n} |a_{ki}|$)
$\Rightarrow$ il fatto che 0 sia autovalore viola il secondo teorema
e quindi assurdo $*$.

Esempio La matrice $A = \begin{bmatrix} 2 & -1 & & & \\ -1 & 2 & -1 & & \\ & -1 & 2 & \ddots & \\ & & \ddots & \ddots & -1 \\ & & & -1 & 2 \end{bmatrix} \in \mathbb{R}^{n\times n}$

Per qualsiasi $n \in \mathbb{N}$, il grafo associato A è:

$G(A)$ è fortemente connessa, ovvero A è irriducibile
A è a predominanza diagonale debole perchè

$$j \in [2, n-1] \qquad 2 = a_{jj} = |a_{jj-1}| + |a_{jj+1}| = |-1| + |-1| = 2$$

e se $j = [1, n]$ $\qquad 2 = |a_{jj}| > |a_{jj-1}| + |a_{j-1\,j}| = 1$

questo dimostra la predominanza diagonale debole + irriducibile

$\Rightarrow$ A è non singolare (invertibile) $\forall n \in \mathbb{N}$

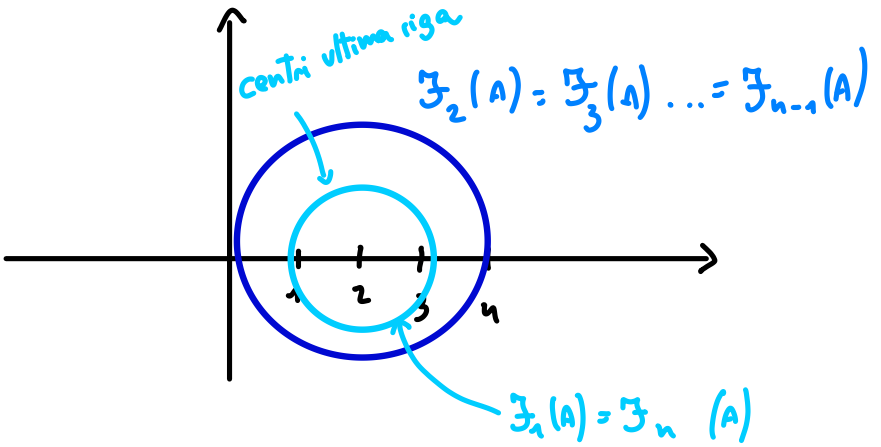

Dunque se 0 fosse un autovalore starebbe sulla frontiera di tutti i cerchi, ma qui sta solo sulla frontiera dei cerchi $[2, n-1]$ e non di $[1, n]$. Q non può essere autovalore $\det(A) \neq 0 \rightarrow$ invertibile

Esercizio d'esame

(i) [4 Punti] Sia $A \in \mathbb{C}^{4\times 4}$ e si considerino i tre grafici qua sotto come possibili configurazioni dei cerchi di Gershgorin e degli autovalori della matrice A (sull'asse delle x ci sono le parti reali mentre sull'asse delle y le parti immaginarie). Per ognuna di tali configurazioni dire se è ammissibile o non ammissibile; nel caso di non ammissibilità giustificare la risposta.

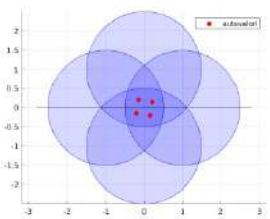

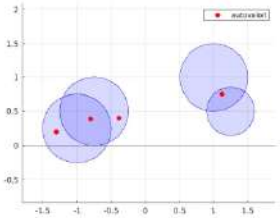

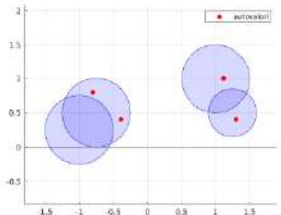

① I punti sono nell'unione dei cerchi → ammisibile
② Non è ammissibile perchè vida il secondo teorema

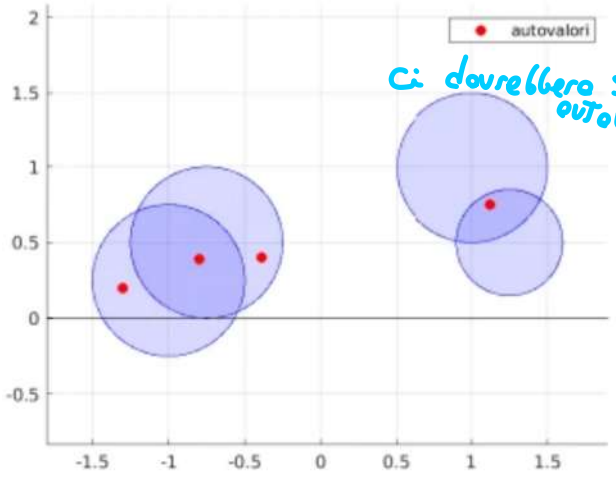

③ Questa è ammissibile,
Perchè * è un cerchio vuoto,
è un cerchio che non contiene
nessun autovalore è una situazione
che non viene esclusa dal teorema,
noi sappiamo che nell'unione
dei cerchi ci stanno tutti, ma non
è detto che un cerchio non
possa essere vuoto, ovviamente non
può essere disgiunto dagli altri

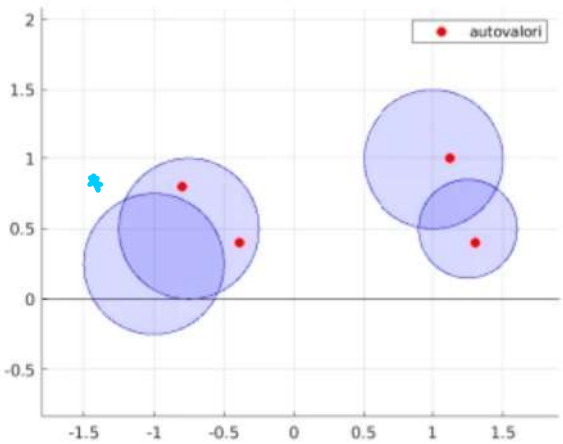

(ii) 4 Punti Stesso quesito del punto precedente assumendo stavolta che $A \in \mathbb{R}^{4\times4}$ e le seguenti configurazioni.

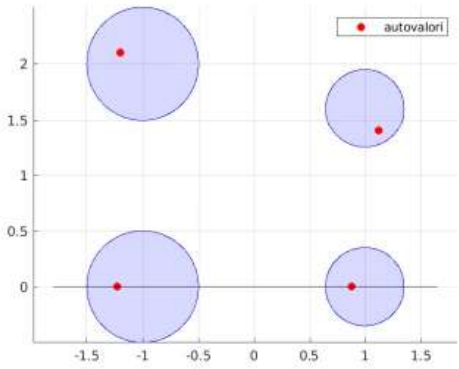

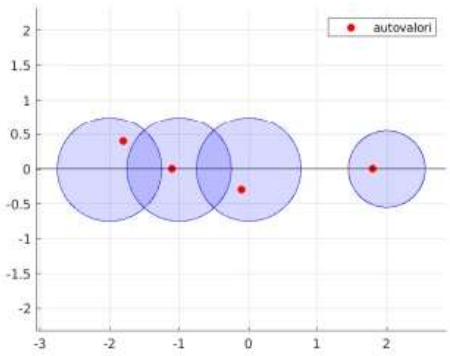

Nomi configurazioni: (a) a sinistra e (b) a destra.

① Non è ammissibile, perchè i centri dei cerchi sono numeri complessi e la matrice è a coefficienti reali, e questo non è possibile

② Ci sono autovalori complessi, ma necessariamente ci devono essere i loro complessi coniugati, e in questo caso non ci sono!

Matrici a Blocchi

È conveniente, scrivere una matrice dal punto di vista implementativo non a scalari, entrata per entrata, ma specificare porzioni di una matrice, specificando matrici più piccole.

↳ TALVOLTA è conveniente scrivere una matrice in termini di sottomatrici, piuttosto che delle sue entrate scalari

esempio

$$A = \begin{bmatrix} * & * & * & * \\ * & * & * & * \\ * & * & * & * \end{bmatrix} \quad \begin{matrix} B & C \\ D & E \end{matrix}$$

dunque $A = \begin{bmatrix} B & C \\ D & E \end{bmatrix}$

$B \in \mathbb{C}^{2\times 3}$

$C \in \mathbb{C}^{2\times 1}$

$D \in \mathbb{C}^{1\times 3}$

$E \in \mathbb{C}$

Questa cosa si può fare anche in Matlab

in Matlab

```
>> B=randn(2,3)

B =

    0.5377   -2.2588    0.3188
    1.8339    0.8622   -1.3077

>> C=randn(2,1)

C =

   -0.4336
    0.3426

>> D=randn(1,3)

D =

    3.5784    2.7694   -1.3499

>> E=randn

E =

    3.0349
```

⟶ `A = [B, C; D, E]`

mi restituisce la matrice

Esempio $A = \begin{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} & \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix} \\ \begin{bmatrix} 1 & 1 \\ 1 & 1 \\ 1 & 1 \end{bmatrix} & \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \end{bmatrix}$ $\quad A = \begin{bmatrix} I_2 & E \\ E^T & I_3 \end{bmatrix}$

in Matlab

```
A = [eye(2) ,ones(2,3); ones(3,2), eye(3)]
```

Senza stare a scrivermi tutte e 25 le entrate.

Questa notazione si può sempre usare?

Sì, purchè abbiano delle righe e colonne compatibili, tra di loro. (specificare una matrice tramite blocchi!) purchè abbiano dimensioni compatibili. In generale, possiamo definire MATRICE A BLOCCHI una scrittura del tipo:

$$A = \begin{bmatrix} A_{11} & \dots & A_{1t} \\ \vdots & & \vdots \\ A_{s1} & \dots & A_{st} \end{bmatrix} \quad \text{con } A_{ij} \in \mathbb{C}^{m_i \times n_j} \quad \text{con } \sum_{i=1}^{s} m_i = m, \quad \sum_{i=1}^{t} n_i = n$$

$\rightarrow \mathbb{R}^{m \times n}$

La convenzione che usiamo sarà la seguente:

- Assumiamo che $s = t$ e $m_i = n_i \ \forall i = 1 \dots s = t$, ovvero tutte matrici quadrate a blocchi, con matrici quadrate sulla diagonale principale

DEF

Le matrici triangolari a blocchi, sono della forma:

$$A = \begin{bmatrix} A_{11} & & 0 \\ & \ddots & \\ A_{ss} & \dots & A_{ss} \end{bmatrix} \quad \text{oppure} \quad A = \begin{bmatrix} A_{11} & \dots & A_{1s} \\ & \ddots & \vdots \\ 0 & & A_{ss} \end{bmatrix}$$

è diagonale a blocchi se

$$A = \begin{bmatrix} A_{11} & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & A_{ss} \end{bmatrix}$$

(i blocchi sulla diag quadrati)

proprietà Se A è triang A blocchi o diagonale a blocchi, allora

$$\det(A) = \prod_{j=1}^{s} \det(A_{jj})$$

(prodotto dei blocchi sulla diagonale)

Si possono fare operazioni matriciali con le matrici a blocchi, trattando gli elementi come se fossero scalari, ovviamente le dimensioni devono essere compatibili.

proprietà se ho 2 matrici a blocchi A, B posso calcolare $A+B$ e $A \cdot B$, trattando i sottoblocchi come scalari, perché le loro dimensioni siano compatibili

$$A = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix} \qquad B = \begin{bmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{bmatrix}$$

se $\text{size}(A_{ij}) = \text{size}(B_{ij})$

$$\Rightarrow A+B = \begin{bmatrix} A_{11}+B_{11} & A_{12}+B_{12} \\ A_{21}+B_{21} & A_{22}+B_{22} \end{bmatrix}$$

$$A \cdot B = \begin{bmatrix} A_{11}B_{11} + A_{12}B_{12} & \cdots \\ \cdots & \cdots \end{bmatrix}$$

Analogamente per operazioni MATRICE-VETTORE

$$A = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix} \qquad x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \qquad Ax = \begin{bmatrix} A_{11}x_1 + A_{12}x_2 \\ A_{21}x_1 + A_{22}x_2 \end{bmatrix}$$

Dove può essere utile questo? Nelle matrici riducibili

DEF MATRICE RIDUCIBILE

$A \in \mathbb{C}^{n\times n}$, $n \geq 2$ è detta riducibile se $\exists \Pi \in \mathbb{R}^{n\times n}$ matrice permutazione, tale che

$$B = \Pi A \Pi^T = \begin{bmatrix} \tilde{A}_{11} & \tilde{A}_{12} \\ 0 & \tilde{A}_{22} \end{bmatrix}$$

Con $\tilde{A}_{11} \in \mathbb{C}^{k\times k}$ quadrato
$\tilde{A}_{22} \in \mathbb{C}^{(n-k)(n-k)}$ quadrato
$\tilde{A}_{12} \in \mathbb{C}^{k\times(n-k)}$

Quindi l'idea è mettere un pò di 0, nella parte in basso a sx, in modo tale che A_{11} e A_{22}, siano quadrati

OSS se $\exists \Pi_1$ di permutazione : $\Pi_1 A \Pi_1^T = \begin{bmatrix} \tilde{A}_{11} & \tilde{A}_{12} \\ 0 & \tilde{A}_{22} \end{bmatrix}$ allora

$\exists \Pi_2$ di permutazione : $\Pi_2 A \Pi_2^T = \begin{bmatrix} \tilde{A}_{11} & 0 \\ \tilde{A}_{21} & \tilde{A}_{22} \end{bmatrix}$

Questa proprietà può essere interessante nel contesto di risolvere sistemi lineari con matrici riducibili

↳ Supponiamo di voler risolvere $Ax = b$, $A \in \mathbb{R}^{n\times n}$ e che A sia riducibile e supponiamo di conoscere Π : $\Pi A \Pi^T = \begin{bmatrix} \tilde{A}_{11} & \tilde{A}_{12} \\ 0 & \tilde{A}_{22} \end{bmatrix}$

Vediamo come sfruttare questa informazione per risolvere $Ax = b$:

$$Ax = b \longrightarrow \Pi A x = \Pi b \overset{\text{posso sfruttare il fatto che le matrici di permutazione sono ortogonali}}{\Longleftrightarrow} \Pi A \underbrace{\Pi^T \Pi}_{I} x = \Pi b \Longleftrightarrow (\Pi A \Pi^T) y = c$$

$I \cdot x = x$

chiamo $\Pi x = y$, $\Pi b = c$

Questo risultato ha la struttura che voglio

$$\begin{bmatrix} \tilde{A}_{11} & \tilde{A}_{12} \\ 0 & \tilde{A}_{22} \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} c_1 \\ c_2 \end{bmatrix}$$

mi sono riscritto il sistema in 2x2 con matrice triangolare superiore

A questo punto ci scriviamo esplicitamente il sistema 2x2 a blocchi come se fossero equazioni scalari

$$\begin{cases} \tilde{A}_{11} y_1 + \tilde{A}_{12} y_2 = c_1 \\ \tilde{A}_{22} y_2 = c_2 \end{cases} \longrightarrow$$ Risolvo questo sis. lineare di dimensione $(n-k)(n-k)$ e mi trovo y_2

Una volta trovato y_2 andiamo a Risolvere

$$\tilde{A}_{11} y_1 = c_1 - \tilde{A}_{12} y_2$$ sist. lineare di dimensione $k \times k$

Infine trovo x dalla relazione $x = \Pi^T y = \Pi^T \begin{bmatrix} y_1 \\ y_2 \end{bmatrix}$

Modus operandi

- Trovo y_1
- Trovo y_2
- Trovo x ripermutando $\begin{bmatrix} y_1 \\ y_2 \end{bmatrix}$

In conclusione: abbiamo rimpiazzato la risoluzione di un sistema lineare $n \times n$ con la risoluzione di due sistemi lineari più piccoli

Approccio standard	VS	Risolvo un sistema $(n-k) \times (n-k)$ e uno $k \times k$
sist lineare (el gauss) $n \times n$ $O(n^3)$		$O((n-k)^3 + k^3)$
②		①

Ci abbiamo guadagnato? dipende da k! La situazione più favorevole è quando $k = \frac{n}{2}$ * in cui si ha, facendo una sostituzione:

① $(n-k)^3 + n^3 = \left(n - \frac{n}{2}\right)^3 + \left(\frac{n}{2}\right)^3 = 2 \cdot \left(\frac{n}{2}\right)^3 = \frac{n^3}{4}$

VS

② n^3

Ci abbiamo guadagnato un fattore 4

* Per vederlo formalmente derivare rispetto a k $(n-k)^3 + k^3$ trovo il pt. minimo dell'espr

I Sistemi lineari

L'ultima volta abbiamo visto che data $A \in \mathbb{C}^{n \times n}$ è riducibile se $\exists \Pi$ matrice di permutazione che la rende triangolare a blocchi tale che

$$\Pi A \Pi^T = \begin{bmatrix} * & * \\ 0 & * \end{bmatrix}$$

* matrici quadrate di possibilmente dimensioni diverse $k \times k$, $n-k \mid (n-k)$

0 blocchi di zeri

Fare questa cosa, può risolvermi il sistema lineare, conoscendo questa permutazione posso risolvermi il sistema lineare con una complessità inferiore rispetta ad un metodo per matrici generiche

VANTAGGI per sistemi lineari:

- CALCOLO DEL DETERMINANTE
- Calcolo degli autovalori

Conoscere dunque la matrice triangolare a blocchi vuol dire ridurre questi tipi di problemi a problemi per i BLOCCHETTI DIAGONALI DELLA MATRICE, dunque per matrici più piccole $\longrightarrow$ costo minore

QSS Siccome $\Pi A \Pi^T$ (Π^T è l'inversa di Π, poichè ortogonale) questa matrice è simile ad A, dunque queste due matrici hanno gli stessi autovalori, e questa cosa si può fare guardando gli autovalori dei blocchi sulla diagonale.

Vediamo un criterio che ci dice come scoprire se una matrice è riducibile o no, dunque se il problema può essere semplificato e che da anche un modo costruttivo per trovarsi Π (la matrice di permutazione)

Come capisco se una matrice è riducibile?

Si ha il seguente TEOREMA

Teorema una matrice $A \in \mathbb{C}^{n \times n}$ è riducibile se e solo se il grafo associato ad A ($G(A)$) non è fortemente connesso.

Dimostrazione (ci risulterà utile anche da un punto di vista pratico perchè ci dirà come costruire π)

un'osservazione preliminare è che se io prendo una matrice A e faccio la permutazione delle righe e delle colonne moltiplicando a destra e sinistra per π e per π^T, morolmente il suo grafo NON CAMBIA, quello che faccio è solo cambiare il name dei vertici

→ $G(A)$ e $G(\pi A \pi^T)$ sono lo stesso grafo a meno di rinominare i vertici. Perchè $B = \pi A \pi^T$, $b_{ij} = a_{\sigma(i)\sigma(i)}$ (permutazione indice i)

Esempio

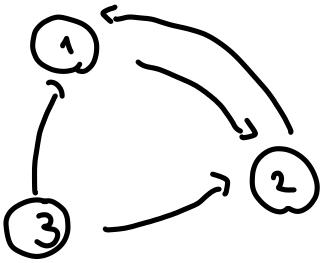

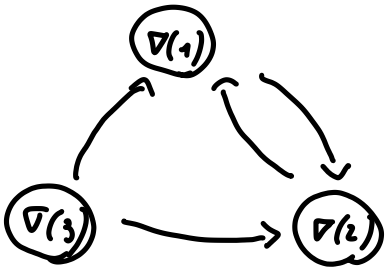

Questo per dire che il grafo associato ad A $G(A)$ è Fortemente connesso se e solo se $G(\pi A \pi^T)$ è Fortemente connesso

(1) dimostriamo che (A riducibile → $G(A)$ fortemente connesso)

Se la matrice A è riducibile $\pi A \pi^T$ esiste dunque si ha una matrice nella seguente forma $= \begin{bmatrix} B_{11} & B_{12} \\ 0 & B_{22} \end{bmatrix}$

Abbiamo detto che studiarci il suo grafo è equivalente a STUDIARCI quello di A, vediamo se questo grafo è fortemente connesso o no.

studiamo $G(B)$, e si vede che $G(B)$ non può essere fortemente connesso

(per via del blocco di zeri in basso a sinistra), perché il blocco di zeri in basso a sinistra rappresenta gli archi che vanno dai vertici in $\{k+1, k+2 \dots n\}$ a $\{1 \dots k\}$

$$B = \begin{bmatrix} B_{11} & B_{12} \\ 0 & B_{22} \end{bmatrix}$$

Se parto dal vertice n, non riuscirò mai ad andare in 1

$\Rightarrow$ non ci sono connessioni da $\{k+1; \dots, n\}$ a $\{1 \dots n\}$.

dunque il grafo non è fortemente connesso $G(B)$

② Adesso supponiamo che il grafo non è fortemente connesso e cerchiamo Π

$$G(A) \text{ non fortemente connesso} \Rightarrow \exists \Pi : \Pi A \Pi^T \text{ riducibile}$$

$G(A)$ non è fortemente connesso allora $\exists (j, h)$ coppia di vertici tali che non posso andare da (j) ad (h) in $G(A)$, esiste una coppia di vertici tale per cui vale questa cosa.

Divido il mio insieme di vertici in due insiemi:
- quelli che possono essere raggiunti da j $\quad P = \{\text{vertici raggiungibili da } j\}$
- quelli che non possono essere raggiunti da j $\quad Q = \{\text{vertici non raggiungibili da } j\}$

$P \neq \phi$ contiene almeno (j)
$Q \neq \phi$ contiene almeno (h)

Inoltre questi formano una partizione dei vertici, la loro unione forma un'insieme $1 \dots n$. $P \cup Q = \{1 \dots n\}$

devo creare una situazione simile a quella Triangolare, cioè gli indici che metto in fondo sono quelli RAGGIUNGIBILI da J.

CONSIDERO UNA PERMUTAZIONE Π (Π che mi mette all'inizio tutti gli indici che stanno in Q, ordinati come ci pare e poi tutti gli indici che sono in P) che mette in testa gli indici di Q e in coda quelli di P (ordinati tra loro come voglio) e quindi:

$$\Pi A \Pi^T = \begin{array}{c} \\ Q \\ P \end{array} \begin{array}{c} \begin{array}{cc} Q & P \end{array} \\ \begin{bmatrix} \text{Archi che uniscono indici in Q con indici in Q} & \text{archi che vanno da Q a P} \\ \text{Archi che da P vanno a Q, quindi zeri!!!} & \text{Connessioni Tra indici in P tra di loro} \end{bmatrix} \end{array}$$

Se per assurdo, ci fosse qualcosa di diverso da zero in questo blocco, dunque un arco da un elemento di P ad uno di Q allora posso raggiungere un elemento di Q partendo da J e questo per come abbiamo definito gli insiemi NON può succedere, sarebbe assurdo!

ESERCIZIO

$$A = \begin{bmatrix} 3 & 0 & 6 \\ 2 & 4 & 7 \\ 3 & 0 & 0 \end{bmatrix}$$

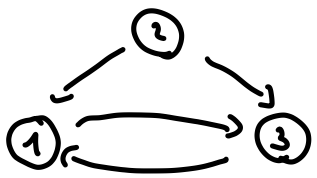

NODI	P raggiungibili	non Q raggiungibili
1	1 3	2
2	1 2 3	∅
3	1 3	2

scegliamo un nodo per cui Q ≠ 0 → ad esempio scegliamo uno

Considero la permutazione Π che mette 2 in testa seguita da 1 e 3 (in coda)

Π (permutazione sulle righe della matrice I) $= \begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix}$

$$\Pi A \Pi^T = \begin{bmatrix} 4 & 2 & 7 \\ 0 & 3 & 6 \\ 0 & 3 & 0 \end{bmatrix}$$

archi da 1,3 a 2 — $(n-k)(n-k)$ connessioni 1,3 e se stesse

Questa cosa si implementa in Matlab facilmente

in Matlab

Si può agire sugli indici che rappresentano le righe e le colonne di una matrice, si può definire il vettore $P = [2\ 1\ 3]$ e definire $B = A(P, P)$
Questo mi applico direttamente una permutazione sugli indici di riga e di colonna di A → ho la forma triangolare a blocchi

```
>> A=[3 0 6; 2 4 7; 3 0 0]

A =

     3     0     6
     2     4     7
     3     0     0

>> p=[2 1 3]

p =

     2     1     3

>> A(p, p)

ans =

     4     2     7
     0     3     6
     0     3     0

>>
```

OSS Ovviamente matrici non assicura che la matrice sia riducibile

$$A = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \end{bmatrix}$$ tanti zeri ma

G(A) è fortemente connesso, A è irr.

OSS il parametro k e $n-k$ ovvero le dimensioni dei blocchi diagonali corrispondono al n° dei vertici nelle colonne Sx e Dx della tabella.

oss dopo aver fatto $\Pi A \Pi^T = \begin{bmatrix} A_{11} & A_{12} \\ 0 & A_{22} \end{bmatrix}$ niente vieta di ripetere l'approccio ricorsivamente sui blocchi A_{11} e A_{22}, se sono riducibili. Ad esempio se troviamo

$$\Pi_1 : \bar{\Pi}_1 A_{11} \bar{\Pi}_1^T = \begin{bmatrix} * & * \\ 0 & * \end{bmatrix} \qquad \Pi_2 : \bar{\Pi}_2 A_{22} \bar{\Pi}_2^T = \begin{bmatrix} * & * \\ 0 & * \end{bmatrix}$$

$$\Rightarrow \begin{bmatrix} \bar{\Pi}_1 & 0 \\ 0 & \bar{\Pi}_2 \end{bmatrix} \bar{\Pi} A \bar{\Pi}^T \begin{bmatrix} \bar{\Pi}_1^T & 0 \\ 0 & \bar{\Pi}_2^T \end{bmatrix}$$

$$\Rightarrow \begin{bmatrix} \bar{\Pi}_1 A_{11} \bar{\Pi}_1^T & * \\ 0 & \Pi_2 A_{22} \bar{\Pi}_2^T \end{bmatrix}$$

sarà una cosa così fatta $\longrightarrow \begin{bmatrix} * & * & * \\ 0 & * & \\ & & * \\ 0 & & 0 \end{bmatrix}$

Posso procedere dunque ancora e ancora,
IDEALMENTE, continuo fino a che non trovo blocchi diagonali irriducibili e la matrice appare come

$$\begin{bmatrix} A_{11} & \cdots & A_{1t} \\ & \ddots & \vdots \\ & & A_{tt} \end{bmatrix}$$ (tanti blocchettini)

Se ho un sistema lineare con questa struttura posso fare un procedimento simile a quello della scorsa lezione, ma con più blocchi e aspettami che il guadagno nel costo sia ancora maggiore

"Se ci devo risolvere un sistema lineare posso agire come visto la volta scorsa:"

$$\begin{cases} A_{11} x_1 + \cdots A_{1t} x_t = b_1 \\ \vdots \\ A_{t-1,t-1} x_{t-1} + A_{t-1,t} x_t = b_{t-1} \\ A_{tt} x_t = b_t \end{cases}$$

← sostituisco x_t e trovo x_{t-1} e continuo

← risolvo questa per prima e vado su

il guadagno è che si risolvono sistemi lineari con le matrici A_{ii} più piccole di A.

↓

Avere una matrice Riducibile, mi aiuta ad avere problemi più semplici.

Purtroppo però molto spesso le matrici, non sono riducibili dunque si hanno problemi

Problema dei sistemi Lineari

Problemi dove A, non è riducibile

$Ax = b \quad A \in \mathbb{C}^{n \times n}$ consideriamo

$$\begin{cases} a_{11}x_1 + \dots + a_{1n}x_n = b_1 \\ \vdots \\ a_{n1}x_1 + \dots + a_{nn}x_n = b_n \end{cases}$$

n equazioni n incognite → TUTTA LINEARE (solo potenza 1)

Vedremo 2 possibili approcci per questo problema lineare

1. Metodi diretti (esiste solo in casi lineari)
2. Metodi iterativi

il Metodo DIRETTO = sono come le formule, o meglio dire, ci sono formule risolutive, si ha un procedimento (formula o espressioni da calcolare), ci assicura che se noi agiamo SENZA COMMETTERE ERRORI, ci garantisce che facendo un certo numero di operazioni si arriva esattamente alla soluzione del problema.

↳ "in Aritmetica ESATTA (no errori di arrotondamento) si arriva alla soluzione del problema con un numero finito di operazioni)

↳ non è detto per cose non lineari

Metodi iterativi: l'idea è che anche se si opera, senza errori di arrotondamento, non si arriva alla soluzione con un numero finito di operazioni, ma ci si arriva tramite un processo limite, cioè si genera un'insieme di punti che sono sempre più accurati, che si avvicinano alla soluzione del problema, ma all'infinito!! non con un numero finito

↳ "Anche operando in aritmetica esatta si genera una successione $\{x_n\}_{k \in \mathbb{N}}$ che converge alla soluzione vera solo al limite $k \to +\infty$"

↳ più in là ci si ferma più accurata sarà la stima della cosa vera, però non si becca mai con un numero finito di passaggi.

Nei sistemi lineari si possono fare entrambe le cose, a regola sceglierei la prima ma il punto è che quando le cose diventano grandi, usare un metodo diretto sarà più costoso di fare un tot di passaggi di un metodo iterativo.

Iniziamo con un METODO DIRETTO

Esempio (metodo Cramer)

Se si ha $Ax=b$, e la matrice A invertibile $\det(A) \neq 0$ ↳ soluzione unica

Ci dice che x_i (del vettore soluzione) $= \dfrac{\det \begin{bmatrix} a_{11} & a_{12} & \dots & b_1 & \dots & a_{1n} \\ \vdots & \vdots & & \vdots & & \vdots \\ a_{n1} & a_{n2} & \dots & b_n & \dots & a_{nn} \end{bmatrix}}{\det(A)}$ (determinante di A)

determinante della matrice A, a cui abbiamo sostituito nella colonna i pari all'entrata che stiamo calcolando il vettore b

Questa si trovano con un numero finito di operazioni aritmetiche, sia al numeratore, denominatore

⇒ cramer è un metodo diretto, e costa $o(n \cdot$ costo del determinante di una matrici$)$

se si usa laplace il costo è di $o(n \cdot n!)$

Un metodo diretto è quello dell'Eliminazione di Gauss, prima di arrivarci, però facciamo prima un caso particolare, che motiva come mai arriviamo a questo metodo, che è il caso in cui il sistema ha una matrice triangolare

Caso di un sistema TRIANGOLARE

supponiamo di avere un sistema $Ux = C$ con $U = \begin{bmatrix} u_{11} & \cdots & u_{1n} \\ & \ddots & \\ 0 & & u_{nn} \end{bmatrix}$

dunque il sistema sarà così fatto

$$\begin{cases} u_{11}x_1 + u_{12}x_2 + \cdots + u_{1n}x_n = c_1 \\ 0 \cdot u_{22}x_2 + \cdots + u_{2n}x_n = c_2 \\ \vdots \\ 0 \cdots \cdots u_{nn}x_n = c_n \end{cases}$$

L'idea è, si parte dal basso, si ricava x_n $x_n = \frac{c_n}{u_{nn}}$ e lo sostituiamo in alto in $u_{n-1\,n-1}x_{n-1} + u_{n-1\,n}x_n = c_{n-1}$ e si ricava $u_{n-1\,n-1}x_{n-1} = c_{n-1} - u_{n-1\,n}x_n$

Si risolve per x_{n-1}, e così via fino alla prima riga, in questo caso qui questo è il metodo migliore per la sostituzione, questo ci fornisce una formula ESPLICITA per le varie componenti

↳ se mettiamo insieme le espressioni delle x_i per $i = n, n-1 \dots 1$ ci da che

$$\begin{cases} x_n = \frac{c_n}{u_{nn}} \\ x_{n-1} = \frac{c_{n-1} - u_{n-1\,n}x_n}{u_{n-1\,n-1}} \\ \vdots \\ x_j = \left(c_j - \sum_{i=j+1}^{n} u_{ji}x_i\right) / u_{jj} \quad j = n-1, \dots, 1 \end{cases}$$

Questo viene detto METODO DI SOSTITUZIONE ALL'INDIETRO

↓

costo? guardiamo quanto costa calcolarsi x_j, e poi guardiamo quanto costa calcolarlo da $n-1$ ad n.

Per calcolare x_j ho $n-j$ prodotti, poi ho $n-j-1$ somme + 2 operazioni (diff e rapp)

Quindi $(n-j) + (n-j-1) + 2 = 2(n-j) + 1$ operazioni

Queste sono le operazioni per calcolarmi un x_j, il costo totale per risolvere $Ux = c$ adesso sarà

$$\sum_{j=1}^{n} 2(n-j)+1 = 2\sum_{j=1}^{n}(n-j) + n = 2\sum_{j=1}^{n-1} j + n = \frac{2(n-1)n}{2} = n^2 - n + n = n^2$$

(j varia fra 1 ed $n-1$; $\sum_{j=1}^{n-1} j$ ha $\frac{n-1}{2}$ addendi)

QSS se il sistema è triangolare inferiore si trova una formula analoga (vedere LAB 4) che viene chiamata SOSTITUZIONE in AVANTI e anche lei costa $O(n^2)$

Qui sono scalari, nel caso delle matrici a blocchi riducibili stavamo cercando di mimare una cosa del genere

METODO di ELIMINAZIONE di GAUSS Questo si applica ad uno non con matrice piena, e l'idea è riportarsi a quel caso lì.

↓

L'idea è applicare delle trasformazioni che mi danno un sistema equivalente (con la stessa soluzioni) ma che abbia una matrice dei coeff, triangolare superiore. Una volta arrivati alla forma triangolare, applico la sostituzione all'indietro.

COME SI ARRIVA A U? Una possibilità è prendere una riga del sistema lineare e sommarle alle altre, moltiplicata per un certo coeff, in modo che le cose opportune si azzerino, le cose che stanno sotto la diagonale della mia matrice.

↳ L'IDEA è SOMMARE un multiplo di un'equazione ad un'altra e provare ad eliminare nella riga j tutti i termini che coinvolgano $x_1 \dots x_{j-1}$, si deve fare un procedimento per gradi. L'idea è mettere una COLONNA PER VOLTA A POSTO

Si elimina al 1° passo x_1 dalle righe $2, \dots, n-1$

$$\begin{cases} a_{11}x_1 + \dots + a_{1n}x_n = b_1 \\ a_{21}x_1 + \dots + a_{2n}x_n = b_2 \\ \vdots \\ a_{n1}x_1 + \dots + a_{nn}x_n = b_n \end{cases}$$

se voglio eliminare a_{21} dalla seconda riga, quello che devo fare è moltiplicare la prima riga, per la cosa giusta e sommarla alla seconda in maniera tale che si cancelli $a_{21}x_1$

Moltiplico la prima equazione per $-\frac{a_{21}}{a_{11}}$ questo è il coefficiente giusto per eliminare il primo termine della seconda riga.
Per la riga j, moltiplico per $-\frac{a_{j1}}{a_{11}}$, dunque, sommo la prima riga a tutte

$$\begin{cases} a_{11}x_1 + \dots + a_{1n}x_n = b_1 \\ a_{21}x_1 + \dots + a_{2n}x_n = b_2 \\ \vdots \\ a_{n1}x_1 + \dots + a_{nn}x_n = b_n \end{cases}$$

Se faccio questo passaggio ottengo (l'apice 1 sta per 1 passaggio di Gauss od indicare che quel termine è cambiato)

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n &= b_1 \\ a_{22}^{(1)}x_2 + \dots + a_{2n}^{(1)}x_n &= b_n^{(1)} \\ \vdots & \\ a_{n2}^{(1)}x_2 + \dots + a_{nn}^{(1)}x_n &= b_n^{(1)} \end{aligned}$$

Adesso eliminiamo x_2, stavolta parto dalla riga 2, perché se sommassi multipli della prima sotto, rischierei di introdurre cose $\neq 0$, dove ho ricavato lo zero.
continuo e uso $a_{22}^{(1)}x_2$ per eliminare i termini sotto di lui, ovvero moltiplico la riga 2 per il coefficiente giusto $-\frac{a_{j2}^{(1)}}{a_{22}^{(1)}}$ e ottengo

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n &= b_1 \quad \text{dopo 2 passi} \\ a_{22}^{(1)}x_2 + \dots + a_{2n}^{(1)}x_n &= b_2^{(1)} \\ a_{33}^{(2)}x_3 + a_{3n}^{(2)}x_2 &= b_3^{(2)} \\ \vdots & \quad \vdots \\ a_{n3}^{(2)}x_3 + a_{nn}^{(2)}x_n &= b_n^{(2)} \end{aligned}$$

La matrice avrà una struttura di questo tipo :

$$\begin{bmatrix} * & \dots & * \\ & * & * \\ 0 & * & \dots & * \\ & \vdots & & \vdots \\ & * & \dots & * \end{bmatrix}$$

dopo $n-1$ passi si ha il sistema in forma triangolare $Ux = c$ dove

$$U = \begin{bmatrix} a_{11} & \cdots & \cdots & a_{1n} \\ & a_{22}^{(1)} & \cdots & a_{2n}^{(1)} \\ & & a_{33}^{(2)} & \\ & & & \ddots \\ & & & a_{nn}^{(n-1)} \end{bmatrix} \qquad c = \begin{bmatrix} b_1 \\ b_2^{(1)} \\ \vdots \\ b_n^{(n-1)} \end{bmatrix}$$

Queste cose richiedono un numero finito di operazioni $\longrightarrow$ metodo diretto

definizione questi $\dfrac{a_{ij}^{(j-1)}}{a_{jj}^{(j-1)}}$ sono detti MOLTIPLICATORI

Quanto costa? Questo costo della riduzione a triangolare $O\left(\frac{2}{3}n^3\right)$
a cui uno deve aggiungere il costo della sostituzione all'indietro x ris $Ux = c$ $O(n^2)$
ma non ce lo metto perché il costo della riduzione è superiore

ESERCIZIO Risolvere

$$\begin{bmatrix} -2 & 1 & 1 \\ -1 & 3 & 1 \\ 1 & 1 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} -2 \\ -3 \\ 2 \end{bmatrix}$$

ci metto anche il vettore dei termini noti

$$\left(\begin{array}{ccc|c} -2 & 1 & 1 & -2 \\ -1 & 3 & 1 & -3 \\ 1 & 1 & 2 & 2 \end{array}\right)$$

moltiplico per $-1/2$ la prima riga e la sommo alla seconda $\longrightarrow$

$$\left(\begin{array}{ccc|c} -2 & 1 & 1 & -2 \\ 0 & 5/2 & 1/2 & -2 \\ & & & \end{array}\right)$$

moltiplico per $1/2$ la prima e la sommo all'ultima $\longrightarrow$

$$\left(\begin{array}{ccc|c} -2 & 1 & 1 & -2 \\ 0 & 5/2 & 1/2 & -2 \\ 0 & 3/2 & 5/2 & 1 \end{array}\right)$$

ora devo annullare $3/2$

moltiplico la seconda per $-\frac{3}{5}$, e la sommo alla terza $\longrightarrow$

$$\left(\begin{array}{ccc|c} -2 & 1 & 1 & -2 \\ 0 & \frac{5}{2} & \frac{1}{2} & -2 \\ 0 & 0 & \frac{11}{5} & \frac{11}{5} \end{array}\right) \sim Ux = c$$

(U = la matrice a sinistra, c = il vettore a destra)

Riscriviamolo per risolverlo con la sostituzione all'indietro

$$\begin{cases} -2x_1 + x_2 + x_3 = -2 \\ \frac{5}{2}x_2 + \frac{1}{2}x_3 = -2 \\ \frac{11}{5}x_3 = \frac{11}{5} \end{cases}$$

$\rightsquigarrow x_3 = 1$ lo vado a sostituire sopra

$$\frac{5}{2}x_2 = -2 - \frac{1}{2}\cdot 1 = -\frac{5}{2} \Rightarrow x_2 = -1 \quad \text{e poi nella prima}$$

$$-2x_1 = -2 - (-1) - 1 = -2 \Rightarrow x_1 = 1$$

La soluzione è $x = \begin{bmatrix} 1 \\ -1 \\ 1 \end{bmatrix}$

in Matlab

Per verificare la soluzione potete testare `b - A.*x`, `norma(b - A*x)` vedere se è 0 o vicino ad esso.

OSS 1 Si può estendere questo metodo, quando ho tanti sistemi lineari con la stessa matrice, ma tanti termini noti, se ho un'equazione lineare del tipo

$$Ax = B \quad \text{dove} \quad B = [b_1 | \dots | b_s]$$

e quindi $x \in \mathbb{C}^{n \times s}$ (un pò di vettori) l'incognita diventa una matrice rettangolare, questo è come dire, equivalente a risolvere s sistemi lineari in cui la matrice è sempre A, ma cambio il vettore dei termini NOTI:

$$Ax^{(1)} = b_1 \quad \dots\dots \quad Ax^s = b_s \qquad x = [x^{(1)} | \dots | x^s]$$

Posso fare Gauss, in maniera uguale, ma nella matrice di partenza vanno appese tutte le colonne di b. $[A|B]$ fino ad arrivare ai sistemi equivalenti $[U|C] = \left[\begin{array}{ccc|ccc} * & \cdots & * & * & \cdots & * \\ & \ddots & \vdots & \vdots & & \vdots \\ & & * & * & \cdots & * \end{array}\right]$ e risolvere ciascun sistema triangolare lineare separatamente

$Ux^{(j)} = c_j$ dove $C = [c_1 | \dots | c_s]$ con il metodo della sostituzione all'indietro.

OSS 2 L'algoritmo si blocca se $a_{jj}^{(j-1)}$ dopo $(j-1)$ passi $=0$, oppure in senso numerico, siccome lavoriamo con FP, quando è vicino a 0, dunque potrebbe diventare inaccurato se $a_{jj}^{(j-1)} \approx 0$. Questi elementi vengono chiamati PIVOT, ovvero l'elemento per il quale divido per avere il moltiplicatore, la cura a questa cosa è adottare STRATEGIE di PIVOTing per andare a cambiare cosa c'è sulla diagonale per evitare zero o cose vicino ad esso. dunque per evitare moltiplicatori molto grandi ⟶ strategie di PIVOTing.

Guardiamo adesso un'interpretazione più matriciale dell'Algoritmo di eliminazione di Gauss, come operazioni fra matrici, e ci porterà alla FATTORIZZAZIONE LU

FATTORIZZAZIONE LU

L'algoritmo di Gauss può essere visto come una serie di moltiplicazioni sull'equazione matriciale $Ax=b$

ad esempio il 1° passo può essere visto come moltiplicare a sinistra e destra per una matrice così

moltiplicatori

$$\begin{bmatrix} 1 & 0 & \cdots & 0 \\ -l_{21} & \ddots & & 0 \\ \vdots & & \ddots & 0 \\ -l_{n1} & \cdots & & 1 \end{bmatrix} Ax = \begin{bmatrix} 1 & & & \\ -l_{11} & \ddots & & 0 \\ \vdots & & \ddots & \\ -l_{n-1} & & & 1 \end{bmatrix} b$$

H_1

$$Ax=b \quad \Rightarrow \quad H_1 Ax = H_1 b$$

Al passo generico j, sto moltiplicando per:

$$\begin{bmatrix} 1 & & & & 0 \\ & \ddots & & & \\ 0 & & 1 & & \\ & & -l_{j+1,j} & \ddots & \\ 0 & & \vdots & 0 & 1 \\ & & -l_{nj} & & \end{bmatrix} = H_j \qquad H_j \cdots H_1 Ax = H_j \cdots H_1 b$$

Alla fine ottengo $H_{n-1} H_{n-2} \cdots H_1 Ax = H_{n-1} \cdots H_1 b \longrightarrow Ux = c$

dunque $H_{n-1} \dots \cdot H_1 A = U$ queste matrici H sono invertibili, (diagonale con uno) dunque posso riscrivere A come $A = H_1^{-1} \dots H_{n-1}^{-1} \cdot U$

La cosa che si può dimostrare è che questo prodotto di inverse $H_1^{-1} \dots H_{n-1}^{-1} =$ è una matrice triangolare con i moltiplicatori $= L$

dunque ci siamo scritti $A = L \cdot U$ = un prodotto per una matrice triangolare inferiore . una triangolare superiore

OSS nel caso in cui sappiamo che $A = LU$, se ci chiedono di risolvere un sistema lineare possiamo farlo più in fretta, invece di partire con Gauss, possiamo risolvere $Ax = b$ più efficacemente perchè in tal caso $Ax = b \approx LUx = b$ e possiamo scompore questa cosa in due sistemi lineari come $\begin{cases} Lc = b \\ Ux = c \end{cases}$ risolvo prima $Lc = b$ e poi $Ux = c$

è un pò come dire $x = U^{-1} L^{-1} b$, questi sistemi lineari siccome ognuno di questi è triangolare il costo di trovarsi x è $O(n^2)$

OSS quando facciamo Gauss, la prima fase consiste nel trovarsi U e calcolare $L^{-1} b$, che costa $O\left(\frac{2}{3} n^3\right)$, se qualcuno ci da LU, possiamo risparmiarci questa cosa.

L'ultima volta s'è parlato di risolvere problemi nella forma $Ax=b$, sistemi lineari, n equazioni, n incognite, con una matrice n righe x n colonne, b è il nostro vettore entrate. e x anch'esso è un vettore.

Abbiamo visto il metodo di Gauss, tramite un pè di passaggi si porta il sistema in una forma equivalente $Ux=c$ dove U è una matrice Triangolare superiore, e si risolve con il metodo di sostituzione all'indietro.

↳ tutto questo procedimento ha un costo di $O(\frac{2}{3}n^3)$, la parte di eliminazione di Gauss.
Risolvere $Ux=c$ è $O(n^2)$, che non è dominante rispetto a $O(\frac{2}{3}n^3)$. ⟶ costa tutto $O(n^2)$

Abbiamo anche parlato di come questo metodo di El.Gauss si possa fare anche con delle moltiplicazioni tra matrici.

$$Ax=b \longrightarrow M_1Ax = M_1b \longrightarrow M_2M_1Ax = M_2M_1b \longrightarrow$$
$$M_{n-1}\dots M_1Ax = M_{n-1}\dots M_1b \longrightarrow Ux=c$$

ALLA FINE $A = \underbrace{M_1^{-1}\dots M_{n-1}^{-1}}_{L} U$ diviene $A=LV$

$$L = \begin{bmatrix} 1 & & \\ \vdots & \ddots & \\ * & \dots & 1 \end{bmatrix} = \begin{bmatrix} 1 & & \\ l_{21} & \ddots & \\ l_{n1} & \dots & l_{n,n-1} \end{bmatrix}$$

l_{ij} è moltiplicatore $= \dfrac{a_{ij}^{(j-1)}}{a_{jj}^{(j-1)}}$

dunque quando facciamo Gauss possiamo calcolarci l_{ij} volta per volta e costruire la matrice L.

Quindi uno può usare l'algoritmo di Gauss, per risolvere il sistema lineare

oppure avere una FATTORIZZAZIONE LU della matrice.

ESERCIZIO Risolvere $AX = B$ dove

$$A = \begin{bmatrix} -2 & 1 & 1 \\ -3 & 1 & 1 \\ 1 & 1 & 2 \end{bmatrix} \quad B = \begin{bmatrix} -2 & 0 \\ -3 & 0 \\ 2 & 1 \end{bmatrix}$$

Questa volta abbiamo due vettori dei termini noti

dunque cerchiamo una matrice soluzione $X \in \mathbb{C}^{3\times 2}$

Questo è come risolvere due sistemi lineari, con la stessa matrice A, uno con termini noti la prima colonna di B, e uno con termini noti la seconda colonna di B.

Applichiamo Gauss

$$\left[\begin{array}{ccc|cc} -2 & 1 & 1 & -2 & 0 \\ -1 & 3 & 1 & -3 & 0 \\ 1 & 1 & 2 & 2 & 1 \end{array}\right]$$

al primo passo → sommo alla seconda riga, la prima moltiplicata per $-\frac{a_{21}}{a_{11}} = -\frac{1}{2}$

Inizio anche a costruire L

$$L = \begin{bmatrix} 1 & 0 & 0 \\ -1/2 & 1 & 0 \\ & & 1 \end{bmatrix}$$

$$\left[\begin{array}{ccc|cc} -2 & 1 & 1 & -2 & 0 \\ 0 & 5/2 & 1/2 & -2 & 0 \\ & & & & \end{array}\right]$$

per annullare la terza riga moltiplico la prima per $\frac{1}{2}$ e → la sommo alla terza

$$L = \begin{bmatrix} 1 & 0 & 0 \\ -1/2 & 1 & 0 \\ 1/2 & & 1 \end{bmatrix}$$

$$\left[\begin{array}{ccc|cc} -2 & 1 & 1 & -2 & 0 \\ 0 & 5/2 & 1/2 & -2 & 0 \\ 0 & 3/2 & 5/2 & 1 & 1 \end{array}\right]$$

Ora dobbiamo liberarci del termine 3/2

Alla terza riga sommo la seconda moltiplicata per -3/5 →

$$L = \begin{bmatrix} 1 & 0 & 0 \\ -1/2 & 1 & 0 \\ 1/2 & -\frac{3}{5} & 1 \end{bmatrix}$$

$$\left[\begin{array}{ccc|cc} -2 & 1 & 1 & -2 & 0 \\ 0 & 5/2 & 1/2 & -2 & 0 \\ 0 & 0 & 11/5 & 11/5 & 1 \end{array}\right]$$

U C

Per risolvere, calcolo $UX = C$, lo tratto come due sistemi lineari tr entrambi con la matrice U, e applico IL METODO DI SOSTITUZIONE all'indietro in maniera indipendente. $X = \begin{bmatrix} x_1^{(1)} & x_1^{(2)} \\ x_2^{(1)} & x_2^{(2)} \\ x_3^{(1)} & x_3^{(2)} \end{bmatrix}$

I sistema

$$\begin{cases} -2x_1^{(1)} - x_2^{(1)} + x_3^{(1)} = -2 \\ 5/2\, x_2^{(1)} + \frac{1}{2} x_3^{(1)} = -2 \\ \frac{11}{5} x_3^{(1)} = \frac{11}{5} \end{cases}$$

risolvendolo $\begin{cases} x_1^{(1)} = 1 \\ x_2^{(1)} = -1 \\ x_3^{(1)} = 1 \end{cases}$ Prima colonna di X

II sistema

$$\begin{cases} -2x_1^{(2)} - x_2^{(2)} + x_3^{(2)} = 0 \\ \frac{5}{2} x_2^{(1)} + \frac{1}{2} x_3^{(2)} = 0 \\ \frac{11}{5} x_3^{(2)} = 1 \end{cases}$$

risolvendolo $\begin{cases} x_1^{(2)} = \frac{2}{11} \\ x_2^{(2)} = -\frac{1}{11} \\ x_3^{(2)} = \frac{5}{11} \end{cases}$

Quindi in conclusione $X = \begin{bmatrix} 1 & 2/11 \\ -1 & -1/11 \\ 1 & 5/11 \end{bmatrix}$

FATTORIZZAZIONE LU di $A = \underbrace{\begin{bmatrix} 1 & 0 & 0 \\ +1/2 & 1 & 0 \\ -1/2 & +3/5 & 1 \end{bmatrix}}_{L} \underbrace{\begin{bmatrix} -2 & -1 & 1 \\ 0 & 5/2 & 1/2 \\ 0 & 0 & 11/5 \end{bmatrix}}_{U}$

Attenzione alla fattorizzazione LU, i moltiplicatori nella L, si mettono a segno invertito rispetto a quelli che vado a costruire quando faccio Gauss.

Dunque abbiamo visto che con il METODO DI GAUSS:

- Risolvo un sistema lineare
- Trovo fattorizzazione LU
- Trovare l'inversa di una matrice (NUOVO!)

TROVARE l'inversa di una matrice (Gauss-Jordan)

$A \in \mathbb{C}^{n \times n}$ voglio trovare $X = A^{-1}$, l'idea è che X risolve $AX = I = \begin{bmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{bmatrix}$ ovvero risolve n sistemi lineari con termini noti le colonne della matrice identica.

↳ l'idea è uso Gauss, con questa scelta particolare di colonne e risolvo tutto, alla fine quella che ottengo sarà la MATRICE INVERSA

ESEMPIO Calcolare l'inversa di $A = \begin{bmatrix} 2 & 3 & 1 \\ 1 & 3 & 1 \\ 0 & 2 & 1 \end{bmatrix}$

$$\left[\begin{array}{ccc|ccc} 2 & 3 & 1 & 1 & 0 & 0 \\ 1 & 3 & 1 & 0 & 1 & 0 \\ 0 & 2 & 1 & 0 & 0 & 1 \end{array}\right] \xrightarrow{\text{applichiamo Gauss}} \left[\begin{array}{ccc|ccc} 2 & 3 & 1 & 1 & 0 & 0 \\ 0 & 3/2 & 1/2 & -1/2 & 1 & 0 \\ 0 & 2 & 1 & 0 & 0 & 1 \end{array}\right] \longrightarrow \left[\begin{array}{ccc|ccc} 2 & 3 & 1 & 1 & 0 & 0 \\ 0 & 3/2 & 1/2 & -1/2 & 1 & 0 \\ 0 & 0 & 1/3 & 2/3 & -4/3 & 1 \end{array}\right]$$

Ho 2 opzioni

- Procedo come prima e risolvo i sistemi triangolari all'indietro, per sostituzione
- Continuo a fare le mosse di Gauss fino ad ottenere una matrice diagonale a sinistra

$$\left[\begin{array}{ccc|ccc} 2 & 3 & 1 & 1 & 0 & 0 \\ 0 & 3/2 & 1/2 & -1/2 & 1 & 0 \\ 0 & 0 & 1/3 & 2/3 & -4/3 & 1 \end{array}\right] \xrightarrow{\substack{\text{uso l'elemento } a_{33} \text{ per annullare } a_{23} \ a_{13} \\ \text{moltiplico la terza riga per dei moltiplicatori e la sommo alla prima e alla seconda}}} \left[\begin{array}{ccc|ccc} 2 & 3 & 0 & -1 & 4 & -3 \\ 0 & 3/2 & 0 & -3/2 & 3 & -3/2 \\ 0 & 0 & 1/3 & 2/3 & -4/3 & 1 \end{array}\right]$$

$$\longrightarrow \left[\begin{array}{ccc|ccc} 2 & 0 & 0 & 2 & -2 & 0 \\ 0 & 3/2 & 0 & -3/2 & 3 & -3/2 \\ 0 & 0 & 1/3 & 2/3 & -4/3 & 1 \end{array}\right] \xrightarrow{\text{divido per } 2, 3/2, 1/3 \text{ le varie righe}} \left[\begin{array}{ccc|ccc} 1 & 0 & 0 & 1 & -1 & 0 \\ 0 & 1 & 0 & -1 & 2 & -1 \\ 0 & 0 & 1 & 2 & -4 & 3 \end{array}\right]$$

A^{-1}

OSS Dunque se affianco una matrice A, la sua identità, e applico Gauss Jordan fino ad ottenere [I|B], la matrice B, sarà l'inversa A^{-1}, questa sarà la soluzione di $AX = I$ con $X = A^{-1}$

Parliamo di un altro aspetto del metodo di Gauss ⟶ quando si fa il metodo di Gauss una condizione per andare avanti è che tutte le volte non ci sia 0, nella posizione diagonale, cioè l'elemento che dobbiamo usare per annullare le cose sotto la diagonale, il PIVOT.

↳ Se c'è zero in teoria ci dovremmo bloccare, ma anche se non c'è zero, ma qualcosa di molto piccolo, andando avanti le cose diventano un pò problematiche. Quando siamo in queste situazioni qua bisogna mottiplicare Gauss per rendere l'algoritmo un pò più stabile. Si fa PIVOTING

PIVOTING in generale la condizione $a_{jj}^{(j-1)} \neq 0 \quad \forall j = 1 \dots n-1$ (che fatto j-1 passi)
nessuno ci assicura che questa condizione sia sempre verificata, può non essere verificata, costringendo l'algoritmo a fermarsi, oppure se si ha $a_{jj}^{(j-1)} \approx 0$ può essere problematico dal punto di vista della stabilità numerica.
Per ovviare a questo problema si fanno degli scambi di righe (PERMUTAZIONE)

- nello specifico al passo generico j si porta in posizione (j,j) ovvero sulla diagonale l'elemento più grande nella parte della colonna j dove voglio mettere gli zeri

↳ detta meglio ⟶ Al passo j, considero il candidato "pivot" che può essere a_{jj} e tutti gli elementi sotto di lui:

- Se il massimo è già sulla diagonale (a_{jj}) = non scambio nulla, il pivot è già ottimo
- Se il massimo è in una riga sotto (a_{ij}) = Porto quella riga in posizione jj tramite uno scambio (modulo), (fra le righe disponibili da a_{jj} in giù)

Supponiamo di avere una situazione del genere:

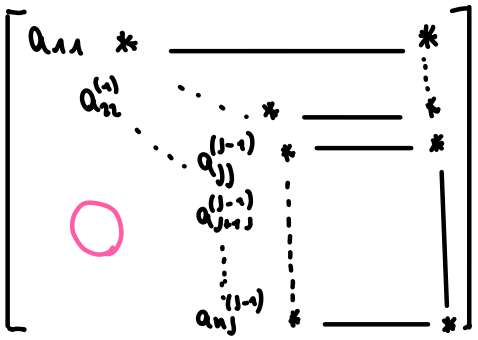

a_{jj} potrebbe essere piccolo oppure zero, si va a considerare dunque la colonna $\begin{bmatrix} a_{jj}^{(j-1)} \\ \vdots \\ a_{nj}^{(j-1)} \end{bmatrix}$, e vado a portare l'elemento

di massimo modulo in posizione a_{jj}, quindi suppongo che

- la riga i ha $i = \operatorname{arg\,max}_{\text{punto di massimo}} |a_{ij}^{(j-1)}|$ dove i varia: $j, j+1, \dots, n$

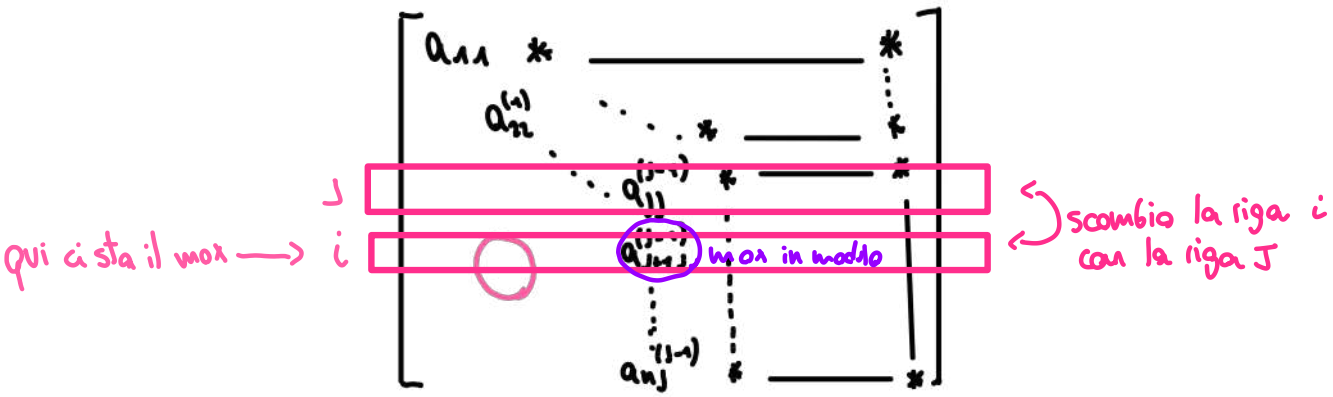

E poi continuo con Gauss, al passo successivo applico di nuovo questa TECNICA di PIVOTING. Questa cosa, potrei farla se ho 0 oppure qualcosa di piccolo, in realtà poi lo faremo sempre.

↳ L'algoritmo di Gauss con lo scambio di righe ad ogni passo si dice ELIMINAZIONE DI GAUSS CON PIVOTING PARZIALE (O PIVOTING PER COLONNE), parziale poichè cerco il massimo solo sulle colonne.

ESEMPIO $A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}$ $b = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$

applichiamo G. con PVT parziale

$$\left[\begin{array}{ccc|c} 1 & 2 & 3 & 1 \\ 4 & 5 & 6 & 2 \\ 7 & 8 & 9 & 3 \end{array}\right]$$

L'elemento + grande sulla prima colonna è 7, scambio terza riga con prima $1 \leftrightarrow 3$

$$\longrightarrow \left[\begin{array}{ccc|c} 7 & 8 & 9 & 3 \\ 4 & 5 & 6 & 2 \\ 1 & 2 & 3 & 1 \end{array}\right]$$

passo di Gauss, uso il 7, per annullare, gli altri

$$\longrightarrow \left[\begin{array}{ccc|c} 7 & 8 & 9 & 3 \\ 0 & 3/7 & 6 & 2/7 \\ 0 & 6/7 & 3 & 4 \end{array}\right]$$

Il max è $6/7$, scambio la riga 2 con la tre $2 \leftrightarrow$

$$\left[\begin{array}{ccc|c} 7 & 8 & 9 & 3 \\ 0 & 6/7 & 3 & 4/7 \\ 0 & 3/7 & 6 & 2/7 \end{array}\right]$$

ultimo passo di Gauss $\longrightarrow \left[\begin{array}{ccc|c} 7 & 8 & 9 & 3 \\ 0 & 6/7 & 3 & 4/7 \\ 0 & 0 & 9/2 & 0 \end{array}\right]$ risolvendo il sistema $\begin{cases} x_1 = -\frac{1}{3} \\ x_2 = \frac{2}{3} \\ x_3 = 9 \end{cases}$

Cosa cambia dal punto di vista della fattorizzazione LU, se si introduce il mecconismo delle permutazioni? (PIVOTING)

Se facciamo il pivoting stiamo moltiplicando a sinistra per una matrice di permutazione. Introdurre il Pivoting (scambio di righe) significa moltiplicare in ogni passo di Gauss, per matrici di PERMUTAZIONE Π_j, con j che va da $1 \dots n-1$. $A \longrightarrow \underbrace{\Pi A}_{\text{pivoting}} \longrightarrow \underbrace{H_1 \Pi_1 A}_{\text{gauss}} \longrightarrow \underbrace{\Pi_2 H_1 \Pi_1 A}_{\text{pivoting}} \longrightarrow H_{n-1} \Pi_{n-1} \dots H_1 \Pi_1 A$

Senza dimostrazione, possiamo mettere tutte queste matrici Π da una parte: si possono portare tutte le matrici Π_j a destra delle matrici H_j a meno di permutare un pochino gli elementi nelle H_j

↳ sto dicendo esiste un trucco per spostare tutti gli scambi di riga all'inizio, come se avessi deciso tutti gli scambi prima di fare i passi di Gauss. Ma il prezzo da pagare è che gli elementi dentro H_1 si spostano di posizione.

in particolare vale che $\Pi A = LU$

- Π: matrice di tutte le permutazioni che sono state fatte, scambi di righe.
- L: contiene i moltiplicatori pesa permutati in base alle permutazioni che si sono fatte, in base alle matrici Π_j applicate
- U: matrice triangolare superiore trovata in fondo all'esecuzione dell'algoritmo

Andiamo a vedere come è fatto questo caso qui con un esempio

ESEMPIO $\begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 0 \end{bmatrix}$ Applichiamo Gauss con pivoting per la LU

$3 \leftrightarrow 1$ $\begin{bmatrix} 7 & 8 & 0 \\ 4 & 5 & 6 \\ 1 & 2 & 3 \end{bmatrix}$ $\Pi_1 = \begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix}$ $\Pi_1 A$

passo di Gauss $\begin{bmatrix} 7 & 8 & 0 \\ 0 & 3/7 & 6 \\ 0 & 6/7 & 3 \end{bmatrix}$ $H_1 \Pi_1 A$ $H_1 = \begin{bmatrix} 1 & 0 & 0 \\ 4/7 & 1 & 0 \\ 1/7 & 0 & 1 \end{bmatrix}$

scambio $2 \leftrightarrow 3$ $\begin{bmatrix} 7 & 8 & 0 \\ 0 & 6/7 & 3 \\ 0 & 3/7 & 6 \end{bmatrix}$ $\Pi_2 H_1 \Pi_1 A$ $\Pi_2 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix}$

passo di gauss $\begin{bmatrix} 7 & 8 & 0 \\ 0 & 6/7 & 3 \\ 0 & 0 & 9/2 \end{bmatrix} = U$ $H_2 \Pi_2 H_1 \Pi_1 A$ $H_2 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 1/2 & 1 \end{bmatrix}$

Per la matrice L_1 quando applichiamo Π_2, che scambia la seconda e la terza, la si deve applicare sulle entrate della L_1 calcolate fino a quel punto che stanno sotto la diagonale (L_{11}) quindi vanno scambiati secondo Π_2 $L = \begin{bmatrix} 1 & 0 & 0 \\ 1/7 & 1 & 0 \\ 4/7 & 1/2 & 1 \end{bmatrix}$

non c'è nessuna permutazione dopo rimane lì

La regola è = quando applichiamo una permutazione, Π_j va effettuato lo scambio sulle colonne di L_1 $1, 2 \dots j-1$.

↳ nel caso precedente l'ho applicato sulla colonna 1

$\Pi A = LU$ Π è la composizione delle permutazioni $\Pi \rightarrow \begin{bmatrix} 1\to3\to3 \\ 2\to2\to1 \\ 3\to1\to2 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}$

Dunque abbiamo tutto Π, L, U.

Un'applicazione importante di questa fattorizzazione LU, è il calcolo del DETERMINANTE

CALCOLO DEL DETERMINANTE Se uno sfrutta la fattorizzazione LU, e l'algoritmo di Gauss per calcolare il determinante, si riesce ad ottenere un notevole guadagno

↳ un'osservazione è che guardando al teorema di Binet Cauchy, una conseguenza di questo è che $\det(A) = \det(L) \cdot \det(U)$

L, U sono matrici triangolari, il determinante è il prodotto degli elementi diagonali

Sappiamo che su L_1 ci sono tutti uni!

$$\det(A) = \det(L) \cdot \det(U) = \det(U) = \prod_{j=1}^{n} u_{jj}$$

dopo Gauss, alla fine

Conosco gli $u_{jj} = a_{jj}^{(j-1)}$ pivot! Alla fine dell'esecuzione di Gauss.
Se uso l'algoritmo di Gauss per trovarmi il determinante il costo mi

diventa il costo di Gauss $O\left(\frac{2}{3}n^2\right)$ costo del calcolo del $\det(A)$!
molto meglio di $O(n!)$ costo con Laplace.

Se usiamo la LU con il pivoting parziale si ha
$\det(\Pi)\det(A) = \det(L)\det(U) = \det(U)$
C'è in più il $\det(\Pi)$, sappiamo che le matrici di permutazioni son speciali

↳ la matrice Π di permutazione (scambio di righe) ha sempre
$\det(\Pi) = (-1)^{\text{elevato al n di scambi di righe}}$

$$A = LU \longrightarrow \det(A) = (-1)^{\#\text{scambi}} \cdot \det(U)$$

Parliamo adesso, di stabilità numerica, quella che nel caso degli (errori) visti all'inizio, sarebbe collegato all'errore inerente

↳ nel caso di sistemi lineari si parla di condizionamento

Condizionamento di un sistema lineare Come si amplifica l'errore inerente sui dati del problema!

Prendiamo $A \in \mathbb{C}^{n\times n}$, $b \in \mathbb{C}^n$ supponiamo di voler risolvere $Ax = b$, ma a causa di errori nei dati, risolviamo

$$(A + \underbrace{\delta A}_{\text{delta}})(x + \delta x) = b + \delta b$$

Stiamo dicendo, se io mi sposto un pochino dal punto vero dove calcolare questa funzione, quanto si modifica la cosa che sto calcolando?

- Con δA e δb piccoli, perturbazioni relativamente piccole rispetto ad A e b. Queste provengono dalla misurazione dei dati, oppure quando lavoriamo in FP, nell'ordine della precisione di macchina, rispetto alla A e alla b vera

Domanda

Supponiamo che ho un problema perturbato così, e lo risolvo in maniera esatta, quanto vado lontano dalla soluzione del problema vero?

↳ La soluzione che calcolo $(x + \delta x)$ è vicina ad x? (ovvero δx è piccolo) ← in generale no

Se noi pensiamo il PROBLEMA nel caso scalare, sarebbe $x = \frac{b}{A}$, questa è un'operazione sicura, nel caso matriciale potrebbero succedere dei guai.

Esempio supponiamo di avere $(\delta A = 0 \quad e \quad \delta b \neq 0)$

$$\begin{bmatrix} 1 & -1 \\ 1 & -1{,}00001 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \longrightarrow x = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

Perturbiamolo ← perturbazione piccola 10^{-7}

$$\begin{bmatrix} 1 & -1 \\ 1 & -1{,}000001 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0{,}999999 \\ 1 \end{bmatrix} \longrightarrow x = \begin{bmatrix} -10^{-6} \\ -1 \end{bmatrix}$$

Una soluzione del tutto diversa! nei dati di input mi sono spostato di poco, la soluzione invece si è spostata un sacco!

La PERTURBAZIONE δb è dell'ordine 10^{-6}, mentre la variazione δx è dell'ordine dell'unità

In una situazione di questo tipo si parla di SISTEMA LINEARE MAL CONDIZIONATO, un piccolo errore sui dati di input si amplifica parecchio.

Cerchiamo di capire quel'è il parametro che causa questo tipo di effetto.
Da cosa dipendono $\|\delta x\|$ (errore assoluto) e $\frac{\|\delta x\|}{\|x\|}$ (errore relativo) sulla soluzione?

Facciamo dei calcoli, assumiamo che la matrice sia invertibile e la soluzione sia unica. $\delta A = 0$, $\det(A) = \emptyset$ (Problema ben posto)

Sappiamo che

$$\begin{cases} A(x+\delta x) = b + \delta b \\ Ax = b \end{cases} \xrightarrow{\text{sottraiamo la seconda della prima}} A\delta x = \delta b \Rightarrow \delta x = A^{-1}\delta b$$

(la perturbazione è la soluzione)

passando alle norme (la norma permette di trasformare il vettore in un unico numero reale non negativo)

$$\Rightarrow \|\delta x\| \leq \|A^{-1}\| \cdot \|\delta b\|$$

norma dell'errore ass. — perturbazione

Se questa norma dell'inversa è grande rischio che l'errore assoluto sia grande. (1)

L'errore assoluto ci interessa fino ad un certo punto, la cosa importante è l'errore relativo, l'errore assoluto può essere anche grande ma se la qt che calcolo è gigantesca "chi se ne frega". L'importante da tenere sotto controllo è l'errore relativo.

Dobbiamo trovare una limitazione per $\frac{\|\delta x\|}{\|x\|}$, quello che ci manca è trovarci una limitazione dal basso di $\|x\|$, qualcosa che maggiori il numeratore $\|\delta x\|$ ce l'ho, mi manca qualcosa di più piccolo del denominatore

Lo troviamo da $Ax = b$ passando alle norme $\|Ax\| = \|b\|$ disuguaglianza moltiplicativa delle norme $\|A\| \cdot \|x\| \geq \|b\|$

$$\Rightarrow \|x\| \geq \frac{\|b\|}{\|A\|} \quad (2)$$

Mettiamo insieme le due disuguaglianze (1) e (2) otteniamo che l'errore relativo

$$\frac{\|\delta x\|}{\|x\|} \leq \frac{\|A^{-1}\| \cdot \|\delta b\| \cdot \|A\|}{\|b\|} = \underbrace{\mu(A)}_{\text{cose che dipendono da A}} \cdot \frac{\|\delta b\|}{\|b\|}$$

(maggiorato; raggruppo le cose che dipendono da A e da b)

DEFINIZIONE $\mu(A) = \|A\| \cdot \|A^{-1}\|$ viene detto numero di condizionamento della matrice A, rispetto alla norma usata $\|\cdot\|$

$$\frac{\|\delta x\|}{\|x\|} \leq \frac{\|A^{-1}\| \cdot \|\delta b\| \cdot \|A\|}{\|b\|} = \mu(A) \cdot \frac{\|\delta b\|}{\|b\|}$$

(maggiorato; raggruppa le cose che dipendono da A e da b; cose che dipendono da A)

Stiamo dicendo che l'errore relativo è maggiorato da $\frac{\|\delta b\|}{\|b\|}$ errore relativo che facciamo sul termine noto, che è qualcosa che ci aspettiamo che sia piccolo, nell'ordine della grandezza dello strumento di cui facciamo la misurazione, oppure dell'ordine della precisione di macchina se è di arrotondamento.

La cosa che può andare storta è che $\mu(A)$ sia grande, che amplifica l'errore sui dati di partenza, infatti non a caso viene chiamato numero di condizionamento perché determina se il nostro sistema è mal condizionato o ben condizionato.

OSS $\mu(A) \geq 1$ sempre perché $\|A\| \cdot \|A^{-1}\| \geq \|A \cdot A^{-1}\| = \|I\| \geq 1$ (Hirsch)

Ben che vada questo numero è 1, se è tanto più grande di 1, il sistema, si dice MAL CONDIZIONATO $\mu(A) >> 1$!

Se $\mu(A) \approx 1$ vicino ad 1, il sistema è Ben condizionato

Chi determina se una cosa è vicina ad 1, o molto più grande di 1?

L'occhio di chi guarda, un possibile metro di giudizio è che se $\mu(A) \approx 10^a$, e ho un TOT di cifre significative sui dati di partenza, mi aspetto di perdere a fa cifre sul risultato.

Mettiamo caso che ho un accuratezza di 16 cifre sul dato di partenza, quando vado a vedere il risultato se $\mu(A) = 10^6$, mi aspetto di perdere sei cifre.

Infatti il condizionamento perfetto è $\mu(A) = 10^0$, non perdo cifre.

L'ultima volta abbiamo visto il **condizionamento di un sistema lineare**
Vorrei risolvere $Ax=b$, quanto è differente la soluzione di $(A+\delta A)(x+\delta x)=b+\delta b$ se δb e δA sono piccole? Quando $x+\delta x$ è vicino a x? Dipende da $\mu(A)$

Dove $\mu(A) = \|A\| \cdot \|A^{-1}\|$. Avevamo ricavato la scorsa volta il seguente **TEOREMA**

Teorema nel caso $\delta A = 0$ e A è invertibile, allora $\frac{\|\delta x\|}{\|x\|} \leq \mu(A) \cdot \frac{\|\delta b\|}{\|b\|}$
più in generale vale che (caso $\delta A \neq 0$) se A e $A+\delta A$ sono invertibili allora vale:

$$\frac{\|\delta x\|}{\|x\|} \leq \frac{\mu(A)}{1-\mu(A)\frac{\|\delta A\|}{\|A\|}} \cdot \left(\frac{\|\delta A\|}{\|A\|} + \frac{\|\delta b\|}{\|b\|} \right)$$

$\frac{\|\delta A\|}{\|A\|}$ → errore relativo su A
$\frac{\|\delta b\|}{\|b\|}$ → errore relativo sul termine noto

questo risultato ci dice **di quanto si sposta la soluzione** se perturbo la matrice oppure il vettore dei termini noti.

OSS Se sostituisco $\delta A = 0$ ritrovo la prima disuguaglianza.

OSS i risultati sopra ci danno un'idea della distanza tipica fra x e $x+\delta x$ (ovvero quanto si amplifica l'errore) nel caso peggiore, cioè "alla peggio" succede questo, non può **andare peggio di così!** le cose (anche se raramente) potrebbero andare meglio.

fare $\mu(A)$ dunque **il numero di condizionamento**, non è una cosa che viene gratis, questo perchè c'è bisogno della norma dell'inversa, e anche la norma di A! In genere non vogliamo davvero stimare $\mu(A)$.

→ quello che si può fare è **STIMARE L'errore a posteriori**, $\mu(A)$ potrebbe dirci prima che errore si commette, una cosa che costa meno, è che dopo aver eseguito il metodo numerico per risolvere il sistema, cercare di vedere quanto questo è LONTANO dalla cosa vera.

↓

supponiamo di avere calcolato $\tilde{x}$ soluzione approssimata di $Ax=b$ (ad esempio con il metodo di Gauss) Per stimare l'errore posso considerare il RESIDUO associato a questa soluzione, per avere un'idea di quanto sia buona questa soluzione

posso considerare la quantità $b - A\tilde{x} = r$ "vettore residuo associato a $\tilde{x}$"

(se x fosse la cosa vera $b - A\tilde{x}$ sarebbe un vettore nullo. Invece non fa 0, sarà un vettore con entrate piccole)

Dato che questa è una quantità che posso calcolarmi in maniera easy, da quanto è grande questo residuo, posso dedurre quanto sono vicino alla soluzione vera?

Quindi ho due equazioni $\begin{cases} Ax = b & \text{soluzione vera verifica questo} \\ A\tilde{x} = b - r & \text{soluzione approssimata verifica questo} \end{cases}$

sottraiamo una dall'altra si ottiene che

$$A(\tilde{x} - x) = -r \longrightarrow \tilde{x} - x = -A^{-1}r$$

$$\Longrightarrow \underbrace{\|\tilde{x} - x\|}_{\text{errore}} \leq \|A^{-1}\| \|r\| \quad \text{se adesso lo combiniamo con la disuguaglianza } \|x\| \leq \frac{\|b\|}{\|A\|}$$

si ottiene

$$\underbrace{\frac{\|\tilde{x} - x\|}{\|x\|}}_{\text{errore relativo su } x} \leq \mu(A) \cdot \frac{\|r\|}{\|b\|}$$

Guardare al residuo ci da un'idea di come va l'errore, però ancora una volta c'è $\mu(A)$, se il numero di condizionamento è alto avere un residuo piccolo, non significa che l'errore sia piccolo mentre se il problema è ben condizionato un residuo piccolo è equivalente all'avere un errore piccolo.

Se il problema è MAL condizionato ($\mu(A) >> 1$) avere un residuo piccolo non garantisce essere vicini alla soluzione vera.

Se invece $\mu(A)$ è "MODERATO" allora residuo piccolo assicura essere abbastanza vicini alla soluzione vera, in generale nelle applicazioni dato che $\mu(A)$ non si può sapere controllare il residuo è la cosa che si può fare in genere per decidere se una soluzione è accettabile o meno

residuo piccolo $\neq$ errore piccolo

Comunque se $\mu(A)$ non si conosce o è costoso da trovare, il residuo (la norma del residuo) è usata per valutare la bontà della soluzione approssimata

OSS nel caso sottomono, ho una matrice Hermitiona, ($A = A^H$ oppure simmetrica $A = A^T$) il numero di condizionamento si può riportare ad una quantità che dipende solo dagli autovalori della matrice, il numero di condizionamento in norma due, diventa

$$\kappa(A) = \|A\|_2 \cdot \|A^{-1}\|_2 = \rho(A) \cdot \rho(A^{-1}) = \max_{i=1\dots n} |\lambda_i| \cdot \max_{i=1\dots n} |\lambda_i|^{-1} = \frac{\max_{i=1\dots n} |\lambda_i|}{\min_{i=1\dots n} |\lambda_i|}$$

raggio spettrale

anche questa matrice è Hermitiona

nel caso Hermitiono trovare $\kappa(A)$ si riconduce a trovare gli autovalori con modulo + grande e + piccolo di A.

ATTENZIONE Non si invertono mai le matrici! La soluzione di $Ax=b$, può essere scritta come $x = A^{-1}b$. Potrei pensare di calcolare l'inversa di A e moltiplicarmi x:

- Dal punto di vista teorico queste cose sono equivalenti, in aritmetica esatta
- Dal punto di vista pratico non conviene poichè:
  - Algoritmo più costoso.
  - Meno stabile, tende di più ad amplificare gli errori.

Questi 2 approcci (risolvere il sistema lineare, invertire A e moltiplicare per b) sono equivalenti, in aritmetica esatta però invertire A, comporta due svantaggi.

CASO SCALARE $n=1$:

$ax=b$ —1 approccio→ $x = b/a$ 1 operazione

—2 approccio→ $\left(\frac{1}{a}\right)$ e poi $x = \left(\frac{1}{a}\right) \cdot b$ 2 operazioni 2 troncamenti/errori di arrotond.

CASO $n>1$

Invertire A costa più o meno $O(2n^3)$ con gauss-Jordan, o varianti di questo tipo, poichè quando invertiamo A con Gauss Jordan, stiamo risolvendo n sistemi lineari $AX = I$.
Costa circa 3 volte quanto costa l'eliminazione di Gauss.
Inoltre quando faccio Gauss Jordan, per rendere la procedura stabile si ha bisogno di fare pivoting

→ alla fine facciamo più operazioni e più errori di arrotondamento

Regola D'oro Quando c'è una quantità del tipo $A^{-1}v$ o $A^{-1}B$, non si deve mai pensare (nell'implementazione) invertire A e poi MOLTIPLICARE, ma risolvere sistemi lineari. Bisogna guardarla con l'occhio di chi sta Risolvendo SISTEMI LINEARI

in Matlab

`inv(A)*b` no!

`A\b` sì, \ chiama il risolutore di sistemi lineari

METODI ITERATIVI

Si parla sempre di sistemi lineari od n equazioni, n incognite, sempre $Ax=b$, l'idea è quella di fare qualcosa di meno preciso, di quanto io mi avvicini alla soluzione vera, che però abbia un costo computazionale minore!

- Metodi diretti $Ax=b$ hanno un costo $O(n^3)$ se n grande vorrei spendere meno (es $n > 1000$)

e può essere conveniente considerare metodi che generano successioni di soluzioni approssimate con accuratezza crescente)

↓

Per essere conveniente un tale approccio deve verificare due proprietà:

1. Ogni iterazione (generare la nuova sol approssimata) costi meno di $O(n^3)$
2. Per raggiungere una certa accuratezza devono bastare "poche" iterazioni

Un metodo iterativo:

$$\begin{cases} x_0 \text{ DATO} \\ x_{k+1} = \dots \end{cases}$$

operazioni sulle soluzioni precedenti ← deve costare meno di $O(n^3)$ ← Ad esempio sono leciti i prodotti matrice/vettore $O(n^2)$

Oppure risolvere sistemi triangolari con costo $O(n^2)$

METODI DI PUNTO FISSO

IDEA partire dall'equazione $Ax-b=0$ e riscriverla in una forma equivalente che sia uguale a $x=Hx+c$

Ci sono modi per fare questo.

$$\underbrace{x = \textcircled{H}x + c}_{\text{equazione del punto fisso.}}$$

matrice di iterazione

Supponiamo di avere sistemato di già $x=Hx+c$, e consideriamo il seguente METODO ITERATIVO!

Questo metodo $\begin{cases} x^{(0)} \text{ DATO / generato casualmente} \leftarrow \text{si parte da qui} \\ x^{(k+1)} = Hx^{(k)} + c \end{cases}$ ← utilizziamo l'equazione del punto fisso che ci genera a partire da una soluzione approssimata la prossima

OSS Questa cosa ha senso, perché se converge, ovvero arriva ad un limite, se il metodo converge $\exists \lim_{k\to+\infty} x^{(k)} = x$

allora x è il "punto fisso" e verifica:

$$x^{(k+1)} = H x^{(k)} + c$$

applichiamo il limite

$$\lim_{k\to+\infty} x^{(k+1)} = \lim_{k\to+\infty} H x^{(k)} + c \longrightarrow x = Hx + c$$

$\lim x^{(k+1)} = x$ per def. $\quad \lim H x^{(k)} = Hx$

dunque il limite di questa successione, se sto funzionando ed esiste è proprio la soluzione dell'equazione di punto fisso. e quindi converge alla soluzione del sistema lineare.

Esempio, come si arriva all'equazione di punto fisso!

Un modo (non l'unico!) per ottenere eq. di punto fisso equivalente a $Ax=b$ è considerare una matrice G, invertibile, $G \in \mathbb{C}^{n\times n}$, e prendere:

$$x = x - G(Ax - b) = \underbrace{(I - GA)}_{H} x + \underbrace{Gb}_{c}$$

Dunque

$Ax=b$ —(scelgo H e c)→ $x = Hx + c$ —(eseguo metodo punto fisso)→ $\begin{cases} x^{(0)} \\ x^{(k+1)} = Hx^{(k)} + 1 \end{cases}$ → Funziona!

Per capire se questa cosa funziona o meno, c'è un risultato che ci viene in aiuto, e che lega la convergenza DEL METODO con la proprietà della matrice H

↳ Cioè se IO guardo, la matrice di iterazione H, riesco a capire se il metodo che sto considerando funziona oppure no.

Definiamo prima la convergenza del metodo

DEF il metodo di punto fisso, $x^{(k+1)} = Hx^{(k)} + c$, si dice convergente se $\forall x^{(0)} \in \mathbb{C}^n$ (per ogni scelta di pt. iniziale non importa da dove si parte)

$\exists x = \lim_{k\to+\infty} x^{(k)}$ che verifica $x = Hx + c$, per qualsiasi scelta di punto iniziale ⟶ una convergenza globale

Teorema quando si ha convergenza globale di un certo metodo, il metodo iterativo $\begin{cases} x^{(0)} \\ x^{(k+1)} = Hx^{(k)} + c \end{cases}$ è convergente $\overset{\text{se e solo se}}{\iff}$ $\rho(H) < 1$ (ovvero se la matrice H ha tutti autovalori di modulo minori di 1)

DUBBIO La definizione mi dice cosa significa convergente, il teorema mi dice come verificare se accadrà.

DIM: $x^{(k+1)} = Hx^{(k)} + c$ togliamo sia da sinistra che da destra la soluzione esatta

$x^{(k+1)} - x = Hx^{(k)} + c - (Hx + c) \longrightarrow x^{(k+1)} - x = H(x^{(k)} - x)$

$x^{(k+1)} - x$: distanza della soluzione approssimata al passo $k+1$ e la soluzione vera

$e^{(k+1)}$: errore al passo $k+1$

$x^{(k)} - x$: $e^{(k)}$ errore al passo k

$\longrightarrow e^{(k+1)} = He^{(k)}$

Dire che la nostra successione converge è equivalente a dire che l'errore va a 0. La sua distanza da x va a zero, se dimostriamo questo abbiamo finito.

$e^{(k+1)} = He^{(k)} = H \cdot He^{(k-1)} = \dots = H^{k+1} e^{(0)}$ ← errore al passo iniziale

Se guardiamo cosa fa $\lim_{k \to \infty} e^{k} = \lim_{k \to +\infty} H^{k} e^{(0)}$

Utilizziamo adesso un risultato dall'algebra lineare che mi dice che le potenze di H vanno a 0 se $\rho(H) < 1$

↳ H^k converge a matrice nulla se e solo se $\rho(H) < 1$

$= \begin{bmatrix} 0 & - & 0 \\ | & & | \\ 0 & - & 0 \end{bmatrix} \cdot e^{(0)} = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}$ si dice così che il nostro metodo converge ovvero la distanza x^k da x converge a 0

Dunque se ho selezionato il metodo di punto fisso devo guardare alla matrice H, che lo regola, se questa $\rho(H) < 1$, quello che sto generando converge

OSS Siccome guardare ai raggi spettrali vuol dire calcolare gli autovalori ogni volta uno potrebbe guardare a delle condizioni più facili da verificare

La condizione $\|H\| < 1$ per una qualsiasi norma allora so che per il teorema di Hirsch il raggio spettrale è minore di 1. Questa è una condizione sufficiente a rendere il metodo convergente però non è necessaria.

Oppure se $|\det(A)| > 1$, è il prodotto degli autovalori, allora sicuro c'è un autovalore più grande di 1, e non si ha la condizione sul raggio spettrale $\rho(H) > 1$, in particolare $|\det(A)| < 1$ è condizione necessaria ma non sufficiente, affinchè il metodo sia convergente.

Dunque questa proprietà sulla matrice di iterazione discrimina se il metodo converge oppure no. Però in genere si vuole sapere quanto veloce converge, se ci arrivo in fretta oppure no, in un contesto in cui ho risorse computazionali elevate.

Velocità asintotica di convergenza

dal teorema (in particolare dalla dimostrazione vista prima) sappiamo che $\frac{\|e^{(k)}\|}{\|e^{(0)}\|} \leq \|H^k\|$ (possiamo maggiorarlo così)

Inoltre (per risultati di Algebra lineare) sappiamo che

lo norma di H, si comporta come $\rho(H)^k$ dunque $\|H^k\| \approx \rho(H)^k$ $\left(\text{questo perché } \lim_{k\to+\infty} \sqrt[k]{\|H^k\|} = \rho(H)\right)$

Questo ci dice che l'errore ad ogni passo l'errore si riduce (circa) di un fattore $\rho(H)$ in particolare si può dare una stima di quanti passi servono per ridurre l'errore iniziale $\|e^{(0)}\|$ di un fattore δ $\left(\text{DELTA}\ \delta = 10^{-8}\right)$.

↳ L'idea è parto con un certo errore, la soluzione ha un certo errore, dopo quanti passi riesco ad ottenere una soluzione con un errore 10^{-8} volte più piccolo?

Basta risolvere la disuguaglianza: $\rho(H)^k \leq \delta \Rightarrow \boxed{k \geq \frac{\log(\delta)}{\log(\rho(H))}}$

questo dice quante iterazioni k servono affinchè l'errore si sia ridotto di 10^{-8}?

Inoltre se ho due metodi iterativi per lo stesso sistema lineare, il primo con matrice H_1, il secondo con matrice H_2

Diciamo che posso confrontarli sulla velocità che hanno per CONVERGERE, tutto ciò che devo fare è guardare i raggi spettrali delle matrici di iterazione

- se $\rho(H_1) < \rho(H_2)$ allora il primo metodo convergerà più in fretta, poichè il fattore di errore sarà più piccolo ancora (viceversa $\rho(H_2) < \rho(H_1)$)

CRITERI DI ARRESTO

Guardare al raggio spettrale etc, non è sempre conveniente, magari si preferisce eseguire il metodo, generare questa successione di vettori, e decidere mentre si stanno calcolando le cose se è una buona idea fermarsi, oppure no!

↳ dato che in generale non conosco , può essere utile decidere quando fermarsi, utilizzando criteri alternativi più facili da valutare.

Per esempio si potrebbe calcolare il residuo del sistema lineare associato all'iterazione k

$r^{(k)} = b - Ax^{(k)}$

① $\frac{\|r^{(k)}\|}{\|b\|} < \delta$ guardare quando questa è minore di δ, guardare la norma del residuo piccola abbastanza

Oppure guardare alla differenza tra due iterazioni successive, e fermarsi quando la differenza, in norma è piccola abbastanza, questo magari perché sono arrivato al punto in cui la soluzione non viene aggiornata tanto. Non sto cambiando tanto perché sono vicino alla convergenza

② $\|x^{(k+1)} - x^{(k)}\| < \delta$ differenza tra due iterate successive piccola abbastanza.

Vediamo dei Metodi Iterativi

Metodi iterativi Classici Problema $Ax = b$

L'idea è che si decompone A nella somma di tre parti

$$A = \underbrace{D}_{\text{diagonale}} - \underbrace{E}_{\text{parte sotto la diagonale}} - \underbrace{F}_{\text{parte sopra la diagonale}}$$

$$A = \begin{bmatrix} a_{11} & & \\ & \ddots & \\ & & a_{nn} \end{bmatrix}_{D} + \begin{bmatrix} 0 & & \\ a_{21} & \ddots & \\ \vdots & \ddots & 0 \\ a_{n1} & \cdots & a_{n,n-1} \; 0 \end{bmatrix}_{-E} + \begin{bmatrix} 0 & a_{12} & \cdots & a_{1n} \\ & \ddots & \ddots & \vdots \\ & & \ddots & a_{n-1,n} \\ & & & 0 \end{bmatrix}_{-F}$$

Per cui $Ax = b \longleftrightarrow (D - E - F)x = b$

Vediamo 2 modi per farlo

Metodo di Jacobi Si porta a destra dell'uguale come segue $Dx = (E+F)x + b$

moltiplico per l'inversa di D

$$\longrightarrow \quad x = D^{-1}(E+F)x + D^{-1}b$$

questa è l'equazione di punto fisso, x uguale a qualcosa

matrice H di Jacobi — c nell'eq di punto fisso

dove $H_J = D^{-1}(E+F)$ $\qquad$ $D^{-1}b$

dunque il metodo di Jacobi è

$$\begin{cases} x^{(0)} \text{ dato} \\ x^{k+1} = D^{-1}(E+F)x^k + D^{-1}b = D^{-1}\left[(E+F)x^k + b\right] \end{cases}$$

OSS Un'iterazione del metodo di Jacobi comporta fare un prodotto matrice_vettore $(E+F)x^{(k)}$ $O(n^2)$ poi una somma tra vettori $(+b)$ $O(n)$, calcolare $D^{-1}t$ dove $t = (E+F)x^k + b$

$$D^{-1}t = \begin{bmatrix} a_{11} & & \\ & \ddots & \\ & & a_{nn} \end{bmatrix}^{-1} \begin{bmatrix} b_1 \\ \vdots \\ b_n \end{bmatrix} = \begin{bmatrix} \frac{b_1}{a_{11}} \\ b_2 \\ a_{21} \\ \frac{b_n}{a_{nn}} \end{bmatrix}$$ costa $O(n)$

dunque in questo caso il costo dominante è $O(n^2)$

$\longrightarrow$ Un'iterazione di Jacobi

OSS Per applicare Jacobi serve la condizione $a_{ii} \neq 0 \ \forall i$. se non si ha, si può cercare di modificare il sistema con le matrici di permutazione e poi applicare Jacobi.

OSS $H_J = \begin{bmatrix} \frac{1}{a_{11}} & & \\ & \ddots & \\ & & \frac{1}{a_{nn}} \end{bmatrix} \underbrace{\begin{bmatrix} 0 & \cdots & \\ a_{11} & & \\ \vdots & & \\ a_{n1} & \cdots & a_{n,n-1} \end{bmatrix}}_{-(E+F)} = \begin{bmatrix} 0 & \frac{a_{12}}{a_{11}} & \cdots & \frac{a_{1n}}{a_{11}} \\ \frac{a_{21}}{a_{22}} & & \ddots & \\ \vdots & & & \\ \frac{a_{n1}}{a_{nn}} & \cdots & & 0 \end{bmatrix}$ $\qquad$ $(H_J)_{ij} = \begin{cases} -\frac{a_{ij}}{a_{ii}} & \text{se } i \neq j \\ 0 & \text{altrimenti} \end{cases}$

Le equazioni che descrivono il metodo di Jacobi sono

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{\substack{j=1 \\ j \neq i}}^{n} a_{ij} x_j^{(k)} \right)$$

OSS Per calcolare $x_j^{(k+1)}$ servono tutte le entrate di $x^{(k)}$, non si possono sovrascrivere le entrate di $x^{(k)}$ fino a che non si è trovato $x^{(k+1)}$

Gauss - Seidel

Mentre Jacobi risolve un sistema diagonale, un'altro sistema che posso risolvere è un sistema con la matrice triangolare, invece di invertire la parte diagonale, inverto la parte triangolare inferiore della matrice A.

Si parte da $(D-E)x = Fx + b \longrightarrow x = (D-E)^{-1}Fx + (D-E)^{-1}b$

la matrice di iterazione sarà $H_{GS} = (D-E)^{-1}F$

Il vettore c sarà $c = (D-E)^{-1}b$

Metodo di Gs $\begin{cases} x^{(0)} \text{ dato} \\ x^{(k+1)} = (D-E)^{-1}Fx^{(k)} + (D-E)^{-1}b = (D-E)^{-1}[Fx^{(k)} + b] \end{cases}$

OSS: Quanto costa?

Per calcolare un'iterazione di Gs serve:

- $Fx^{(k)}$ costa $O(n^2)$
- $Fx^{(k)} + b$ costa $O(n)$
- $(D-E)^{-1} \cdot z$ costa $O(n^2)$ $\longrightarrow$ con il metodo di sostituzione in avanti
  (dove $z = Fx^{(k)} + b$)

$\longrightarrow$ volutare un'iterazione di GS costa $O(n^2)$

OSS: scrittura di H_{GS} in maniera esplicita

H_{GS} non ha forma esplicita semplice in termini delle entrate di A, però si può dire

$H_{GS} = \underbrace{(\quad)^{-1}}_{(D-E)^{-1}} \begin{pmatrix} 0 & * & * \\ 0 & 0 & * \\ 0 & 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & * & * \\ 0 & 0 & * \\ 0 & 0 & 0 \end{pmatrix}$ H_{GS} non è invertibile $\det(H_{GS}) = 0$

L'ultima volta si sono visti i METODI ITERATIVI $Ax=b$,
Partiamo da $x^{(0)}$ e generiamo una successione $\{x^k\}_{k\in\mathbb{N}}$ e sperabilmente si vuole avere che $\lim_{k\to+\infty} x^{(k)} = x$ soluzione di $Ax=b$

Abbiamo visto METODI di punto fisso: $x^{(k+1)} = Hx^{(k)} + c$ dove H è la matrice di iterazione, se $\rho(H)<1$ allora il metodo converge
Abbiamo visto come scegliere H in due modi

- Metodo di Jacobi $H_J = D^{-1}(E+F)$ $\quad A = D-E-F$
  l'iterazione sarà $x^{(k+1)} = H_J x^{(k)} + D^{-1}b$
- Metodo di Gauss-Seidel $H_{GS} = (D-E)^{-1}F$
  l'iterazione sarà $x^{(k+1)} = H_{GS} x^{(k)} + (D-E)^{-1}b$

Mentre con Jacobi, abbiamo detto che ogni volta che calcoliamo l'iterazione dobbiamo salvarci il vettore, per calcolare quella successiva x^k
Se ho bisogno di risparmiare memoria, Gauss-Seidel permette ogni volta di non doverci salvare un vettore in più (x^{k+1} e x^k)

OSS Se si moltiplica l'iterazione di Gauss Seidel per $D^{-1}(D-E)$ quello che si ottiene è:

$$x^{(k+1)} = D^{-1}Ex^{(k+1)} + D^{-1}Fx^k + D^{-1}b$$

Se me la scrivo come $x_i^{(k+1)} = \frac{1}{a_{ii}}\left(b_{ii} - \sum_{j=1}^{i-1} a_{ij}\, x_j^{(k+1)} - \sum_{j=i+1}^{n} a_{ij}\, x_j^{(k)}\right)$

(entrate che ho già calcolato al passo $k+1$)

da questa relazione si nota come io non abbia bisogno delle entrate $1,\dots,i$ di $x_i^{(k)}$ e quindi le posso sovrascrivere → non mi serve un'altro vettore per tenere le cose in memoria.

Ci sono un pò di risultati più generali che risparmiano alcuni conti, delle proprietà a priori sulla matrice del sistema lineare per i quali si riesce a dire $\longrightarrow$ questi metodi convergono

Teorema Sia $A \in \mathbb{C}^{n \times n}$ e consideriamo il sistema $Ax = b$. Se A verifica una delle seguenti proprietà:

- A a predominanza diagonale forte
- A irriducibile e a predominanza diagonale debole

Allora il metodo di Jacobi applicato ad $Ax = b$ è convergente

DIM facciamo vedere che il metodo di Jacobi è applicabile ovvero che $a_{ii} \neq 0 \ \forall i = 1, \dots, n$

nell'ipotesi (i) abbiamo che $|a_{ii}| > \sum_{\substack{j=1 \\ j \neq i}} |a_{ij}| \geq 0 \Rightarrow |a_{ii}| > 0$

nell'ipotesi (ii), assumiamo per assurdo che $a_{ii} = 0$ per un certo i allora $0 = |a_{ii}| = \sum_{\substack{j=i \\ j \neq i}}^{n} |a_{ij}|$

$\Rightarrow$ questo vuol dire $a_{ij} = 0 \ \forall j = 1 \dots n$

in particolare $A = \begin{bmatrix} * & \cdots & * \\ * & \cdots & * \\ 0 & \cdots & 0 \\ * & \cdots & * \\ * & \cdots & * \end{bmatrix}$ riga i $\longrightarrow$ Siccome si ha una riga i di tutti zeri non è invertibile

Ciò è assurdo poichè abbiamo dimostrato che sotto queste ipotesi il terzo teorema di Gershgorin ci dice che la matrice è invertibile!

Dunque non si hanno zeri sulla diagonale $\longrightarrow$ possiamo fare il metodo di Jacobi
Vediamo perchè converge!

Come è fatta $H_J = \begin{bmatrix} 0 & & -\frac{a_{ij}}{a_{ii}} \\ & \ddots & \\ -\frac{a_{ij}}{a_{ii}} & & 0 \end{bmatrix}$, Vogliamo far vedere che questa matrice ha autovalori tutti nel cerchio unitario, cioè che $\rho(H_J) < 1$ ovvero tutti gli autovalori sono nel cerchio di centro 0 e raggio 1!

Ci viene in aiuto Gershgorin! Vediamo come sono fatti i cerchi di questa matrice

I cerchi di Gershgorin di H_J hanno centro 0 (TUTTI) e raggio $\sum_{\substack{j=1 \\ j\neq i}} \frac{|a_{ij}|}{|a_{ii}|}$

Nell'ipotesi (1 predominanza diagonale forte) abbiamo che $\sum_{\substack{j=1 \\ j\neq i}}^{n} |a_{ij}| < |a_{ii}| \longrightarrow \sum_{\substack{j=1 \\ j\neq i}}^{n} \frac{|a_{ij}|}{|a_{ii}|} < 1$

$\longrightarrow$ i cerchi di Gershgorin hanno tutti raggio $< 1 \longrightarrow \rho(H_J) < 1$

Nell'ipotesi 2 non possiamo concludere immediatamente perché ci può essere un minore uguale, si ha $\sum_{\substack{i=1 \\ j\neq i}} \frac{|e_{ij}|}{|a_{ii}|} \leq 1$, ma se avessi un autovalore di modulo uno questo dovrebbe stare

sulla frontiera di tutti i cerchi (irriducibilità!)

Questo non può accadere perché dato che la matrice è a prod. diag. debole, (c'è almeno una riga < 1) e per il terzo teorema di Gershgorin.

Teorema sotto le stesse ipotesi del teorema precedente anche il metodo di Gauss Seidel converge.

DIM Supponiamo per assurdo che $\exists \lambda$ autovalore di H_{GS} tale che $|\lambda| = 1$

in particolare vale: (azzera il polinomio caratteristico)

$$0 = \det(\lambda I - H_{GS}) = \det(\lambda I - (D-E)^{-1}F) = \det\left((D-E)^{-1}(\lambda(D-E) - F)\right)$$

$$\overset{\text{Binet Cauchy}}{=} \underbrace{\det(D-E)^{-1}}_{\neq 0 \text{ altrimenti non l'avrei potuta invertire}} \det(\lambda(D-E) - F)$$

$$\Rightarrow 0 = \det(\lambda(D-E) - F) \overset{\text{porto fuori } \lambda}{=} \lambda^n \det(D - E - \lambda^{-1}F)$$

$\neq 0$ per Hp $\lambda > 1$

$$\Rightarrow 0 = \det(\underbrace{D-E}_{\text{parte triangolare inferiore di A}} - \underbrace{\lambda^{-1}F}_{\text{parte triangolare superiore con elementi divisi per } \lambda})$$

$$\begin{bmatrix} a_{11} & \frac{a_{12}}{\lambda} & \cdots & \frac{a_{1n}}{\lambda} \\ \vdots & \ddots & \ddots & \frac{a_{n-1,n}}{\lambda} \\ a_{n1} & \cdots & & a_{nn} \end{bmatrix}$$

$\longrightarrow$ ha gli stessi elementi $\neq 0$ di A (A irriducibile allora la è anche questa matrice) ed inoltre gli stessi centri dei cerchi di Gersh con raggi $\leq$ a quelli dei cerchi di A. (poiché divido per λ)

$\Rightarrow$ Per Gershgorin (I° o III°) abbiamo che M è non singolare

La morale della storia è che: se si hanno queste proprietà qui non dobbiamo calcolare raggio spettrale o altro, ma possiamo subito concludere che i metodi sono applicabili e convergano.

Sistemi Rettangolari

Sistemi dove il numero di incognite e di equazioni, non sono necessariamente uguali.

Abbiamo da Risolvere $Ax=b$ ma $A \in \mathbb{C}^{m \times n}$ (righe, colonne) $x \in \mathbb{C}^{n}$ (colonne) $b \in \mathbb{C}^{m}$ (righe)

Si parla di sistemi **SOTTODETERMINATI / SOVRADETERMINATI**

- Se $m<n$ si parla di sistema sottodeterminato
- Se $m>n$ si parla di sistema sovradeterminato

Nel caso sottodeterminato si può far finta che il problema sia quadrato (Aggiungendo ad esempio equazioni fittizie)

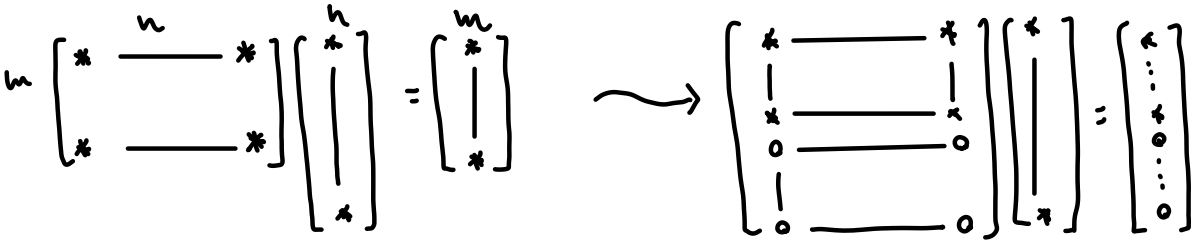

E si applica l'eliminazione di Gauss ad esempio (come preferiamo con o senza pvt)

Nel caso sovradeterminato

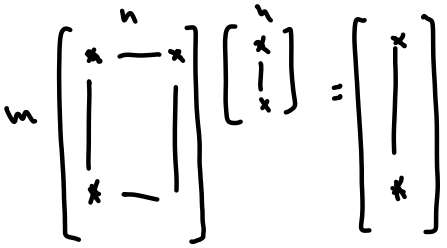

Posso Applicare Gauss, fregandomene del fatto che non sia quadrata arrivando a

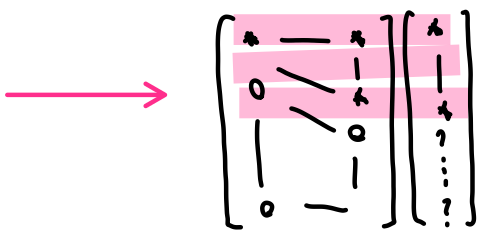

Se i ? sono tutti uguali esiste una soluzione esiste una soluzione e si trova guardando alle prime m righe che è un sistema quadrato in forma triangolare

Se $\exists$ almeno un $?\neq 0$ il sistema non è quadrato e non c'è soluzione!

Cosa si fa in genere? Nel caso del sistema sovradeterminato senza soluzione si considera il **problema quadrato** invece di trovare una x per cui $Ax-b=0$ si cerca di minimizzare il **residuo** ovvero la quantità:

$$\min_{x\in\mathbb{C}^n} \|b-Ax\|_2 \quad \text{oppure} \quad \min_{x\in\mathbb{C}^n} \|b-Ax\|_2^2 \qquad r=b-Ax \text{ vettore residuo}$$

L'idea è se non c'è la soluzione voglio andarci vicino più possibile, voglio rendere piccolo un vettore residuo in qualche senso! Voglio ovvero una configurazione delle incognite che non è lontano da quella esatta!

Sistemi sovradeterminati $m>n$

$Ax=b \quad A\in\mathbb{C}^{m<n}$ m equazioni n incognite, si hanno più equazioni che incognite.

situazione tipica $\longrightarrow$ non c'è una soluzione.
c'è soluzione quando per rouche capelli $\text{Rango}(A|b)=\text{rango}(A)$

↳ questa cosa qui in genere è violata non c'è un vettore x che mi verifica $Ax=b$!

Ma non ci arrendiamo! Cerchiamo di rendere la differenza $b-Ax$ più piccola che posso ovvero:

↳ se non c'è soluzione cerco di minimizzare $\underbrace{\|b-Ax\|_2}_{r(x)}$ vettore residuo $b-Ax$

Più precisamente al posto di $Ax=b$ cerchiamo di Risolvere questa Problema di ottimizzazione ovvero:

$$\min \text{ al variare di } \mathbb{C} \rightarrow \min_{x\in\mathbb{C}} \|b-Ax\|_2^2 = \min_{x\in\mathbb{C}^n} \sum_{i=1}^{m} |r_i(x)|^2 \qquad (P)$$

(vettore; usiamo il quadrato! ci liberiamo della radice)

Il problema di ottimizzazione (P) è detto **PROBLEMA LINEARE AI minimi quadrati!**

NOTA Si minimizza il residuo, ovvero trovare la x che rende questo scarto il più piccolo possibile, è come se x fosse la "migliore approssimazione possibile" nel senso che, anche se non soddisfa esattamente nessuna equazione di $Ax=b$, minimizza l'errore complessivo commesso su tutte!

Esiste la soluzione di (P)? (Caso Reale $x \in \mathbb{R}^n$)

Si ha una funzione obbiettivo da minimizzare $\|b-Ax\|_2^2$

Scriviamola in maniera diversa per ricavare alcune proprietà:

$\Psi(x)$ (psi) = la norma di un vettore quadrato si può scrivere come il prodotto di un vettore per se stesso $d = (b-Ax)^T(b-Ax)$

Questa è una funzione convessa (ha la forma di una conca!) da $\mathbb{R}^n \to \mathbb{R}$

Quindi i suoi punti di minimo se esistono verificano

gradiente $\nabla \Psi(x) = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}$

Cerchiamo un'espressione di $\min (b-Ax)^T(b-Ax)$

$$\Psi(x) = \sum_{i=1}^{m} r_i(x)^2 \quad \text{per} \quad x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$$

$$r_i(x)^2 = \left(b_i - \sum_{j=1}^{n} a_{ij} x_j\right)^2$$

$r_i(x)^2$: residuo al quadrato della riga i esima!

b_i: scalare

$\sum_{j=1}^{n} a_{ij} x_j$: scalare

$$Ax = \begin{bmatrix} \text{riga } 1 \\ \vdots \\ \text{riga } n \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} \sum a_{1j} x_j \\ \vdots \\ \sum a_{mj} x_j \end{bmatrix}$$

Vediamo cosa succede se faccio la derivata parziale di questa funzione con una certa entrata x_s

$$\frac{\partial}{\partial x_s}\left(r_i(x)^2\right) = \frac{\partial}{\partial x_s}\left[\left(b_i - \sum_{j=1}^{n} a_{ij} x_j\right)^2\right] =$$

devo andare a vedere cosa dipende da x_s in questa espressione

derivata dentro propria quando $j=s$

$$= 2\left(b_i - \sum_{j=1}^{n} a_{ij}x_j\right)\cdot\left(-a_{is}\right) = 2\left(-b_i a_{is} + \sum_{j=1}^{n} a_{ij}a_{is}\cdot x_j\right)$$

dunque $$\frac{\partial}{\partial x_s}(\Psi(x)) = \sum_{i=1}^{m}\frac{\partial}{\partial s}(r_i(x))^2 = 2\sum_{i=1}^{m}\left(\sum_{j=1}^{n} a_{ij}a_{is}x_j - b_i a_{is}\right)$$

$$= 2\left(\sum_{i=1}^{m}\sum_{j=1}^{n} a_{is}a_{ij}x_j - \sum_{i=1}^{m} b_i a_{is}\right) =$$

$$= 2\left(\sum_{i=1}^{m} a_{is}\sum_{j=1}^{n} a_{ij}x_j - \sum_{i=1}^{m} b_i a_{is}\right) = 2\left(A^TAx - A^Tb\right)_s$$

singola componente gradiente

$\sum_{j=1}^{n} a_{ij}x_j = (Ax)_i$; $\sum_{i=1}^{m} b_i a_{is} = (A^Tb)_s$; $\sum_{i=1}^{m} a_{is}(Ax)_i = (A^TAx)_s$

Siccome questo vale $\forall s = 1,\dots,n$ abbiamo che

$$\nabla\Psi(x) = 2(A^TAx - A^Tb)$$

Questa da in pasto un vettore e ritorna le derivate parziali. Quindi cercare le soluzioni di $\nabla\Psi(x)=0$ è equivalente a risolvere

$$A^TAx = A^Tb$$

non è più rettangolare ma è un sistema quadrato ad n equazioni n incognite

↓

sistema delle equazioni normali

- Il sistema delle equazioni normali è un sistema in cui $A^TA \in \mathbb{R}^{n\times n}$ (quindi quadrato)

Quindi la nostra domanda di partenza avere quando esistono punti di minimo è equivalente a dire quando questo sistema lineare ha soluzione.
Le soluzioni sono tutte e sole quelle che verificano $\nabla\Psi(x)=0$

Conclusione (P) ha punti di minimo se e solo se il sistema delle eq. normali ha soluzione

Si può dimostrare che questo sistema qualunque sia la A o lo b da cui siamo partiti ha sempre soluzione!

NOTA nel caso complesso tutto uguale con il sistema $A^HAx = A^Hb$

Teorema il sistema delle eq. normali ha soluzione sempre ($\forall A \in \mathbb{C}^{n\times m}$ e $\forall b \in \mathbb{C}^n$) inoltre la soluzione è unica (ovvero (P) ha soluzione unica) se e solo se A ha rango MAX ovvero ($\text{rango}(A) = n$).

Esistenza della soluzione

DIM Dire che $A^H Ax = A^H b$ ha soluzione è equivalente a dire che $A^H b \in Im(A^H A) = \{z \in \mathbb{C}^m : A^T Ay = z\}$. Quest'ultimo però è un sottospazio vettoriale

Un caso "fortunato" è quando $b \in Im(A) \longrightarrow b = Ay$ per un certo y e quindi $A^H b = A^H Ay$
Ma non è sempre così, perché se così fosse il sistema di partenza sarebbe risolubile
Possiamo dire che b magari non sta nell'immagine di A, ma c'è un pezzetto che ci sta e poi qualcos'altro!

↳ Scrivo lo spazio totale $\mathbb{C}^m$ come $= Im(A) \oplus Im(A)^\perp$ ($Im(A)^\perp$ = complemento ortogonale)
dato che $Im(A)$ è un sottospazio posso completare questo sottospazio, con il suo ortogonale che sono le cose che stanno fuori!

Questo vuol dire che ogni vettore di $\mathbb{C}^m$ lo posso scrivere come somma di 2 vettori, uno che sta in $Im(A)$ e l'altro in $Im(A)^\perp$.

In particolare $b = \underbrace{b_1}_{Im(A)} + \underbrace{b_2}_{Im(A)^\perp}$

NOTA $Im(A)^\perp$ sono l'insieme di vettori che sono ortogonali al sottospazio cioè che se ci faccio il prodotto scalare viene zero

$$Im(A)^\perp = \{y : y^H x = 0, \forall x \in Im(A)\}$$

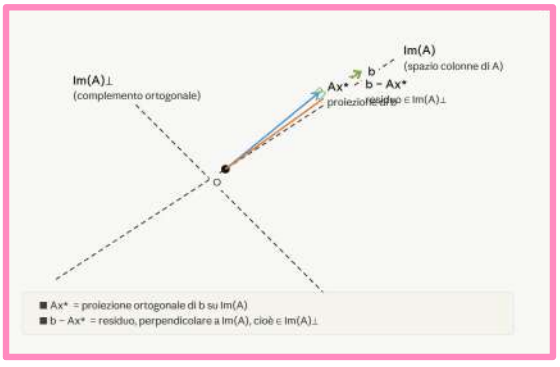

* Si applica A^H ad entrambi i membri

$$A^H b = A^H b_1 + A^H b_2$$

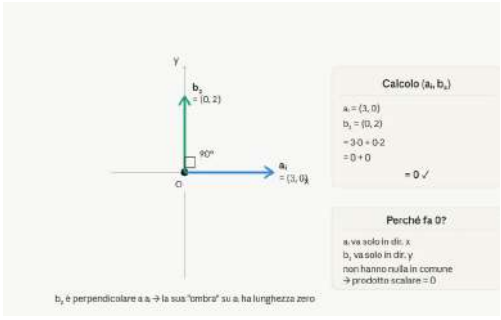

- $b_1 \in Im(A) \longrightarrow A^H b_1 \in Im(A^H A)$
- $b_2 \in Im(A)^\perp$ → b_2 è ortogonale a tutti i vettori che stanno in $Im(A)$

le colonne di A stanno sicuro in $Im(A)$. Quindi $\langle a_i, b_2 \rangle = 0 \ \forall i$

dunque (ortogonali, prodotto scalare 0)

$$b_2 \in Im(A)^\perp \Rightarrow b_2 \perp a_i \ \forall i \Rightarrow \langle a_i, b_2 \rangle = 0 \ \forall i \rightarrow A^H b_2 = 0$$

$$A^H b_2 = \begin{bmatrix} \langle a_1, b_2 \rangle \\ \vdots \\ \langle a_n, b_2 \rangle \end{bmatrix} = \begin{bmatrix} a_1^H b_2 \\ \vdots \\ a_n^H b_2 \end{bmatrix} = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}$$

→ perché le colonne di A stanno in $Im(A)$ e $b_2 \in Im(A)^\perp$.

In definitiva abbiamo che $A^H b = A^H b_1 \in Im(A^H A)$, dunque non importa dove ho scelto A e b, questa cosa è sempre vera ed il sistema ha sempre soluzione!

unicità

DIM

Raminder $A \in \mathbb{C}^{m \times n}$ ha rango massimo (n) è equivalente ad avere che $Ker(A) = \{0\}$ (l'unico vettore che se moltiplicato per A ci da zero è il vettore 0) ovvero, $Ax = 0$ se e solo se $x = 0$. $(m \geq n)$

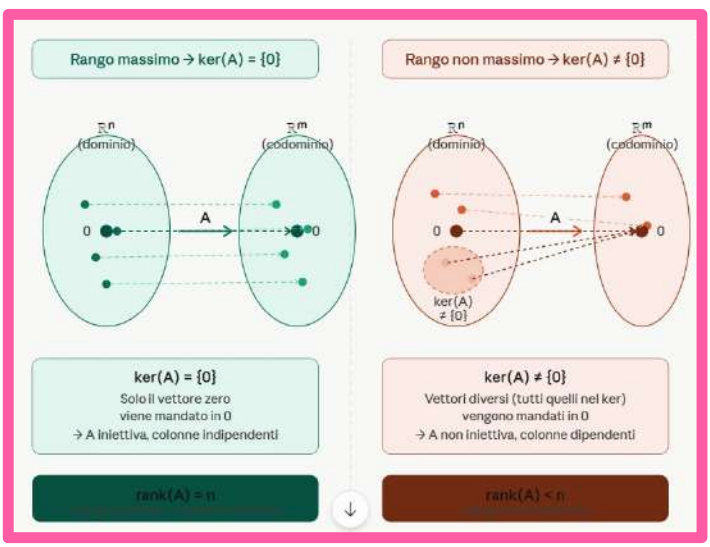

Perché Ax è come se fosse una combinazione lineare delle colonne di A e dire che ha rango massimo vuol dire che sono TUTTE LIN. IND. e l'unico modo per

dire che questa fa 0 è che tutti i coefficienti scelti siano zero!

$$Ax = a_1 x_1 + __ + a_n x_n = 0$$

Vale anche nel caso $m = n$!

Vogliamo far vedere che la soluzione dell'equazioni normali è unica sotto l'ipotesi A rango max $A^t A x = A^t b$ ha una sola soluzione.

↳ ovvero dato che il sistema è quadrato $A^t A$ è invertibile

Dimostriamo supponiamo che $v \in \mathbb{C}^n$ tale che $A^t A v = 0$ allora anche

$v^t A^t A v = 0 \longrightarrow (Av)^t (Av) = 0$ è come fare un prodotto scalare per se stesso $\longrightarrow \|Av\|_2^2 = 0$

per le proprietà delle norme $\longrightarrow Av = 0$

data che A ha rango massimo $Av = 0 \overset{\text{implica}}{\Rightarrow} v = 0$

Dunque abbiamo fatto vedere che se un vettore sta nel kernel di $A^t A$ allora v è necessariamente 0

$\ker(A^t A) = \{0\} \longrightarrow A^t A$ è invertibile → rango max + quadrata

→ la soluzione del sistema lineare è unica → la soluzione del problema dei minimi quadrati è unica

OSS Se A non ha rango max allora le equazioni normali avrebbero più di una soluzione → (P) avrebbe più punti di minimo

Quanto ci costa risolvere un sistema delle equazioni normali?

Partiamo con A e b $\quad A \in \mathbb{R}^{m \times n}$ $\quad b \in \mathbb{R}^m$

1. Calcolo A^TA $\quad A^T \in \mathbb{R}^{n \times m}$ $\quad A \in \mathbb{R}^{m \times n}$ $\quad O(mn^2)$
2. Calcolo A^Tb $\quad A^T \in \mathbb{R}^{n \times m}$ $\quad b \in \mathbb{R}^{m \times 1}$ $\quad O(mn \cdot 1)$
3. Risolvere $(A^TA)x = A^Tb$ Con Gauss $\quad O\left(\frac{2}{3}n^3\right) \approx O(n^3)$

Costo totale $O(mn^2 + n^3) \overset{m \geq n}{\approx} O(mn^2)$

Il problema di questo approccio è il condizionamento!

Condizionamento di Risolvere $A^TAx = A^Tb$

Il problema è quando si va a risolvere il problema dei minimi quadrati il numero di condizionamento di $\mu(A^TA) = \|A^TA\|_2 \cdot \|(A^TA)^{-1}\|_2$
Può essere significativamente più grande di quello di partenza (P)

L'idea è che se perturbiamo la A e la b del problema dei minimi quadrati la soluzione dovrebbe variare meno di quella se perturbiamo A^TA ... (P).

Ad esempio nel caso $m=n$ si ha $\mu(A^TA) = \mu(A)^2$
Può essere un problema se $\mu(A^TA) >> 1$

C'è un metodo più sicuro per risolvere le equazioni normali

METODO QR per problemi ai minimi quadrati

Riscriveremo il problema di partenza di minimizzare una norma
⟶ l'idea è semplificarci le cose tramite matrici unitarie.

- Proprietà delle matrici unitarie: $QQ^H = Q^HQ = I \quad Q \in \mathbb{C}^{m \times m}$
  - $\forall x \in \mathbb{C}^n$
    $\|Qx\|_2 = \|x\|_2$

DIM

$$\|Qx\|_2^2 = (Qx)^H(Qx) = x^H \underbrace{Q^HQ}_{I} x = x^Hx = \|x\|_2^2$$

Se Applichiamo queste matrici ad un vettore non cambia la norma

Una cosa analoga succede quando si guarda alle matrici

Se si ha $A \in \mathbb{C}^{m \times m} \rightarrow \|QA\|_2 = \|A\|_2 \qquad \|AQ\|_2 = \|A\|_2$

DIM

$$\|QA\|_2^2 = \rho((QA)^H QA) = \rho(A^H Q^H QA) = \rho(A^H A) = \|A\|_2^2$$

$$\|AQ\|_2^2 = \rho(\underbrace{Q^H A^H AQ}_{\text{è simile ad } A^H A \text{ (stessi autovalori)}}) = \rho(A^H A) = \|A\|_2^2$$

Si sfrutta una fattorizzazione di A che coinvolge le matrici unitarie

FATTO data una matrice $A \in \mathbb{C}^{m \times n}$ rettangolare esistono sempre una matrice unitaria e una matrice rettangolare $R \in \mathbb{C}^{m \times n}$ della forma

$$R = \begin{bmatrix} * & \cdots & * \\ & \ddots & \vdots \\ & 0 & * \end{bmatrix} = \begin{bmatrix} R_1 \\ 0 \end{bmatrix} \qquad R_1 = \begin{bmatrix} * & \cdots & * \\ & \ddots & \vdots \\ & & * \end{bmatrix} \in \mathbb{C}^{n \times n}$$

(rettangolare triangolare)

tali per cui $A = QR$ FATTORIZZAZIONE QR di A

OSS La fattorizzazione QR di A non è Mai!! unica.

TORNIAMO AL PROBLEMA di OTTIMIZZAZIONE (P)

Vogliamo $\min_{x \in \mathbb{C}^n} \|Ax - b\|_2^2 \overset{\rho}{=} \min_{x \in \mathbb{C}} \|QRx - b\|_2^2 =$

se conosco una fattorizzazione QR di A

$$= \min_{x \in \mathbb{C}^n} \|Rx - Q^H b\|_2^2$$

la norma 2 è invariante se moltiplico per matrici unitarie, Moltiplico dentro per Q^H

Rx posso vederla come $Rx = \begin{bmatrix} R_1 \\ 0 \end{bmatrix} x = \begin{bmatrix} R_1 x \\ 0x \end{bmatrix} = \begin{bmatrix} R_1 x \\ 0 \end{bmatrix} \begin{matrix} \} n \text{ righe} \\ \} m-n \text{ righe} \end{matrix}$

$Q^H b$ posso vederlo come $Q^H b = c = \begin{bmatrix} c_1 \\ c_2 \end{bmatrix} \begin{matrix} n \text{ righe} \\ m-n \text{ righe} \end{matrix}$

$$= \min_{x \in \mathbb{C}^n} \left\| \begin{bmatrix} R_1 x - c_1 \\ 0 - c_2 \end{bmatrix} \right\|_2^2 = \min_{x \in \mathbb{C}^n} \left\| \begin{bmatrix} R_1 x - c_1 \\ -c_2 \end{bmatrix} \right\|_2^2 = \min_{x \in \mathbb{C}^n} \|R_1 x - c_1\|_2^2 + \|c_2\|_2^2$$

applico def norma due somma dei quadrati delle entrate

Stiamo minimizzando questa quantità al variare delle x, la seconda quantità non dipende da x, quindi devo cercare di minimizzare la prima parte.

↳ Scegliere x in modo da minimizzare $\|R_1 x - c_1\|_2^2$. $R_1 x = c_1$ è un sistema nxn (sistema lineare quadrato) e nel caso in cui A ha rango massimo) è non singolare (invertibile!!) ($\det(R_1) \neq 0$)
Quindi posso prendere x come soluzione di $R_1 x = c$ e questo mi da la soluzione ottima di (P) problema ai minimi quadrati. (Posso rendere x zero!!!)
Il valore ottimo della norma del residuo è proprio $\|c_2\|_2^2$, ovvero:

$Q^H b = \begin{bmatrix} * \\ c_2 \end{bmatrix}$

$$\min_{x \in \mathbb{C}^n} \|Ax - b\|_2^2 = \|c_2\|_2^2$$

Quindi in cosa consiste il metodo QR dei minimi quadrati

1. Calcolo una fattorizzazione QR di A
2. Calcolo $Q^H b = \begin{bmatrix} c_1 \\ c_2 \end{bmatrix}$ costo $O(m^2)$
3. Risolvere $R_1 x = c_1$ ← coincide con quella delle equazioni normali
   ↳ costo $O(n^2)$ matrice R_1 triangolare superiore R_1

(Guardare esercizio 13 della dispensa)

OSS Se A non ha rango massimo ($< n$) allora la matrice R_1 non è invertibile e il sistema $R_1 x = c_1$ avrà infinite soluzioni! Ognuna di queste è un valido punto di minimo per (P).

dicevamo sui sistemi rettangolari quando $A \in \mathbb{C}^{m \times n}$ $x \in \mathbb{C}^n$ $b \in \mathbb{C}^m$ stavamo guardando al $\min_{x \in \mathbb{C}^n} \|b - Ax\|_2$ la norma del residuo!

↳ nel caso $Ax = b$ questa è una soluzione molto vicina!

i punti di minimo di questa sono tutti quelli che verificano le equazioni normali ovvero $A^*Ax = A^*b$ che ha sempre soluzione e potrebbe avercene infinite.

↳ un metodo equivalente che porta alla soluzione dei minimi quadrati, che dal punto di vista numerico è più stabile è il Metodo QR

Poichè A^*A può essere mal condizionata per cui ha senso cercare un metodo alternativo (in questo caso QR)

Il problema $\min_{x \in \mathbb{C}^n} \|b - Ax\|_2$ si riscrive come $\min_x \|QRx - b\|_2 = \min_x \|\underset{\text{triangolare}}{R}x - Q^*b\|_2$

Minimizzare questa norma è equivalente a risolvere il sistema $R_1 x = c_1$ $R = \begin{bmatrix} R_1 \\ 0 \end{bmatrix}$ $Q^*b = \begin{bmatrix} c_1 \\ \end{bmatrix}$

Come trovo la fattorizzazione QR?

Esiste sempre la fatt QR di A, non è mai unica. $A = (QR)(D^{-1}R)$

dove $D = \begin{bmatrix} * & & \\ & \ddots & \\ & & * \end{bmatrix} = \begin{bmatrix} d_1 & & \\ & \ddots & \\ & & d_n \end{bmatrix}$ $|d_{ii}| = 1$ per $d_{ii} \in \mathbb{C}$

IDEA fare un processo di Triangolarizzazione (metto 0 nelle colonne dove devono stare) usando moltiplicazioni da sx con matrici unitarie!
(sfruttare che prodotto di matrici unitarie è ancora una matrice unitaria)

Come nel caso di Gauss, le matrici che si vanno a prendere non sono unitarie generiche ma sono matrici unitarie di un sottoinsieme speciale

Si chiamano matrici di Householder:

Matrici di Householder dato un vettore $v \in \mathbb{C}^m$, si definisce la matrice di HouseHolder associata a questo vettore $H_v \in \mathbb{C}^{m \times m}$ quadrata. Come:

$$H_v = \underbrace{I}_{\in \mathbb{R}^{m \times m}} - \frac{2vv^H}{\|v\|_2^2}$$

È una matrice che per essere descritta ha bisogno solo del vettore

Reminder Una matrice è Hermitiana quando $A = A^H$, Una matrice è unitaria quando $U^H U = I$ oppure $U^H = U^{-1}$

Proprietà

- H_v è Hermitiana (1) ed unitaria (2)
  - Per l'Hermitiana

$$H_v^H = \left(I - \frac{2}{\|v\|_2^2} \cdot vv^H\right)^H = I^H - \frac{2}{\|v\|_2^2} \cdot \left(v^H\right)^H \cdot v^H = I - \frac{2}{\|v\|_2^2} v \cdot v^H = H_v$$ è Hermitiana

  - Per l'unitaria

$$H_v \cdot H_v = \left(I \cdot \frac{2}{\|v\|_2^2} vv^H - \frac{2}{\|v\|_2^2} vv^H + 4 \frac{v \overbrace{v^H v}^{\|v\|_2^2} v^H}{\|v\|_2^4}\right) = I - \frac{4vv^H}{\|v\|_2^2} + \frac{4vv^H}{\|v\|_2^2} = I$$

Se è unitaria ed Hermitiana $H = H^H = H^{-1}$!!! (non importa come ho scelto v)

Vale questa proprietà

- Preso un vettore qualsiasi $x \in \mathbb{C}^m$ si può sempre trovare una matrice di Hausolder che lo manda in un multiplo del primo vettore della base canonica.

Si può trovare una matrice di Hausolder H_v tale che:

$$H_v \cdot x = \begin{bmatrix} \alpha \\ 0 \\ 0 \\ 0 \end{bmatrix} \quad \alpha \in \mathbb{C}$$

Immagino un vettore x nello spazio. La matrice di Hausolder fa in modo che x cada sulla direzione $e_1 = \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$. Il risultato sarà un vettore che ha un valore α in cima e 0 in tutte le altre.

OSS α non può essere cosa ci pone poiché $|\alpha| = \|x\|_2$, α è la lunghezza del vettore originale, tutto il "peso" del vettore x viene concentrato sulla prima coordinata

Dato che $\|\cdot\|_2$ è preservata quando si moltiplica per matrici unitarie (Hv lo è) si deve avere che

$$|\alpha| = \|x\|_2$$

Questo perché le matrici unitarie moltiplicate per un vettore non ne modificano la norma (lunghezza)

$$\|Ux\|_2 = \|x\|_2 \quad \text{dunque} \quad |\alpha| = \|x\|_2$$

Una possibile scelta per Hv è prendere la matrice di Householder associata ad A:

Come vettore $$v = \begin{bmatrix} x_1 \pm \|x\|_2 \\ x_2 \\ \vdots \\ x_m \end{bmatrix} = x \pm e_1 \cdot \|x\|_2$$

(da A)

vettore modificato limitatamente alla prima componente

(senza dimostrazione) dunque se ho un x, e voglio trovare Hv, mi calcolo come fatto sopra v e faccio Hvx che mi da un multiplo di e_1

OSS ho una possibile scelta sul segno (a più o meno) funzionano entrambi, dal punto di vista numerico c'è una scelta più stabile dell'altra, in base al segno di x_1 scelgo $\pm$ per avere sono concordi.

Nel caso reale si sceglie il segno ($\pm$) in base al segno di x_1, per evitare cancellazioni numeriche se x_1 complesse $\in \mathbb{C}$ si guarda la sua parte reale.

Dunque vettor x, costruisco H_v in maniera tale che $H_v x = \begin{bmatrix} \text{qualcosa} \\ 0 \\ \vdots \\ 0 \end{bmatrix}$ dove v, serve per costruire H_v!

Possiamo sfruttare le matrici di HouseHolder per triangolarizzare A, una colonna per volta:

Come si fa?

① Passo A guardata per colonne $A = \left[\begin{array}{c|c} a^{(1)} & * \cdots * \\ \vdots & \vdots \\ * & * \cdots * \end{array}\right]$ e scelgo

H_1 (matrice HouseHolder) tale che $H_1 a^{(1)} = \begin{bmatrix} \text{qualcosa} \\ 0 \\ \vdots \\ 0 \end{bmatrix}$ dove

$$H_1 = I - \frac{2vv^H}{\|v\|_2^2} \quad \text{e} \quad v = \begin{bmatrix} x_1 \pm \|x\|_2 \\ x_2 \\ \vdots \\ x_m \end{bmatrix}$$

(da A)

② Passo ora $H_1 A = \begin{bmatrix} * & * & * & \cdots & * \\ 0 & & * & \cdots & * \\ \vdots & & \vdots & & \vdots \\ 0 & & * & \cdots & * \end{bmatrix}$ al solita scelgo $\tilde{H}_2 \in \mathbb{C}^{(m-1)\times(m-1)}$

(guardo questa vettore dalla seconda riga in giù! $a^{(2)}$)

tale che $\tilde{H}_2 a^{(2)} = \begin{bmatrix} * \\ 0 \\ \vdots \\ 0 \end{bmatrix}$ dove $\tilde{H}_2 = I - \frac{2vv^H}{\|v\|_2^2}$ e $v = \begin{bmatrix} x_1 \pm \|x\|_2 \\ \vdots \\ x_m \end{bmatrix}$ ($a^{(2)}$)

(dim $m - k + 1$)

A questo punto $H_2 = \left[\begin{array}{c|c} 1 & 0 \\ \hline 0 & \tilde{H}_2 \end{array}\right] \in \mathbb{C}^{m\times m}$ unitaria

dunque metto a posto la seconda colonna di A con questa $H_2 A$

Al passo k:

$$H_{k-1} \cdots H_1 A = \begin{bmatrix} * & * & * & * & * \\ 0 & \ddots & & * & * \\ & & & 0 & * \\ & & & \vdots & \vdots \\ 0 & & & * & * \end{bmatrix}$$

fino a k-1 | al passo k aspettiamo ancora che vengano modificate al passo k

($a^{(k)}$)

dunque ancora $\tilde{H}_k a^{(k)} = \begin{bmatrix} * \\ \vdots \\ 0 \end{bmatrix} \in \mathbb{C}^{m-k}$ allora

$$H_k = \left[\begin{array}{c|c} I_{k-1} & 0 \\ \hline 0 & \tilde{H}_k \end{array}\right] \in \mathbb{C}^{m \times m}$$ Posso generico!

- dopo n passi (dopo n colonne sistemate) si avrà:

$$H_n \cdot H_{n-1} \dots H_1 A = \begin{bmatrix} * & \cdots & * \\ 0 & \ddots & * \\ \vdots & \ddots & 0 \\ 0 & \cdots & 0 \end{bmatrix} = R$$

Come matrice Q si prende

poiché $H^{-1} = H$ perché sono unitarie

$$A = \underbrace{H_1 \cdot H_2 \dots H_n}_{Q} R$$

Q unitaria perché prodotto di matrici unitarie (H_i)

Costo computazionale si sfrutta il fatto che le matrici di HouseHolder si scrivono come l'identità più una matrice di rango uno, come vettore colonna x vettore riga.

Si sfrutta la proprietà che le matrici di HouseHolder si scrivono come somma di Identità + rango 1 = Identità + colonna x riga.

In particolare

$$\underbrace{(I - vv^H) \cdot A}_{\text{differenza } O(mn)} = A - v\underbrace{(v^H A)}_{\text{mi ritorna un vettore}} \longrightarrow O(mn)$$

$v^H \in \mathbb{C}^{1 \times m}$

$A \in \mathbb{C}^{m \times n}$

$O(mn)$

vettore colonna $v \in \mathbb{C}^{m \times 1}$

vettore riga $v^H \in \mathbb{C}^{1 \times m}$

$O(mn)$ $(m \times 1)(1 \times n)$

Siccome faccio n passi di questa procedura il costo sarà $O(mn^2)$

Tornando al metodo QR: ci serve R e ci serve $Q^t b$

- R la trovo alla fine del procedimento con le matrici di HouseHolder $O(mn^2)$
- $Q^t b = H_n \cdot H_{n-1} \dots H_1 b$ la trovo come n prodotti matrice di HouseHolder per vettore $\longrightarrow$ costo $O(mn^2)$

Operativamente si può applicare la procedura con le matrici di HouseHolder ad $(A|b)$ e alla fine del procedimento, dopo n passi, si ha)

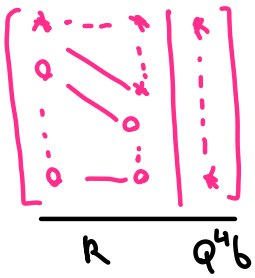

Quindi il metodo QR costa:

① Calcolare R e $Q^t b$ $\rightsquigarrow O(mn^2)$

② Risolvere $R_1 x = c_1$ $\rightsquigarrow O(n^2)$ triangolare

TOTALE $O(mn^2)$ stesso costo asintotico delle equazioni normali

OSS nel caso $m=n$ potremo usare la fattorizzazione QR anche per risolvere sistemi lineari.

$$Ax = b \rightsquigarrow QRx = b \rightsquigarrow \underbrace{Rx = Q^t b}_{O(n^2)}$$

Risolverlo costa $O(n^2)$

Il costo è $O\left(\frac{4}{3}n^3\right)$ ovvero il doppio dell'eliminazione di Gauss

Approssimare funzioni

PROBLEMA abbiamo una conoscenza empirica (puntuale) di una certa $f: \mathbb{R} \to \mathbb{R}$ che conosciamo in un insieme di punti $(x_0, y_0) \dots (x_k, y_k)$ ($k+1$ punti) e vorremo costruire un'approssimazione di f, qualcosa che si comporti più o meno come f.

Graficamente

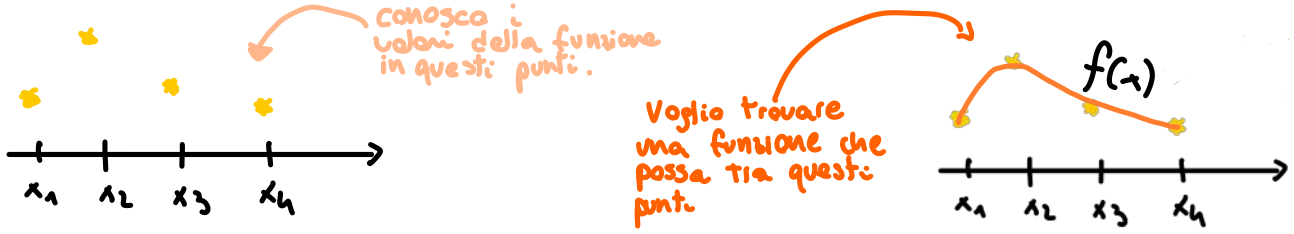

Vorremo trovare $f(x)$ tale per cui $f(x_i) = y_i$, se la funzione f passa esattamente dai punti si chiama funzione INTERPOLANTE. Ed i punti: $x_0, x_1 \dots x_k \in \mathbb{R}$ sono detti nodi dell'interpolazione
La funzione che passa per quei punti "rappresenterà bene" il fenomeno che ho sott'occhio.

In altri contesti quando si hanno molti dati (molti punti) ci si accontenta di qualcosa che non passi esattamente dai punti ma ci passi abbastanza vicino
f che passi abbastanza vicino ai dati, secondo un qualche criterio quantitativo.

Esempio (regressione lineare)

Si hanno tanti punti e ci vogliamo far passare una retta

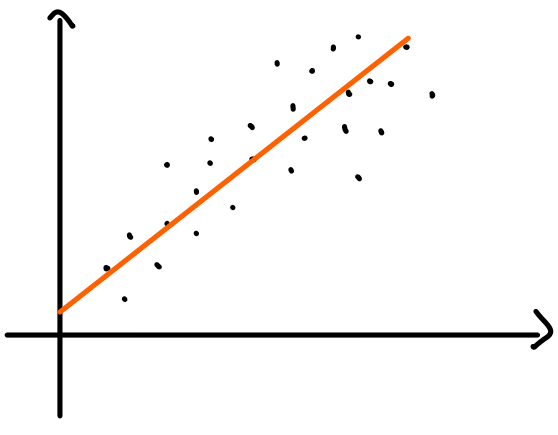

Supponiamo un'andamento lineare ma i punti non sono allineati (rumore nelle misurazione, errori di approssimazione)

Lo scopo dunque sarà cercare di approssimare questa funzione f incognita con qualcosa di semplice, che sappiamo gestire bene

↳ in questi tipo di problemi si cercano funzioni approssimanti f che siano di una forma semplice in modo da poterla usare per fare previsioni, ovvero valutarla fuori dai nodi ed estrarre altri tipi di informazione (Ad esempio integrali)

facciamo il primo cosa, quello dell'interpolazione

INTERPOLAZIONE polinomiale

Cerchiamo una funzione che passa esattamente dai punti che io vedo, e cerco di tirare fuori un'approssimazione f con un polinomio

Dati $(k+1)$ nodi $x_0 \dots x_k \in \mathbb{R}$ distinti $\left(\begin{matrix} x_i \neq x_j \\ \text{se } i \neq j \end{matrix}\right)$ e $(k+1)$ valori $y_0 \dots y_k \in \mathbb{R}$ e cerchiamo il polinomio $P_k(x)$ di grado al massimo k tale che è verificata la condizione di interpolazione

↳ passa dai punti ed è verificata la condizione di interpolazione.

Cosa vol dire questa? che se valuto (polinomio) $P_k(x_i) = y_i$
$\forall i = 0, 1 \dots k$

questo polinomio P_k viene detto polinomio d'interpolazione per i nodi $(x_0, y_0) \dots (x_k, y_k)$

Oss
Voglio calcolare un polinomio, cosa significa? un generico polinomio di grado al massimo k, si scrive come

$$a_0 + a_1 x + a_2 x^2 + \dots + a_k x^k = \sum_{j=0}^{k} a_j x^j$$

Trovare $P_k(x)$ significa determinare i coefficienti a_j con $j=0\dots k$.

↳ Per cercare di trovare dunque le nostre incognite, imponiamo le condizioni che vogliamo, ovvero:

- Imponendo le condizioni $P_k(x_i)=y_i$ otteniamo:

$$P_k(x_0) = a_0 + a_1 x_0 + a_2 x_0^2 + \dots a_k x_0^k = y_0$$

faccio la stessa cosa per

$$P_k(x_1) = a_0 + a_1 x_1 + a_2 x_1^2 + \dots a_k x_1^k = y_1$$

$$\vdots \qquad\qquad \vdots$$

$$P_k(x_k) = a_0 + a_1 x_k + a_2 x_k^2 + \dots + a_k x_k^k = y_k$$

queste equazioni sono tutte lineari quindi se le interpretiamo come eq di incognite a_j è un sistema lineare $(k+1)$ equazioni

↳ è un sistema lineare quadrato nelle incognite a_j

lo possiamo scrivere come

matrice → V ← vettore incognite coefficienti: $Va = y$

$$a = \begin{bmatrix} a_0 \\ \vdots \\ a_k \end{bmatrix} \qquad y = \begin{bmatrix} y_0 \\ \vdots \\ y_k \end{bmatrix} \qquad V = \begin{bmatrix} 1 & x_0 & x_0^2 & \dots & x_0^k \\ 1 & x_1 & x_1^2 & \dots & x_1^k \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_k & x_k^2 & \dots & x_k^k \end{bmatrix}$$

matrice che moltiplica i coefficienti

→ Matrici di questa forma vengono dette matrici di Vandermonde associate ai nodi $x_0 \dots x_k$

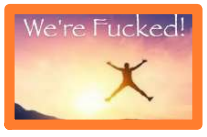

Oss

dato che abbiamo scritto tutto come un sistema lineare, per le conclusioni che ci interessano tipo Il polinomio interpolante è unico, si traducono nel linguaggio dell'algebra lineare, come questo sistema lineare ha una soluzione? è unica?

Alla luce di quello scritto il polinomio interpolante di grado al + k, esiste ed è unico se e solo se esiste ed è unica la soluzione di $VA=y$

A questo punto la DOMANDA è, esiste ed è unica la soluzione di questo sistema lineare?

Abbiamo un risultato che ci dimostra tutto questo in particolare che è il determinante delle matrici di Vandermonde

Teorema $\det(V) = \prod_{\substack{i \neq j \\ n \geq i > j \geq 0}} (x_i - x_j)$ Senza dimostrazione!

il det è zero se e solo se uno dei fattori del prodotto è zero!
Però questi fattori sono le differenze tra i nodi, se questi sono tutti distinti allora $\det \neq 0$

Corollario Se i nodi sono distinti $(x_i \neq x_j \ \forall i \neq j)$ allora $P_n(x)$ esiste ed è unica (la matrice di Vandermode è invertibile e la soluzione del sistema è $V^{-1}y$)

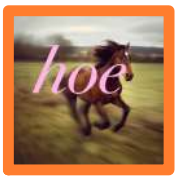

OSS
L'unicità vale per i polinomi $\leq n$, se si prende un grado più alto, se ne possono trovare altri.

OSS
Il grado di $P_n(x)$ può essere strettamente $< n$, Ad esempio se prendiamo n punti allineati, la soluzione sarà una retta che passa per questi punti.

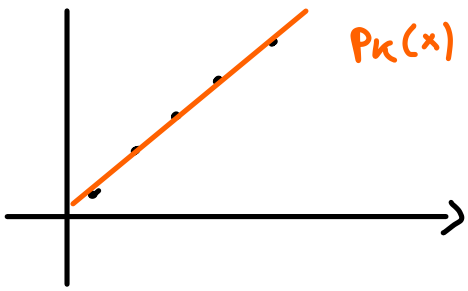

$P_n(x) = a_0 + a_1 x$

la soluzione del sistema lineare sarà $a = \begin{bmatrix} a_0 \\ a_1 \\ \vdots \end{bmatrix}$

dunque il grado lo risolviamo solo quando risolviamo il sistema lineare, Sappiamo che può essere $\leq n$ o $< n$, mai sopra n!

Esempio in Matlab

Prendo $f(x) = e^x$ $x_0 \dots x^n$ nodi equispaziati su $(0,2)$ e calcolo il polinomio interpolante dell'esponenziale per vari gradi!

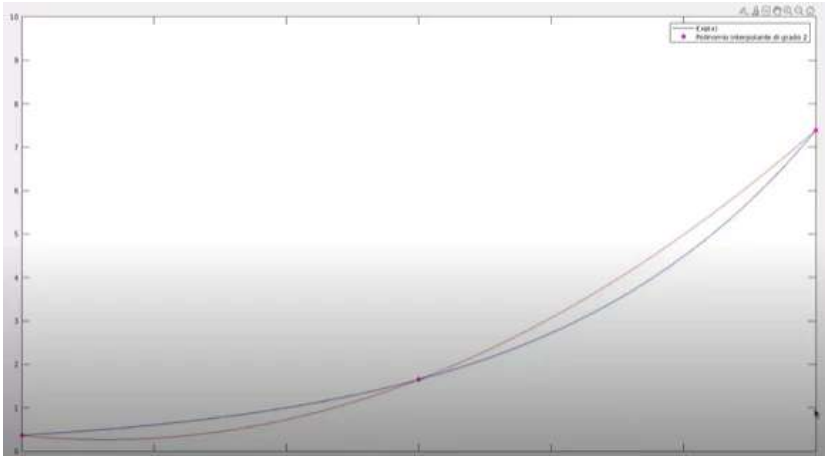

il polinomio di grado due passa per due punti

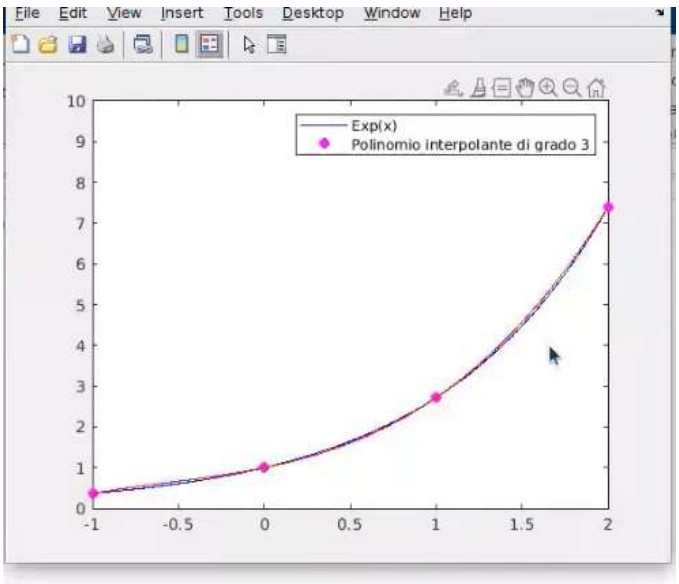

il polinomio di grado 3 passa per tre punti

↳ Si continua così, gradi più grandi passano per tot punti, approssimando meglio la funzione

La volta scorsa abbiamo visto che per trovare $P_k(x)$, si può risolvere un sistema lineare della forma

$$\begin{bmatrix} 1 & x_0 & \dots & x_0^k \\ 1 & x_1 & \dots & x_1^k \\ \vdots & \vdots & & \vdots \\ 1 & x_k & \dots & x_k^k \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_k \end{bmatrix} = \begin{bmatrix} y_0 \\ y_1 \\ \vdots \\ y_k \end{bmatrix}$$

(incognite: $a_0, a_1, \dots, a_k$)

è un sistema $(k+1) \times (k+1)$ con matrice invertibile se $x_i \neq x_j \ \forall i \neq j$

$\curvearrowright$ valori del polinomio nei vari nodi

Per cui se prendo nodi sempre distinti la soluzione è unica ed esiste, ed esiste il polinomio di grado al più $k+1$ che verifica queste condizioni

$\rightarrow$ $P_k(x)$ esiste ed è unico

Se mi danno dei nodi, faccio questo sistema lineare, la risolvo e ho un'espressione del polinomio di interpolazione.

Problema

il problema nel fare questa cosa è che la matrice di Vandermond diventa molto mal condizionata per valori abbastanza piccoli dei nodi!
La matrice ha tipicamente un numero di condizionamento troppo elevato anche per valori piccoli di k (ad esempio se $k > 10$ probabilmente $\text{cond}(V) \approx 10^{20}$)

Esempio in Matlab

genero k punti equidistanti in $(0,1)$, definisco la matrice di Vandermonde e guardo al suo condizionamento in $\|\cdot\|_2$, con il comando cond. $\kappa(A) = \|A\|_2 \cdot \|A^{-1}\|_2$ $\leftarrow$ cond(A,2) fa questo

Codice $k = 7$

```
x = linspace(0,1,k+1)'   % intervallo k+1 punti per creare polinomio di grado 7; vettore colonna di punti
x.^[0:k]
```

↳ Genera una matrice di Vandermode. Prende ogni elemento del vettore colonna x e lo eleva a tutte le potenze specificate nel vettore riga [0:k]
Ogni colonna è data dall'elemento x elevato all'esponente (0,1..k)

```
>> x.^[0:k]

ans =

  Columns 1 through 7

    1.0000         0         0         0         0         0         0
    1.0000    0.1429    0.0204    0.0029    0.0004    0.0001    0.0000
    1.0000    0.2857    0.0816    0.0233    0.0067    0.0019    0.0005
    1.0000    0.4286    0.1837    0.0787    0.0337    0.0145    0.0062
    1.0000    0.5714    0.3265    0.1866    0.1066    0.0609    0.0348
    1.0000    0.7143    0.5102    0.3644    0.2603    0.1859    0.1328
    1.0000    0.8571    0.7347    0.6297    0.5398    0.4627    0.3966
    1.0000    1.0000    1.0000    1.0000    1.0000    1.0000    1.0000

  Column 8

         0
    0.0000
    0.0002
    0.0027
    0.0199
    0.0949
    0.3399
    1.0000
```

V = x.^[0:k] matrice di Vandermode

il condizionamento cond(V) = $2,6782 \cdot 10^8$

```
>> k = 11;
>> x =linspace(0, 1, k+1)';
>> V = x.^[0:k];
>> cond(V)

ans =

   8.8348e+08
```

Se aumento i punti si va su abbastanza in fretta.
La potenza di 10 ci fa perdere accuratezza sul risultato Se ad esempio con Vandermode calcolano i coefficienti ad esempio a 16 cifre, ne perdiamo 8!

Dunque non è una cosa conveniente per l'accuratezza.

Cosa si conclude?
Se ho piccole perturbazioni sui dati $y_0 \dots y_k$ i coefficienti a_j (e quindi $P_k(x)$) variano sensibilmente. Cioè non mi posso

più fidare di cosa vado a calcolare. Cioè se magari cambio di un pochino il punto dove deve passare il polinomio magari questo viene completamente stravolto, quindi non è molto affidabile come approssimazione di f, soprattutto se mi allontano dai nodi x_j.

Questo è un problema numerico è un problema di quando noi andiamo a calcolarci questo P_k,
c'è un modo di aggirare questa cosa, che è cercare una rappresentazione diversa di questo polinomio interpolante

Soluzione Cercare una rappresentazione diversa di $P_k(x)$, posso cercare di formulare il polinomio in un modo diverso che non ha questo problema.
Il problema è la rappresentazione di $P_k = \sum a_j x^j$ come combinazione lineare di $\{1, x, x^2 .. x^k\}$ ← funzioni.

L'idea è cercare una rappresentazione diversa ovvero una combinazione lineare diverse dai monomi.

Quello che si può fare è cercare di scriverci $P_k(x) = \sum_{j=0}^{k} c_j q_j(x)$
dove $q_j(x)$ sono polinomi di grado $\leq k$, (diversi possibilmente da $1, x, x^2$ etc)

Sperando che se $q_j(x)$ sono scelti "bene", il calcolo dei coefficienti c_j, sia più semplice di risolvere il sistema con la VANDERMONDE, (non comporta un sistema malcondizionato, è più conveniente, più stabile rispetto a VANDERMONDE.

NOTA P_k è sempre lo stesso, è solo la maniera in cui si scrive che cambia!

Vediamo due metodi questi due metodi cambiano solo la scelta di funzioni $q_j(x)$

INTERPOLAZIONE di Lagrange Si scelgano come polinomi di base (i $q_j(x)$ di prima) i polinomi seguenti

$$\ell_i(x) = \frac{(x-x_0)(x-x_1)\dots(x-x_{i-1})(x-x_{i+1})\dots(x-x_k)}{(x_i-x_0)(x_i-x_1)\dots(x_i-x_{i-1})(x_i-x_{i+1})\dots(x_i-x_k)} =$$

(si salta quello i!)

($\ell_i(x)$ è polinomio i-esimo)

$$= \frac{\text{Polinomio di grado } k}{\text{COSTANTE (TUTTI numeri)}} = \prod_{\substack{j=1 \\ j\neq i}}^{n} \frac{(x-x_j)}{(x_i-x_j)}$$

Perché questa scelta che può apparire scervellotica è una buona scelta?

Perché vale la seguente proprietà

PROPRIETÀ questi polinomi $\ell_i(x)$ si comportano bene quando li valutiamo nei nodi

$$\ell_i(x_j) = \begin{cases} 1 & \text{se } i=j \\ 0 & \text{se } i\neq j \end{cases}$$

Vuol dire che prendendo dei punti equispaziati

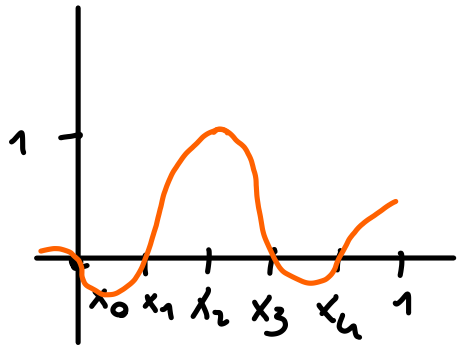

Se consideriamo $\ell_2(x_2)$ vale 1 nel punto x_2 poiché $2=2$ $i=j$ e 0 dalle altre parti.

Questa cosa rende estremamente banale trovarsi i coefficienti c_j della rappresentazione di $P_k(x)$.

Imponiamo $P_k(x_j) = y_j$ vorremo verificare questa condizione

Stiamo supponendo che il nostro polinomio si scriva come

$P_k(x) = \sum c_j \ell_j(x)$, imponendo $P_k(x_h) = y_h$ otteniamo che

$$P_k(x_h) = \sum_{j=0}^{k} c_j \ell_j(x_h) = c_h \ell_h(x_h) = c_h$$

($\ell_j(x_h)$: sono tutti zero tranne per $j = h$; $\ell_h(x_h)$: sappiamo che $= 1$)

a sinistra $P_k(x_h) = y_h \longrightarrow c_h = y_h \quad \forall h = 0 \dots k$

Quindi abbiamo che $P_k(x) = \sum_{j=0}^{k} y_j \cdot \ell_j(x)$

- Con questa formula zero sforzo per calcolmi i coefficienti!
L'unica sforza è calcolarmi i polinomi interpolanti di lagrange!

Esempio

supponiamo di avere la seguente tabella

	x_0	x_1	x_2	x_3
x	0	1	2	-1
y	1	1	3	3
	y_0	y_1	y_2	y_3

4 nodi (grado del polinomio : $k - 1$)

Calcoliamoci i polinomi $\ell_j(x)$ ed il polinomio $P_3(x)$:

- $\ell_0(x) = \dfrac{(x-1)(x-2)(x+1)}{(0-1)(0-2)(0+1)} = \dfrac{(x-1)(x-2)(x+1)}{2}$

- $\ell_1(x) = \dfrac{(x-0)(x-2)(x+1)}{(1-0)(1-2)(1-(-1))} = \dfrac{x(x-2)(x+1)}{2}$

- $\ell_2(x) = \dfrac{x(x-1)(x+1)}{(2-0)(2-1)(2+1)} = \dfrac{x(x-1)(x+1)}{6}$

$$l_3(x) = \frac{x(x-1)(x-2)}{(-1)(-2)(-3)} = -\frac{x(x-1)(x-2)}{6}$$

Stiamo dicendo che questo si scrive come

$$P_3(x) = 1 \cdot l_0(x) + 1 \cdot l_1(x) + 3 l_2(x) + 3 l_3(x)$$

Se sostituiamo a $l_j(x)$ le loro espressioni e facciamo i calcoli otteniamo un'espressione del tipo $a_3x^3 + a_2x^2 + a_1x + a_0$ che si trova risolvendo il sistema VANDERMONDE!

Vediamo un'altra possibilità che ci da dei vantaggi rispetto a Lagrange

Interpolazione di Newton

L'idea è che, nel caso di Lagrange se qualcuno arriva e ci fornisce un'altro punto, con Lagrange bisogna rifare tutto da capo.
Newton permette ogni volta di aggiungere un pezzo se mi vengono forniti nuovi punti mi devo calcolare 1 o 2 termini in più.

Il secondo vantaggio è che nell'interpolazione di newton vedo subito il grado k del polinomio $p_k(x)$.

Nell'interpolazione di newton si scrive $P_k(x) = \sum_{j=0}^{k} c_j n_j(x)$
dove gli $n_j(x)$ sono definiti:

$n_0(x)$ $\quad$ $n_1(x)$ $\quad$ $n_2(x)$ $\quad$ $n_j(x)$

1 $\quad$ $(x-x_0)$ $\quad$ $(x-x_0)(x-x_1)$ $\quad$ $(x-x_0)\dots(x-x_{a_{j-1}})$

$n_k(x)$

$(x-x_0)\dots(x-x_{k-1})$

$n_j(x)$ dipende solo dai nodi $x_0 \dots x_{j-1}$ ed ha grado j.

Inoltre dato che $P_k = \sum_{j=0}^{k} c_j n_j(x)$ si ha che il grado di $P_k(x)$ è il massimo valore di j tale che $c_j \neq 0$.

Chi sono i coefficienti c_j nel caso di Newton?

Si ha (senza dimostrazione) che $c_j = f[x_0, x_1 \dots x_j]$ ←

dove questa quantità è detta differenza divisa di ordine j della funzione f rispetto a $x_0, \dots, x_j$

DEF $f: \mathbb{R} \to \mathbb{R}$ e $x_0 \dots x_{k-1} \in \mathbb{R}$ con $x_i \neq x_j$, la funzione definita per ricorrenza

$$\begin{cases} f[x] = f(x) & \text{differenza divisa in un punto se } k=0 \\ f[x_0, x] = \dfrac{f(x)-f(x_0)}{x-x_0} & \text{se } k=1 \text{ (questo è il rapporto incrementale possiamo immaginarlo come un'approssimazione grezza della derivata in } x_0) \\ \vdots & \\ f[x_0, x_1 \dots x_{n+1}, x] = \dfrac{f[x_0 \dots x_{k-2}, x] - f[x_0, x_1 \dots x_{k-1}]}{x - x_{k-1}} & \text{differenza di due diff divise di ordine inferiore divise scalare} \end{cases}$$

dunque se ogni passaggio lo interpretiamo come un'approssimazione grezza della derivata, l'ultimo sarà un'approssimazione grezza della derivata di ordine k

OSS Per $k=1$ è il rapporto incrementale avevo un'approssimazione "grezza" di $f'(x)$, si può pensare alla differenza divisa di ordine k, come a un'approssimazione di $f^{(k)}(x)$

OSS Per calcolare $c_j = f[x_0, x_1, \dots, x_j]$ tutto quello che ci serve sapere di f sono i valori $f(x_0), f(x_1) \dots f(x_j)$.
y_0 y_1 y_j

Vediamo operativamente, come calcolare le differenze divise

Impostiamo una tabella di calcolo fatta in questo modo:

x	$f(x)$	D.D.1	D.D.2	D.D.3
x_0	$f(x_0)=y_0$ (c_0)			
x_1	$f(x_1)=y_1$	$f[x_0,x_1]$ (c_1)		
x_2	$f(x_2)=y_2$	$f[x_0,x_2]$	$f[x_0,x_1,x_2]$ (c_2)	
x_3	$f(x_3)=y_3$	$f[x_0,x_3]$	$f[x_0,x_1,x_3]$	$f[x_0,x_1,x_2,x_3]$ (c_3)

——— sono i coefficienti che ci servono per il polinomio nella base di Newton

$$f[x_0,x_1] = \frac{f(x_1)-f(x_0)}{x_1-x_0}$$
$$f[x_0,x_1,x_2] = \frac{f[x_0,x_2]-f[x_0,x_1]}{x_2-x_1}$$
$$f[x_0,x_1,x_2,x_3] = \frac{f[x_0,x_1,x_3]-f[x_0,x_1,x_2]}{x_3-x_2}$$

la tabella si può riempire incrementalmente una colonna per volta da Sx a Dx!

Se guardiamo ai dati nella matrice

$$A = \begin{bmatrix} f(x_0) & & & \\ f(x_1) & f[x_0,x_1] & & \\ \vdots & \vdots & \ddots & \\ f(x_k) & f[x_0,x_k] & \dots & f[x_0 \dots x_k] \end{bmatrix}$$

Abbiamo la formula $$a_{ij} = \frac{a_{i\,j-1} - a_{(j-1)(j-1)}}{x_i - x_{j-1}}$$

OSS Calcolare c_j e $n_j(x)$ non richiede di avere accesso a $x_{j+1}, x_{j+2}, \dots$ Quindi se mi vengono dati punti aggiuntivi ad esempio (x_{k+1}, y_{k+1}) abbiamo che $P_{k+1}(x) = P_k(x) + c_{k+1} n_{k+1}(x)$

↳ $\sum_{j=0}^{k} c_j n_j(x)$

Calcolare il pezzo aggiuntivo richiede una riga e una colonna aggiuntive nella tabella di prima!

OSS Nel caso in cui in una colonna della tabella si hanno tutte quantità uguali (tutte le differenze divise di un certo ordine sono uguali) $\Rightarrow$ tutte le colonne seguenti saranno uguali a 0, e quindi il grado di $P_k(x)$ sarà uguale all'ordine delle ultime diff divise $\neq 0$!

L'ultima domanda che ci facciamo è: funziona davvero questo polinomio di interpolazione? è una approssimazione abbastanza accurata della funzione? Quale è l'errore se valuto questo polinomio non nei nodi!

Errore dell'interpolazione Polinomiale

Teorema $x_0, \dots, x_k \in \mathbb{R}$, $x_i \neq x_j \ \forall i \neq j$ $f: \mathbb{R} \to \mathbb{R}$ tale che $f \in C^{k+1}(I)$ con $I \subseteq \mathbb{R}$ intervallo che contiene i nodi $x_0 \dots x_k$.

C^{k+1} = è derivabile $k+1$ volte su I

Se $P_k(x)$ è il polinomio d'interpolazione di grado al più k sui punti $(x_0, f(x_0)), \dots, (x_k, f(x_k))$ allora vale:

$$f(x) - p_k(x) = \pi(x) \cdot \frac{f^{(k+1)}(\xi)}{(k+1)!}$$

polinomio — derivata $k+1$ esima in un punto ξ — $\xi \in I$

$$\pi(x) = (x-x_0) \dots (x-x_k) = \prod_{j=0}^{k} (x-x_j)$$

Più precisamente $\xi \in [\min\{x_0 \dots x_n, x\}, \max\{x_0 \dots x_k, x\}]$
il punto ξ verifica ↑

- ξ non lo conosciamo ma sappiamo dove sta!

OSS Se si conosce una stima dall'alto di $|f^{(k+1)}|$ e di $|\pi(x)|$ su I, si possono dare limitazioni dall'alto sull'errore in punti diversi dai nodi, nodi in cui l'errore è zero, $\neq x_j$.
ξ è il punto x in cui voglio calcolare l'errore, l'errore che si va a calcolare è tutto il blocco a sinistra dell'uguale!

RECAP:	NEWTON	LAGRANGE
BASE USATA	$n_j(x) = (x-x_0)\dots(x-x_{j-1})$	$\ell_j(x) = \prod_{i \neq j} \left(\frac{x-x_i}{x_j-x_j}\right)$
COEF.	$c_j = f[x_0, \dots, x_{j-1}]$	$c_j = y_j$
UPDATE	SE HO CALCOLATO $P_n(x)$ E VOGLIO $P_{k+1}(x)$ DEVO SOLO TROVARE: $n_{k+1}(x)$ e $f[x_0, \dots, x_{k+1}]$	DEVO RICALCOLARE TUTTI GLI $\ell_j(x)$
	POSSO VEDERE IL GRADO FACILMENTE E' L'ULTIMO $c_j \neq 0$	PER OTTENERE IL GRADO DEVO ESPANDERE P_k NELLA BASE DEI MONOMI
INDIPENDENTEMENTE DALLA BASE, L'ERRORE VERIFICA: $+ P_k(x) - f(x) = \pi(x) \cdot f^{(k+1)}(\xi) \cdot \frac{1}{(k+1)!}$		

Abbiamo detto che, se abbiamo $k+1$ punti $(x_0, y_0) \dots (x_k, y_k)$ c'è un unico polinomio di grado al più k che ci passa.
Questa cosa viene fatta per approssimare una certa funzione incognita

Oss Se la funzione $f(x)$ è anch'essa un polinomio di grado al k allora necessariamente $f = P_k(x)$

Si sono visti tre modi per rappresentare P_k — Vandermode, Lagrange, Newton

L'errore di approssimazione è dato da $f(x) - P_k(x) = \pi(x) \cdot \frac{f^{(k+1)}(\xi)}{(k+1)!}$ *

Si sa che $\xi \in [x_0, x_k]$ $\quad x_0 < x_1 < \dots x_k \quad x \in [x_0, x_k]$
dunque non si sa bene chi è ma si sa dove sta e si prova a stimare questa quantità! *

Se mi serve un'alta precisione sulla mia approssimazione l'unica arma che ho è aumentare il grado k di $p_k(x)$.
Questo comporta due tipi di svantaggi:

- avere più punti dove conoscere $f(x)$
- effetti oscillatori, Fenomeno di runge

Esempio $f(x) = \frac{1}{1+25x^2}$ su $[-1,1]$ calcolo $P_k(x)$ per k crescenti

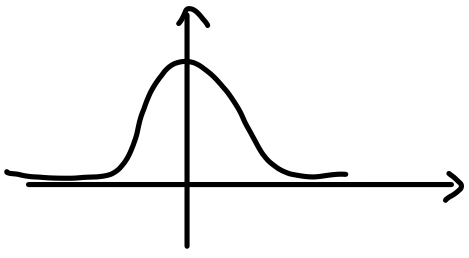

Andiamo a vedere cosa fa con Matlab il polinomio interpolante

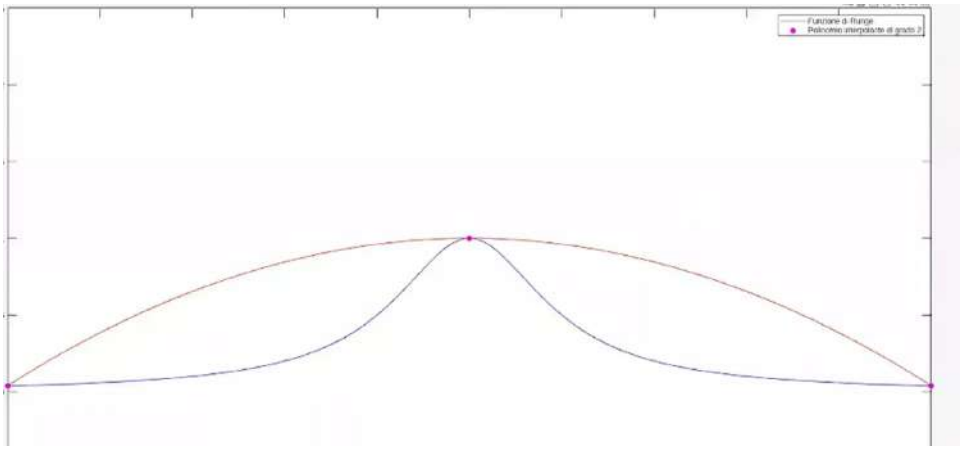

Grado 2

3 punti x_0, x_1, x_2

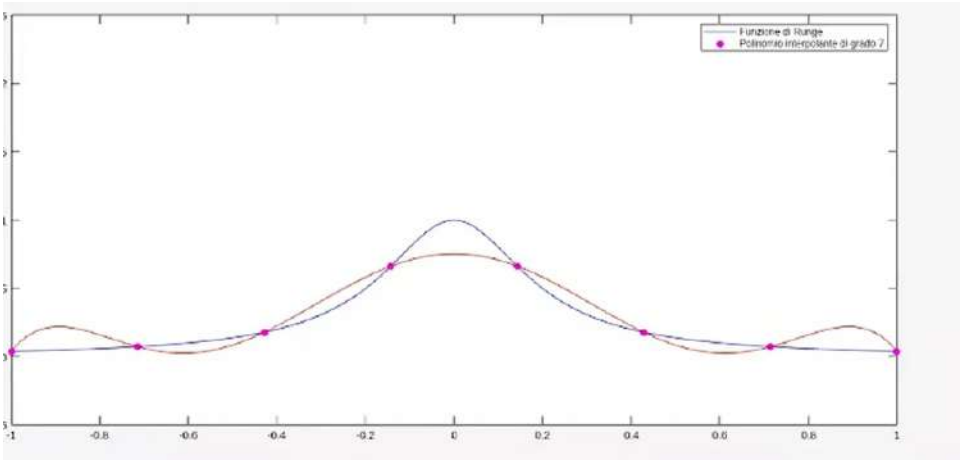

Grado 7

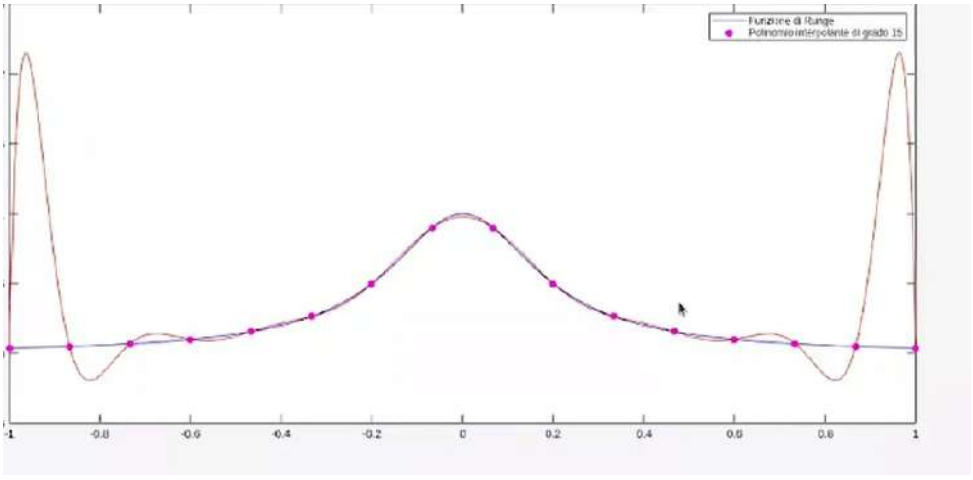

Grado 15

Se notiamo ai lati ci sono delle oscillazioni un pò strombe, no delle oscillazioni sempre più estreme

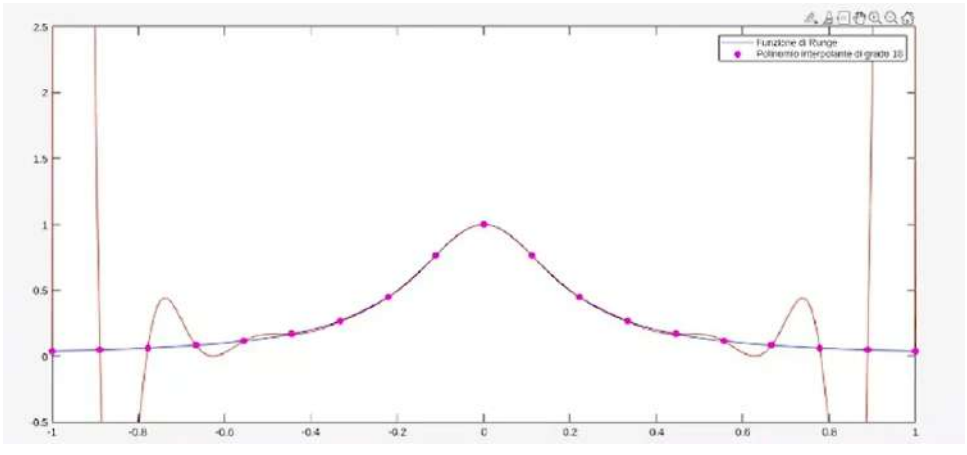

Grado 18

Continua ad esplodere!

PROBLEMA La scelta nei nodi equispaziati non è la migliore, in genere quello che si fa è prendere punti che si accumulano sugli estremi

dell'intervallo (ed esempio i nodi di Chebyshev)

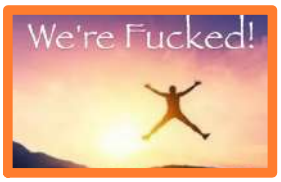

BRUTTA NOTIZIA DALLA TEORIA

C'è il seguente Teorema

Teorema Faber

Informale qualunque strategia io fisso di scelta dei nodi, (nodi equispaziati, di Chebyshev etc). Posso sempre costruire una funzione per cui quella scelta del polinomio di interpolazione non funziona bene, vedo se con il grado e il polinomio interpolante non converge alla funzione

formale $\forall$ strategia di scelta dei nodi $\exists\ f \in C[a,b]$ tale che se faccio $\lim_{k \to +\infty} \max_{x \in [a,b]} |f(x) - p_k(x)| \neq 0$

Dunque quando interpoli una funzione f con un polinomio p_k di grado k, speri che aumentando il grado k il polinomio si avvicini sempre di più ad f. Cioè vorrei che

$$\max_{x \in [a,b]} |f(x) - p_k(x)| \to 0 \quad \text{per } k \to \infty$$

Ma così non è, esiste sempre una funzione continua f per cui l'interpolazione non converge, per una qualunque strategia di scelta dei nodi.

Conclusione non c'è una scelta universalmente buona di nodi per l'interpolazione.

Quindi Cosa fare?

opzione 1: interpolazione polinomiale a tratti

- Si divide $[a,b]$ in sottointervalli contenenti un numero moderato di nodi di interpolazione
- Si calcola il polinomio d'interpolazione in ciascun sottointervallo
- Si usa come approssimazione $F(x) \approx f(x)$ (approssimante) la funzione definita a tratti, come i vari polinomi interpolanti

Esempio (interpolazione lineare a tratti)

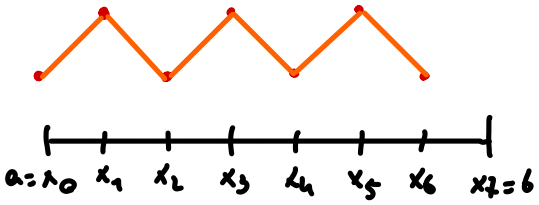

$$F(x) = \begin{cases} m_0 x + n_0 & \text{su } [x_0, x_1] \\ m_1 x + n_1 & \text{su } [x_1, x_2] \\ \vdots & \vdots \end{cases}$$

opzione 2: approssimazione ai minimi quadrati

Supponiamo di avere $(x_0, y_0) \dots (x_k, y_k)$ con k grande.
Vogliamo generalizzare l'interpolazione in due direzioni

1. approssimare f con qualcosa che non sia necessariamente un polinomio
2. usare una combinazione lineare di m funzioni elementari con $m < k$ (poche funzioni)

In definitiva cerchiamo un'approssimazione $\Phi(x) \approx f(x)$ con

$$\Phi(x) = \sum_{i=0}^{m} c_i \varphi_i(x)$$

(φ_i: funzioni elementari)

$\varphi_i(x) : \mathbb{R} \to \mathbb{R}$ funzioni modello (elementari)

Esempio

$$\varphi_0(x) = e^{2x} \qquad \varphi_1(x) = \sin\left(\frac{x}{2}\right) \qquad \varphi_2(x) = \frac{1}{3x^2+4}$$

$$\Phi(x) = c_0 \cdot e^{2x} + c_1 \sin\left(\frac{x}{2}\right) + \frac{c_2}{3x^2+4}$$

per qualche scelta di $c_0, c_1, c_2 \in \mathbb{R}$

Cerco una funzione fatta così che approssimi bene questi dati

Le $\varphi_i(x)$ le scelgo io, i coefficienti vanno determinati nel modo migliore!

OSS nel caso dell'interpolazione avevamo $m = k$ e $\varphi_j(x)$ polinomio di grado al più k

Esempio (regressione lineare)

Vogliamo approssimare tutto con una retta

$\varphi_0(x) = 1$

$\varphi_1(x) = x$ $\quad\quad \Phi(x) = c_0 + c_1 x$

È ragionevole qui imporre una condizione di interpolazione!

Come si scelgono i coefficienti c_i?

Una risposta breve e intuitiva: la scelta dipenderà da

$(x_0, y_0) \dots (x_k, y_k)$

Anche qui si vuole guardare alla scarto tra la funzione approssimante che si genera e i dati!

Si guarda alla differenza tra $\Phi(x)$ e $f(x)$ e si cerca di stabilire un criterio ragionevole

Si va a vedere

x_j è un certo punto

$$\Phi(x_j) - f(x_j)$$

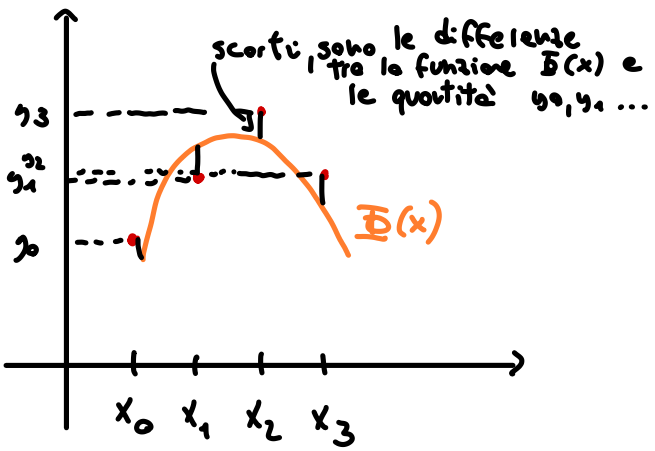

Con questi scarti ci devo fare qualcosa voglio scegliere c_i, affinché questi siano minimi in qualche senso!

Un primo criterio potrebbe essere $\sum_{j=0}^{k} \Phi(x_j) - f(x_j)$ ← minimizzare

somma questi scarti

Però per effetto di cancellazione tra scarti positivi e negativi potrei

ottenere approssimazioni poco accurate!

↳ allora potrei prendere $\sum_{j=0}^{k} |\Phi(x_j) - f(x_j)|$

Cioè se trovo un'approssimazione che rende piccola questa quantità qua, è una buona approssimazione
Però non è differenziabile!

Allora prendiamo:

$$\Psi(c) \overset{psi}{=} \Psi(c_0, c_1 \dots c_m) = \sum_{j=0}^{k} (\Phi(x_j) - f(x_j))^2$$

E scegliamo $c_0 \dots c_m$, come quelli per cui si ottiene

$$\min_{c_0 \dots c_m} \Psi(c) = \min_{c_0 \dots c_m} \sum_{j=0}^{k} (\Phi(x_j) - f(x_j))^2 =$$

($\Phi(x_j)$: questa è la parte che dipende da $c_0 \dots c_m$)

$$= \min_{c_0 \dots c_m} \sum_{j=0}^{k} \left[\sum_{i=0}^{m} c_i \varphi_i(x_j) - f(x_j) \right]^2 *$$

Approssimare f nel senso dei minimi quadrati rispetto alle funzioni φ_j e ai punti $(x_0, y_0) \dots (x_k, y_k)$ significa risolvere *

OSS

Cosa succede se aumento i coefficienti c_j?
Aumentare i coefficienti c_j, significa che stiamo considerando più funzioni modello, l'errore inteso come valore della Ψ, andrà meglio, sicuramente non crescerà perché sto minimizzando, su un'insieme più ampio di funzioni, l'errore sicuramente diminuisce, vado più vicino ai punti sicuramente.
Se si aumenta il numero di funzioni modello (le φ_j) il valore di $\Psi(c)$ non aumenta, ma non è detto che sia migliore l'approssimazione, dipende da quanto è sensata la scelta delle φ_j.

Abbiamo definito questi ci come soluzioni per problemi di minimo
Adesso diciamo come SI RISOLVE IL PROBLEMA DI MINIMO!

OSS lo funzione $\Psi(c)$ si può vedere come la norma 2 al quadrato di un certo vettore!

$$\Psi(c) = \left\| \begin{bmatrix} \Phi(x_0) - f(x_0) \\ \Phi(x_1) - f(x_1) \\ \vdots \\ \Phi(x_k) - f(x_k) \end{bmatrix} \right\|_2^2 = \left\| \begin{bmatrix} \Phi(x_0) \\ \vdots \\ \Phi(x_k) \end{bmatrix} - \begin{bmatrix} f(x_0) \\ \vdots \\ f(x_k) \end{bmatrix} \right\|_2^2$$

Vogliamo adesso far comparire qualcosa della forma $Ax=b$

Osserviamo come è fatta un'entrata $*$ questo vettore

$\Phi(x_j) = \sum_{i=0}^{m} c_i \varphi_i(x_j)$ corrisponde al prodotto scalare tra

vettore c_i — vettore valutazione funzione modello in x_j

il vettore c ed il vettore $[\varphi_0(x_j) \dots \varphi_m(x_j)]$ Ci possiamo scrivere tutto come prodotto matrice vettore

$$\begin{bmatrix} \Phi(x_0) \\ \vdots \\ \Phi(x_k) \end{bmatrix} = \begin{bmatrix} \varphi_0(x_0) \varphi_1(x_0) \dots \varphi_m(x_0) \\ \varphi_0(x_1) \varphi_1(x_1) \dots \varphi_m(x_1) \\ \vdots \\ \varphi_0(x_k) \varphi_1(x_k) \dots \varphi_m(x_k) \end{bmatrix} \cdot \begin{bmatrix} c_0 \\ \vdots \\ c_m \end{bmatrix} \qquad b = \begin{bmatrix} y_0 \\ | \\ y_n \end{bmatrix} = \begin{bmatrix} f(x_0) \\ | \\ f(x_k) \end{bmatrix}$$

$$\Psi(c) = \|Ac - b\|_2^2$$

È un problema ai minimi quadrati associato a un sistema sarà determinato con $(k+1)$ equazioni in $(m+1)$ incognite.

Il sistema è $\begin{cases} \Phi(x_0) = f(x_0) \\ \vdots \\ \Phi(x_n) = f(x_n) \end{cases}$ $\quad Ac = b$

Conclusione Esistono sempre dei ci che minimizzano questa ottimi!
problema, sono unici se la matrice A ha rango max. e per trovarli possiamo usare metodo delle equazioni normali oppure metodo QR!

Integrazione numerica

Il nostro obiettivo questa volta è STIMARE quantità della forma integrali definiti

↳ vogliamo fornire dei metodi PRATICI per calcolare/stimare quantità della forma:

* $I(\rho \cdot f) = \int_a^b f(x) \cdot \rho(x)\,dx$ (Integrale di $\rho \cdot f$; ρ = funzione peso)

dove $[a,b] \subseteq \mathbb{R}$
$f(x) \in C[a,b]$
$\rho(x) \geq 0$ su $[a,b]$

* questa è la quantità esatta, dunque

Perchè approssimare?

(i) di molte funzioni non c'è la primitiva (spesso succede per funzioni a più variabili)

(ii) Anche se la primitiva c'è può essere costoso valutarla o trovarla

(iii) A volte non conosciamo f, è disponibile solo in alcuni punti $f(x_j)$ oppure f disponibile solo come black-box. (conosco input e output ma non la formula)

IDEA: Approssimare $\int_a^b f(x)\,\rho(x)\,dx$ con una formula di questo tipo

$$J_n(f) = \sum_{j=0}^{n} a_j f(x_j)$$

(n = numero dei nodi se un n ne sto usando $n+1$; a_j = coeff = pesi; $f(x_j)$ = funzione valutata in... = nodi)

Formula di quadratura

Supponendo di avere $a \leq x_0 < x_1 < \dots < x_n \leq b$ $\quad a_0 \dots a_n \in \mathbb{R}$

Dunque se ho a disposizione solo delle valutazioni della funzione in certi punti voglio combinarle con certi coefficenti per dare una STIMA dell'integrale!

$$J_n(x) \overset{\text{approssima}}{\approx} I(\rho \cdot f)$$

La domanda è, è una buona idea?

La risposta è, dipende da come scelgo questi coefficienti

DEF Definiamo l'errore di questa formula come segue

$$E_n(f) = I(gf) - J_n(f)$$

Un criterio possibile per capire quanto è accurata un'espressione di questa tipo qua $J_n(f)$ è vedere per funzioni elementari quando è esatta, cioè quando il valore della formula torna il valore esatto dell'integrale e le funzioni più semplici per le quali si conosce l'integrale in forma chiusa sono i monomi.

DEF La formula di quadratura $J_n(f)$ ha grado di precisione $m \in \mathbb{N}$ se verifica che

integrale funz. 1 — integrale $f=x$ — integrale $f=x^m$

$$0 = E_n(1) = E_n(x) = \dots = E_n(x^m) \quad \text{e}$$

$$E_n(x^{m+1}) \neq 0$$

Se vale questa cosa la precisione ha grado m.

OSS Data che l'operatore integrale e la formula di quadratura sono lineari nella funzione da integrare abbiamo che:

$$I(c_1 f_1 + c_2 f_2) = \int_a^b (c_1 f_1 + c_2 f_2) g(x)\,dx = c_1 \int_a^b f_1\, g(x)\,dx + c_2 \int_a^b f_2 g(x)\,dx$$
$$= c_1 I(f_1) + c_2 I(f_2)$$

Vale lo stesso per la formula di quadratura seguente

$$J_n(c_1 f_1 + c_2 f_2) = \sum_{j=0}^{n} a_j (c_1 f_1(x_j) + c_2 f_2(x_j)) =$$

$$= c_1 \sum a_j f(x_j) + c_2 \sum_{j=0}^{n} a_j f(x_j) = c_1 J_n(f_1) + c_2 J_n(f_2)$$

$\Rightarrow$ Avere grado di precisione m, significa che la formula di

quadratura è esatta per polinomi di grado $\leq m$!

Si può usare il criterio di massimizzare il grado di precisione per trovare formule di quadratura

Esempio $\int_{-1}^{1} f(x)\,dx$ $\quad (a=-1 \quad b=1 \quad \underset{\text{funzione peso}}{\rho(x)=1})$

Inoltre supponiamo di prendere come nodi $\underset{\text{nodi}}{x_0=-1 \quad x_1=1}$

Vogliamo trovare una formula del tipo $J_1(f) = a_0 f(-1) + a_1 f(1)$

La domanda che ci poniamo è, quali coefficienti a_1, a_{-1} rendono massimo il grado di precisione?

- Partiamo dall'integrare la funzione 1, l'errore che faccio su di essa

$$E_1(1) = \int_{-1}^{1} 1\,dx - J_1(1) = 2 - \underbrace{(a_0 + a_1)}_{\text{con } f(x)=1 \text{ vale sempre 1!!}} \overset{\text{impongo che sia 0}}{=} 0$$

- Siccome ho due parametri voluto anche

$$E_1(x) = \int_{-1}^{1} x\,dx - J_1(x) = 0 - \underbrace{(-a_0 + a_1)}_{\text{con } f(x)=x \text{ vale } x \text{ stesso che c'è dentro!}} = 0$$

ho il sistema

$$\begin{cases} a_0 + a_1 = 2 \\ a_0 - a_1 = 0 \end{cases} \quad \begin{cases} a_0 = a_1 = 1 \end{cases}$$

$$J_1(f) = f(-1) + f(1)$$

Che grado di precisione ha? almeno 1! $\quad f(x)=1$ grado 0 ✓ $\quad f(x)=x$ grado 1 ✓

Verifichiamo adesso l'errore su $f(x^2)$

$$E_1(x^2) = \int_{-1}^{1} x^2 dx - J_1(x^2) = \frac{2}{3} - 2 \neq 0$$

lo formula sbaglia su x^2, quindi il grado di precisione è esattamente uno! $m = 1$

Questa formula di quadratura si chiama formula dei trapezi

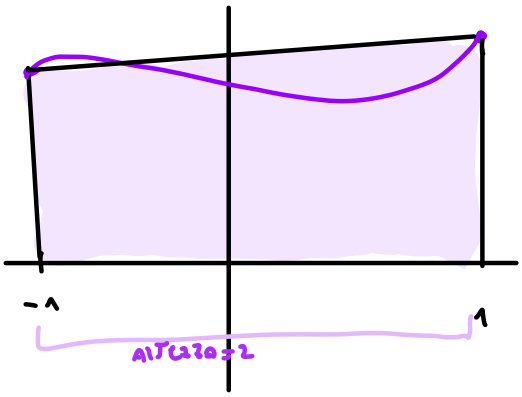

facciamo un grafico
se facciamo una curva e poi uniamo i punti notiamo che stiamo calcolando l'area di un trapezio!

$$J_1(f) = f(-1) + f(1) = \text{base maggiore} + \text{base minore} \cdot \frac{\text{altezza}}{2}$$

(altezza = 2, quindi $\frac{2}{2} = 1$) ⟶ formula dei trapezi su $[-1,1]$

Quello che noi stiamo facendo è: la regola del trapezio approssima la funzione con una retta tra $f(-1)$ e $f(1)$ e calcola l'area sotto quella retta invece che sotto la curva vera!

Si può generalizzare ad un intervallo $[a,b]$ qualsiasi:

$$\int_a^b f(x)\,dx \approx \frac{[f(a) + f(b)](b-a)}{2}$$

(base, altezza)

X CASA dimostrare che la formula su $[0,1]$ è quella che massimizza il grado se si usano come nodi gli estremi intervallo!

Esempio 2 Supponiamo di aggiungere un nodo per ottenere una formula più accurata, prendiamo come nodi $x_0 = a$ $x_1 = \frac{a+b}{2}$ $x_2 = b$

Caso $a = -1$, $b = 1$ $\longrightarrow$ $x_0 = -1$ $x_1 = 0$ $x_2 = 1$

$$J_2(f) = a_0 f(-1) + a_1 f(0) + a_2 f(1)$$

[Cerchiamo come al solito a_0, a_1, a_2 in modo che abbia grado di precisione massimo la formula]

Imponiamo

$$E_1(1) = \int_{-1}^{1} 1\,dx - (a_0 + a_1 + a_2) = 2 - a_0 + a_1 + a_2$$

$$E_2(x) = 0 - (a_0 + a_2) = 0$$

$$E_2(x^2) = \frac{2}{3} - (a_0 + a_2) = 0$$

NOTA Se ho $n+1$ nodi ho $n+1$ coefficienti $a_0, a_1 \dots a_n$, quindi posso imporre $n+1$ errori uguali a zero, cioè esattezza su $1, x, x^2 \dots x^n$!

Ritornando a noi il nostro sistema lineare sarà del tipo

$$\begin{cases} a_0 + a_1 + a_2 = 2 \\ a_0 = a_2 \\ a_0 + a_2 = \frac{2}{3} \end{cases}$$

Risolvendo $\longrightarrow$ $a_0 = \frac{1}{3}$, $a_2 = \frac{1}{3}$, $a_1 = \frac{4}{3}$

La nostra formula diventa

$$J_2(f) = \frac{f(-1)}{3} + \frac{4}{3} f(0) + \frac{f(1)}{3} = \frac{1}{3}\left(f(-1) + 4f(0) + f(1)\right)$$

Questa è una formula nota si chiama formula di Simpson su $[-1,1]$ (o cavolieri simpson)

Che grado di precisione ha? almeno 2! Verifichiamo che sia esattamente 2!

$$E_2(x^3) = 0 - \left(-\frac{1}{3} + \frac{1}{3} \right) = 0$$ Il grado di precisione è almeno 3!

$$E_2(x^4) = \frac{2}{5} - \left(\frac{1}{3} + \frac{1}{3} \right) = \frac{2}{5} - \frac{2}{3} \neq 0$$

⟶ il grado di precisione della formula di simpson è $m=3$!

Su un generico intervallo $[a,b]$ la formula di simpson è

$$J_2(f) = \frac{b-a}{6} \left[f(a) + 4f\left(\frac{a+b}{2} \right) + f(b) \right]$$

Interpretazione Grafica di Simpson

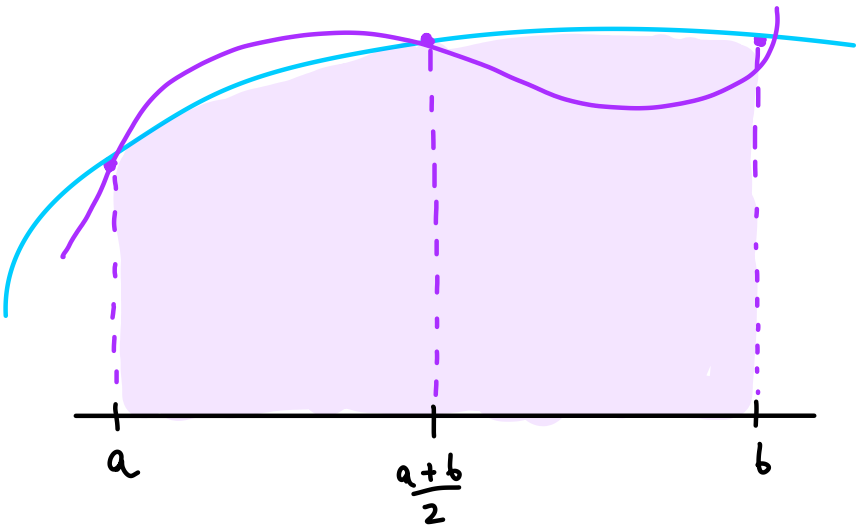

Quello che fa Simpson è trovare l'integrale del polinomio di grado 2 che passa per i punti, e calcola l'area sottesa dalla parabola

L'idea è calcolo il polinomio di grado due che interpola la funzione nei punti a, b e $\frac{a+b}{2}$, approssima l'integrale di f con l'integrale di p e viene proprio fuori la formula di Simpson!

OSS Abbiamo assunto in questi esercizi che la funzione **PESO** fosse 1 $g(x)=1$, se prendiamo un peso diverso da 1, l'unica cosa che cambia è quando calcoliamo l'integrale esatto, questo cambia nella formula di $E_n(x^j) = \int_a^b x^j \rho(x)dx - J_n(x^j)$

Abbiamo visto che se i nodi sono dati, calcolare i coefficienti (pesi) che massimizzano il grado, ci comporta risolvere un sistema lineare $(n+1)\times(n+1)$

↳ Se voglio ottimizzare sia sui pesi, che sui nodi, mi trovo a dover risolvere un sistema di equazioni non lineari.

Esempio

facciamo $\rho(x)=1$ su intervallo $[-1,1]$, supponiamo di voler approssimare

$$\int_{-1}^{1} f(x)dx \approx a_0 f(x_0) + a_1 f(x_1)$$

ho 4 parametri da scegliere/trovare $\rightsquigarrow$ impongo 4 equazioni

Impongo che $E_1(1) = E_1(x) = E_1(x^2) = E_1(x^3) = 0$

Si ottiene: Integrale esatto funzione - formula di quadratura

$$\begin{cases} a_0 + a_1 = 2 \\ a_0 x_0 + a_1 x_1 = 0 \\ a_0 x_0^2 + a_1 x_1^2 = \frac{2}{3} \\ a_0 x_0^3 + a_1 x_1^3 = 0 \end{cases}$$

Le incognite sono a_0, a_1, x_0, x_1

Queste cose sono non lineari, ma questo sistema ha una struttura abbastanza speciale e si può sempre trovare la soluzione! Ed è anche unica.

Si può verificare con qualche manipolazione algebrica che la

soluzione esiste, ed è

$$x_0 = -\frac{\sqrt{3}}{3} \qquad x_1 = \frac{\sqrt{3}}{3} \qquad a_0 = a_1 = 1$$

La formula sarà $J_1(f) = f\left(-\frac{\sqrt{3}}{3}\right) + f\left(\frac{\sqrt{3}}{3}\right)$ — questa ha grado di precisione più alto possibile se posso scegliere sia i nodi che i pesi

Quanto è il suo grado di precisione "dmeno"? 3! Poiché abbiamo imposto che $E(x^3) = 0$

Verifichiamo che non sia 4

$$E_1(x^4) = \frac{2}{5} - \left(\frac{9}{3^4} + \frac{9}{3^4}\right) = \frac{2}{5} - \frac{2}{9} \neq 0$$

$\Rightarrow$ il grado di precisione è esattamente tre → è più precisa di quella dei trapezi

Ma questa è valutabile in $f\left(-\frac{\sqrt{3}}{3}\right) + f\left(\frac{\sqrt{3}}{3}\right)$? non è detto! non conosciamo magari la f!. Quindi non è detto che si può usare sempre la formula migliore! Però se ho la f la scelta migliore è questa;

In generale per qualsiasi intervallo $[a,b]$ e un generico numero di nodi $n+1$, e un qualsiasi peso $\rho(x)$ la formula di quadratura che massimizza il grado al variare di nodi e pesi, verifica il sistema non lineare:

$$(*)\begin{cases} a_0 + a_1 + ____ + a_n = m_0 \\ a_0 x_0 + a_1 x_1 + ____ + a_n x_n = m_1 \\ a_0 x_0^2 + a_1 x_1^2 + ____ + a_n x_n^2 = m_2 \\ \vdots \\ a_0 x_0^{2n+1} + a_1 x_1^{2n+1} + a_n x_n^{2n+1} = m_{2n+1} \end{cases}$$

sistema di $2n+2$ equazioni in $2n+2$ incognite!

dove gli m_J sono gli integrali esatti $m_J = \int_a^b x^J \cdot \rho(x)\,dx$

Teorema il sistema $(*)$ ammette sempre un'unica soluzione!
(qualunque scelta di $[a,b]$, n e $\rho(x)$)

DEF le formule di quadratura che verificano $(*)$ vengono dette formule Gaussiane!

oss Il grado di precisione di una formula Gaussiana è almeno $2n+1$ e sono le uniche con un grado di precisione così alto tra quelle che hanno lo stesso numero di nodi!

Parliamo adesso di errore, voglio dare una stima se uso le formule di quadratura al posto dell'integrale esatto

Errore delle formule di quadratura (in generale!)

Vale il seguente risultato che caratterizza l'errore in termini del grado di precisione

Teorema di Peano Se $f(x) \in \mathcal{C}^{m+1}([a,b])$ (abbastanza derivabile $m+1$ volte), ed $J_n(f)$ ha grado di precisione $m \in \mathbb{N}$ allora vale:

$$E_n(f) = I(f) - J_n(f) \overset{\text{si può scrivere come}}{=} \frac{1}{(m+1)!} \int_a^b f^{(m+1)}(t) \cdot G(t)\,dt$$

($f^{(m+1)}$: derivata; $E_n(f)$: errore che la formula di quad. fa su una funzione speciale s)

dove $G(t) = E_n(s_m(x-t)) = I(s_m(x-t)) - J_n(s_m(x-t)) = \int_a^b s_m(x-t)\,\rho(x)\,dx - J_n(s_m(x-t))$

$$s(x) = \begin{cases} x^m & \text{se } x \geq 0 \\ 0 & \text{se } x \leq 0 \end{cases}$$

graficamente

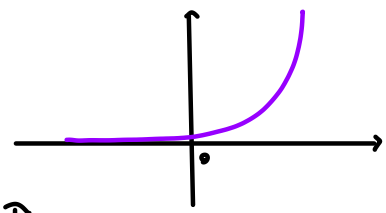

in particolare $s_m(x-t) =$

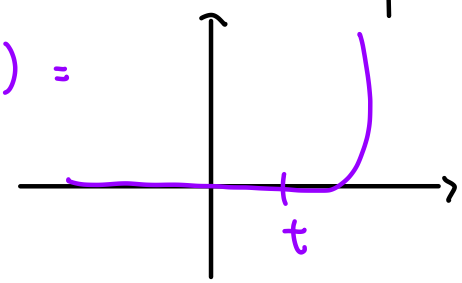

NOTA

m grado di precisione, n numero nodi, t variabile ausiliaria posizione generica in $[a,b]$

$G(t)$ è detta **NUCLEO DI PEANO!**

$$\int_a^b f^{(m+1)}(t) \cdot G(t)\,dt$$

→ Vediamo da dove viene questa formula è l'errore che viene fatto sul resto dell'approssimazione di Taylor su questa funzione

Cioè stiamo dicendo che per calcolare l'errore su una f generica la si calcola con il nucleo di Peano su $(x-t)_+^m$, una funzione semplice. L'errore totale su f si ottiene poi integrando $G(t)$ pesato da $f^{(m+1)}(t)$ (nucleo di peano sarebbe l'errore della formula di quadratura quando si va ad integrare una funzione del tipo $(x-t)_+^m$))

Esempio

il nucleo di Peano dipende solo dalla formula di quadratura e dal grado di precisione, calcoliamolo per la formula dei trapezi su $[a,b] = [-1,1]$ con $m=1$

$G(t) : [a,b] \longrightarrow \mathbb{R}$ ha un certo valore di t $\xrightarrow{\text{che associa}}$

$$\int_a^b G(t)\, f(x)\,dx - I_n(G(t)) = \int_t^b (x-t)^m f(x)\,dx - I_n\left((x-t)_+^m\right)$$

nel caso della formula dei trapezi abbiamo $(n=1)$

$$G(t) = \int_t^1 (x-t)\,dx - \underbrace{\left[\overbrace{(-1-t)_+}^{=0 \ -1-t<0 \ \forall t\in(-1,1]} + \overbrace{(1-t)_+}^{=1-t}\right]}_{\text{Valore della formula di quadratura dei trapezi per questa funzione}} =$$

$$= (x-t)^2\Big|_t^1 - \left[0 - (1-t)\right] =$$

$$= \frac{(1-t)^2}{2} + 1 - t = \frac{t^2-1}{2} = \text{nucleo di peano per la formula dei trapezi su } [-1,1]$$

Una volta nota $G(t)$ l'errore della formula dei trapezi applicata a qualsiosi f è

$$E_1(f) = \frac{1}{2!}\int_{-1}^1 f''(t)\cdot\frac{t^2-1}{2}\,dt$$

- $s(1) = \begin{cases} x & x\geq 0 \\ 0 & x<0 \end{cases}$ per $t\in[-1,1]$

  - $-1-t$: $-1-(-1)=0$ e $-1-1=-2$ dunque $-1-t\leq 0$ sempre $(-1-t)_+=0$
  - $1-t$: $+1-(-1)=2$ e $1-1=0$ $(1-$

Proprietà importante nel caso in cui $G(t)$ non cambi segno per $t \in [a,b]$ (cosa verificata nell'esempio dei trapezi) la formula dell'errore si semplifica, possiamo applicare il teorema della media integrale alla formula data nel teorema di Peano!

$$\frac{1}{(m+1)!}\int_a^b G(t) f^{m+1}(t)\,dt = \frac{1}{(m+1)!} f^{m+1}(\xi) \int_a^b G(t)\,dt$$

f^{m+1} è $\xi \in [a,b]$

se non cambia segno, possiamo scrivere

Oss che per $f = x^{m+1}$ otteniamo che:

$$\underbrace{E_n(x^{m+1})}_{\text{errore fatto in } x^{m+1}} = \frac{(m+1)!}{(m+1)!}\int_a^b G(t)\,dt = \int_a^b G(t)\,dt$$

Corollario

Se $f \in \mathcal{C}^{m+1}([a,b])$, m grado di precisione di $J_n(f)$ e $G(t)$ non cambia segno in $[a,b]$ allora:

$$E_n(f) = \frac{f^{(m+1)}(\xi)}{(m+1)!} \cdot E_n(x^{m+1})$$

Esempio

nel caso dei trapezi su $[a,b]$ si vede graficamente che $G(t)$ non cambia segno

$$G(t) = \int_a^b s_m(x-t)\,dx - J_n(s_m(x-t))$$

Per i trapezi $m=1$ ed $s_m(x-t) = \begin{cases} x-t & \text{se } x \geq t \\ 0 & \text{altrove} \end{cases}$

dunque $G(t)$ è la differenza tra

- l'integrale esatto di $D_n(x-t)$
- l'approssimazione con i trapezi di $D_n(x-t)$

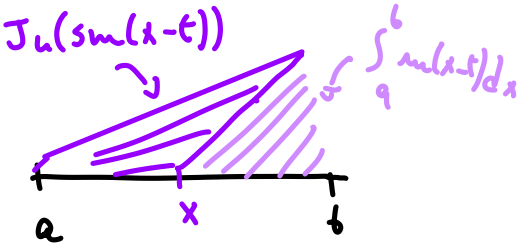

dunque $J_n(sm(x-t)) \geq \int_a^b sm(x-t)dx$

$\longrightarrow G(t) = \int_a^b sm(x-t)dx - J_n(sm(x-t)) \leq 0 \quad \forall t \in [a,b]$

Quindi si può usare la formula di sopra per stimare l'errore della formula dei trapezi.

$$E_1(f) = \frac{f''(\xi)}{2!} \cdot \underbrace{E_1(x^2)}_{\text{errore sulla formula dei trapezi applicata a } x^2} = \frac{f''(\xi)}{2}\left(\int_a^b x^2dx - \frac{b^2+a^2}{2}\right) =$$

$$= \frac{f''(\xi)}{2}\left[\frac{b^3-a^3}{3} - \frac{(b^2+a^2)(b-a)}{2}\right] = -\frac{(b-a)^3}{6}\cdot\frac{f''(\xi)}{2} =$$

$$= -\frac{(b-a)^3}{12} f''(\xi) \longrightarrow \text{errore associato alla formula dei trapezi su } [a,b]$$

Esempio (x Simpson) facciamo il calcolo dell'errore anche per la formula di Simpson $\longrightarrow$ non sappiamo se Simpson ha la proprietà del nucleo di Peano che non cambia segno!
(anche per Simpson $G(t)$ non cambia segno. Supponendo $a=-b$ $b=1$

In questo caso $n=3$

$$E_2(x^4) = \int_{-1}^{1} x^4dx - J_2(f) = \frac{2}{5} - \frac{2}{3} = -\frac{4}{15}$$

$$E_2(f) = -\frac{4}{15}\cdot\frac{f^{(iv)}(\xi)}{4!} = -\frac{1}{90}f^{(iv)}(\xi) \qquad \xi \in [-1,1]$$

Su $[a,b]$ generico viene

$$E_2(f) = -\frac{(b-a)^5}{2880} \cdot f^{(IV)}(\xi)$$

errore della formula di simpson $[a,b]$

Parliamo delle formule di Simpson e dei trapezi da un punto di vista più generale!

- formula dei trapezi corrisponde a prendere la linea che unisce il valore di $f(a)$ e $f(b)$ (un polinomio di grado 1) e integrare quello
- formula di Simpson si integra un polinomio interpolante di grado 2

Questo concetto si può generalizzare a, prendo un pò di nodi e faccio il polinomio interpolante di questi punti e uso l'integrale di questo polinomio come approssimazione della funzione

Questa idea è alla base delle formule di quadratura interpolatorie cui simpson e trapezi sono le istanze più semplici (quelle con meno nodi)

formule di quadratura interpolatorie

Idea: per stimare $\int_a^b f(x)\,p(x)\,dx$ uso $\int_a^b P_n(x)\,p(x)\,dx$

ove $P_n(x)$ è il polinomio di interpolazione di f sui nodi $x_0 \dots x_n$.

Trapezi e simpson sono le formule interpolatorie per le scelte dei nodi

$x_0 = a \quad x_1 = b$ Trapezi (nel caso $p(x) = 1$)

$x_0 = a \quad x_1 = a + \frac{b}{2} \quad x_2 = b$ Simpson

In generale se ho nodi $x_0 < x_1 < \dots < x_n$ possiamo scrivere

$f(x) = \underbrace{P_n(x)}_{\text{polinomio di int}} + \underbrace{R(x)}_{\text{resto}}$

Se facciamo $\int_a^b f(x)\rho(x)dx = \int_a^b [P_n(x) + R(x)]\rho(x)dx = \overbrace{\int_a^b P_n(x)\rho(x)dx}^{\text{Questa è la formula di quadratura}}$

$+ \underbrace{\int_a^b R(x)\rho(x)dx}_{\text{errore della formula di quadratura}}$

come ritroviamo un'espressione del tipo $J_n(f) = \sum_{i=0}^{n} a_i f(x_i)$

andiamo a sfruttare la rappresentazione del polinomio in una delle basi che abbiamo vista.

Sfruttiamo che questo $P_n(x) = \sum_{i=0}^{n} f(x_i)\cdot l_i(x)$

Scegliamo questa poiché è quella che espone più chiaramente le valutazioni della funzione

$l_i(x) = \prod_{j \neq i} \frac{x - x_j}{x_i - x_j}$

Quindi abbiamo che:

$$J_n(f) = \int_a^b P_n(x)\rho(x)dx = \int_a^b \sum_{i=0}^{n} f(x_i)\, l_i(x)\rho(x)dx =$$

$$= \underbrace{\sum_{i=0}^{n} f(x_i)}_{\substack{\text{somatoria valutazione funzione} \\ \text{nodi della formula}}} \underbrace{\int_a^b l_i(x)\rho(x)dx}_{\substack{\text{coefficienti } a_i \\ \text{(pesi della formula)}}}$$

Quindi i nodi di una formula di quadratura interpolatoria coincidono con i nodi usati per l'interpolazione, mentre i pesi coincidono con gli integrali dei polinomi di Lagrange $l_i(x)$

OSS Per costruzione una formula interpolatoria con $n+1$ nodi ha grado di precisione almeno n!

Viceversa fissati $n+1$ nodi c'è un'unica formula di quadratura che ha grado di precisione almeno n. ← questa deve essere la formula di quadratura interpolatoria!

Perché se fisso i nodi e massimizzo il grado devo risolvere il sistema

$$\begin{cases} a_0 + \dots + a_n \\ a_0 x_0 + \dots + a_n x_0 \\ a_0 x_0^2 + __ + a_n x_n^2 \\ \vdots \\ a_0 x_0^2 + __ + a_n x_n^2 = \int x^h \rho(x) \end{cases}$$

{ Sistema lineare in $a_0 _ a_n$ con matrice di Vandermode → soluzione unica

OSS una formula interpolatoria è univocamente determinata dalla scelta dei nodi di interpolazione!

Teorema le formule che usavano nodi equispaziati in $[a,b]$, si dicono formule di **Newton-Cotes**!

In particolare se usiamo $n+1$ nodi si ha

$$x_0 = a \quad , x_1 = a+h \quad , x_2 = a+2h \quad \dots \quad x_n = b$$

$h = b - \frac{a}{n}$ viene detto **PASSO della formula**!

Proprietà il nucleo di Peano delle formule di Newton-Cotes non cambia segno e quindi per queste formule vale sempre:

$$E_n(f) = \frac{f^{(m+1)}(\xi)}{(m+1)!} E_n(x^{m+1})$$

in particolare l'errore associato alle formule di Newton-Cotes, assume un'espressione del tipo

$$E_n(f) = \begin{cases} \overbrace{c_n}^{\text{costante}} \cdot \overbrace{h^{n+2}}^{\text{passo}} f^{(n+1)}(\xi) & n \text{ dispari} \\ c_n \cdot h^{n+3} \cdot f^{(n+2)}(\xi) & n \text{ pari} \end{cases}$$

Esempio trapezi $\xrightarrow{n=1 \quad h=b-a}$ $-\frac{(b-a)^3}{12} f''(\xi) = \underbrace{-\frac{1}{2}}_{c_1} h^3 \cdot f''(\xi)$

simpson $\xrightarrow{n=2 \quad h=\frac{b-a}{2}}$ $-\frac{(b-a)^5}{2880} f^{(IV)}(\xi) = \underbrace{-\frac{1}{90}}_{c_2} \cdot h^5 \cdot f^{(IV)}(\xi)$

DEF formule Gaussione sono le formule di quadratura interpolatoria che usano come nodi di interpolazione quelli per cui si ottiene il grado di precisione massimo (si trovano come zeri di certi polinomi!)

Torniamo sulle delle formule di quadratura di Newton-Cotes, formule di quadratura interpolatoria con nodi equispaziati, di cui Simpson e trapezi sono le istanze base.

Ci chiediamo quanto sono accurate queste formule
Quanto è vicino il valore che restituiscono rispetto all'integrale vero?

In particolare sappiamo che

$$E_n(f) = \int_a^b f(x)dx - J_n(f) = \begin{cases} C_n \cdot h^{n+2} \cdot f^{(n+1)}(\xi) & n \text{ dispari} \\ C_n \cdot h^{n+3} \cdot f^{(n+2)}(\xi) & n \text{ pari} \end{cases}$$
$$\xi \in [a,b]$$

$h = \frac{b-a}{n}$ → distanza tra due nodi adiacenti della formula di N.Cotes!

$n+1 = \#\text{nodi}$

$$\begin{cases} n=1 \text{ Trapezi} \rightarrow E_1(f) = -\frac{1}{12} h^3 f''(\xi) \\ n=2 \text{ Simpson} \quad E_2(f) = -\frac{1}{90} \cdot h^5 f^{IV}(\xi) \end{cases}$$

L'idea è che se h (chiamato passo della formula) è grande ci aspettiamo che la formula non sia molto accurata, se invece h è piccino, può essere una valida stima dell'integrale vero.

Se h è grande mi aspetto poca accuratezza, cosa posso fare?
① Aumento il numero dei nodi di quadratura n!
Ma questa cosa è problematica nelle formule di Newton-Cotes, perché quando si prendono più di 7 nodi, i pesi della formula di newton hanno segni alternati.

Perché è un problema? Perché se sommo cose positive e

cose negative rischio di avere cancellazione numerica, e la formula diventa meno affidabile!

(II) Suddividere $[a,b]$ in sottointervalli più piccoli, applicare la formula su ogni sottointervallo ed infine sommare tutto!

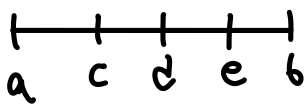

vale sempre che

$$\int_a^b f(x)\,dx = \int_a^c f(x)\,dx + \int_c^d f(x)\,dx + \int_d^e f(x)\,dx + \int_e^b f(x)\,dx$$

applica su ognuno di questi la formula di quadratura che più mi piace! $J_n(f)$
Ed infine somma tutto

L'idea ovviamente è usare una formula di Newton-Cotes con $n \leq 7$, nodi, per quanto detto prima.

Più ~~fondamentale dal punto di vista notazionale~~

- Si divide $[a,b]$ in L sottointervalli di uguale ampiezza il parametro $h = \frac{b-a}{L}$ e si utilizza una formula di Newton Cotes con $(n+1)$ nodi in ciascun sottointervallo!

Si identificano i punti $x_0 = a < x_1 = x_0 + h < x_2 = x_0 + 2h < \dots < x_L = b$

dunque si hanno $L+1$ punti equispaziati nel segmento $[a,b]$ che descrivono come sto dividendo questo intervallo

$$\int_a^b f(x)\,dx \quad \rho(x)=1! \quad = \sum_{i=1}^{L} \int_{x_{i-1}}^{x_i} f(x)\,dx \overset{\text{appr}}{\approx} \sum_{i=1}^{L} J_n^{(i)}(f)$$

(formula applicata su $[x_{i-1}, x_i]$ estrema

Applicare una formula di Newton Cotes con $n+1$ nodi in un generico intervallo $[x_{i-1}, x_i]$ richiede di introdurre

$n+1-2 = n-1$ punti

Trapezi, non ci servono nuovi punti

$n+1 = 2$

$2-2=0$!

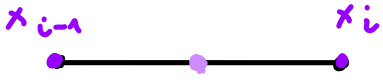

Simpson

$n+1-2$

$n+1 = 3$

$3-2 = 1$ in più

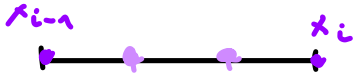

Newton Cotes con 4 punti (formula dei 3/8)

$n+1 = 4$

$n+1-2 = 2$ in più

- nodi già contati nella suddivisione in sottoint
- nodi aggiuntivi per la formula di Newton-Cotes!

Con L sottointervalli

- i nodi della suddivisione originale sono $L+1$
- ogni sottointervallo aggiunge $n-1$ nodi interni
- su L sottointervalli $L(n-1)$ nodi aggiuntivi!

numero totale $L+1+(n-1)L = nL+1$

oss $nL+1$ corrisponde al numero di valutazioni della funzione f, il numero di punti dove dobbiamo conoscere il suo valore che ci servono per valutare la formula di quadratura!

esempio

Una volta che definiamo una formula di Newton-Cotes che vogliamo definire in ogni intervallino possiamo definire una nuova formula di quadratura che viene chiamata Generalizzata.

Per sottointervalli divisi ed in ognuna applica questa formula

Formula dei trapezi Generalizzata

$$\int_a^b f(x)dx = \sum_{i=1}^{L} \int_{x_{i-1}}^{x_i} f(x)dx \qquad \sum_{i=1}^{L} f\frac{(x_{i-1}) + f(x_i)}{2} \cdot (x_i - x_{i-1})$$

ognuno di questi integrali

ampiezza dell'intervallo

Adesso la distanza tra x_i e x_{i-1} è una costante

$$(x_i - x_{i-1}) = h = \frac{b-a}{L}$$

$$= \frac{b-a}{2L} \sum_{i=1}^{L} \left[\frac{f(x_{i-1}) + f(x_i)}{2} \right]$$

Vado a sviluppare questa somma immaginando la retta suddivisa in intervalli equispaziati

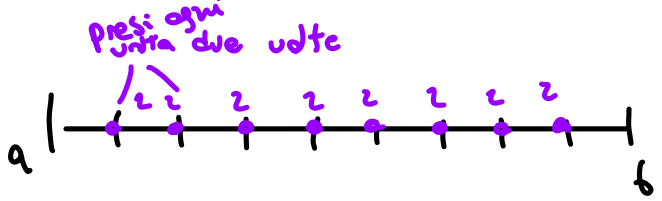

$$= \frac{b-a}{2L} \left(\left(f(a) + 2 \sum_{i=1}^{L-1} f(x_i) + f(b) \right) \right)$$

formula dei trapezi generalizzata

Per i trapezi con $n+1 = 2 \rightarrow n = 1$, il numero totale dei nodi è $mL + 1 = L + 1$, che è esattamente lo stesso di quello di una formula, nessun nodo interno aggiunto, coerente con il fatto che i trapezi hanno 0 nodi interni per sottointervallo!

$$J_1^{(b)}(f) = \frac{b-a}{2L} \left[f(a) + 2 \sum_{i=1}^{L-1} f(x_i) + f(b) \right]$$

Formula di Simpson Generalizzata (Cavalieri-Simpson)

$$\int_a^b f(x)dx = \sum_{i=1}^{L} \int_{x_{i-1}}^{x_i} f(x)dx \approx \sum_{i=1}^{L} \frac{b-a}{6L}\left(f(x_{i-1}) + f(x_i) + 4f\left(\frac{x_i + x_{i-1}}{2}\right)\right)$$

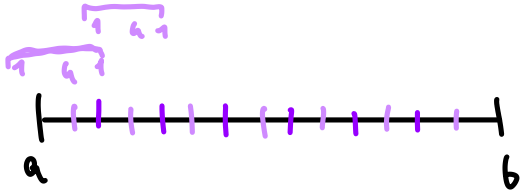

Per lo stesso ragionamento di prima tutti i nodi come prima negli estremi sono contati 2 volte e quelli nel punto medio 4, per come è costruita la formula di Simpson!

$$= \frac{b-a}{6L}\left[f(a) + f(b) + 2\sum_{i=1}^{L-1} f(x_i) + 4\sum_{i=1}^{L}\left(\frac{x_i + x_{i-1}}{2}\right)\right] = J_2^{(6)} f$$

numero di valutazioni di f (nodi ≥) $2L+1$

$(n+1=3 \quad n=2 \quad nL+1 = 2L+1)$

Vediamo come si comporta l'errore all'aumentare di questi pt

Parliamo di

Errore nelle formule Generalizzate:

L'idea è che in ogni singolo intervallino sappiamo la valutazione dell'errore sulla base della formula utilizzata!

↳ In ogni intervallo $[x_{i-1}, x_i]$ sappiamo che l'errore è della forma è della forma $c \cdot h^{\alpha} \cdot f^{(\alpha-1)}(\xi) \quad \xi \in [x_{i-1}, x_i]$

L'errore totale fatto dalla formula generalizzata sarà la somma dei contributi dell'errore nei singoli sottointervalli!

$$E_n^{(6)}(f) = \sum_{i=1}^{L} c \cdot h^{\alpha} f^{(\alpha-1)}(\xi_i) = \quad \xi_i \in [x_{i-1}, x_i] \text{ intervallo i-esimo!}$$

Cerchiamo di rendere la formula più rangevole

$$= c \cdot h^{\alpha} \sum_{i=1}^{L} f^{(\alpha-1)}(\xi_i)$$

Vorrei ottenere una cosa per un ξ generico

$$= c \cdot h^{\alpha} \cdot L \left(\sum_{i=1}^{L} \frac{f^{(\alpha-1)}(\xi_i)}{L} \right) = c \cdot h^{\alpha} \cdot L \cdot f^{(\alpha-1)}(\xi) \qquad \xi \in [a,b]$$

è una media dei valori della derivata nei punti ξ_i

Quindi per le formule generalizzate di N.C valgono:

$$E_n^{(G)}(f) = \begin{cases} c_n \cdot \frac{(b-a)^{n+2}}{L^{n+1}} \cdot f^{(n+1)}(\xi) & n \text{ dispari!} \\ c_n \cdot \frac{(b-a)^{n+3}}{L^{n+2}} \cdot f^{(n+2)}(\xi) & n \text{ pari!} \end{cases}$$

Aumentando L, ovviamente l'errore va a zero.

Trapezi $\longrightarrow$ $-\frac{(b-a)^3}{12L^2} f''(\xi)$

Simpson $\longrightarrow$ $-\frac{(b-a)^5}{2880L^4} f^{IV}(\xi)$

Un'altra possibilità per stimare l'integrale oltre a quella che coinvolge solo valori della funzione, si può fare una cosa analoga, mettendoci oltre a valori della funzione, derivate o derivate successive!

Mettere le derivate è come dire che non solo passa per li stessi punti ma deve avere anche la stessa derivata!

Formule di quadratura che coinvolgono derivate della funzione integranda

L'approccio visto per trovare pesi e nodi ottimali si

generalizza in modo analogo ad espressioni che coinvolgono derivate di f_1 nel caso in cui quest'ultima sia sufficientemente derivabile

Equazioni Non Lineari

Equazioni non lineari

Cerchiamo di trovare una (o più) soluzioni di $f(x)=0$
$f: \mathbb{R} \to \mathbb{R}$ con f non lineare!

Cioè f è una cosa diversa da $f(x) \neq a_0 x + a_1$

- Gli x che verificano $f(x)=0$, si dicono zeri o radici di f e in generale non è detto che ne esista una sola, tante, infinite, che esista!

  ↳ quando la funzione è non lineare può succedere di tutto!

In generale possono esserci un numero qualsiasi di radici di f (nessuna, una, tante, infinite)

OSS

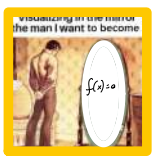

in generale per f non lineare non c'è una formula che possiamo valutare, ovvero un numero finito di passaggi che ci assicura di trovare una radice oppure uno zero di f, con un numero finito di operazioni elementari
$\{\pm, \times, \setminus, \sqrt{}\}$

Ad esempio per polinomi di ≥ 5, non c'è una formula generale per le radici (non può esistere TEORIA GALOIS)

dunque non ci sono metodi DIRETTI, ma dobbiamo farlo con metodi indiretti ⟶ metodo iterativo che genera una successione di punti che sperabilmente si avvicina sempre di più ad una soluzione del problema!

PER CALCOLARE approssimazioni degli zeri di una funzione dobbiamo usare metodi iterativi che in generale hanno la seguente forma:

ϕ_n fi - la funzione dati gli ultimi n valori, restituisce il successivo
il pedice n indica quanti passi vengono usati!

$$x_{n+1} = \phi_n(x_n, x_{n-1}, \dots x_{n-k+1}) \quad \text{per} \quad n = 0, 1, 2 \dots k \geq 1$$

funzione di un pò di punti precedenti. La funzione dipende da n! Si può decidere di fare una cosa diversa ad ogni passaggio del metodo!

ϕ_n si dice funzione di iterazione del metodo! (dipende dal parametro n)

↳ La scelta di ϕ_n dipenderà dalla particolare funzione di cui vogliamo trovare gli zeri.

OSS Per far partire il metodo è necessaria la scelta di k punti iniziali $x_0, x_1 \dots x_{1-k}$

Una volta noti i valori iniziali il metodo genera una successione $\{x_n\}_{n \in \mathbb{N}}$ che sperabilmente convergerà ad una radice α di f

ovvero tale per cui $f(\alpha) = 0$!

DEF Un metodo iterativo $\{\phi_n\}$ si dice convergente da $x_0 \dots x_{k-1}$ se $\lim_{n \to +\infty} x_n = \alpha$ con $f(\alpha) = 0$!

↑ limite della successione che genera!

Possiamo dire che si parla di convergenza da alcuni punti INIZIALI! Quindi è una scelta di convergenza vincolata da questi punti iniziali!

"Si parla di convergenza fissato un certo punto di partenza"

DEF Quando un metodo dipende da k valori di partenza (o k precedenti) si dice un metodo a k punti

DEF un metodo in cui la funzione di iterazione ϕ_n non cambia allora il metodo si dice **stazionario!**
Ovvero quando $\phi_n = \phi \quad \forall n \in \mathbb{N}$ (la funzione di iterazione è fissata).

DEF ha senso quantificare quanto velace converge un metodo, perchè vol dire in termini di n di iterazioni quanto vicino si arriva alla radice, con un n. di iterazioni
⟶ è nostro interesse che si arrivi "presto" poiché le iterazioni ci costano **tempo** e **risorse computazionali**

Introduciamo così "**La convergenza di ordine p**"

Sia $\{x_n\}_{n \in \mathbb{N}}$ una successione **convergente** ad α, e si ponga $\underbrace{e_n}_{\substack{\text{successione} \\ \text{degli errori}}} = \underbrace{x_n - \alpha}_{\substack{\text{successione} \\ \text{delle distanze} \\ \text{di questi punti} \\ \text{dalla successione} \\ \text{della soluzione}}}$ allora se esistono le seguenti due

costanti $\exists p \geq 1$ e $C \neq 0$ tale che: (limite errore al passo $n+1$)

$$\lim_{n \to +\infty} \frac{|x_{n+1} - \alpha|}{|x_n - \alpha|^p} = \lim_{n \to +\infty} \frac{|e_{n+1}|}{|e_n|^p} = C$$

(limite errore al passo n!)

Se il limite è finito e diverso da zero, si dice che la **successione converge con ordine p!**
nel caso $p = 1$, si deve avere che questa costante C, è fra zero ed uno! $C \in (0,1)$

Cosa vuol dire questa definizione?

Se noi confrontiamo l'errore del prossimo punto della successione, questo non è più piccolo dell'errore al passo precedente ma si comporta come una potenza dell'errore!

Cioè se siamo vicini a zero, dire che l'errore al prossimo passo va come "una certa potenza p" dell'errore al passo precedente ci dice quanto veloce va il metodo

Se la convergenza è lineare, vuol dire che il rapporto fra l'errore al nuovo passaggio e quello al passo precedente è una COSTANTE! quindi magari l'errore si dimezza ad ogni passo (costante $c = 1/2$ ad es) se fosse >1, ci direbbe che l'errore sta raddoppiando quindi non sta andando verso lo zero!

per $p=1$ c è il fattore di riduzione dell'errore ad ogni iterazione

$$|e_{n+1}| \approx c \cdot |e_n|$$

- $c=0.1$ $\longrightarrow$ l'errore si divide per 10 ad ogni passo
- $c=0.9$ $\longrightarrow$ l'errore cala lentamente!

OSS In genere i metodi per equazioni non lineari convergono solo LOCALMENTE, cioè partendo "abbastanza vicini ad una certa radice α". Per cui è conveniente quando possibile cercare degli intervalli/regioni ristretti dove sappiamo che si trova la radice per poter scegliere dei buoni punti di partenza per il metodo! (per le radici di f)

↳ e anche perchè magari la funzione ha molte radici, quindi se eseguiamo il metodo una volta sola ne troviamo una, quindi se so che ce ne sono tre, so più o meno

dove stanno, quindi magari posso far partire il mio metodo da tre punti diversi e cercare di trovarle tutte!

"Per questo obbiettivo possiamo usare tecniche di analisi 1"

FACCIAMO alcuni esempi

① Se ho due punti $[a,b]$, una f continua, e in un punto la funzione è negativa, e in un punto positiva allora so che nel mezzo tra a e b, cioè sicuramente almeno una radice!

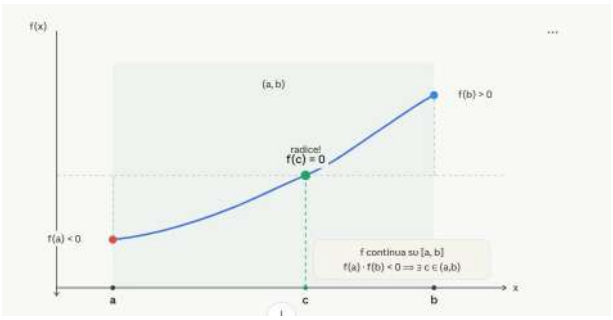

"$f(a) \cdot f(b) < 0$"
$\longrightarrow$ $\exists$ almeno uno zero di f $[a,b]$

→ è sempre crescente oppure sempre decrescente

Inoltre se f è strettamente monotona in $[a,b]$ allora $\exists!$ esiste ed è unica! una radice di f in $[a,b]$

② studio della derivata e del segno di $f(x)$

esempio

$f(x) = x \log(x) + \frac{1}{3}$ poiché c'è un logaritmo, il dominio della funzione è ristretto ai numeri reali positivi $x \in (0, +\infty)$

Si calcola subito il limite ai due estremi del dominio

- per $x \to 0^+$ il limite notevole $x\log(x)$ tende a 0

$$\lim_{x \to 0^+} f(x) = \frac{1}{3}$$

- per $x \to +\infty$ sia x che $\log(x)$ tendono a $+\infty$ quindi

$$\lim_{x \to +\infty} f(x) = +\infty$$

Studiamo la derivata prima (massimi e minimi)
Per capire l'andamento (dove cresce o decresce la curva)
Si calcola la derivata prima $f'(x)$

$$f'(x) = 1 \cdot \log(x) + x \cdot \frac{1}{x} + 0 = \log(x) + 1$$

Viene poi studiato il segno della derivata prima

- decrescenza $f'(x) < 0 : \log(x) + 1 < 0 \to \log(x) < -1$

$\log(x) = -1 \Rightarrow x = e^{-1}$

$\longrightarrow 0 < x < e^{-1}$

- crescenza $f'(x) \geq 0 : \log(x) + 1 \geq 0 \to \log(x) \geq -1 \to x \geq e^{-1}$

Questo ci dice che la funzione scende fino a $x = e^{-1}$ e poi torna a risalire!

dunque sappiamo che quando mi avvicino allo zero, la funzione parte da 1/3, scende fino a toccare $x = e^{-1}$, risale fino a $+\infty$

Si nota dal grafico che la curva interseca l'asse delle x esattamente due volte, questi punti di intersezione sono le radici!

$\alpha_1 \in (0, e^{-1})$
$\alpha_2 \in (e^{-1}, +\infty)$

"Posso sostituire α con qualsiasi valore h tale per cui $f(h) \geq 0$ e $h \geq e^{-1}$"

↳ Per "isolare" l'intervallo dove si trova la seconda radice α_2 non siamo obbligati a usare l'intervallo che va fino a $+\infty$ Possiamo trovare un qualsiasi valore numerico concreto h in cui la funzione diventa positiva o nulla, in questo modo posso restringere la ricerca di α_2 all'intervallo

$(e^{-1}, h]$

(3) Separazione grafica:

è quando la funzione $f(x)$ che stiamo studiando si può scrivere come differenza di due funzioni note

$$f(x) = g(x) - h(x)$$

Gli zeri di f corrispondono alle soluzioni di $g(x) = h(x)$ ovvero le intersezioni di questi due

Esempio $f(x) = 5x^2 - 2e^x$

Singolarmente sono funzioni con cui abbiamo una certa esperienza!

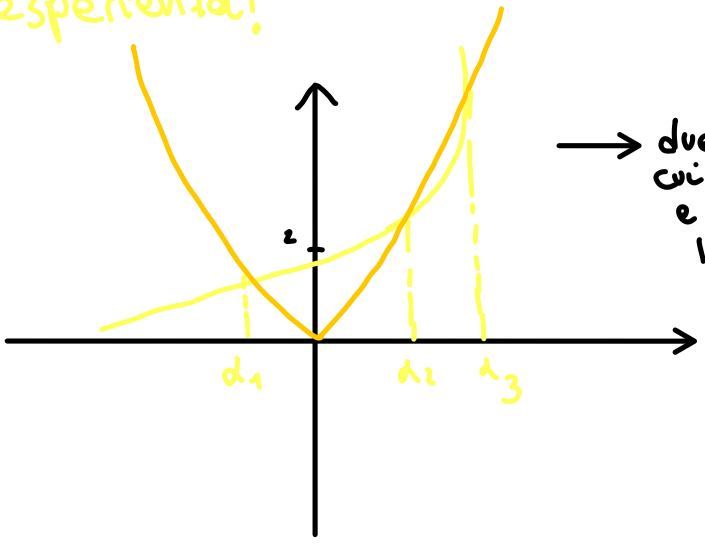

→ due possibilità una in cui $5x^2$ supera l'esponenziale e poi viene risuperato, poiché l'esponenziale domina

Altro caso in cui l'esponenziale sta sempre sopra! (non si incontrano mai)

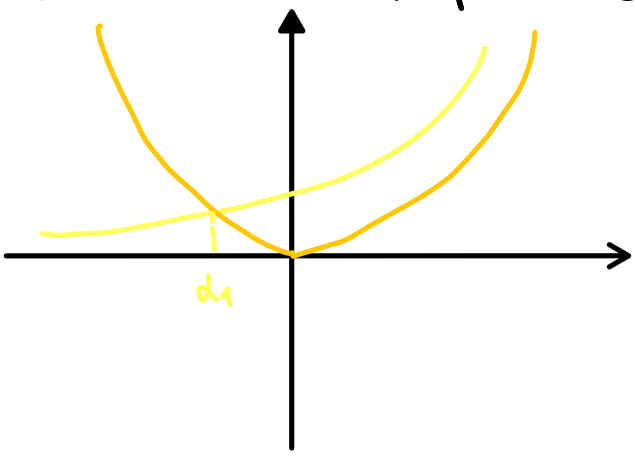

dunque bisogna fare delle valutazioni per capire se è un caso oppure l'altro (1 radice o 3 radici)

Questo è per darci un'idea di dove sono le radici e quali punti di partenza scegliere! ⟶ Vediamo quale esempio di metodo si può applicare

un metodo che sfrutta la ① proprietà è il METODO DI BISEZIONE

METODO DI BISEZIONE (Ricerca binaria)

IDEA si ha $[a,b]$: $f(a) \cdot f(b) < 0$, vado a considerare il punto medio dell'intervallo e ho tre possibilità

- nel punto medio la funzione vale zero (non succederà mai!)
- nel punto medio la funzione sia o positiva o negativa, a quel punto ho che il segno del punto medio dell'intervallo sarà opposto ad uno di quello negli estremi, quindi posso dividere l'intervallo in due e concentrare la mia ricerca solo nell'intervallo che ha per estremi valori discordi, e continuo così, dimezzando ogni volta l'ampiezza dell'intervallo fino a che non arrivo vicino alla soluzione ovvero ho creato un intervallo abbastanza "piccolo"

ho questo intervallo dove so che c'è la radice ⟶ divido l'intervallo in due! e continuo sul semiintervallo in cui ho ancora estremi con

valutazione di segno discorde.

$x_0 = a \quad x_1 = b \quad x_2 = \frac{a+b}{2}$ a questo punto se $f(x_2) \cdot f(x_0) < 0$ considero $[x_0, x_2]$ e vado avanti $\longrightarrow x_3 = \frac{x_0 + x_2}{2}$

Altrimenti considero $[x_0, x_1]$ e vado avanti $\longrightarrow x_3 = \frac{x_1 + x_2}{2}$

Come criterio di Arresto

Ci si può fermare quando la lunghezza dell'intervallo al quale siamo arrivati è più piccola di una tolleranza che decidiamo noi.

Si considera $|x_{n-1} - x_n| \leq$ Tolleranza $\rightarrow$ TOL scelta da noi (es TOL $= 10^{-6}$)

(ultimi due punti generati dal metodo di bisezione)

L'errore che commette il metodo al passo n si può maggiorare con l'ampiezza di questo intervallo dopo n passi ovvero

$\frac{b-a}{2^n}$ ← ampiezza dell'intervallo dopo aver fatto n passi del metodo di bisezione

(ogni volta l'intervallo si divide per due)

Quindi in genere si usa come criterio di arresto

$$\frac{b-a}{2^n} < \text{TOL}$$

Quindi dato "TOL" mi fermerà esattamente dopo

$$(b-a) < \text{TOL} \cdot 2^n \rightarrow \frac{b-a}{\text{TOL}} < 2^n \rightarrow n > \log_2\left(\frac{b-a}{\text{TOL}}\right)$$

Prendiamo n parte intera superiore

$$n = \lceil \log_2\left(\frac{b-a}{\text{TOL}}\right) \rceil$$ quindi più piccolo è questo TOL (maggiore è l'accuratezza) più iterazioni ci serviranno

OSS Il numero di iterazioni ci dice anche quante sono il numero di valutazioni di f vanno fatte che è $n+2$
(indice del costo di tempo a riserse)

Il metodo di bisezione è un'esempio di metodo a 2 punti ovvero che ogni volta ci servono due valori precedenti, non stazionario, ovvero che la funzione considerando quale punto valutare dopo cambia da iterazione a iterazione!

Esempio di metodo stazionario a due punti: metodo delle secanti

Si parte con un'idea simile a quella della bisezione dunque si hanno due punti a,b, in uno la funzione è positiva in una negativa

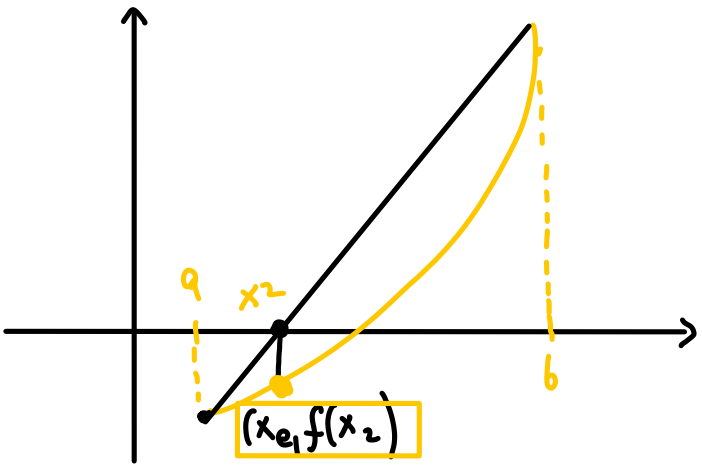

$(x_0, f(x_0))$ $(x_1, f(x_1))$

Quello che facciamo è considerare la retta che passa per questi due punti (la secante)
E considerare come prossimo punto il punto in cui la retta taglia l'asse delle x!

$$x_{n+1} = x_n - f(x_n) \cdot \frac{x_n - x_{n-1}}{f(x_n) - f(x_{n-1})}$$

Teorema se $f \in C^2[a,b]$ allora il metodo delle secanti converge localmente con ordine $p = \frac{1+\sqrt{5}}{2}$

Ci focalizziamo sui metodi stazionari ad un punto
⟶ la funzione non cambia mai ed il nuovo punto dipende solo dal punto precedente

NOTA

Metodo Stazionario — "Il termostato"

Immagina di voler portare una stanza a 20°C. Hai un termostato rotto che **aggiunge sempre 2°C fissi** ogni ora, indipendentemente da quanto sei lontano dalla temperatura target.

- Se sei a 10°C → aggiungi 2°C
- Se sei a 18°C → aggiungi ancora 2°C
- Se sei a 21°C → aggiungi comunque 2°C (e sbagli!)

Il "passo" è **sempre lo stesso**, non si adatta. Questo è un metodo **stazionario**.

Metodo Non Stazionario — "Il termostato intelligente"

Stesso problema, ma ora il termostato **misura ogni ora quanto sei lontano** dal target e regola la potenza di conseguenza.

- Se sei a 10°C (lontano) → aggiungi tanto, 5°C
- Se sei a 18°C (vicino) → aggiungi poco, 0.5°C
- Se sei a 20.1°C (quasi arrivato) → aggiungi pochissimo, 0.05°C

Il "passo" α_k **si ricalcola ogni volta** in base alla situazione corrente. Questo è un metodo **non stazionario**.

La differenza in una riga

> Nel metodo stazionario sai già prima di iniziare quanto farai ogni passo. In quello non stazionario, lo decidi di volta in volta guardando dove sei arrivato.

METODI STAZIONARI AD UN PUNTO

Avremo cose della forma

$$\begin{cases} x_{n+1} = \phi(x_n) \\ x_0 \text{ dato} \end{cases}$$

Come si trovano delle buone funzioni $\phi(f_i)$?
un modo è riscriversi il problema $f(x)=0$ come un problema di punto fisso $x = \phi(x)$ e prendere ϕ ($\phi(x)=x$ e $f(x)=0$ devono essere tali per cui un pt fisso della prima è radice della seconda) * x che soddisfa $x=\phi(x)$ si chiama punto fisso di ϕ, cioè un punto che la funzione manda in se stesso!

Ma come si genera un'equazione di pt fisso?
Esempio

un modo di trovarli è lavorare sull'espressione di f!

$f(x) = x^3 + 4x^2 - 10$

- preso $f(x) = 0 \longrightarrow x^2 = \frac{10 - x^3}{4} \longrightarrow x = \sqrt{\frac{10 - x^3}{4}}$

$\longrightarrow \phi(x) = \sqrt{\frac{10 - x^3}{4}}$

- aggiungere x da entrambe le parti

$$+x + x^3 + 4x^2 - 10 = x$$

questa è già eq di pt fisso $x = x + qualcosa$

$$\phi(x) = x + x^3 + 4x^2 - 10$$

- dividere per x:

$$x^2 + 4x - \frac{10}{x} = 0 \longrightarrow x = \left(\frac{10}{x} - x^2\right)\frac{1}{4}$$

$$\phi(x) = \left(\frac{10}{x} - x^2\right)\frac{1}{4}$$

Ogni modo che ci porta a scrivere l'equazione come $x = qualcosa$ ci da un possibile candidato pt fisso!

Un modo canonico per trovare un'equazione di punto fisso è prendere

$$\phi(x) = x - g(x) f(x)$$

Con $g(x)$ funzione che non si annulla in a radice di f!
infatti:

$$\phi(\alpha) = \alpha - g(\alpha)\underbrace{f(\alpha)}_{0} = \alpha$$

Ovviamente non siamo costretti a fare una scelta di questo tipo possiamo essere più o meno creativi.

DEF α è detto punto fisso di ϕ (che è una rad di f)

Quindi siamo partiti da $f(x)=0$, si è trovato un'equazione $\phi(x)=x$ di punto fisso, il metodo associato è

$$x_{n+1} = \phi(x_n)$$

L'ordine logico è:

- Ho $f(x)=0$ da risolvere (non so la radice)
- Costruisco ϕ tale che punto fisso $\longrightarrow$ radice
- Itero $x_{n+1}=\phi(x_n)$ finchè non converge
- la sequenza mi porta alla radice α

È un buon metodo?

la successione $\{\phi(x_n)\}_{n\in\mathbb{N}}$ generata dal metodo dipende dalla nostra scelta di punto fisso, chi mi dice che ho fatto una buona scelta? Quando è convergente?
Me lo dice il seguente teorema

Teorema di convergenza locale

Supponiamo $I \subseteq \mathbb{R}$ intervallo dove $\alpha \in I$: $\phi(\alpha)=\alpha$, supponiamo che $\phi \in C^1(I)$ sia derivabile e supponiamo che ci sia un'intervallino attorno alla radice in cui questa derivata è più piccola di uno in modulo.

↳ supponiamo che $\exists \rho \in \mathbb{R}^+$ (ampiezza intervallo) e $K \in (0,1)$ tali per cui:

$$|\phi'(x)| \leq K \quad \forall x \in [\alpha-\rho, \alpha+\rho]$$

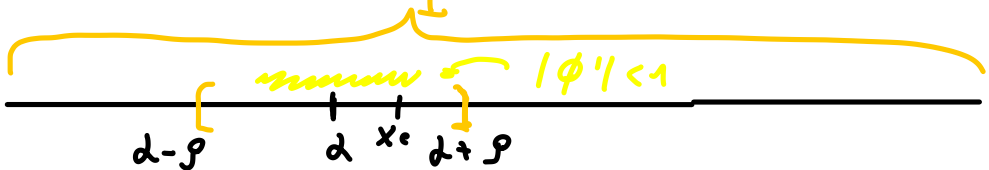

Allora sotto questa assunzione valgono: (suff non necessaria)

(i) Se $x_0 \in [\alpha - \rho, \alpha + \rho]$ il metodo non esce mai $\longrightarrow x_n \in [\alpha - \rho, \alpha + \rho] \ \forall n \geq 0$

(ii) Se $x_0 \in [\alpha - \rho, \alpha + \rho] \longrightarrow \lim_{n \to +\infty} x_n = \alpha$

(iii) α è l'unico punto fisso di ϕ in $[\alpha - \rho, \alpha + \rho]$

Dunque serve a dire che se x_0 lo scelgo in questo intervallo $[\alpha - \rho, \alpha + \rho]$ il metodo converge a soluzione del problema!

DIM

① Procediamo per induzione su $n = 0$ la proprietà è vera adesso dimostriamola per $n+1$

andiamo a vedere questo distanza

$|x_{n+1} - \alpha|$ perchè dire che qualcosa sta tra $[\alpha - \rho, \alpha + \rho]$ è equivalente a dire che il modulo della differenza con α è più piccolo di ρ

punto fisso di ϕ

$$|x_{n+1} - \alpha| = |\phi(x_n) - \alpha| = |\phi(x_n) - \phi(\alpha)| \overset{\text{Taylor stoppato al grado 0}}{=} |(x_n - \alpha) \cdot \phi'(\xi)| = |x_n - \alpha| |\phi'(\xi)| \leq |x_n - \alpha| \cdot K$$

con $\xi \in [x_n, \alpha]$

per ipotesi induttiva data che $x_n \in [\alpha - \rho, \alpha + \rho]$

$\leq \rho \cdot K \leq \rho$ ($K < 1$)

Abbiamo dimostrato che $|x_{n+1} - \alpha| < \rho$, la differenza tra $n+1$ e α è in modulo più piccola di ρ!

② Si possono prendere alcuni passaggi già scritti nel punto 1!

$|x_{n+1} - \alpha|$ vogliamo far vedere che il lim di questa cosa fa 0, cioè la distanza tra x_{n+1} e α deve andare a zero!

$$= |x_n - x| \cdot |\phi'(\xi)| \leq K |x_n - \alpha| \leq K^2 |x_{n-1} - \alpha| \leq$$
$$K^3 |x_{n-2} - \alpha| \leq \dots \leq K^{n+1} |x_0 - \alpha| \leq K^{n+1} \rho$$

$$0 \leq \lim_{n \to +\infty} |x_{n+1} - \alpha| \leq \lim_{n \to +\infty} \underbrace{K^{n+1}}_{\to 0} \cdot \rho = 0$$

③ Vogliamo dimostrare che α è l'unico punto fisso qua dentro procediamo per ASSURDO! e supponiamo che

$$\exists \tilde{\alpha}, \ \tilde{\alpha} \neq \alpha, \ \tilde{\alpha} \in [\alpha - \rho, \alpha + \rho] : \phi(\tilde{\alpha}) = \tilde{\alpha}$$

Allora:

$$|\alpha - \tilde{\alpha}| = |\phi(\alpha) - \phi(\tilde{\alpha})| \overset{\text{th di Lagrange}}{=} |(\alpha - \tilde{\alpha}) \cdot \phi'(\xi)| =$$

$|\alpha - \tilde{\alpha}|$: entrambi punti fissi!

$\xi \in (\alpha, \tilde{\alpha}) \to \xi \in (\alpha - \rho, \alpha + \rho)$

$$= |\alpha - \tilde{\alpha}| \cdot \underbrace{|\phi'(\xi)|}_{\leq K} \leq |\alpha - \tilde{\alpha}| \cdot \underbrace{K}_{\text{più piccolo di } 1} < |\alpha - \tilde{\alpha}|$$

$|\alpha - \tilde{\alpha}| < |\alpha - \tilde{\alpha}|$ contraddizione è assurdo!! quindi non può esistere un altro $\tilde{\alpha} \neq \alpha$!

OSS I ragionamenti fatti per questa dimostrazione ci dicono qualcosa in più, sul comportamento di queste successioni di punti che generiamo!

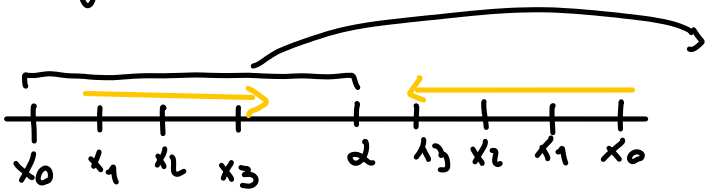

immaginiamo di avere una successione di punti che è monotona, cioè in maniera crescente verso α

O viceversa se parto da destra in maniera decrescente

Quando succede questo si parla di convergenza monotona del metodo!

se riguardiamo la dimostrazione $x_{n+1} - \alpha = \phi'(\xi) \cdot (x_n - \alpha)$
dice fondamentalmente che il segno di $x_{n+1} - \alpha$ che ci dice se il numero sta alla destra o alla sinistra di α

$$\text{segno}(x_{n+1} - \alpha) = \overbrace{\text{segno}(x_n - \alpha)}^{\text{passo precedente}} \cdot \text{segno}(\phi'(\xi))$$

- Se ϕ' fosse > 0 in $[\alpha - \rho, \alpha + \rho]$ allora la convergenza è monotona (tutti i punti a sn o dest di α)
- Se ϕ' fosse < 0 allora i punti saltano (se parto alla sinistra di α allora il secondo punto è alla sua destra etc) si avrà un comportamento di questo tipo

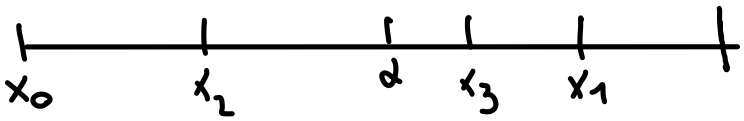

Questa tipo di convergenza si dice CONVERGENZA ALTERNATA DEL METODO

Ora guardiamo, l'ordine di convergenza, se prima abbiamo detto se o meno la successione converge ad α, ora parliamo di quanto velocemente ci va!

Teorema sull'ordine di convergenza

Sia $\phi(x) \in C^p(I)$ sufficientemente derivabile e che la successione $\{\phi(x_n)\}_{n \in \mathbb{N}}$ sia localmente convergente ad $\alpha \in I$, e supponiamo che la successione converge allora le seguenti condizioni sono equivalenti

(i) $\exists \rho \in \mathbb{R}^+ : \forall x_0 \in [\alpha - \rho, \alpha + \rho]$ La successione $x_{n+1} = \phi(x_n)$ converge con ordine p

(ii) $\phi'(\alpha) = \phi''(\alpha) = \dots = \phi^{(p-1)}(\alpha) = 0$ e $\phi^{(p)}(\alpha) \neq 0$

DIMOSTRAZIONE

La (2) implica la (1), consideriamo lo sviluppo di Taylor (centrato in α)

$$x_{n+1} = \phi(x_n) = \phi(\alpha) + \phi'(\alpha)(x_n - \alpha) + \dots + \phi^{(p-1)}(\alpha) \cdot \frac{(x_n - \alpha)^{p-1}}{(p-1)!}$$

$$+ \phi^{(p)}(\xi) \cdot \frac{(x_n - \alpha)^p}{p!} =$$

Adesso usiamo il fatto che tutte le derivate sono zero

$$= \underbrace{\phi(\alpha)}_{\alpha} + \phi^{(p)}(\xi) \frac{[x_n - \alpha]^p}{p!}$$

$$x_{n+1} - \alpha = \phi^{(p)}(\xi) \frac{(x_n - \alpha)^p}{p!} \longrightarrow \frac{x_{n+1} - \alpha}{(x_n - \alpha)^p} = \frac{\phi^{(p)}(\xi)}{p!}$$

La quantità a sinistra dell'uguale è la cosa di cui deve studiare il limite

$$\lim_{n \to +\infty} \frac{x_{n+1} - \alpha}{|x_n - \alpha|^p} = \lim_{n \to +\infty} \left| \frac{\phi^p(\xi)}{p!} \right| = \quad \xi \in [\alpha, x_{n+1}] \to \xi \to \alpha$$

$$= \left| \frac{\phi^{(p)}(\alpha)}{p!} \right| \neq 0$$

La ① implica la ②

dobbiamo far vedere che le derivate si annullano, facciamo vedere che la derivata di ordine n di ϕ, si annulla in α con $1 \leq n \leq \lambda - 2$

Per induzione assumiamo che $\phi'(\alpha) = \dots = \phi^{(n-1)}(\alpha) = 0$

Sviluppando con Taylor fino all'ordine $n-1$ otteniamo:

$$\phi(x_n) - \phi(\alpha) = (x_n - \alpha)\phi'(\alpha) + \dots + \frac{(x_n - \alpha)^{n-1}}{(n-1)!} \phi^{(n-1)}(\alpha) + \frac{(x_n - \alpha)^n}{n!} \phi^{(n)}(\xi)$$

con $\xi \in [x_n, \alpha]$

Se consideriamo $\lim_{n \to +\infty} \frac{|\phi(x_n) - \alpha|}{|x_n - \alpha|^n}$ deve fare zero!

(perchè il numeratore va a 0 come $|x_n - \alpha|^p$ ovvero più velocemente del denominatore)

derivata fa zero!

$$= \lim_{n \to +\infty} \frac{\phi^{(n)}(\xi)}{r!} = \frac{\phi^{(r)}(\alpha)}{r!} \Rightarrow \frac{\phi^{(r)}(\alpha)}{r!} = 0 \Rightarrow \phi^{(r)}(\alpha) = 0$$

Eravamo arrivati al concetto che era utile scriversi

$f(x) = 0$ con f non lineare come un'equazione di punto fisso!

$x = \phi(x)$ in maniera tale che le soluzioni di un problema sono anche le soluzioni dell'altro!

Avevamo definito una condizione sufficiente affinché questa scelta sia fortunata

↳ una volta che abbiamo l'equazione di pt fisso possiamo definire la successione

$$\begin{cases} x_0 \\ x_{n+1} = \phi(x_n) \end{cases}$$

Avevamo definito una condizione sufficiente sotto la quale questa successione converge a una soluzione della nostra equazione di partenza.

Se $|\phi'(x)| < 1$ in un intervallo $[\alpha - \rho, \alpha + \rho]$ allora se x_0 è abbastanza vicino ad α, la successione converge ad α!

OSS Se ϕ è continua allora ci basta verificare che $|\phi'(\alpha)| < 1$, dato che sotto questa condizione si trova $\rho \in \mathbb{R}^+$ sufficientemente piccolo per cui vale la condizione del teorema

↳ perciò quando ci viene chiesto se un metodo di punto fisso converge localmente ci riconduciamo a dimostrare che il valore della derivata prima di $|\phi(\alpha)| < 1$

L'inghippo sta nel fatto che non sempre conosciamo α, se lo conosciamo:

- calcoliamo ϕ'
- lo valutiamo in α
- vediamo cosa succede.

Se invece è un'equazione complicata di cui di α non si conosce la forma esplicita allora si devono fare delle deduzioni su α

↳ magari riusciamo a localizzarlo in un certo intervallo, riusciamo magari a limitarne il valore!

"Molto spesso α non si conosce ma si può dedurre un intervallo dove sta e da questa informazione si può cercare di capire se vale $|\phi'(\alpha)| < 1$"

Ci concentriamo su un metodo di punto fisso particolarmente di SUCCESSO

METODO DI NEWTON (o delle tangenti)

è un metodo che consente di avere spesso una convergenza quadratica!

Ha un'interpretazione geometrica abbastanza CHIARA

- È un metodo ad un punto solo, STAZIONARIO, si prende la retta tangente al grafico, e si prende l'intersezione di questa con l'asse x come nuovo punto!

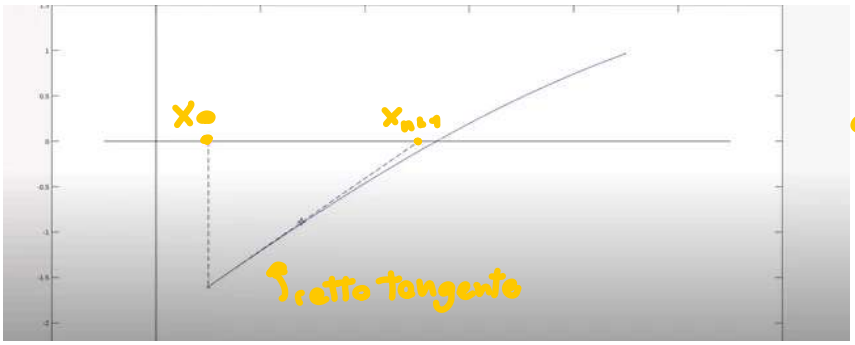

ancora →

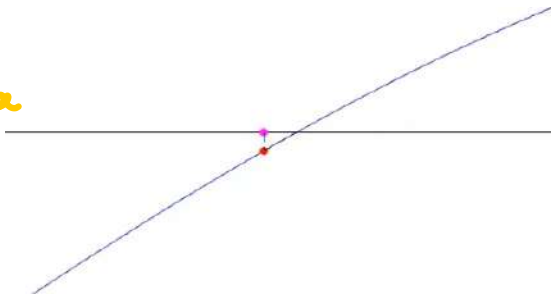

→ e così via fino alla radice

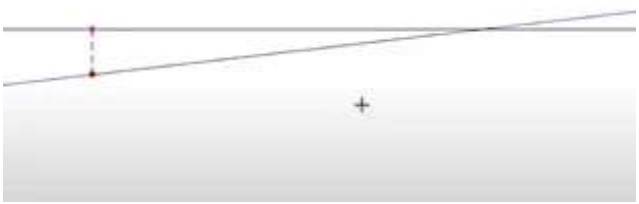

L'idea è che vicino la radice la funzione si comporta come una retta, che L'APPROSSIMAZIONE CON LA TANGENTE È PROPRIO UNA BUONA STIMA!

Scritto in maniera delle formule

$\phi(x) = x - \frac{f(x)}{f'(x)}$ $\quad f \in C^1(\mathbb{R})$ ← ALMENO derivabile

$f'(\alpha) \neq 0$

$$\begin{cases} x_0 \text{ dato} \\ x_{n+1} = x_n - \dfrac{f(x_n)}{f'(x_n)} \end{cases}$$

Retta TANGENTE a $(x_0, f(x_0))$ ha equazione $f'(x_0)(x - x_0) + f(x_0)$

ci troviamo questa ponendola pari a 0

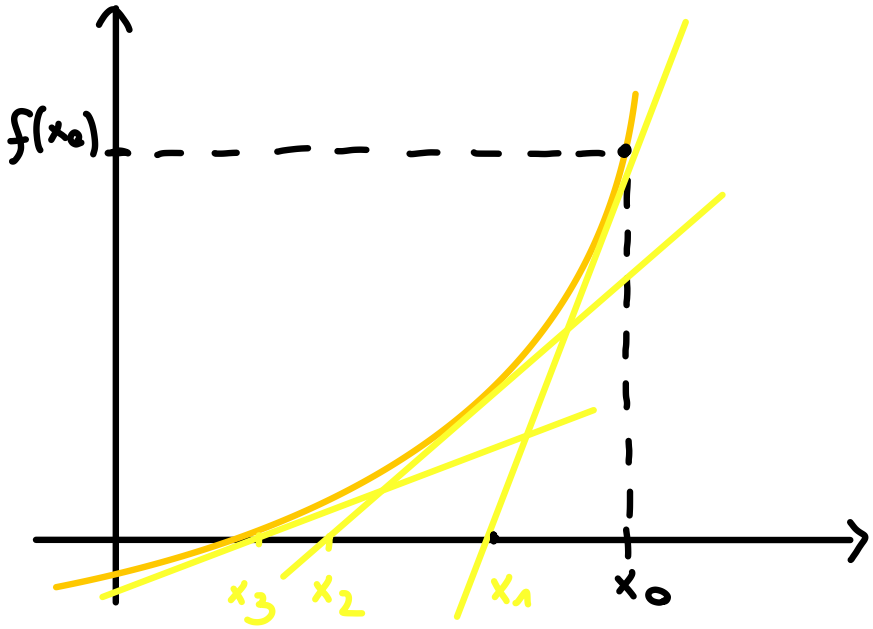

Le cose possono andare "male" quando si ha una funzione che è molto piatta vicino alla radice α, Si può avere convergenza LENTA.

$(x - \alpha)^m$ con $m > 0$ ← descrive quando f si avvicina a zero!

$p=1$ dritta verso lo zero

$p=2$ scende piano come una parabola

$p=3$ scende pianissimo funzione piatta

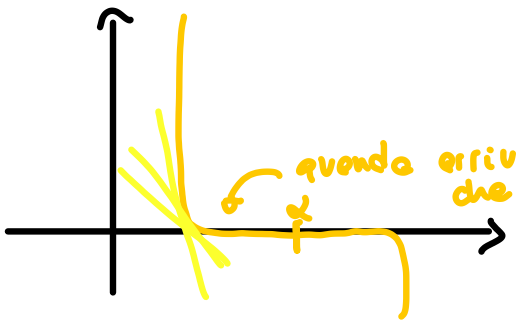

Cerchiamo di descrivere questa cosa introducendo il concetto di **molteplicità di una radice**

DEF $f:[a,b] \to \mathbb{R}$ continua e α tale che $f(\alpha)=0$
α è detta radice di molteplicità r se:

$$\lim_{x\to\alpha} \frac{f(x)}{(x-\alpha)^r} = c < +\infty \quad \text{con } c \neq 0$$

(ovvero per x vicino ad α $f(x) \approx (x-\alpha)^r$)

Se $r=1$ allora α è detta **RADICE SEMPLICE**

Proprietà: se $f \in C^r([a,b])$ (f sufficientemente derivabile), allora α è radice di molteplicità r se e solo se:

$$f(\alpha) = f'(\alpha) = \dots = f^{(r-1)}(\alpha) = 0 \quad , f^{(r)}(\alpha) \neq 0$$

NOTA

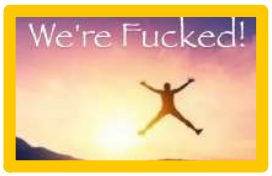

- per $r=1$, la radice è semplice poichè la funzione attraversa l'asse x con una pendenza ben visibile. La tangente in α non è orizzontale
- per $r=2$, la radice è doppia, la funzione tocca l'asse x e torna indietro ∩ ∪, come una parabola. La tangente in α è orizzontale ($f'=0$)
- per $r=3$ la funzione attraversa l'asse ma in modo molto piatto ⊓ Newton fa fatica per $r \geq 2$, perchè la tangente in α è quasi orizzontale, quindi la tangente incontra l'asse x molto lontano da α

Con l'ultima proprietà possiamo definire il seguente **TEOREMA**

TEOREMA Se α è radice semplice di f e $f \in C^2$ (f derivabile due volte) allora il metodo di Newton converge in modo superlineare (almeno quadratico). In particolare converge con ordine 2 se $f'(\alpha) \neq 0$ e con ordine >2 se $f'(\alpha) = 0$

DIM dobbiamo prendere la derivata prima di Newton e far vedere $\phi(\alpha)=0$

$$\phi(x) = x - \frac{f(x)}{f'(x)}$$

$$\phi'(x) = 1 - \frac{[f'(x)]^2 - f(x)f''(x)}{[f'(x)]} = \frac{f(x)f''(x)}{[f'(x)]^2}$$

$$\phi'(\alpha) = \frac{f(\alpha)f''(\alpha)}{[f'(\alpha)]^2} = 0 \longrightarrow$$ IL METODO CONVERGE CON ORDINE SUPERLINEARE

$$\phi''(x) = \frac{(f'\cdot f'' + f\cdot f''')[f']^2 - ff''\cdot 2f'f''}{(f')^4}$$

$$\Rightarrow \phi''(\alpha) = \frac{[f'(\alpha)]^3 f''(\alpha)}{[f'(\alpha)]^4} = \frac{f''(\alpha)}{f'(\alpha)} \Rightarrow$$ ordine 2 se $f''(\alpha)\neq 0$ ALTRIMENTI ordine >2

RADICI MULTIPLE nel caso α abbia molteplicità >1 la derivata si annulla poiché piatta, si ridefinisce l'iterazione di Newton

$$\phi(x) = \begin{cases} x - \frac{f(x)}{f'(x)} & \text{se } x \neq \alpha \\ \alpha & \text{se } x = \alpha \end{cases}$$

questo metodo non ha più convergenza superlineare, ma converge ancora localmente in modo lineare (ci avviciniamo però più lentamente)

Vediamo perché

Supponiamo di riscriverci $f(x) = g(x)\cdot(x-\alpha)^m$ $g(\alpha)\neq 0$

con $m \in \mathbb{N}, m > 1$

Andiamo a vedere cosa succede alle derivate

$$f'(x) = g'(x)(x-\alpha)^m + g(x)(x-\alpha)^{m-1}$$
$$f''(x) = g''(x)(x-\alpha)^m + m g'(x)(x-\alpha)^{m-1} + m g'(x)(x-\alpha)^{m-1} + m(m-1)g(x)(x-\alpha)^{m-2}$$

$$\phi'(\alpha) = \frac{f(\alpha)f''(\alpha)}{[f'(\alpha)]^2}$$ ← lo avevamo visto nella dimostrazione del teorema di prima

Un sacco di cose si annullano $(\alpha - \alpha) = 0$!

ancora non valutato in α

$$\phi'(\alpha) = \frac{1 - m g(\alpha)^2}{m^2 g(\alpha)^2} = 1 - \frac{1}{m} < 1 \quad \text{Per } r > 1$$

dunque il metodo converge ma non è mai zero (dunque la convergenza non è mai più che lineare)
Inoltre se si aumenta la molteplicità della radice la velocità di convergenza è sempre più lenta poiché $1 - \frac{1}{m}$ è sempre più vicino ad 1!

OSS Se si conosce m, si può ristorare la convergenza superlineare (almeno quadratica), modificando come segue.

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)} \cdot m$$

Esempio

Calcolare il reciproco di $t \in \mathbb{R}^+$ senza usare divisioni, con il METODO DI NEWTON.

$f(x) = x^{-1} - t$ la cui radice è $\alpha = t^{-1}$ e si applica Newton

$$\phi(x) = x - \frac{x^{-1} - t}{-x^{-2}} = x + x - tx^2 = 2x - tx^2$$

$$x_{n+1} = 2x_n - tx_n^2$$ ← moltiplicazioni e sottrazioni invece di /

come scelgo x_0? devo studiare dove la derivata è < 1

$$\phi'(x) = 2(1 - xt)$$

Vado a vedere quando $|\phi'(x)| < 1$

$|\phi'(x)| < 1 \iff |1 - xt| < \frac{1}{2} \longrightarrow \begin{cases} 1 - xt < \frac{1}{2} \\ 1 - xt > -\frac{1}{2} \end{cases} \iff$

$\iff \begin{cases} x > \frac{1}{2t} = \frac{t^{-1}}{2} \\ x < \frac{3}{2t} = \frac{3}{2}t^{-1} \end{cases}$ $\quad x_0 \in \left[\frac{1}{2}t^{-1}, \frac{3}{2}t^{-1}\right]$

Lezione 21

Con newton abbiamo detto che:
data $f: \mathbb{R} \to \mathbb{R}$ non lineare, cerchiamo gli $\alpha \in \mathbb{R}: f(\alpha)=0$
dove il metodo iterativo è dato da

$$\begin{cases} x_0 \\ x_{n+1} = x_n - \dfrac{f(x_n)}{f'(x_n)} = \phi(x_n) \end{cases} \qquad \phi(x) = x - \frac{f(x)}{f'(x)}$$

$f \in C^1$ (derivabile almeno 1 volta)

↳ se la derivata prima non si annulla nella radice
Allora il metodo converge superlinearmente
ovvero in maniera più che lineare!

se $f \in C^2$ e $f'(\alpha) \neq 0$ Abbiamo visto che newton converge in modo almeno quadratica (perchè quando ma è vicino alla soluzione l'errore, ovvero la distanza dalla soluzione vera, viene elevata al quadrato, pensi ad un numero piccolino elevato al quadrato è nettamente più piccolo!)

Metodi Iterativi e Metodi di Newton, garantiscono che funzionano se ma parte sufficientemente vicino $[\alpha-\rho, \alpha+\rho]$ abbastanza piccolo!

In generale se non siamo particolarmente vicini ad α con il numero di partenza, potrebbe succedere che il metodo non converge oppure non converge ALLA RADICE che ci ASPETTIAMO

Esempio $f(x) = 3x^2 \cdot e^{-x} + 1 \qquad f(x)=0 \Rightarrow 3x^2 = e^x$

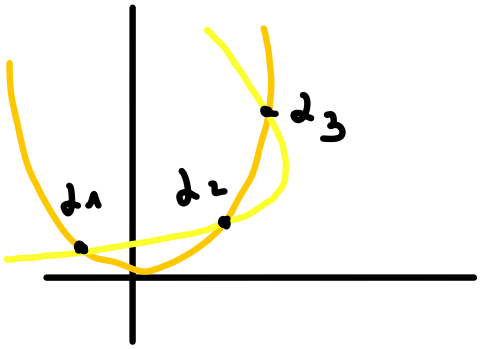

$\alpha_1 < \alpha_2 < \alpha_3$

$x_0 = -\frac{1}{2}$ → newton converge ad α_1

$x_0 = 1$ → newton converge ad α_2

$x_0 = 5$ → newton converge ad α_3

Per casa, verificare con MATLAB!

Come ULTIMO risultato su Newton, vediamo dei casi in cui si hanno convergenze più forti (convergenza globale)
Non si ha più questa restrizione dove → devo partire abbastanza vicino ad α per essere sicuro di convergere a quella radice.

Questo accade nel caso in cui la FUNZIONE F_1 abbia particolari proprietà di convessità o concavità.

DOMANDA Quando possiamo assicurare che il metodo di Newton converge $\forall x_0 \in [a,b]$?

TEOREMA (vale $\forall$ metodo di pt fisso non solo x newton)
Sia $\phi(x) \in C^1([a,b])$ tale che:
(i) $\phi(x) \in [a,b] \quad \forall x \in [a,b]$
↳ l'intervallo viene mappato tramite questa fi, dentro se stesso. Se parto dal dentro, non posso uscire dall'intervallo.
(ii) $|\phi'(x)| < 1 \quad \forall x \in [a,b]$

Allora c'è un'unica soluzione α di $\alpha = \phi(\alpha)$ in $[a,b]$ e il metodo $x_{n+1} = \phi(x_n)$ converge $\forall$ scelta di x_0 in $[a,b]$

↳ ogni volta che scelgo x_0 in $[a,b]$ se ho queste due proprietà il metodo viene ATTRATTO dalla soluzione α, quindi al limite si va ad α!

OSS

Cosa cambia rispetto alla convergenza locale?

(i) La prima proprietà → dove la funzione mappa l'intervallo dentro se stesso.

↓

"Se do in pasto alla funzione un numero che sta in $[a,b]$ il risultato che esce sta ancora in $[a,b]$"

Per il METODO DI NEWTON si riesce a garantire la proprietà 1 e 2 con delle ipotesi più esplicite sulla funzione f.

TEOREMA Sia $\alpha \in [a,b]$ (semplice) di $f(x) \in C^2([a,b])$ e supponiamo che f abbia la derivata prima che non cambia segno (crescente o decrescente), e la derivata seconda non cambia segno (o concava o convessa) su $[a,b]$

↳ Allora il metodo di Newton converge $\forall x_0 \in [a,b]$ che verifica $f(x_0) \cdot f(x_0)'' > 0$

dunque converge a destra o sinistra della soluzione in base alle varie proprietà su f.

OSS Se f è concava allora si converge per $f(x_0) < 0$, se f è convessa per $f(x_0) > 0$

ABBIAMO 4 CASI

- $f' > 0$ $f'' > 0$ crescente e convessa

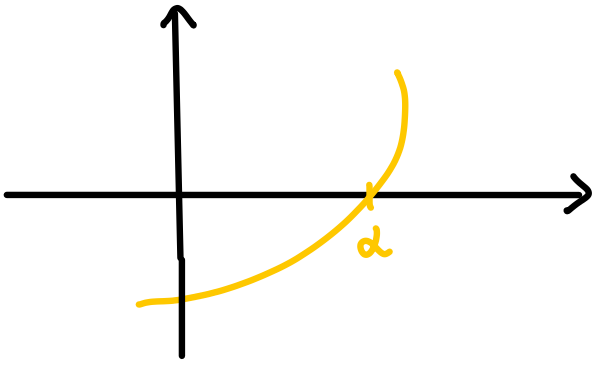

Si converge ogni qualvolta che x_0 è preso alla destra di α

$f(x_0) > 0$ ALLA DESTRA

- $f' > 0$ $f'' < 0$ crescente e concava

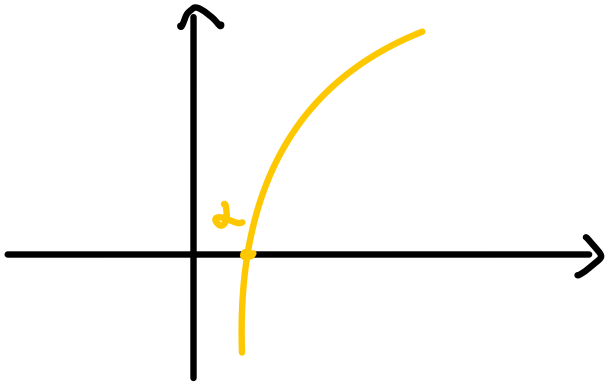

Si converge ogni qualvolta che x_0 è scelto alla sinistra di α!
$f(x_0) < 0$ alla sinistra

- $f' < 0$, $f'' > 0$ decrescente e convessa

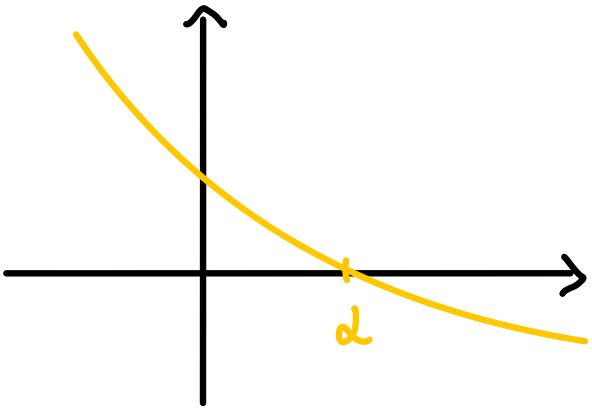

Si converge ogni qualvolta che x_0 è scelto alla sinistra di α
$f(x_0) > 0$ alla sinistra

- $f' < 0$, $f'' > 0$ descrescente concava

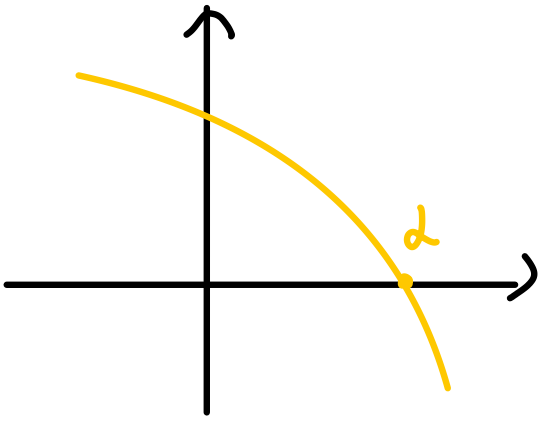

Si converge ogni qualvolta che x_0 è scelto alla destra di α
$f(x_0) < 0$ alla destra

" Queste proprietà abbastanza forti di monotonia e concavità/convessità se la soluzione è stimata per eccesso o per difetto, rispetto al nostro pt di partenza si arriva sempre a convergenza"

Equazioni non lineari in $\mathbb{R}^m$

Questa volta si ha $f: \mathbb{R}^m \to \mathbb{R}^m$

$$\begin{pmatrix} x_1 \\ \vdots \\ x_m \end{pmatrix} \longrightarrow \begin{pmatrix} f_1(x_1 \dots x_m) \\ \vdots \\ f_m(x_1 \dots x_m) \end{pmatrix}$$

bisogna cercare i vettori $\alpha = \begin{bmatrix} \alpha_1 \\ \vdots \\ \alpha_m \end{bmatrix}$ che verificano

$f(\alpha) = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}$ che è equivalente a risolvere il sistema

$$\begin{cases} f_1(x_1 \dots x_m) = 0 \\ \vdots \\ f_m(x_1 \dots x_m) = 0 \end{cases} \quad \text{con } f_j(x): \mathbb{R}^m \to \mathbb{R}$$

Cerchiamo adesso di estendere la teoria vista per $f: \mathbb{R} \to \mathbb{R}$ a questo caso in più variabili

oss Nel caso in cui le $f_j(x)$ sono lineari, si torna al caso del sistema LINEARE

$$f(x) = b - Ax$$

Anche qui, l'idea è quella di riscrivere $f(x) = 0$, come un'equazione di punto fisso vettoriale:

$$x = \phi(x) \quad \text{con} \quad \phi: \mathbb{R}^m \to \mathbb{R}^m$$

Una scelta canonica per scegliere ϕ consiste nello scegliere una funzione $G: \mathbb{R}^m \to \mathbb{R}^{m \times m}$ e considerare:

$$\phi(x) = x - \underbrace{G(x)}_{\text{matrice}} \underbrace{f(x)}_{\text{vettore}}$$

Dove $G(x)$ è tale per cui $G(\alpha)$ è INVERTIBILE (per mantenere l'unicità della soluzione) $(\det(G(\alpha)) \neq 0)$

↳ $\ker(G(\alpha)) = \{0\}$ ← questo perché così siamo sicuri di non star creando altre radici di f

Una volta scelta l'equazione di pt fisso si considera l'iterazione

$$\begin{cases} x^0 \text{ DATO} \\ x^{(n+1)} = \phi(x^{(n)}) \quad n = 0, 1, 2 \dots \end{cases}$$

Quindi abbiamo un modo per generarci una successione di vettori che speriamo convergono alla soluzione del sistema di equazioni NON LINEARI!

Uno può scegliere questa G oppure può manipolare il sistema trovano $x = \text{qualcosa}$

Una volta definita la successione $\{x^{(n)}\}_{n \in \mathbb{N}}$ associata ad un metodo iterativo, possiamo estendere i concetti di convergenza e ordine di convergenza impiegando le norme al posto dei valori assoluti.

DEF $\{x^{(n)}\}_{n \in \mathbb{N}}$ converge ad $\alpha \in \mathbb{R}^m$ se

$$\lim_{n \to +\infty} \|x_n - \alpha\|_2 = 0$$

E la convergenza si dice di ordine $p > 0$ se vale

$$\lim_{n \to +\infty} \frac{\|x_{n+1} - \alpha\|_2}{\|x_n - \alpha\|_2^p} = c \quad \text{con } c \neq 0 \text{ e } c < +\infty$$

COMMENTO Data che le norme vettoriali sono equivalenti si può rimpiazzare la norma 2 con una qualsiasi norma!

Dunque abbiamo $\phi : \mathbb{R}^m \to \mathbb{R}^m$ che definisce il metodo iterativo

$$\phi(x_1 \dots x_m) = \begin{bmatrix} \Phi_1(x_1 \dots x_m) \\ \vdots \\ \Phi_m(x_1 \dots x_m) \end{bmatrix} \quad \text{dove } \phi_j(x) : \mathbb{R}^m \to \mathbb{R}$$

Si introduce la matrice Jacobiana di ϕ dove, ad ogni riga corrisponde il gradiente di una di queste funzioni

$$J\phi(x) = \begin{bmatrix} \frac{\partial \phi_1(x)}{\partial x_1} & \frac{\partial \phi_1(x)}{\partial x_2} & \dots & \frac{\partial \phi_1(x)}{\partial x_m} \\ \vdots & & & \\ \frac{\partial \phi_m(x)}{\partial x_1} & \frac{\partial \phi_m(x)}{\partial x_2} & \dots & \frac{\partial \phi_m(x)}{\partial x_m} \end{bmatrix}$$

$J\phi(x)$ è la matrice Jacobiana di ϕ, che va da $\mathbb{R}^m \to \mathbb{R}^{m \times m}$, cioè ad ogni punto x associa una matrice $m \times m$

L'elemento (i,j) della Jacobiana è

$$[J\phi(x)]_{ij} = \frac{\partial \phi_i(x)}{\partial x_j}$$

convergenza locale in più variabili

Teorema Sia $\phi(x) \in C^1(\Omega)$, $\Omega \subseteq \mathbb{R}^m$, e che $\alpha \in \Omega$ sia tale che $\alpha = \phi(\alpha)$ (α è invettore)

Chiediamo che, se $\rho(J\phi(\alpha)) < 1$

Allora:

- $\exists\, \delta > 0$ tale per cui: se scelgo il punto di partenza a distanza minore di δ dalla soluzione, se $x^{(0)}$ verifica $\|x^{(0)} - \alpha\|_2 < \delta$

Allora la successione $\begin{cases} x^{(0)} \\ x^{(n+1)} = \phi(x^{(n)}) \end{cases}$ converge ad α

qualsiasi norma

Oss se vale che $\|J\phi(\alpha)\| \leq K \in (0,1)$ allora il metodo è convergente perché $\rho(J\phi(x)) \leq \|J\phi(\alpha)\|$

non vale il viceversa!

Una cosa che si può generalizzare in questo ambiente è il metodo di Newton.
Che nel caso di più variabili è chiamata

Metodo di Newton-Raphson

Si prende l'espressione del metodo di Newton, e dove c'è la parte della derivata di f, si prende il corrispettivo in più variabili ovvero il Jacobiano di f.

$$\phi(x) = x - Jf(x)^{-1} f(x)$$

← funzione di iterazione del metodo di Newton-Raphson.

Questa cosa ha senso se le funzioni $f_J(x)$ sono derivabili, con continuità, e $Jf(x)$ sia invertibile in una regione $\Omega \subseteq \mathbb{R}^m$ che contiene α: $f(\alpha)=0$

OSS nell'implementazione ogni volta che si deve calcolare $x^{(n+1)}$ si risolve il sistema lineare

$$Jf(x^{(n)}) \cdot y = f(x^{(n)})$$

ed infine si calcola $x^{(n+1)} = x^{(n)} - y$

Per quanto riguarda la convergenza

Vale un risultato analogo al caso scalare, che assicura una convergenza superlineare

Teorema $f \in C^2(\Omega)$, $\Omega \subseteq \mathbb{R}^m$, $\alpha : \substack{f(\alpha)=0 \\ \alpha \in \Omega}$, se $Jf(\alpha)$ è invertibile allora esiste un intorno S di α, ed esiste $\beta > 0$ tale che:

$\forall x^{(0)} \in S$ la successione $\{x^{(n)}\}$ generata da Newton-Raphson

Verifica

$$\|x^{(n+1)} - \alpha\|_2 \leq \beta \|x^{(n)} - \alpha\|_2^2$$

($x^{(n+1)} - \alpha$: errore al passo nuovo; $x^{(n)} - \alpha$: errore al passo vecchio)

questo significa che Newton Raphson ha convergenza quadratica

(ovvero $\lim_{n \to +\infty} \frac{\|x^{(n+1)} - \alpha\|_2}{\|x^{(n)} - \alpha\|_2^2} \leq \beta$)

Ci sono un pò di vantaggi su questo metodo

- C'è una scelta canonica della formula
- Se vogliamo convergenza ci basta guardare all'invertibilità del Jacobiano e non a tutti gli autovalori. (solo x newton)

- Per un metodo iterativo generico va studiato il raggio spettrale
- Newton-Raphson dobbiamo studiare lo Jacobiano!

VARIANTI di Newton Raphson

Ad ogni passo NR richiede 2 operazioni potenzialmente Costose (se m grande)

1. Calcolare $Jf(x^{(n)})$ che richiede valutare m^2 funzioni non LINEARI
2. Risolvere il sistema $Jf(x^k)\, y = f(x^{(n)})$, che come sappiamo in generale costa $O(m^3)$

Per questo, quando m grande si propongono STRATEGIE (metodi quasi newton) in cui si rimpiazza il Jacobiano con qualcos'altro per rendere le iterazioni meno costose!

STRATEGIA 1 Newton semplificato

Si usa sempre $Jf(x^{(0)})$ per tutte le iterazioni

$$x^{(n+1)} = x^{(n)} - Jf(x^{(0)})^{-1} f(x^{(n)})$$

- Valuto una sola volta le funzioni non lineari
- Posso calcolarmi una sola fattorizzazione LU di $Jf(x^{(0)})$ in modo tale che ad ogni iterazione devo soltanto risolvere sistemi triangolari con costo $O(n^2)$

STRATEGIA 2 Metodo non Lineare di Jacobi

Ad ogni passo uso la diagonale del Jacobiano al posto di TUTTO $Jf(x^{(n)})$

$$\text{DIAG}\left(\frac{\partial f_1}{\partial x_1}(x), \frac{\partial f_2}{\partial x_2}(x) \dots \frac{\partial f_m}{\partial x_m}(x)\right)$$

$$x^{n+1} = x^n - D J(x^{(n)})^{-1} \cdot f(x^{(n)})$$

Valuto solo $O(n)$ funzioni NON LINEARI
Risolvere i sistemi LINEARI costa solo $O(n^2)$

Approssimare / Calcolare Autovalori e Autovettori

L'obbiettivo è trovare le coppie (λ, v) dove λ scalare, e v vettore che verificano l'equazione caratteristica.

Si $A \in \mathbb{C}^{n \times n}$ vogliamo trovare una / TUTTE LE soluzioni (λ, v): $v \in \mathbb{C}^n \setminus \{0\}$, $\lambda \in \mathbb{C}$ di

$$\boxed{Av = \lambda v}$$

→ vettori tali che se gli applichiamo la matrice A vengono mandati in un multiplo scalare di se stessi!

Vedremo due metodi iterativi per fare questa, che approcciano due versioni di questo problema

(i) Calcolo di una singola AUTOCOPPIA (λ, v) ad esempio quella relativa all'autovalore di modulo massimo!

(ii) Calcolo SIMULTANEO di tutte le autocoppie (λ, v)

"L'idea è capire cosa c'è nascosto nel comando eig(A) di Matlab"

Supponiamo di avere $(\tilde{\lambda}, \tilde{v})$ candidata e supponiamoci di chiederci è una buona approssimazione? $\tilde{\lambda} \in \mathbb{C}$, $\tilde{v} \in \mathbb{C}^n$ come faccio a valutare la qualità di questa approssimazione?

OPZIONE 1 Calcolarsi la norma $\dfrac{\|A\tilde{v} - \tilde{\lambda}\tilde{v}\|_2}{\|\tilde{v}\|_2}$

opzione 2 $\dfrac{\tilde{v}^H A \tilde{v}}{\tilde{v}^H \tilde{v}} = \dfrac{\tilde{v}^H A \tilde{v}}{\|\tilde{v}\|_2^2}$

L'ultima quantità è buona per capire quanto siamo vicini alla soluzione

DEFINIZIONE La quantità $\dfrac{\tilde{v}^H A \tilde{v}}{\tilde{v}^H \tilde{v}} = R(\tilde{v})$ è detta quoziente di Rayleigh ed è tale per cui:

se valutiamo questa quantità in autovettore, se v è autovettore associato a λ, allora

$$R(v) = \frac{v^H A v}{v^H v} = \lambda \frac{v^H v}{v^H v} = \lambda$$

METODO DELLE POTENZE

facciamo un esempio semplice, prendiamo:

$$A = \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix} \quad \text{(diagonale)}$$

E supponiamo di voler trovare l'autocoppia associata all'autovalore di modulo max!

Si ha una matrice diagonale e vogliamo trovare l'autovalore e l'autovettore associato di modulo massimo, allora in questo caso le soluzioni sono semplici perché

- l'autovalore sarà l'elemento sulla diagonale di modulo massimo
- l'autovettore associato sarà il vettore della base canonica con indice l'indice dell'autovalore associato

Se l'autovalore è λ_i, l'autovettore è e_i

Supponiamo i sia l'indice per cui $|\lambda_i| > |\lambda_j| \quad \forall i \neq j$

Quindi la soluzione al nostro problema è (λ_i, e_i)

$$e_i = \begin{bmatrix} 0 \\ 0 \\ 1 \\ 0 \\ 0 \end{bmatrix} \leftarrow i$$

Vogliamo un metodo che ci identifica questa cosa (senza farlo noi con carta e penna)

l'idea del metodo delle potenze è

Prendo un vettore generato a caso ad esempio, porto con $z^{(0)} \in \mathbb{C}^n$: generato casualmente

e comincio a moltiplicare questo vettore per la matrice A, iterativamente.

Considero $z^{(1)} = Az^{(0)}$; $z^{(2)} = Az^{(1)} = A^2 z^{(0)}$; $z^{(3)} = Az^{(2)} = A^{(3)} z^{(0)}$

Ad ogni passaggio:

$z^{(0)} = \begin{bmatrix} z_1^{(0)} \\ z_2^{(0)} \\ \vdots \\ z_n^{(0)} \end{bmatrix}$ → quando moltiplichiamo per A, stiamo moltiplicando ogni entrata singolarmente per un λ diverso

$z^{(1)} = \begin{bmatrix} \lambda_1 z_1^{(0)} \\ \lambda_2 z_2^{(0)} \\ \vdots \\ \lambda_n z_n^{(0)} \end{bmatrix}$, $z^{(2)} = \begin{bmatrix} \lambda_1^2 z_1^{(0)} \\ \lambda_2^2 z_2^{(0)} \\ \vdots \\ \lambda_n^2 z_n^{(n)} \end{bmatrix}$

Iterazione k ..... $z^{(k)} = \begin{bmatrix} \lambda_1^{(k)} z_1^{(0)} \\ \lambda_2^{(k)} z_2^{(0)} \\ \lambda_i^{(k)} z_i^{(0)} \\ \lambda_n^{(k)} z_n^{(0)} \end{bmatrix}$ → In questo vettore vedremo emergere una componente più grande degli altri

Dopo un pò di iterazioni sarà evidente chi è l'entrata di massimo modulo!

↳ Se divido $z^{(k)}$ per la sua norma otterremo:

$$\frac{z^{(k)}}{\|z^{(k)}\|_2} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ \vdots \\ 0 \\ 0 \end{bmatrix}$$

qt piccole

in posizione i l'unica non trascurabile! (vicino ad 1)

qt vicino a 0

Quindi questo vettore $\frac{z^{(k)}}{\|z^{(k)}\|_2}$ sta convergendo a e_i, vettore che ha tutti 0 ed 1, in pos. i che è proprio la soluzione del problema

Questa è l'idea in un caso facile, data la matrice diagonale sappiamo come è fatto l'autovettore.

FACCIAMO UN CASO PIÙ GENERALE

Supponiamo $A \in \mathbb{C}^{n \times n}$, diagonalizzabile e che i suoi autovalori verificano:

$$|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots \geq |\lambda_n|$$

e chiamiamo $v^{(1)} \dots v^{(n)}$ delle scelte dei corrispondenti Autovettori

Vediamo, che, fare un procedimento di quello visto prima, ovvero moltiplicare un vettore di partenza con le potenze di A, ci porta ad un modo per trovare $\lambda_1 v_1$

L'idea è, preso $z^{(0)} \in \mathbb{C}^n$, dato che la matrice è diagonalizzabile, questi autovettori $v_1 \dots v_n$ formano una base di $\mathbb{C}^n$, vuol dire che posso scrivermi $z^{(0)}$ come una combinazione lineare degli autovettori!

$$z^{(0)} = \sum_{j=1}^{n} c_j v^{(j)} \quad \text{per certi } c_j \in \mathbb{C}$$

Quindi

- $$A z^{(0)} = A \sum_{j=1}^{n} c_{ij} v^{(j)} = \sum_{j=1}^{n} c_j A v^{(j)} = \sum_{j=1}^{n} c_j \lambda_j v^{(j)}$$

facciamo passaggio due del metodo delle potenze

- $$A z^{(1)} = A^2 z^{(0)} = A \sum_{j=1}^{n} c_j \lambda_j v^{(j)} = \sum c_j \lambda_j \underbrace{A v^{(j)}}_{\lambda_j v_j} = \sum_{j=1}^{n} c_j \lambda_j^2 v^{(j)}$$

Al passo k

- $$z^{(k)} = A z^{(k-1)} = A^k z^{(0)} = \sum_{j=1}^{n} c_j \lambda_j^k v^{(j)} =$$ Se si volesse continuare....

Ancora una volta ci spunto la potenza degli autovalori, quindi la pote che dominera in questa sommatoria sarà quella con la potenza dell'autovalore più grossa, e quindi quella che possiamo estrarre come approssimazione dell'autovettore!

$$= \lambda_1^k \left(c_1 v^{(1)} + \underbrace{\left(\frac{\lambda_2}{\lambda_1}\right)^k} v^{(2)} + \dots + \underbrace{\left(\frac{\lambda_n}{\lambda_1}\right)^k} v^{(n)} \right)$$

convergono a 0 per $k \to +\infty$

Teorema $A \in \mathbb{C}^{n\times n}$ Hermitiana $(A = A^H)$ con autovalori

$$|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots \geq |\lambda_n|$$

e sia $z^{(0)} \in \mathbb{C}^n$ tale che:

$$[v^{(1)}]^H z^{(0)} \neq 0$$ ← pt di partenza ($z^{(0)}$ non ortogonale all'autovettore v_i)

e sia $h \in \{1 \dots n\}$ tale per cui $v_h^{(1)} \neq 0$ allora la successione

$$\begin{cases} z^{(0)} \\ z^{(k)} = A z^{(k+1)} \end{cases}$$ è tale per cui:

$$\lim_{k \to +\infty} \frac{z^{(k)}}{z_h^{(k)}} = \tilde{v}^{(1)}$$ è un multiplo di $v^{(1)}$ (multiplo autovettore!) con componente 1 in posizione h.

↑ Risultato sulla convergenza dell'autovettore

E si ha che il limite del quoziente di Reilgh

$$\lim_{k \to +\infty} \frac{[z^{(k)}]^H A z^{(k)}}{[z^{(k)}]^H z^k} = \lambda_1$$ ← buona approssimazione di λ_1!

dunque la successione del quoziente di Railgh associati a questa successione di autovettori converge all'autovalore.

DIMOSTRAZIONE dato che la matrice è Hermitiana allora sappiamo che dal teorema spettrale questa è diagonalizzabile.
dunque si ha una base di autovettori $(v_1 \dots v_n)$

Possiamo scegliere $v^{(1)} \dots v^{(n)}$ in modo che formino una base unitaria di $\mathbb{C}^n$, ovvero

$$v_i^H v_j = \begin{cases} 1 & \text{se } i = j \\ 0 & \text{altrimenti} \end{cases}$$

In particolare se $b^{(0)} = \sum_{J=1}^{n} c_J v^{(J)}$ abbiamo che

c_J può essere scritta come $c_J = [v^{(J)}]^H z^{(0)} = \sum_{J=1}^{n} c_J [v^{(i)}]^H v^{(J)} =$

questi prodotti sono tutti 0, tranne quando J è scelto uguale ad i!

$= c_i \cdot \underbrace{[v^{(i)}]^H v^{(i)}}_{1} = c_i$

Quindi la nostra assunzione $[v^{(i)}]^H z^{(0)} \neq 0$ ci dice che $c_1 \neq 0$!

Dunque il nostro punto di partenza ha una componente $\neq 0$ lungo l'autovettore $v^{(1)}$

Come già discusso in precedenza (facendo gli stessi passaggi visti prima) si ha che:

ANDRÀ A 0, per $k \to +\infty$ diventano sempre + picc

$$z^{(k)} = A^k z^{(0)} = \lambda_1^k \left[\underbrace{c_1 v^{(1)}}_{\neq 0} + \sum_{J=2}^{n} \underbrace{\left(\frac{\lambda_J}{\lambda_1}\right)^k}_{\to 0} v^{(J)} \right]$$

Per cui:

$$\lim_{n \to +\infty} \frac{z^{(k)}}{z_h^{(k)}} = \lim_{k \to +\infty} \frac{\lambda_1^k \left[c_1 v^{(1)} + \sum_{J=2}^{n} \left(\frac{\lambda_J}{\lambda_1}\right)^k v^{(J)} \right]}{\lambda_1^k \left[c_1 v_h^{(1)} + \sum_{J=2}^{n} \left(\frac{\lambda_J}{\lambda_1}\right)^k v_h^{(J)} \right]} =$$

$$= \lim_{k \to +\infty} \frac{c_1 v^{(1)}}{c_1 v_h^{(1)}} = \frac{v^{(1)}}{v_h^{(1)}}$$

Infine:

DIVIDO sopra e sotto per la componente h di $z^{(k)}$

$$\lim_{k \to +\infty} \frac{[z^{(k)}]^H A z^{(k)}}{[z^{(k)}]^H z^{(k)}} = \lim_{k \to +\infty} \frac{\left[\frac{z^{(k)}}{z_h^{(k)}}\right]^H A \frac{z^{(k)}}{z_h^{(k)}}}{\left[\frac{z^{(k)}}{z_h^{(k)}}\right]^H \left[\frac{z^{(k)}}{z_h^{(k)}}\right]} =$$

$$= \frac{\left[\frac{v^{(1)}}{v_h^{(1)}}\right]^H A \left[\frac{v^{(1)}}{v_h^{(1)}}\right]}{\left[\frac{v^{(1)}}{v_h^{(1)}}\right]^H \left[\frac{v^{(1)}}{v_h^{(1)}}\right]} = \frac{[v^{(1)}]^H A v^{(1)}}{[v^{(1)}]^H v^{(1)}} = R(v^{(1)}) = \lambda_1$$

↶ quoziente di Rayleigh in autovettore

OSS la successione $z^{(k)} = A z^{(k-1)}$ può portare facilmente a problemi di overflow o underflow.

dato che moltiplicare/dividere per uno scalare, non cambia la proprietà di convergenza di $z^{(k)}$, l'implementazione pratica del metodo delle potenze comporta un passaggio di normalizzazione del vettore

METODO DELLE POTENZE

$z^{(0)}$

for $k = 1, 2, 3$

$y^{(k)} = A \cdot z^{(k-1)}$

$z^{(k)} = y^{(k)} / \|y^{(k)}\|_2$

Il costo è quindi dato dal costo del prodotto matrice vettore, più il costo del calcolo della norma che è $O(n)$.

CRITERIO di arresto Si può usare

$$R(z^{(k)} - R(z^{(k-1)}) < TOL$$

oppure $\|A z^{(k)} - R(z^{(k)}) z^{(k)}\|_2 < TOL$

OSS Per eseguire il metodo, non serve neanche formare A esplicitamente, nel caso basta una funzione blackbox, che preso un vettore $v \to Av$

COMMENTO SULLE IPOTESI DEL TEOREMA

(i) non è necessario $A = A^H$, la dimostrazione funziona anche con A diagonalizzabile

(ii) L'assunzione $[v^{(1)}]^H z^{(0)} \neq 0$ può sembrare da garantire a priori, ma se si genera $z^{(0)}$ in modo casuale, l'ipotesi è

verificata con probabilità 1.

(iii) l'assunzione $|\lambda_1| > |\lambda_2|$ non è rimovibile ad esempio $A = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$ ha autovalori ± 1 e se ono parte con

$b^{(0)} \neq \begin{bmatrix} 1 \\ 1 \end{bmatrix}$ o $b^{(0)} \neq \begin{bmatrix} 1 \\ -1 \end{bmatrix}$ (o da un loro multiplo scalare) non converge.

appare

$$b^{(0)} = \begin{bmatrix} 2 \\ 3 \end{bmatrix} \rightsquigarrow b^{(1)} = \begin{bmatrix} 3 \\ 2 \end{bmatrix} \rightsquigarrow b^{(2)} = \begin{bmatrix} 2 \\ 3 \end{bmatrix} \rightsquigarrow \dots$$