lezione 1 (26/02/2024)

04 March 2024 18:12

analisi numerica = " studio di algoritmi per problemi di matematica nel continuo"

matematica nel continuo → le incognite ed i dati di partenza sono numeri reali o complessi

errori sui dati → sono necessarie approssimazioni dei dati intermedi e delle soluzioni
inoltre nel 99% dei casi non ho formule esatte che esprimono la soluzione e devo usare procedimenti iterativi

argomenti del corso:

1. rappresentazione dei numeri (analisi errore)
2. richiamo algebra lineare
3. sistemi lineari (Ax=b)
4. equazioni non lineari
5. calcolo autovalori e autovettori
6. approssimazione di funzioni (interpolazione, approssimazione minimi quadrati)
7. integrazione
8. equazioni differenziali

come interagiscono gli errori sugli algoritmi?
quanto in fretta convergono le procedure di risoluzione? → costo computazionale, accuratezza

algoritmi: stabili / instabili

NUMERI IN VIRGOLA MOBILE: $x \in \mathbb{R}$

vogliamo rappresentare x solo con parametri interi (es. fisso una base e rappresento il numero in quella base)

↳ fissiamo $\beta \in \mathbb{N}$, $\beta > 1$ e troviamo $e \in \mathbb{Z}$ ed una successione ... di cifre tali che

$$x = \text{segno}(x) \cdot \beta^e \cdot \sum \alpha_j \beta^{-j}$$

esempio: (notazione scientifica) $\beta = 10 \longrightarrow -3{,}14 \cdot 10^3$

problema 1: non è unica
quando ho numeri periodici

teorema di rappresentazione: $\beta \in \mathbb{N}$, $\beta > 1$, $x \in \mathbb{R}$, $x \neq 0$ allora $\exists!$ rappresentazione di x in base β tale che (1) $\alpha_1 \neq 0$
(2) non esiste $k \in \mathbb{N}$: $\alpha_j = \beta - 1 \quad \forall j > \alpha$

definizione: data una base β, l'unica rappresentazione che verifica le ipotesi del teorema viene detta "rappresentazione in virgola mobile normalizzata" (floating point)

la serie $\sum_{j=1}^{\infty} \alpha_j \beta^{-j}$ è chiamata "mantissa" (sempre < 1)
↳ la mantissa verifica sempre $\frac{1}{\beta} \leq \sum_{j=1}^{\infty} \alpha_j \beta^{-j} < 1$

problema 2: abbiamo infinite cifre α_j e un'esponente "e" che può essere arbitrariamente grande

definizione: dati 4 interi (β, m, L, U) tali che $\beta > 1$, $m > 0$, $L \leq U$, si definisce insieme dei numeri di macchina

$$F(\beta, m, L, U) \subseteq \mathbb{R} \text{ come: } \left\{ x \in \mathbb{R} : \text{segno}(x) \cdot \beta^e \cdot \sum_{j=1}^{m} \alpha_j \beta^j \;,\; e \in \mathbb{Z},\; L \leq e \leq U,\; \alpha_j \in \{0, \dots, \beta-1\},\; \alpha_1 \neq 0 \right\} \cup \{0\}$$

osservazione:

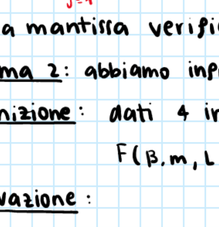

in ogni intervallo $[\beta^j, \beta^{j+1})$, "e" e segno(x) sono fissati ed equispaziati (con distanza il minimo incremento che si ha alla mantissa)

$\beta^e \cdot \beta^{-m} = \beta^{e-m} = \beta^{j+1-m}$
↳ β^{j+1} in questo intervallo

↳ (non sono equispaziati in senso assoluto)

osservazione: la cardinalità di $F(\beta, m, L, U)$ è (quanti sono i numeri di macchina?)

$$2 \cdot (\beta^m - \beta^{m-1}) \cdot (U - L + 1) + 1$$

- 2: segno
- $(\beta^m - \beta^{m-1})$: possibili mantisse con $\alpha_1 \neq 0$ (3 cifre per la mantissa, di cui $\alpha_1 = 1$ → 4 possibili mantisse)
- $(U - L + 1)$: possibili esponenti
- $+1$: valore zero

esempio: $\beta = 2$, $m = 3$, $L = -1$, $U = 3$

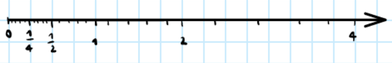

minimo numero positivo rappresentabile? $e = L$
massimo numero rappresentabile? $e = U$

rappresentazioni più comuni di

	β	m	L	U	bit
precisione singola	2	24	-125	128	32
precisione doppia	2	53	-1021	1028	64

troncamento (round-down): prendo sempre l'elemento a sinistra $\lfloor x \rfloor$

- abbiamo $x = \text{segno}(x) \cdot \beta^e \cdot \sum \alpha_j \beta^{-j}$

$$T_R(x) = \text{segno}(x) \cdot \beta^e \cdot \sum_{j=1}^{m} \alpha_j \beta^{-j}$$

(round-up): $U_p(x) = \text{segno}(x) \cdot \beta^e \cdot \left(\sum_{j=1}^{m} \alpha_j \beta^{-j} + \beta^{-m} \right)$

(round-to-nearest): $R_N(x) = \begin{cases} T_R(x) & \text{se } \alpha_{m} < \frac{\beta}{2} \\ U_p(x) & \text{se } \frac{\beta}{2} \leq \alpha_m \leq \beta - 1 \end{cases}$

se $x >$ (maggiore del massimo rappresentabile) non si può arrotondare → OVERFLOW!!
↳ si utilizza una rappresentazione ad hoc

se $x <$ (minimo rappresentabile) → UNDERFLOW!!
↳ in genere si associa $\emptyset$ ad x

errori $|T_R(x) - x| \leq \beta^{e-m}$

$|R_N(x) - x| \leq \frac{1}{2} \beta^{e-m}$

↳ errore assoluto dipende da $|x|$

- errore relativo dell'arrotondamento $\varepsilon_x = \frac{x - R_N(x)}{x} = \frac{\delta_x}{x}$
- errore assoluto dell'arrotondamento $\delta_x = x - R_N(x)$

↳ si vede che $|\varepsilon_x| = \frac{|x - R_N(x)|}{|x|} \leq \frac{1}{2} \beta^{1-m}$

errore relativo dell'arrotondamento è uniforme su range (min rappresentabile − max rappresentabile)
↳ se io pesco un numero qua dentro l'errore non dipende dal suo modulo (è uniforme)
↳ precisione di macchina ($\frac{1}{2} \beta^{1-m}$)
nel caso di precisione doppia: $U \approx 10^{-16}$ (errore) → prime 15 cifre significative sono quelle di cui "ci possiamo fidare"

numeri sottonormalizzati: (subnormal numbers)
numeri più piccoli di β^{L-1}
↳ rinunciano all'assunzione $\alpha_1 = 1$ → in quel caso si usa un valore speciale dell'esponente che indica che sto prendendo β^L ed $\alpha_1 = 0$
(non ho la stessa accuratezza relativa) ↳ in questo modo riesco ad ottenere rappresentazioni del tipo $\beta^L \cdot 0{,}010100\dots$ che quindi riguardano valori fra $[\beta^{L-m}, \beta^{L-1})$

lezione 2 (01/03/2024)

04 March 2024 23:14

operazioni aritmetiche fra numeri floating point: $x, y \in F(\beta, m, L, U)$ $\quad x = \beta^e \cdot \sum_{j=1}^{m} \alpha_j \beta^{-j}$ $\quad \alpha_j \in \{0, \dots, \beta-1\}$ $\quad e \in \mathbb{Z}$ $\quad L \le e \le U$

non è detto che $x \text{ op } y \notin F \longrightarrow \text{op} \in \{+, -, \times, /\}$

definizione: $x \,\widehat{\text{op}}\, y = RD(x \text{ op } y)$ $\quad \text{op} \in \{+, -, \times, /\}$

$\widehat{\text{op}}$ → $\oplus, \ominus, \otimes, \oslash$; RD → operazione di arrotondamento generico (per noi: R_N)

Un effetto collaterale è che si perdono proprietà di base ad esempio, in generale:

$$(x \oplus y) \oplus z \neq x \oplus (y \oplus z)$$

↳ somma non associativa

esempio: $\beta = 10$, $F(10, 3, -99, 99)$

$x = 0{,}135 \cdot 10^{-4}$, $y = 0{,}258 \cdot 10^{-2}$, $z = -0{,}251 \cdot 10^{-2}$

$x \oplus (y \oplus z) = 0{,}135 \cdot 10^{-4} \oplus 0{,}700 \cdot 10^{-4} = 0{,}835 \cdot 10^{-4}$

$(x \oplus y) \oplus z = 0{,}259 \cdot 10^{-2} \ominus 0{,}251 \cdot 10^{-2} = 0{,}800 \cdot 10^{-4}$

] risultati diversi ⟶ differenza relativa circa del 4%

$0{,}001\,35 \cdot 10^{-2}$
$0{,}258\,00 \cdot 10^{-2}$
$0{,}259\,35$

↳ più vicino allo zero che al dieci

analogamente si può far vedere che NON vale la proprietà associativa: $x \otimes (y \oplus z) \neq (x \otimes y) \oplus (x \otimes z)$

conclusione: le parentesi sono importanti (contano più che in matematica esatta!)

errore nel calcolo di una funzione (basata su operazioni esatte): $f: \mathbb{R}^n \to \mathbb{R}$, $f(x_1, \dots, x_n)$ mi interessa $f(P_0)$, $P_0 = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \in \mathbb{R}^n$

↳ valutare la funzione in P_0

ci sono 3 fonti di errore:

① dobbiamo approssimare f con una funzione che utilizza solo $\{+, -, \times, /\}$

↳ tali funzioni si chiamano **razionali**

↳ sono tutte quelle che si scrivono come $\frac{p(x)}{q(x)}$ → p, q polinomi

② $\tilde{f}(x)$ è "tradotta" in un algoritmo, che usa $\oplus, \ominus, \otimes, \oslash$, per cui quello che si valuta veramente è $\tilde{f}_a(x)$

③ al posto di P_0, si valuta $P_1 = R_N(P_0) \in F(\beta, m, L, U)$

conclusione: vorremmo $f(P_0)$ ma in realtà calcoliamo $\tilde{f}_a(P_1)$

definizione: dato $F(\beta, m, L, U)$ ed un algoritmo $\tilde{f}_a(x)$ per approssimare $f(x)$, si definisce ERRORE TOTALE in $P_0 \in \mathbb{R}^n$ la quantità:

↳ un certo insieme di numeri macchina

$$\delta_f = f(P_0) - \tilde{f}_a(P_1) \quad \text{con } P_1 = R_N(P_0)$$

↳ detta ↳ errore totale assoluto

$$\varepsilon_f = \frac{f(P_0) - \tilde{f}_a(P_1)}{f(P_0)}$$

↳ epsilon ↳ errore totale relativo

per semplificarci la vita partiamo dal caso f razionale:

FUNZIONI RAZIONALI in questo caso $f = \tilde{f}$

$$\delta_f = f(P_0) - f_a(P_1)$$

$$\varepsilon_f = \frac{f(P_0) - f_a(P_1)}{f(P_0)}$$

possiamo decomporre l'errore in due componenti:

$$\delta_f = \underbrace{f(P_0) - f(P_1)}_{\text{errore inerente } \delta_d} + \underbrace{f(P_1) - f_a(P_1)}_{\text{errore algoritmico } \delta_a} = \delta_d + \delta_a$$

per l'errore relativo possiamo fare una cosa simile:

$$\varepsilon_f = \frac{f(P_0) - f_a(P_1)}{f(P_0)} \doteq \frac{f(P_0) - f(P_1)}{f(P_0)} + \frac{f(P_1) - f_a(P_1)}{f(P_1)} \cdot \left(1 + \frac{f(P_1) - f(P_0)}{f(P_0)}\right) = \varepsilon_d + \varepsilon_a(1 - \varepsilon_d) = \varepsilon_d + \varepsilon_a - \varepsilon_a\varepsilon_d \doteq \varepsilon_d + \varepsilon_a$$

(ε_d ↳ errore relativo inerente; ε_a ↳ errore relativo (algoritmico?))

stimare l'errore inerente: (l'idea è guardare la derivata)

$\delta_d = f(P_1) - f(P_0)$ $\quad f \in C^1(D)$, $P_0 \in D$

$$\delta_d \doteq f(P_1) - [f(P_0) + \nabla f(P_0)^T (P_1 - P_0)] = -\nabla f(P_0)^T (P_1 - P_0) = -\sum_{j=1}^{n} \frac{\partial f}{\partial x_j}(P_0) \cdot \underbrace{(x_j^{(1)} - x_j^{(0)})}_{-\delta_j} = \sum_{j=1}^{n} f_j \delta_j$$

($P_1 = \begin{pmatrix} x_1^{(1)} \\ \vdots \\ x_n^{(1)} \end{pmatrix}$, $P_0 = \begin{pmatrix} x_1^{(0)} \\ \vdots \\ x_n^{(0)} \end{pmatrix}$)

↳ utilizzo lo sviluppo di Taylor di f in P_1 e lo tronco al primo ordine

f_j ↳ coefficienti di amplificazione dell'errore inerente; δ_j ↳ errore di arrotondamento nella componente j $\quad (\delta_j = x_j^{(1)} - x_j^{(0)})$

osservazione: abbiamo una formula per δ_d, però questa dipende da P_0 e P_1, in genere vorremmo dare delle limitazioni più generali $|\delta_d|$

di solito si seleziona un insieme D che contiene i punti P_0 a cui siamo interessati e si assume che la funzione di arrotondamento faccia rimanere in D: $R_N(P_0) = P_1 \in D \quad \forall P_0 \in D$

sotto queste ipotesi, uno può sempre affermare $|\delta_d| \le \sum \sup_{x \in D} \left|\frac{\partial f}{\partial x_j}(x)\right| \cdot$ max errore assoluto di arrotondamento su D

↳ insieme D viene talvolta chiamato insieme di indeterminazione

in maniera simile $\varepsilon_d \doteq \sum_{j=1}^{n} \frac{\partial f}{\partial x_j}(P_0) \cdot \frac{(x_j^{(1)} - x_j^{(0)})}{f(P_0)} = \sum_{j=1}^{n} \underbrace{\frac{x_j^{(0)}}{f(P_0)} \cdot \frac{\partial f}{\partial x_j}(P_0)}_{\gamma_j} \cdot \underbrace{\frac{x_j^{(1)} - x_j^{(0)}}{x_j^{(0)}}}_{\varepsilon_j} = \sum_{j=1}^{n} \gamma_j \varepsilon_j$

γ_j (coefficiente di amplificazione dell'errore relativo); ε_j ↳ errore relativo di arrotondamento nella componente j

definizione: un certo problema (un calcolo di una funzione) si dice mal condizionato se i γ_j sono tali per cui $\varepsilon_d \gg \max_{j=1,\dots,n} |\varepsilon_j|$

al contrario, il problema si dice ben condizionato $(|\varepsilon_d| \approx \max |\varepsilon_j|)$

errori inerenti nelle operazioni aritmetiche: $f: \mathbb{R}^2 \to \mathbb{R}$, $\begin{pmatrix} x \\ y \end{pmatrix} \to x \text{ op } y$, $\text{op} \in \{+, -, \times, /\}$

op	δ_d	ε_d (γ_x, γ_y)
$x \oplus y$	$\delta_x + \delta_y$	$\frac{x}{x+y}\varepsilon_x + \frac{y}{x+y}\varepsilon_y$
$x \ominus y$	$\delta_x - \delta_y$	$\frac{x}{x-y}\varepsilon_x - \frac{y}{x-y}\varepsilon_y$
$x \otimes y$	$y\delta_x + x\delta_y$	$\varepsilon_x + \varepsilon_y$
$x \oslash y$	$\frac{1}{y}\delta_x - \frac{x}{y^2}\delta_y$	$\varepsilon_x - \varepsilon_y$

⟶ **osservazione**: $\otimes, \oslash$ sono operazioni abbastanza sicure dal punto di vista dell'errore relativo (non c'è amplificazione)

$\oplus, \ominus$ possono essere problematiche ⟶ questo succede quando $|x+y| \ll \min\{|x|, |y|\}$ (↳ minimo fra i due), o analogamente $|x-y| \ll \min\{|x|, |y|\}$

⇓ CANCELLAZIONE NUMERICA!

esempio: vogliamo calcolare e^{π}

$f(x) = e^x$, $P_0 = \pi$

(i) approssimo $e^x \approx 1 + x + \frac{x^2}{2} \longrightarrow \tilde{f}(x) = 1 + x + \frac{x^2}{2}$

(ii) scelgo un algoritmo per valutare $\tilde{f}$:

$r_1 = x \cdot x$
$r_2 = \frac{r_1}{2}$
$r_3 = r_2 + x$
$r_4 = r_3 + 1$

$\rightsquigarrow (((x \otimes x) \oslash 2) \oplus x) \oplus 1 =: \tilde{f}_a(x)$

(iii) approssimo π con $R_N(\pi) = 3{,}1416$ (esempio 5 cifre di mantissa in base 10)

→ alla fine calcoliamo $\tilde{f}_a(3{,}1416) \approx e^{\pi}$

stimare l'errore algoritmico:

una volta fissato un algoritmo ($f_a(x)$), possiamo stimare $\delta_a = f(P_1) - f_a(P_1)$, $\varepsilon_a = \frac{f(P_1) - f_a(P_1)}{f(P_1)}$

↳ dato che $P_1 \in F(\beta, m, L, U)$ possiamo assumere che l'errore inerente sui dati iniziale è $\emptyset$, e si studia come $\ominus, \ominus, \otimes, \oslash$ propagano l'errore di arrotondamento sui risultati intermedi

esempio pratico: (ci concentriamo su ε_a)

$f(x, y, z, w) = x\left(\frac{y}{z} - w\right)$ $\qquad f_a(x) = x \otimes ((y \oslash z) \ominus w)$

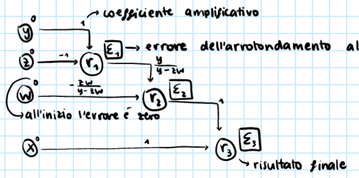

come si calcola l'errore algoritmico? $\varepsilon_a = \varepsilon_3 + (1 \cdot \varepsilon_x^{\circ}) + (1 \cdot \varepsilon_{r_2}) = \varepsilon_3 + \varepsilon_2 + \frac{y}{y-2w}\varepsilon_{r_1} - \frac{2w}{y-2w}\varepsilon_w^{\circ} = \varepsilon_3 + \varepsilon_2 + (\varepsilon_1 - 1 \cdot \varepsilon_2^{\circ} + 1 \cdot \varepsilon_y^{\circ})\frac{y}{y-2w} = \varepsilon_3 + \varepsilon_2 + \varepsilon_1\frac{y}{y-2w}$ ⟶ l'algoritmo è OK se $y - 2w$ non è vicino a $\emptyset$

definizione: un algoritmo è stabile se $|\varepsilon_a| \approx |\varepsilon_d|$ (se $|\varepsilon_a| \gg |\varepsilon_d|$ è instabile)

esempio: $f(x, y) = x^2 - y^2$

algoritmo 1:

$r_1 = x \cdot x$
$r_2 = y \cdot y$
$r_3 = r_1 - r_2$

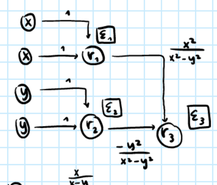

$\varepsilon_a = \varepsilon_3 + \frac{x^2}{x^2-y^2}\varepsilon_{r_1} - \frac{y^2}{x^2-y^2}\varepsilon_{r_2} = \varepsilon_3 + \frac{x^2}{x^2-y^2}\varepsilon_1 - \frac{y^2}{x^2+y^2}\varepsilon_2$

algoritmo 2:

$r_1 = x - y$
$r_2 = x + y$
$r_3 = r_1 \cdot r_2$

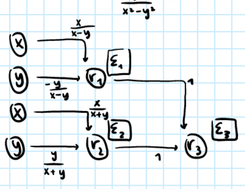

$\varepsilon_a = \varepsilon_3 + 1 \cdot \varepsilon_2 + 1 \cdot \varepsilon_1 = \varepsilon_3 + \varepsilon_2 + \varepsilon_1$

in particolare: **algoritmo 1** $\quad |\varepsilon_a| \le |\varepsilon_3| + \left|\frac{x^2+y^2}{x^2-y^2}\right| \max\{|\varepsilon_1|, |\varepsilon_2|\}$

$\le u + u\left|\frac{x^2+y^2}{x^2-y^2}\right| = u\left(1 + \left|\frac{x^2+y^2}{x^2-y^2}\right|\right)$ ⟶ (se $|x| \approx |y|$ allora ε_a grande)

(u ↳ precisione di macchina)

algoritmo 2 $\quad |\varepsilon_a| \le |\varepsilon_1| + |\varepsilon_2| + |\varepsilon_3| \le 3u$ ⟶ (ε_a sempre piccolo)

lezione 3 (04/03/2024)

06 March 2024 11:37

quando si vuole limitare dall'alto $|\delta_f|$ si considera la disuguaglianza: $|\delta_f| \le |\delta_d| + |\delta_a| \le E_d + E_a$
$E_d = \sum_{j=1}^{n} A_{x_j} |\delta x_j|$ ($\delta x_j = x_j^{(1)} - x_j^{(0)}$ → errore inerente nella componente j, $P_0 = \begin{bmatrix} x_1^{(0)} \\ \vdots \\ x_n^{(0)} \end{bmatrix} \in \mathbb{R}^n$)
$A_{x_j} = \sup_{x \in \mathbb{R}^n} \left| \frac{\partial f}{\partial x_j}(x) \right|$

osservazione: si può fare un discorso analogo con $|\varepsilon_f| \le |\varepsilon_d| + |\varepsilon_a|$

problema diretto: dato un algoritmo, l'insieme dei numeri di macchina e la strategia di arrotondamento trovare un limite superiore (il più piccolo che si riesce a trovare) per $|\delta_f|$ o $|\varepsilon_f|$ → esempio di problema diretto per δ_f: $f(x_1,x_2) = \frac{x_1}{x_2}$ → vogliamo limitare δ_f per $P_0 \in [1,3] \times [4,5]$, supponiamo di utilizzare R_N e $F(10,3,-99,99)$ (così non abbiamo overflow/underflow)

problema inverso: data f, ed un limite superiore $\tau > 0$ per $|\delta_f|$ o $|\varepsilon_f|$ mostrare un algoritmo e/o scegliere parametri della rappresentazione affinché $|\delta_f| \le \tau$ oppure $|\varepsilon_f| \le \tau$

esempio di problema inverso per δ_f:
$f(x_1,x_2) = \frac{x_1}{x_2}$, $P_0 \in [1,2] \times [-2,-1] =: D$, $F(10,m,-99,99)$
- usiamo R_N per arrotondare
- determinare un algoritmo ed un numero (più piccolo possibile) m di cifre per la mantissa che garantiscano $|\delta_f| \le 10^{-2}$
  1. prendiamo come $f_a(x) = x_1 \textcircled{/} x_2$ che da come errore algoritmico δ_a tale che $|\delta_a| \le 10^{e} \cdot \frac{1}{2} 10^{-m}$ dove "e" è l'esponente usato nella rappresentazione floating point di $\left|\frac{x_1}{x_2}\right|$

$\left|\frac{x_1}{x_2}\right| \in \begin{cases} [1,10) \to e=1 \\ [0,1,\ 1) \to e=0 \end{cases} \Rightarrow$ possiamo sempre affermare che $|\delta_a| \le \frac{1}{2} 10^{1-m} \quad \forall x \in D$

per l'errore inerente abbiamo che $|\delta x_j| \le \frac{1}{2} 10^{1-m}$ $j=1,2$
$|\delta_d| \le \frac{1}{2} 10^{1-m} \left(\max_{x \in D} \left|\frac{1}{x_2}\right| + \max_{x \in D} \left|-\frac{x_1}{x_2^2}\right| \right) = \frac{1}{2} 10^{1-m} (1+2) = \frac{3}{2} 10^{1-m}$
$|\delta_f| \le \frac{3}{2} 10^{1-m} + \frac{1}{2} 10^{1-m} = 2 \cdot 10^{1-m} \overset{?}{\le} 10^{-2}$
↳ devo scegliere $m=4$ e sono sicuro che $|\delta_f| \le 2 \cdot 10^{-3}$

osservazione: nel caso di esercizi analoghi riguardanti δ_f, gli errori relativi di arrotondamento faranno tutti limitati superiormente da $\frac{1}{2} \beta^{1-m}$ (precisione di macchina) quando sto usando R_N

2. vediamo quanto sono grandi gli errori inerenti nelle componenti: $x_j \in [1,10)$ ($[10^0, 10^1)$) $\Rightarrow$ rappresentazione in floating point $x_j = 10^0 \cdot 0, \alpha_1 \alpha_2 \alpha_3 \alpha_4 \ldots$ ($\alpha_1' \in \{0,\ldots,9\}$, $\alpha_1 \neq 0$; quando faccio R_N tronco dopo α_3)
$\delta_j = \frac{1}{2} \cdot 10^{0-m} = 10^{-3} \cdot \frac{1}{2} = \frac{1}{2} 10^{-2}$ → $j=1,2$ (vale sia per $j=1$ che $j=2$)
$\delta_d = \frac{\partial f}{\partial x_1}(P) \cdot \delta x_1 + \frac{\partial f}{\partial x_2}(P) \cdot \delta x_2$ $P \in [1,3] \times [4,5] =: D$
↳ $|\delta_d| \le \frac{1}{2} 10^{-2} \left(\max_{(x_1,x_2) \in D} \left|\frac{1}{x_2}\right| + \max_{(x_1,x_2) \in D} \left|-\frac{x_1}{x_2^2}\right| \right) = \frac{1}{2} 10^{-2} \left(\frac{1}{4} + \frac{3}{16} \right) = \frac{7}{32} 10^{-2}$

dobbiamo limitare δ_a:
$(x_1, x_2) \xrightarrow{\div} (z_1) \xrightarrow{\delta_1} \delta_a = \delta_1$ (errore di arrotondamento sul risultato di $\frac{x_1}{x_2}$ → dipende da $\left|\frac{x_1}{x_2}\right|$)
dato che $\left|\frac{x_1}{x_2}\right| \in [0,1,\ 1)$ $\forall (x_1,x_2) \in D \Rightarrow \frac{x_1}{x_2} = 10^0 \cdot 0, \alpha_1 \alpha_2 \alpha_3 \alpha_4 \ldots$
↳ $|\delta_a| \le \frac{1}{2} 10^{-2} = \frac{1}{20} 10^{-1}$
↳ $|\delta_f| \le \left(\frac{3}{32} + \frac{1}{20}\right) 10^{-2} = \frac{43}{100} 10^{-2}$

FUNZIONI NON RAZIONALI

se la funzione non può essere valutata solo con $+, -, /, \times$
ad esempio e^x, $e^{\cos(x+y,z)}$, ...
quello che si fa è considerare $\tilde{f}(x)$ funzione razionale tale che $\tilde{f} \approx f$ almeno in un dominio $D \subseteq \mathbb{R}^n$ che ci interessa, e in tal caso possiamo decomporre l'errore in 3 parti: $f(P_0) - \tilde{f}_a(P_1) = \underbrace{f(P_0) - \tilde{f}(P_1)}_{\delta_f \text{ (errore totale)}} = \underbrace{f(P_0) - f(P_1)}_{\delta_d} + \underbrace{f(P_1) - \tilde{f}(P_1)}_{\delta_m \text{ errore analitico}} + \underbrace{\tilde{f}(P_1) - \tilde{f}_a(P_1)}_{\delta_a \text{ (errore algoritmico inerente)}}$

definizione: $\delta_{an} = f(P_1) - \tilde{f}(P_1)$ (errore analitico assoluto), $\varepsilon_{an} = \frac{f(P_1) - \tilde{f}(P_1)}{\tilde{f}(P_1)}$ (errore analitico relativo) → vale che: $\delta_f = \delta_d + \delta_a + \delta_{an}$, $\varepsilon_f = \varepsilon_d + \varepsilon_a + \varepsilon_{an}$

osservazione: nel caso non razionale l'errore algoritmico $(\delta_a, \varepsilon_a)$ è calcolato per l'approssimante razionale $(\tilde{f})$ ⇝ si può usare la tecnica del grafo per stimare quanto vale l'errore inerente $(\delta_d, \varepsilon_d)$ è valutato sulla f originale, ma questo non è un problema (nella formula si usano le derivate) poiché la formula dell'errore inerente coinvolge le derivate di f e non richiede che si usino solo operazioni elementari

COME SI STIMA L'ERRORE ANALITICO? (sviluppo di Taylor)
- vediamo solo il caso $f: \mathbb{R} \to \mathbb{R}$, f derivabile $k+1$ volte $k \in \mathbb{N}$, in tal caso si può considerare lo sviluppo di Taylor con il resto di Lagrange

---

→ reminder analisi 1:
$f \in C^{k+1}(a,b)$, $x_0 \in (a,b)$ allora $\forall x \in (a,b)$ vale $f(x) = f(x_0) + f'(x_0)(x-x_0) + \frac{f''(x_0)}{2}(x-x_0)^2 + \ldots + \frac{f^{(k)}(x_0)}{k!}(x-x_0)^k + R(x)$
$T_k(x) = \sum_{j=0}^{k} \frac{f^{(j)}(x_0)}{j!}(x-x_0)^j$
↳ $R(x) = \frac{f^{(k+1)}(m)}{(k+1)!}(x-x_0)^{(k+1)}$ $m \in (x, x_0)$
↳ $f(x) - T_k(x) = \frac{f^{(k+1)}(m)}{(k+1)!}(x-x_0)^{(k+1)}$

esempio: (approssimazione di e^x)
approssimiamo e^x con lo sviluppo di Taylor in $x_0=0$ troncato a grado 2, qual'è l'errore analitico quando voglio valutare e^x per $x \in [-1,1]$? (cerco)
$T_2(x) = 1 + x + \frac{x^2}{2}$ → $e^x - \left(1 + x + \frac{x^2}{2}\right) = \frac{e^m}{3!}(x-0)^3 = \frac{e^m}{6} x^3$ $m \in (x,0)$
$|\varepsilon_{an}| \le \frac{\left|\frac{e^m \cdot x^3}{6}\right|}{|e^x|} \le \frac{\max_{m \in [-1,1]} e^m \cdot \max_{x \in [-1,1]} |x^3|}{\min_{x \in [-1,1]} |e^x|} \cdot \frac{1}{6} = \frac{e \cdot 1}{e^{-1} \cdot 6} = \frac{e^2}{6} \approx 1{,}23$
($\max$ m, x in $[-1,1]$; ↳ devo trovare un max, quindi serve il denominatore più piccolo)

se rifacciamo i conti con un generico k (numero di termini del polinomio di Taylor) abbiamo che: $|\varepsilon_{an}| = \left|\frac{e^x + T_k(x)}{e^x}\right| \le \frac{\max_{m \in [-1,1]} e^m \cdot \max_{x \in [-1,1]} |x^{k+1}|}{\min_{x \in [-1,1]} |e^x|} \cdot \frac{1}{(k+1)!} = \frac{e^2}{(k+1)!}$ → piccolo abbastanza velocemente all'aumentare di k (esempio: per $k=4$ otteniamo $|\varepsilon_{an}| \le 0{,}064\ldots$)

osservazione: in questo caso abbiamo scelto $\tilde{f}(x) = T_k(x)$

→ richiami di algebra lineare:
nella maggioranza dei casi $x \in \mathbb{C}^n$, $f(x) \in \mathbb{C}^m$, $m \neq n$, $m,n \ge 1$
in questo contesto le matrici rappresentano tutte le funzioni lineari della forma: $f: \mathbb{C}^n \to \mathbb{C}^m$ tale che $f(x+y) = f(x) + f(y)$ $\forall x,y \in \mathbb{C}^n$, $f(\lambda x) = \lambda f(x)$ $\lambda \in \mathbb{C}$, $x \in \mathbb{C}^n$
in particolare $\exists!$ matrice $A \in \mathbb{C}^{m \times n}$ tale che $f(x) = A \cdot x$ $\forall x \in \mathbb{C}^n$
↳ (abbiamo sottinteso che ci siano state fissate delle basi per $\mathbb{C}^n$ e $\mathbb{C}^m$)
(possiamo vedere gli scalari come matrici 1×1)

$A = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix}$ $A \in \mathbb{C}^{m \times n}$
a_{ij} → indice di colonna $j \in \{1,\ldots,n\}$; ↳ indice di riga $i \in \{1,\ldots,m\}$
$x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} \in \mathbb{C}^n$
$f(x) = A \cdot x = \begin{bmatrix} a_{11} \cdot x_1 + a_{12} \cdot x_2 + \ldots + a_{1n} \cdot x_n \\ \vdots \\ a_{m1} \cdot x_1 + a_{m2} \cdot x_2 + \ldots + a_{mn} \cdot x_n \end{bmatrix} \in \mathbb{C}^m$
$(Ax)_i = \sum_{h=1}^{n} a_{ih} \cdot x_h$

definizione: se $m=n$ la matrice si dice quadrata, se $m \neq n$ è rettangolare
definizione: $x, y \in \mathbb{C}^n$ si definisce prodotto scalare euclideo: $\langle x,y \rangle = x_1 \cdot \overline{y_1} + x_2 \cdot \overline{y_2} + \ldots + x_n \cdot \overline{y_n} = \sum_{j=1}^{n} x_j \overline{y_j}$
($z = a+ib$ ⇝ $\overline{z} = a - ib$)
(se $x, y \in \mathbb{R}^n$ allora $\sum_{j=1}^{n} x_j y_j$)
(vogliamo contare quante operazioni si fanno, per vedere quanto "costa" un algoritmo, e il tempo di svolgimento)
osservazione: per valutare $\langle x,y \rangle$ sono necessarie n moltiplicazioni e $n-1$ somme → quindi in totale $O(n)$ operazioni aritmetiche
nel caso del prodotto matrice per vettore (possiamo ricondurci ai prodotti scalari) $A \in \mathbb{C}^{m \times n}$, $x \in \mathbb{C}^n$, abbiamo che dobbiamo calcolare m componenti del vettore $Ax = y = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix}$ ed ognuna di queste richiede $y_j = (Ax)_j = \sum_{h=1}^{n} a_{jh} x_h = \langle A^{(j)}, x \rangle$ ($A^{(j)} = \begin{bmatrix} a_{j1} \\ a_{j2} \\ \vdots \\ a_{jn} \end{bmatrix}$) ⇝ costa $O(n)$, quindi il costo totale di Ax è $\boxed{O(m \cdot n)}$

definizione: $A \in \mathbb{C}^{m \times n}$ si definiscono $A^T (\in \mathbb{C}^{n \times m})$ matrice trasposta $= (A^T)_{ij} = a_{ji}$ (con entrate a_{ij}); $A^H (\in \mathbb{C}^{n \times m})$ matrice trasposta coniugata $= (A^H)_{ij} = \overline{a_{ji}}$ → esempi:

$A = \begin{bmatrix} 1 & 4 & 7 \\ 2 & 5 & 8 \\ 3 & 6 & 9 \end{bmatrix}^T = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}$
$A = \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix}^T = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}$
$A = \begin{bmatrix} 1 & 2 & 3i \\ -1 & 1+i & 0 \\ 4 & 0 & 3 \end{bmatrix}$ ⇝ $A^H = \begin{bmatrix} 1 & i & 4 \\ 2 & 1-i & 0 \\ -3i & 0 & 3 \end{bmatrix}$

definizione: se una matrice quadrata ha elementi nulli fuori dalla diagonale principale ($a_{ij} = 0$ se $i \neq j$) si dice diagonale
similmente, A si dice triangolare inferiore (o superiore) se ha elementi nulli sopra la diagonale principale → $a_{ij} = 0$ per $j > i$ (o nulli sotto la diagonale principale → $a_{ij} = 0$ $i > j$)

lezione 4 (08/03/2024)

10 March 2024 14:39

→ riduciamo algebrica incognite:

vettori linearmente indipendenti: (siano $x_1,\dots,x_k$, $\in[v_1,\dots,v_n]$, vettori elementi $\neq 0$) si dicono linearmente indipendenti se una loro combinazione lineare $\vec{v}$ uguale a zero nel momento in cui scelgo tutti i coefficienti uguali a zero $\sum_{i=1}^{n} a_i x_i = 0 \Rightarrow a_i = 0 \;\forall i$

$a_i, x_i \in \mathbb{C}$, $j=1,\dots,n$

se $j=n$ allora insieme $x_1,\dots,x_n \neq$ dalla base a $\mathbb{C}$ (significa che posso scrivere ogni vettore di $\mathbb{C}$ come una combinazione lineare di $x_1,\dots,x_n$)

$\vec{y}=\sum_{i=1}^{n} a_i x_i$ → basic, per ogni $y \in \mathbb{C}$ esistono (unici) $a_1,\dots,a_n \in \mathbb{C}$ tali per cui y si scrive $\sum_{i=1}^{n} a_i x_i$

operazioni fra matrici: somma fra matrici → una somma per ogni entrata ai (i.e entrate tono $m \cdot n$)

$A, B \in \mathbb{C}^{m,n} \rightsquigarrow C=A+B \quad (c_{ij}=a_{ij}+b_{ij})$ ⟶ questa operazione costa $O(m \cdot n)$ / $O(n^2)$ se A, B sono quadrate $(m=n)$

Prodotto fra matrici

$A \in \mathbb{C}^{m,n}, B \in \mathbb{C}^{n,p} \rightsquigarrow C=A \cdot B \quad (c_{ij}=\sum_{k=1}^{n} a_{ik} b_{kj})$

↳ è data dal prodotto isolato (nel caso reale) tra la i-esima riga di A e la j-esima colonna di B.

in particolare calcolare 1 entrata di $A \cdot B$ costa $O(n)$ prodotto scalare tra due vettori di $\mathbb{C}^n$

dato che abbiamo fatto per ogni entrata di C con $C \in \mathbb{C}^{m,n}$, questo ci dà un costo $O(m \cdot n \cdot p)$

↳ se $m=n=p$ otteniamo un costo uguale

osservazione: se $A \in \mathbb{C}^{n,n}, B \in \mathbb{C}^{n,n}$ costa di $A \cdot B \in O(n^2)$

osservazione: l'ordine della moltiplicazione influisce anche sul costo

osservazione: la moltiplicazione di matrici si può anche vedere come operazione su colonne o righe

righe $\rightarrow A=\begin{bmatrix} A^1 \\ \dots \\ A^n \end{bmatrix} \rightsquigarrow A \cdot B = \begin{bmatrix} A^1 \cdot B \\ \dots \\ A^n \cdot B \end{bmatrix}$, $A^i \in \mathbb{C}^{1,n}$, $j=1,\dots,p$

colonne $\rightarrow B=[B_1 | \dots | B_p] \rightsquigarrow A \cdot B = [AB_1 | \dots | AB_p]$, $B_i \in \mathbb{C}^{n,1}$, $j=1,\dots,p$

definizione: $A \in \mathbb{C}^{n,n}$ si dice

- hermitiana $A=A^*$
- anti hermitiana $A=-A^*$
- unitaria $A^*A=AA^*=I$
- normale $A^*A=AA^*$
- simmetrica $A=A$
- anti simmetrica $A=-A$

(traccia zero (più o meno, a per i numeri complessi)

(traccia unitaria) $\rightsquigarrow$ ortogonale $AA^T=A^TA=I$

proprietà: (1) $\{\text{matrici simmetriche reali}\} \subset \{\text{matrici hermitiane}\} \subset \{\text{matrici normali}\}$

(2) $\{\text{matrici ortogonali}\} \subset \{\text{matrici unitarie}\}$

(3) le matrici ortogonali ed unitarie hanno l'inversa facile

proposizione: $A \in \mathbb{C}^{n,n}$ hermitiana, allora la quantità $x^*Ax \in$ un numero reale

dimostrazione: $(x^*Ax)^* = (x^*A^*)^* = x^*A^*x = x^*Ax$, avendo A uguale al suo coniugato

definizione: una matrice unitaria (o simmetrica) si dice definita positiva se $x^*Ax > 0 \quad \forall x \in \mathbb{C}^n \setminus \{0\}$

matrice di permutazione: $P \in \mathbb{R}^{n,n}$ è data matrice di permutazione se è ottenuta dalla matrice identità $[e_i]$ tramite una permutazione delle sue righe o colonne

esempio: $P=\begin{bmatrix} 0&1&0 \\ 0&0&1 \\ 1&0&0 \end{bmatrix}$ $\begin{matrix} e_1 \mapsto e_2 \\ e_2 \mapsto e_3 \\ e_3 \mapsto e_1 \end{matrix}$ $\longrightarrow$ $T_\sigma: \begin{matrix} 1 \mapsto 2 \\ 2 \mapsto 3 \\ 3 \mapsto 1 \end{matrix}$ $\longrightarrow$ $T_\sigma=\begin{bmatrix} 0&1&0 \\ 0&0&1 \\ 1&0&0 \end{bmatrix}$ $\begin{matrix} 1 \mapsto 2 \\ 2 \mapsto 3 \\ 3 \mapsto 1 \end{matrix}$ $\longrightarrow$ posti in un sol sourcetesto stesse le righe/colonne per ottenere la matrice identità

proprietà: ogni matrice di permutazione è ortogonale $PP^T=P^TP=I$ la dimostro facendo vedere che a P^T è associata la permutazione inversa

(2) il prodotto di una matrice A per una matrice di permutazione P produce una permutazione delle colonne di A (se P è a destra) o delle righe di A (se P è a sinistra)

esempio: $A=\begin{bmatrix} 1&4&7 \\ 2&5&8 \\ 3&6&9 \end{bmatrix}$, $P=\begin{bmatrix} 0&0&1 \\ 0&1&0 \\ 1&0&0 \end{bmatrix} \Rightarrow AP=\begin{bmatrix} 7&4&1 \\ 8&5&2 \\ 9&6&3 \end{bmatrix}$ $PA=\begin{bmatrix} 3&6&9 \\ 2&5&8 \\ 1&4&7 \end{bmatrix}$ ⟶ moltiplicare per matrici di permutazione non ricalcola operazioni aritmetiche

sistemi lineari: dato $A \in \mathbb{C}^{m,n}$ e $b \in \mathbb{C}^m$, l'equazione $Ax=b$ rappresenta il sistema lineare di m equazioni in n incognite: $\begin{cases} a_{11}x_1+\dots+a_{1n}x_n=b_1 \\ \dots \\ a_{n1}x_1+\dots+a_{mn}x_n=b_m \end{cases}$ $x \in \mathbb{C}^n$ è il vettore delle incognite (non computazionali con un grado maggiore di 1)

↳ computazionale

quando c'è soluzione?

↳ "è ammissibile con b" = matrice A a cui aggiungo come ultima colonna b

teorema di Rouché-Capelli: esiste una soluzione di $Ax=b$ se e solo se $\text{RANGO}(A)=\text{RANGO}(A|b)$ → il primo è uguale al secondo (come dire che b si può scrivere come combinazione lineare delle colonne di A, non ne aumenta il rango) → per definizione di A → per definizione di soluzione

↳ matrice con m righe ed $n+1$ colonne

$A|b=\left[\begin{array}{ccc|c} a_{11} & \dots & a_{1n} & b_1 \\ | & & | & | \\ a_{m1} & \dots & a_{mn} & b_m \end{array}\right] \in \mathbb{C}^{m \times (n+1)}$

per quanto riguarda l'unicità: (2) se $\text{RANGO}(A)=n$ allora la soluzione è unica ↳ numero di colonne di A

(4.1) se $\text{RANGO}(A)<n$ allora ci sono ∞ soluzioni e queste generano uno spazio vettoriale affine, di dimensione $n-\text{RANGO}(A)$ → chiamato anche 'kernel' o 'nucleo'

osservazione: se $m=n$ e $\det(A) \neq 0$ si ha anche $\text{RANGO}(A)=n \Rightarrow$ soluzione unica → ottenuta sostituendo la j-esima colonna di A con b e facendo il determinante $x_j = \frac{\det(A_j)}{\det(A)}$

$\text{ker}(A)$ (spazio vettoriale formato da tutti i vettori che danno zero) → l'ipotesi della soluzione unica è equivalente a $\text{ker}(A)=\{0\}$

$\text{ker}(A)=n-\text{RANGO}(A)=n-n=0$

definizione: nel caso $b=0$ il sistema si dice OMOGENEO ed ha sicuramente almeno una soluzione $(x=0)$

se $\text{RANGO}(A)=n$ questa è unica, altrimenti l'insieme delle soluzioni forma uno spazio vettoriale di dimensione $n-\text{RANGO}(A)$

definizione: se $m>n$ il sistema si dice SOVRADETERMINATO

se $m<n$ il sistema si dice SOTTODETERMINATO

esempio: $\begin{cases} x-2y-2z=0 \\ -2x-y+4z=3 \\ x-2y-33=0 \end{cases} \Rightarrow \begin{cases} x=2y+2z \\ -4y-5z-y+4z=3 \\ \dots \end{cases} \Rightarrow \begin{cases} x=2y+2z \\ -5y=3 \\ \dots \end{cases} \Rightarrow \begin{cases} x=-\frac{6}{5}+2z \\ y=-\frac{3}{5} \end{cases}$

se il sistema è sottodeterminato (meno equazioni che incognite) allora ho ∞ soluzioni (tre incognite più condizioni del grado di libertà)

impongo meno vincoli di quante incognite ho

$A=\begin{bmatrix} 1&-2&2 \\ -2&8&-8 \\ 1&-3&3 \end{bmatrix}$, $b=\begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$ → porto dx a sinistra per A e b a destra

soluzioni $\left\{\begin{bmatrix} -6/5 \\ -3/5 \\ 0 \end{bmatrix} + t\begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} : t \in \mathbb{R}\right\}$ → isolo t (scelgo $z=0$) → porto x e y a destra per z

isolo x e y (scelgo $z=0$)

$\rightsquigarrow$ $??$ lo devo a voce nella lezione successiva

$\det(I)=1$ (1) Binet-Cauchy $\longrightarrow$ $\det(A \cdot A^T)=\det(A)^2$

$\det(A^T)=\det(A)$ → invariante per trasposizione di matrice

$\det(A^*)=\overline{\det(A)}$ → invariante per il trasposto coniugato (viene il coniugato dal determinante)

definizione: A è di alice SINGOLARE se $\det(A)=0$, se $\det(A) \neq 0$ si dice non singolare

definizione: si dice minore di ordine k, con $1 \leq k \leq n$ ($k \in \mathbb{N}$), il determinante di una sottomatrice $k \times k$ di $A \in \mathbb{C}^{m,n}$, ottenuta intersecando k righe con k colonne

esempio: $A=\begin{bmatrix} 1&5&9 \\ 2&6&10 \\ 3&7&11 \\ 4&8&12 \end{bmatrix}$ prendo $k=2 \rightarrow \begin{bmatrix} 1&5 \\ 2&6 \end{bmatrix}$ righe $\{1,2\}$ colonne $\{1,2\}$ → minore principale di ordine 2

sottomatrici 2×2, loro determinanti sono detti minori

$\begin{bmatrix} 5&9 \\ 6&10 \end{bmatrix}$ righe $\{1,2\}$ colonne $\{2,3\}$ → minore principale

$\begin{bmatrix} 3&11 \\ 4&12 \end{bmatrix}$ righe $\{3,4\}$ colonne $\{3,4\}$ → minore non principale

$\begin{bmatrix} 2&10 \\ 4&12 \end{bmatrix}$ righe $\{2,4\}$ colonne $\{2,4\}$ → minore non principale

definizione: un minore è detto "principale" se i suoi elementi diagonali sono un sottoinsieme di quelli della diagonale principale della matrice (in altre parole, se le righe e colonne selezionate coincidono)

definizione: un minore di ordine k è detto "principale di ordine k" se gli indici selezionati sono $\{1,\dots,k\}$, ma per righe che per colonne

definizione: il rango di una matrice $A \in \mathbb{C}^{m,n}$ è anche il massimo numero naturale r tale che A abbia almeno un minore di ordine r non nullo

definizione: una matrice $A \in \mathbb{C}^{m,n}$ è detta a scalini per righe se il numero di zeri che precedono la prima entrata non nulla di ogni riga cresce strettamente fino alla riga m (eventualmente) nulla

definizione: consideriamo la spazio vettoriale $\mathbb{C}^{m,n}$ data $\text{im}_{\mathbb{C}}(A)=\{y \in \mathbb{C}^m : \exists x \in \mathbb{C}^n \text{ tale che } y=Ax\}$ → vale che $\text{RANGO}(A)=\dim(\text{Im}(A))$

teorema (Binet-Cauchy): $A \in \mathbb{C}^{m,n}$, $B \in \mathbb{C}^{n,m}$, $C=A \cdot B \in \mathbb{C}^{m,m}$

$\det(C)=\begin{cases} 0 & \text{se } m>n \\ \det(A)\cdot\det(B) & \text{se } m=n \\ \sum_{S} A_{S,[1,\dots,m]} \cdot B_{[1,\dots,m],S} & \text{se } m<n \end{cases}$ (caso matrici quadrate) (caso matrici non quadrate)

$A \cdot B = \begin{bmatrix} \square & \square \\ \square & \square \end{bmatrix}$ $m \times n$

S varia su tutti i sottoinsiemi di m elementi di $\{1,\dots,n\}$

$A_{S,[1,\dots,m]}$ è il determinante della sottomatrice $m \times m$ di A ottenuta prendendo le righe di indici S e le prime m colonne

$B_{[1,\dots,m],S}$ è il determinante della sottomatrice $m \times m$ di B ottenuta prendendo le prime m righe e le colonne di indici S

definizione: (matrice inversa) $A \in \mathbb{C}^{n,n}$ non singolare ($\det(A) \neq 0$) si dice invertibile se esiste una matrice che chiamo $A^{-1} \in \mathbb{C}^{n,n}$ tale che $A \cdot A^{-1} = I = \begin{bmatrix} 1&&0 \\ &\ddots& \\ 0&&1 \end{bmatrix}$

proprietà: (1) A^{-1} esiste se e solo se $\det(A) \neq 0$ ($\Leftrightarrow A$ ha rango massimo $\Leftrightarrow$ le A ha colonne linearmente indipendenti $\Leftrightarrow$ rango$(A)=n$)

lezione 5 (11/03/2024)

11 March 2024 16:03

definizione: sia $A \in \mathbb{C}^{n\times n}$, $\lambda \in \mathbb{C}$ si dice AUTOVALORE di A se $\exists v \in \mathbb{C}^n \setminus \{0\}$ tale che $Av = \lambda v$ → la coppia (λ, v) si dice "autocoppia" di A

- il vettore v è detto "autovettore destro" della matrice A associato all'autovalore λ
- ogni autovettore è associato a un autovalore
- similmente un vettore $w \in \mathbb{C}^n \setminus \{0\}$ tale che $wA = \lambda w$ è detto "autovalore sinistro" di A associato all'autovalore λ

osservazione: il vettore $v \in \mathbb{C}^n \setminus \{0\}$ soddisfa $Av = \lambda v \iff (A-\lambda I)v = 0$ → per il teorema di Rouché-Capelli, il sistema $(A-\lambda I)v = 0$ ammette soluzioni non nulle se $\det(A-\lambda I) = 0$ ("se il rango è pieno (RANGO(A) = RANGO(A|b)), in questo caso è un vettore nullo (b), la soluzione è unica")

- ossia v è una soluzione del sistema lineare omogeneo di matrice "$A-\lambda I$" e "v" è soluzione non banale del sistema
- ne segue che gli autovalori di A sono tutti e soli i $\lambda \in \mathbb{C}$ per cui è verificata l'equazione caratteristica

$\det(A-\lambda I) = 0$ → equazione caratteristica → autovalori di una matrice sono quelli che soddisfano l'equazione caratteristica (ai una matrice nxn sono n calcolati con la loro molteplicità)

- $\det(A-\lambda I) = c_0 + c_1\lambda + \dots + c_n\lambda^n$ è un polinomio di grado n in λ
- il polinomio $p_A(\lambda) = \det(A-\lambda I)$ è detto "polinomio caratteristico" di A
- questo polinomio ha n radici

non è altro che il polinomio caratteristico uguale a zero → quindi gli autovalori sono le radici di questo polinomio

definizione: per il teorema fondamentale dell'algebra esistono sempre n autovalori contati con la loro molteplicità

definizione: la molteplicità di un autovalore $\tilde\lambda$ come radice del polinomio caratteristico $p_A(\lambda)$ è detta "molteplicità algebrica" di $\tilde\lambda$ e si denota con $\alpha(\tilde\lambda)$

esempio: matrice identità 2x2

$I = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$ quanti autovalori? 2; quali? $\lambda = 1$ con molteplicità algebrica $\alpha(1) = 2$

$\det(I-\lambda I) = \det\begin{bmatrix} 1-\lambda & 0 \\ 0 & 1-\lambda \end{bmatrix} = (1-\lambda)^2$ → polinomio di grado 2 (ha 2 radici) → $\lambda_1 = 1$, $\lambda_2 = 1$

definizione: indicando con $\lambda_1, \dots, \lambda_n$ gli autovalori di $A \in \mathbb{C}^{n\times n}$, possibilmente ripetuti, il polinomio caratteristico si fattorizza come $p_A(\lambda) = \det(A-\lambda I) = (-1)^n(\lambda-\lambda_1)\cdots(\lambda-\lambda_n) = (-1)^n\lambda^n + (-1)^{n-1}\sigma_1\lambda^{n-1} + \dots - \sigma_{n-1}\lambda + \sigma_n$ → dove σ_i (sigma) è la somma dei minori principali (minore principale) di ordine i della matrice A

- $\sigma_1 = \text{traccia}(A) = \sum_{j=1}^{n} a_{jj} = \sum_{j=1}^{n} \lambda_j$ → autovalori di A (elementi sulla diagonale principale)
- $\sigma_n = \det(A) = \prod_{j=1}^{n} \lambda_j$ ("produttoria")

osservazione: $\det(A) = 0 \iff$ ∃ almeno un autovalore nullo

definizione: RANGO(A) è uguale al numero di autovalori non nulli di A, contati con la loro molteplicità

$p_A(\lambda) = \det(A-\lambda I) = (-1)^n\lambda^n + (-1)^{n-1}\sigma_1\lambda^{n-1} + \dots - \sigma_{n-1}\lambda + \sigma_n$

sia $k = \text{RANGO}(A) \le n$ allora avremo $\sigma_i = 0 \ \ \forall i = k+1, \dots, n$ → $p_A(\lambda) = (-1)^n\lambda^n + \dots + (-1)^{n-k}\sigma_k\lambda^{n-k}$ → avrà k autovalori non nulli

esempio:

$A = \begin{bmatrix} 1 & 3 \\ 0 & 4 \end{bmatrix}$, $A-\lambda I = \begin{bmatrix} 1 & 3 \\ 0 & 4 \end{bmatrix} - \begin{bmatrix} \lambda & 0 \\ 0 & \lambda \end{bmatrix} = \begin{bmatrix} 1-\lambda & 3 \\ 0 & 4-\lambda \end{bmatrix}$

$p_A(\lambda) = (1-\lambda)(4-\lambda) = \lambda^2 - 5\lambda + 4$ (5 = traccia(A), corrisponde a $(-1)^{n-1}\sigma_1\lambda^{n-1}$, somma degli autovalori (diagonale); 4 = det(A), prodotto degli autovalori, corrisponde a σ_n)

$\lambda_1 = 1$, $\lambda_2 = 4$

ogni matrice quadrata nxn ha sempre n autovalori, quanti sono gli autovettori?

osservazioni:

(i) sia $v \in \mathbb{C}^n \setminus \{0\}$ autovettore di A associato all'autovalore λ, allora $Av = \lambda v$

(ii) sia $\theta \in \mathbb{C} \setminus \{0\}$, $A(\theta v) = \theta Av = \theta\lambda v = \lambda(\theta v)$

- se $u := \theta v \Rightarrow Au = \lambda u$ quindi anche $u = \theta v$ è autovettore di A associato a λ

(iii) se $v_1, v_2 \in \mathbb{C}^n \setminus \{0\}$ sono tali che $Av_1 = \lambda v_1$ e $Av_2 = \lambda v_2 \Rightarrow A(v_1+v_2) = \lambda(v_1+v_2)$

- la somma di autovettori associati a λ è un autovettore associato a λ
- gli autovettori associati ad un certo valore formano un sottospazio

definizione: dato $\lambda \in \mathbb{C}$ autovalore di $A \in \mathbb{C}^{n\times n}$ si dice "molteplicità geometrica" di λ e si indica con $\gamma(\lambda)$ (gamma) la quantità $\gamma(\lambda) = \dim(\ker(A-\lambda I)) =$ dimensione dello spazio delle soluzioni di $(A-\lambda I)v = 0$ = dimensione dello spazio degli autovettori di A associati a λ

proprietà:

(i) per Rouché-Capelli $\gamma(\lambda) = n - \text{RANGO}(A-\lambda I)$

(ii) $1 \le \gamma(\lambda) \le \alpha(\lambda) \le n$ e molteplicità geometrica di una radice è sempre minore di quella algebrica

definizione: due matrici $A, B \in \mathbb{C}^{n\times n}$ si dicono "simili" se $\exists\, S \in \mathbb{C}^{n\times n}$ invertibile ($\det(S) \ne 0$) tale che $B = S^{-1}AS$, e si scrive $A \sim B$

teorema: (i) $A \sim B \Rightarrow A \in B$ hanno gli stessi autovalori con le stesse molteplicità algebriche e geometriche → **osservazione**: se A e B sono "simili" hanno gli stessi autovalori

- se non hanno gli stessi autovalori non sono simili
- se hanno gli stessi autovalori non basta! potrebbero non essere simili: ci serve anche che abbiano la stessa forma di Jordan

(ii) se $v \in \mathbb{C}^n \setminus \{0\}$ è autovettore di A associato all'autovalore $\lambda \Rightarrow S^{-1}v$ è autovettore di B associato a λ

dimostrazione: (i) dimostriamo che A e B hanno lo stesso polinomio caratteristico

$p_B(\lambda) = \det(B-\lambda I) = \det(S^{-1}AS - \lambda I) = \det(S^{-1}AS - \lambda S^{-1}S) = \det(S^{-1}(A-\lambda I)S)$ → per il teorema di Binet-Cauchy, il determinante di un prodotto è uguale al prodotto di determinanti

($A \sim B$; $S^{-1}S$ = matrice identità) $= \det(S^{-1}) \cdot \det(A-\lambda I) \cdot \det(S) = \det(A-\lambda I) = p_A(\lambda)$

(ii) sia (λ, v) autocoppia di A, vogliamo dimostrare che $(\lambda, S^{-1}v)$ è autocoppia di B

$B(S^{-1}v) \overset{!}{=} \lambda S^{-1}v$

$B(S^{-1}v) = S^{-1}AS(S^{-1}v) = S^{-1}Av \overset{Av=\lambda v}{=} S^{-1}\lambda v = \lambda(S^{-1}v)$ (S(S⁻¹v) = identità)

definizione: una matrice $A \in \mathbb{C}^{n\times n}$ è detta "diagonalizzabile" se è simile ad una matrice diagonale, ossia $\exists\, S \in \mathbb{C}^{n\times n}$ invertibile tale che $S^{-1}AS = \text{diag}(\lambda_1, \dots, \lambda_n) = \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix}$ (non tutte le matrici lo sono)

osservazione: In virtù del risultato del teorema precedente, la matrice diagonale deve contenere gli autovalori di A, e la matrice S gli autovettori di A

teorema: $A \in \mathbb{C}^{n\times n}$ è diagonalizzabile $\iff \alpha(\lambda) = \gamma(\lambda) \ \ \forall \lambda$ autovalore di A

esempio:

$A = \begin{bmatrix} 1 & 1 & & \\ & 1 & 1 & \\ & & 1 & 1 \\ & & & 1 \end{bmatrix}$ $p_A(\lambda) = \det(A-\lambda I) = \det\begin{bmatrix} 1-\lambda & 1 & & \\ & 1-\lambda & 1 & \\ & & 1-\lambda & 1 \\ & & & 1-\lambda \end{bmatrix} = (1-\lambda)^4$ → $\lambda = 1$, $\alpha(\lambda) = 4$ → molteplicità algebrica

≠ A non è diagonalizzabile

$A - \lambda I = A - I = \begin{bmatrix} 0 & 1 & & \\ & 0 & 1 & \\ & & 0 & 1 \\ & & & 0 \end{bmatrix}$ ($k\lambda = 1$) → RANGO(A-I) = 3 ($n = 4$)

$\dim(\ker(A-I)) = n - \text{RANGO}(A-I) = 4-3 = 1$ → $\gamma(1) = n-3 = 1$ → molteplicità geometrica

osservazione: se una matrice nxn ha tutti gli autovalori distinti, ossia $\lambda_i \ne \lambda_j \ \ \forall i,j \in \{1, \dots, n\}$, $i \ne j$ → è sicuramente diagonalizzabile

dimostrazione: $\forall i \in \{1, \dots, n\}$ $\alpha(\lambda_i) = 1$, inoltre $1 \le \gamma(\lambda_i) \le \alpha(\lambda_i) \le n$ → quindi $\gamma(\lambda_i) = 1$ (molteplicità algebrica di λ_i è 1 → ha radici tutte distinte) → $\gamma(\lambda_i) = \alpha(\lambda_i)$

osservazione: dire che $A \in \mathbb{C}^{n\times n}$ è diagonalizzabile equivale a dire che esiste una base di $\mathbb{C}^n$ formata da autovettori di A, ossia se $v_1, \dots, v_n \in \mathbb{C}^n \setminus \{0\}$ sono autovettori di A (linearmente indipendenti) allora $\forall x \in \mathbb{C}^n$, $\exists\, c_1, \dots, c_n \in \mathbb{C}$ tali che $x = c_1v_1 + \dots + c_nv_n$

teorema (spettrale): se $A \in \mathbb{C}^{n\times n}$ è hermitiana, ossia $A = A^H$ → A è diagonalizzabile con "autovalori reali" ed esiste una base "unitaria" di $\mathbb{C}^n$ fatta di autovettori di A

possiamo trovare $v_1, \dots, v_n \in \mathbb{C}^n$ autovettori di A (linearmente indipendenti) tali che $v_i^H v_j = \begin{cases} 1 & \text{se } i = j \\ 0 & \text{se } i \ne j \end{cases}$ $\forall i,j \in \{1, \dots, n\}$

proprietà di autovalori e autovettori:

(1) sia (λ, v) autocoppia di $A \in \mathbb{C}^{n\times n}$ e $\delta \in \mathbb{C}$ (delta) $\Rightarrow (\lambda+\delta, v)$ è autocoppia di $A + \delta I$ → **dimostrazione**: … ?

(2) dato un polinomio $p(x) = \sum_{j=0}^{s} p_j x^j$ possiamo definire una matrice $p(A) = \sum_{j=0}^{s} p_j A^j = p_0 I + p_1 A + \dots + p_s A^s$

- se (λ, v) è autocoppia di $A \Rightarrow (p(\lambda), v)$ è autocoppia di $p(A)$

(3) se $A \in \mathbb{C}^{n\times n}$ invertibile e (λ, v) è autocoppia di $A \Rightarrow (\lambda^{-1}, v)$ è autocoppia di A^{-1} → **dimostrazione**: $Av = \lambda v \Rightarrow A^{-1}Av = \lambda A^{-1}v$

$v = \lambda A^{-1}v \Rightarrow \lambda^{-1}v = A^{-1}v$

(4) se $A \in \mathbb{R}^{n\times n} \Rightarrow p_A(\lambda)$ è un polinomio a coefficienti reali

in particolare, se λ verifica $p_A(\lambda) = 0$ allora $\overline{p_A(\lambda)} = (-1)^n(\bar\lambda)^n + (-1)^{n-1}\sigma_1(\bar\lambda)^{n-1} + \dots + \sigma_n = p_A(\bar\lambda)$ → se λ è autovalore $\Rightarrow \bar\lambda$ è autovalore

definizione: $\rho(A) = \max_{j=1,\dots,n}(\lambda_j)$ è detto raggio spettrale di A

una matrice si dice "convergente" se $\rho(A) < 1$

teorema: $\lim_{k\to+\infty} A^k = 0$ $0 \in \mathbb{C}^{n\times n}$ matrice nulla $\iff A$ è convergente

lezione 6 (15/03/2024)

15 March 2024 15:10

$A \in \mathbb{C}^{n\times n}$ siamo interessati alle soluzioni dell'equazione $Ax = \lambda x$ con $x \in \mathbb{C}^n$, $x \neq 0$, $\lambda \in \mathbb{C}$

(λ, x) autocoppia di A → x autovettore, λ autovalore → in particolare λ soluzioni di $\det(\lambda I - A) = 0 \iff \det(A - \lambda I) = 0$ (polinomio caratteristico)

gli autovalori sono legati al rango della matrice ⟶ RANGO (A) = # di autovalori $\neq 0$ di A (contati con la loro molteplicità algebrica)

<u>osservazioni</u>: (rango e polinomio caratteristico)

$p_c(A) = \lambda^n - c_{n-1}\lambda^{n-1} + c_{n-2}\lambda^{n-2} - \dots + (-1)^n c_0$

c_{n-j} = somma dei minori di ordine j in A $\left(\begin{matrix} c_0 = \det(A) \\ c_1 = T_r(A) \end{matrix}\right)$

se RANGO$(A) = k$ ⟶ $p_c(A) = \lambda^n - c_{n-1}\lambda^{n-1} + \dots + (-1)^{n-k} c_{n-k}\lambda^{n-k} = \lambda^{n-k}(\lambda^n - c_{n-1}\lambda^{n-1} + \dots + (-1)^{n-k} c_{n-k})$

<u>esempio</u>: (matrici di rango 1)

se $A = u \cdot v^T$ → $u = \begin{bmatrix} u_1 \\ \vdots \\ u_n \end{bmatrix}$ $v = \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix}$

prodotto tra vettore colonna e vettore riga

$A = \begin{bmatrix} u_1v_1 & \cdots & u_1v_n \\ \vdots & \vdots & \vdots \\ u_nv_1 & \cdots & u_nv_n \end{bmatrix}$ ⟶ la guardo per colonne

$= \left[v_1 \cdot u \,\middle|\, v_2 \cdot u \,\middle|\, \cdots \,\middle|\, v_n \cdot u \right]$

vettore moltiplicato per uno scalare (entrata di u)

tutte le colonne di $A = u \cdot v^T$ sono multipli scalari di u ⟹ ho 1 colonna/riga linearmente indipendente ⟹ RANGO

↳ analogamente tutte le righe sono multiple scalari di v

chi sono gli autovalori di A?

- sicuramente 0 con molteplicità algebrica almeno $n-1$

$p_c(A) = \lambda^n - T_r(A)\lambda^{n-1} =$ ⟹ l'autovalore mancante è $T_r(A)$ (traccia)

$= \lambda^{n-1}(\lambda - T_r(A))$

$T_r(A) = u_1v_1 + \dots + u_nv_n = v^Tu = u^Tv$ (elementi sulla diagonale)

$\lambda(A) = \begin{cases} 0 \to \text{almeno molteplicità } n-1 \\ v^Tu \end{cases}$

<u>osservazione</u>: più in generale $A \in \mathbb{C}^{n\times n}$ $A = u \cdot v^T$ con $u \in \mathbb{C}^{n\times k}$, $v \in \mathbb{C}^{n\times k}$

$u, v = \left[\ \right]$ $k < n$

vale che RANGO$(A) \leq k$ (verificare che le colonne di A sono tutte combinazioni lineari delle colonne di u / righe di v)

$\left[\ \right] \cdot \left[\ \right]$ → prodotto di una matrice "alta e magra" e una "bassa e grassa" = ha rango pari alla dimensione più piccola

NORME ⟶ servono per misurare quanto è "grande un vettore"

↳ per capire quanto sono distanti x e y

↳ in molti casi ci serve definire la grandezza di un vettore e si fa utilizzando delle funzioni dette "norme", che hanno specifiche proprietà

<u>definizione</u>: una funzione $\|\cdot\| : \mathbb{C}^n \to [0, +\infty)$ è detta <u>NORMA</u> se verifica queste proprietà: (va dallo spazio vettoriale in $0, +\infty$)

- $\|x\| = 0 \iff x = 0 = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}$ (unica soluzione)
- $\|\alpha x\| = |\alpha| \cdot \|x\|$ $\forall \alpha \in \mathbb{C}$, $\forall x \in \mathbb{C}^n$
- $\|x+y\| \leq \|x\| + \|y\|$ (disuguaglianza triangolare ⟶ 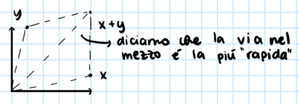

)

<u>esempi</u>:

$\|x\|_1 = \sum_{j=1}^{n} |x_j|$

$\|x\|_2 = \sqrt{\sum_{j=1}^{n} |x_j|^2}$

$\|x\|_\infty = \max_{j=1,\dots,n} |x_j|$

$\|x\|_p = \left(\sum_{j=1}^{n} |x_j|^p\right)^{1/p}$

<u>osservazione</u>: l'insieme dei vettori che hanno norma 1, cambia geometria se cambiate la norma in $\mathbb{R}^2$:

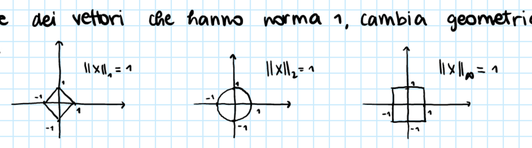

<u>osservazione</u>: nel caso $n = 1$ (non abbiamo vettori, ma scalari)

$\|x\|_1 = \|x\|_2 = \|x\|_\infty = \|x\|_p = |x|$

<u>definizione</u>: due norme vettoriali si dicono equivalenti se esistono due costanti α e β ($\exists \alpha, \beta \in \mathbb{R}^+$) positive, tali per cui $\forall x \in \mathbb{C}^n$ $\alpha\|x\|_p \leq \|x\|_q \leq \beta\cdot\|x\|_p$ $(*)$ ($\|\cdot\|_p, \|\cdot\|_q$)

<u>osservazione</u>: se vale $(*)$ allora $\beta^{-1}\|x\|_q \leq \|x\|_p \leq \alpha^{-1}\|x\|_q$

<u>teorema</u>: tutte le norme su $\mathbb{C}^n$ sono equivalenti (vale questa proprietà)

<u>esempi</u>:

- $\|x\|_2 \leq \|x\|_1 \leq \sqrt{n}\,\|x\|_2$
- $\|x\|_\infty \leq \|x\|_1 \leq n\,\|x\|_\infty$
- $\|x\|_\infty \leq \|x\|_2 \leq \sqrt{n}\,\|x\|_\infty$

<u>osservazione</u>: il calcolo delle norme vettoriali costa $O(n)$ (n operazioni)

NORME MATRICIALI

<u>definizione</u>: una funzione $\|\cdot\| : \mathbb{C}^{m\times n} \to [0, +\infty)$ si dice norma se valgono le seguenti proprietà:

- $\|A\| = 0 \iff A = 0 = \begin{bmatrix} 0 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 0 \end{bmatrix}$
- $\|\alpha A\| = |\alpha|\,\|A\|$ $\forall \alpha \in \mathbb{C}$, $\forall A \in \mathbb{C}^{m\times n}$
- $\|A+B\| \leq \|A\| + \|B\|$ $A, B \in \mathbb{C}^{m\times n}$ (subadditività)

(nel caso $m = n$ (caso quadrato))

- $\|A\cdot B\| \leq \|A\|\cdot\|B\|$ $\forall A, B \in \mathbb{C}^{m\times n}$ (submoltiplicatività)

! da ora in poi ci focalizziamo sul caso quadrato!

NORME INDOTTE

<u>definizione</u>: una norma matriciale $\|\cdot\|_M$ si dice indotta da una norma vettoriale $\|\cdot\|_v$ se è definita come: $\|A\|_M = \sup_{\substack{x\in\mathbb{C}^n \\ x\neq 0}} \frac{\|Ax\|_v}{\|x\|_v} = \sup_{\|x\|_v = 1} \|Ax\|_v$ (se è definita in questo modo verifica le proprietà viste sopra)

$\left(\begin{matrix} \|\cdot\|_M : \mathbb{C}^{n\times n} \to [0, +\infty) \\ \|\cdot\|_v : \mathbb{C}^n \to [0, +\infty) \end{matrix}\right)$

<u>esempi</u>: (norme indotte da $\|\cdot\|_1, \|\cdot\|_2, \|\cdot\|_\infty$)

- $\|A\|_1 = \max_{j=1,\dots,n} \sum_{i=1}^{n} |a_{ij}|$ ⟶ massimo delle somme sulle colonne (somma sulla colonna j)
- $\|A\|_\infty = \max_{i=1,\dots,n} \sum_{j=1}^{n} |a_{ij}|$ analogo, ma su righe
- $\|A\|_2 = \sqrt{\rho(A^*A)}$ = radice del max modulo degli autovalori di A^*A (raggio spettrale)

<u>esempio di norma non indotta</u>: (norma di Frobenius)

$\|A\|_F = \sqrt{\sum_{i,j=1,\dots,n} |a_{ij}|^2}$ ⟶ perché non è indotta? : $\|I\|_F = \left\|\left[\begin{smallmatrix} 1 & & \\ & \ddots & \\ & & 1 \end{smallmatrix}\right]\right\|_F = \sqrt{n} \neq 1$

per tutte le norme indotte, la norma dell'identità <u>deve</u> valere 1 ($\|I\| = 1$), infatti $\|I\| = \sup_{x\neq 0} \frac{\|I\cdot x\|}{\|x\|} = \sup_{x\neq 0} \frac{\|x\|}{\|x\|} = 1$

<u>definizione</u>: una norma matriciale $\|\cdot\|_M$ si dice compatibile con una norma vettoriale $\|\cdot\|_v$ se $\forall A \in \mathbb{C}^{n\times n}$ e $\forall x \in \mathbb{C}^n$ vale: $\|A\cdot x\|_v \leq \|A\|_M \cdot \|x\|_v$ ⟶ <u>proprietà</u>: se la norma $\|\cdot\|_M$ è la norma matriciale indotta da una vettoriale $\|\cdot\|_v$ allora $\|\cdot\|_M$ e $\|\cdot\|_v$ sono compatibili

<u>dimostrazione</u>:

$\forall x \neq 0$ $\frac{\|Ax\|_v}{\|x\|_v} \leq \|A\|_M$ (vale perché la norma è definita come il max delle quantità a sinistra)

<u>teorema di Hirsch</u>: $A \in \mathbb{C}^{n\times n}$, allora per ogni <u>norma matriciale</u> ($\forall \|\cdot\|$) vale: $\rho(A) = \max\{|\lambda| : \lambda \text{ autovalore di } A\} \leq \|A\|$ (ρ raggio spettrale)

equivale a scrivere: λ autovalore di $A \Rightarrow \lambda \in \{z \in \mathbb{C} : |z| \leq \|A\|\}$ (cerchio) $= \{z \in \mathbb{C} : |z - 0| \leq \|A\|\}$

<u>osservazione</u>: Hirsch vale anche per norme non indotte

<u>dimostrazione</u>: prendiamo un generico autovalore e facciamo vedere che sta in questo cerchio

sia (λ, x) autocoppia per A ($x \neq 0$, $Ax = \lambda x$)

e prendiamo $B = \left[x \,\middle|\, \begin{smallmatrix} 0 \\ \vdots \\ 0 \end{smallmatrix} \,\middle|\, \cdots \,\middle|\, \begin{smallmatrix} 0 \\ \vdots \\ 0 \end{smallmatrix}\right] \in \mathbb{C}^{n\times n}$

$A \cdot B = \left[Ax \,\middle|\, A\cdot 0 \,\middle|\, \cdots \,\middle|\, A\cdot 0\right] = \left[A_x \,\middle|\, 0 \,\middle|\, \cdots \,\middle|\, 0\right] = \left[\lambda x \,\middle|\, 0 \,\middle|\, \cdots \,\middle|\, 0\right] = \lambda\left[x \,\middle|\, 0 \,\middle|\, \cdots \,\middle|\, 0\right] = \lambda \cdot B$ (↳ B) → sfruttando le proprietà delle norme

$\|A\cdot B\| \leq \|A\|\cdot\|B\|$ ⟶ $|\lambda|\,\|B\| = \|\lambda B\| = \|A\cdot B\| \leq \|A\|\cdot\|B\|$ ⟹ posso farlo perché $\|B\| \neq 0$ → perché la prima colonna non è zero

$|\lambda|\,\|B\| \leq \|A\|\cdot\|B\|$ → $|\lambda| \leq \|A\|$

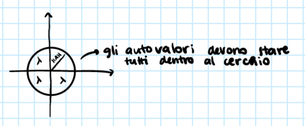

<u>teoremi di Gershgorin</u>: (teoremi di localizzazione degli autovalori)

(! Hirsch da un cerchio unico, Gershgorin da n cerchi)

$A \in \mathbb{C}^{n\times n}$, definiamo gli insiemi (allorale le matrici per gli autovalori sono sempre quadrate!)

$M_i(A) = \{z \in \mathbb{C} : |z - a_{ii}| \leq \rho_i\}$ $\rho_i := \sum_{\substack{j=1 \\ j\neq i}} |a_{ij}|$

$A = i$

è detto cerchio di Gershgorin associato alla riga i di A

<u>esempio</u>: $A = \begin{bmatrix} * & * & * \\ -1 & 1 & i \\ * & * & * \end{bmatrix}$ $\rho_2 = |-1| + |i| = 2$, $a_{22} = 1$ ⟹ $M_2(A)$ 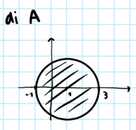

<u>teorema</u>: (1° teorema di Gershgorin)

λ autovalore di $A \Rightarrow \lambda \in \bigcup_{i=1}^{n} M_i(A)$

<u>dimostrazione</u>: (λ, x) autocoppia per A $\left(\begin{matrix} x \neq 0 \\ Ax = \lambda x \end{matrix}\right)$

$x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$ scelgo $k \in \{1, \dots, n\}$ come uno che verifica $|x_k| \geq |x_j|$ $\forall j = 1, \dots, n$ (↳ in particolare $|x_k| > 0$)

↳ consideriamo la k-esima riga dell'equazione $Ax = \lambda x$

$a_{k1}\cdot x_1 + a_{k2}\cdot x_2 + \dots + a_{kn}\cdot x_n = \lambda x_k$

$\sum_{j=1}^{n} a_{kj}x_j = \lambda x_k \iff \sum_{\substack{j=1 \\ j\neq k}}^{n} a_{kj}x_j = \lambda x_k - a_{kk}x_k$

$\Rightarrow \left|\sum_{\substack{j=1 \\ j\neq k}}^{n} a_{kj}x_j\right| = |\lambda x_k - a_{kk}x_k|$

$\Rightarrow |x_k| \cdot \underbrace{|\lambda - a_{kk}|}_{\text{distanza di } \lambda \text{ da } a_{kk}} \leq \sum_{\substack{j=1 \\ j\neq k}}^{n} |a_{kj}|\,|x_j|$ → divido per x_k (non può essere 0 perché è l'elemento di massimo modulo)

$\Rightarrow |\lambda - a_{kk}| \leq \sum_{\substack{j=1 \\ j\neq k}}^{n} |a_{kj}| \frac{|x_j|}{|x_k|}$ (sempre ≤ 1)

$\Rightarrow |\lambda - a_{kk}| \leq \sum_{\substack{j=1 \\ j\neq k}}^{n} |a_{kj}| = \rho_k \Rightarrow \lambda \in M_k(A) \Rightarrow \lambda \in \bigcup_{j=1}^{n} M_j(A)$ (se sta in un cerchio, sta nell'unione di tutti)

<u>definizione</u>: A è una matrice a "predominanza diagonale forte" se $|a_{jj}| > \sum_{\substack{h=1 \\ h\neq j}}^{n} |a_{jh}|$ $\forall j = 1, \dots, n$ (↳ se la somma degli elementi sulla diagonale è sempre più grande della somma degli elementi fuori dalla diagonale)

<u>corollario</u>: A è a predominanza diagonale forte $\Rightarrow$ A è non singolare (sicuramente è invertibile) (↳ in termini di Gershgorin: se il raggio dei cerchi di Gershgorin è più grande del modulo dell'elemento sulla diagonale)

<u>dimostrazione</u>: i cerchi di Gershgorin non contengono lo 0 ← 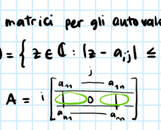

⟶ 0 non è autovalore → matrice è invertibile, $\det \neq 0$, etc.

$\lambda \neq 0$

<u>osservazione</u>: autovalori di A sono uguali agli autovalori di A^T, quindi si può applicare Gershgorin anche su A^T e poi fare l'intersezione

$\lambda \in \left[\bigcup_{i=1}^{n} M_i(A)\right] \cap \left[\bigcup_{i=1}^{n} M_i(A^T)\right]$

lezione 7 (18/03/2024)

18 March 2024 09:13

* ripasso scorsa lezione

teorema: (2° teorema di Gershgorin)

$A \in \mathbb{C}^{n\times n}$ $1 \le s < n$ (s intero) e sia M_1 dato dall'unione di s cerchi di Gershgorin associati ad A e sia M_2 l'unione dei restanti n-s cerchi di Gershgorin

se $M_1 \cap M_2 = \emptyset \Longrightarrow$ M_1 contiene esattamente s autovalori e M_2 contiene esattamente n-s autovalori (contati rispetto alla molteplicità algebrica)

esempio:

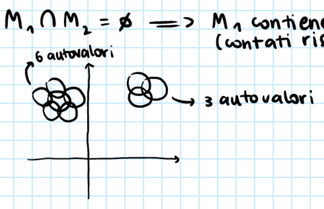

conseguenze del teorema:

(1) se A ha n cerchi disgiunti $\Rightarrow$ A ha n autovalori distinti $\Rightarrow$ A è diagonalizzabile

(2) se $A \in \mathbb{R}^{n\times n}$ e $\mathcal{G}_i(A)$ è un cerchio isolato, cioè $\mathcal{G}_i(A) \cap \left[\bigcup_{j\neq i} \mathcal{G}_j(A)\right] = \emptyset$ (che non tocca gli altri), allora $\mathcal{G}_i(A)$ contiene un autovalore reale

dimostrazione: se λ autovalore di A, $\lambda \in \mathcal{G}_i(A)$ e per assurdo

$\lambda \notin \mathbb{R} \Rightarrow \bar{\lambda}$ è autovalore di $A \Rightarrow \bar{\lambda} \in \mathcal{G}_i(A)$ $\longrightarrow$ assurdo perché viola il secondo teorema di Gershgorin (ci deve essere un solo autovalore se il cerchio è isolato e la matrice è reale)

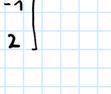

$\longrightarrow$ non è possibile

riflessione di λ rispetto all'asse delle x

definizione: $A \in \mathbb{C}^{m\times m}$ (ad ogni matrice è possibile associare un grafo) si dice "grafo associato ad A", il grafo (V, E) è una coppia nodi-archi

$G(A) = (V, E)$ (archi) definito come $V = \{1, \dots, n\}$ (vertici/nodi)

$E = \{(i,j) : a_{ij} \neq 0\}$

esempi:

$$A = \begin{bmatrix} 1 & 4 & 7 \\ 2 & 5 & 8 \\ 3 & 6 & 9 \end{bmatrix}$$

$$A = \begin{bmatrix} 1 & 0 & 1 \\ -1 & -1 & 1 \\ 0 & 0 & 2 \end{bmatrix}$$

1 $\longrightarrow$ prima riga posso andare solo nel terzo elemento

3 $\longrightarrow$ non può andare in nessun elemento

definizione: un grafo si dice "fortemente connesso" se $\forall$ coppia di vertici (i, j) esiste un cammino orientato, che parte da i e arriva a j

definizione: una matrice A, il cui grafo associato G(A) è fortemente connesso si dice "irriducibile"

teorema: (3° teorema di Gershgorin)

$A \in \mathbb{C}^{n\times n}$ irriducibile e λ autovalore di A, allora:

$\lambda \in$ bordo dell'unione dei cerchi di Gershgorin di A $\Longrightarrow$ $\lambda \in$ bordo di ogni cerchio di $\mathcal{G}_i(A)$

esempio:

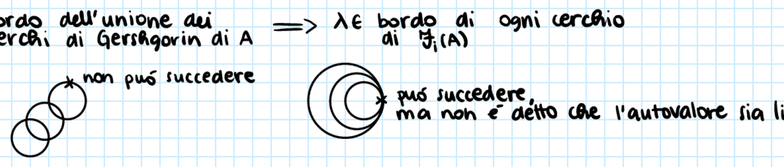

esempio:

$$A = \begin{bmatrix} 2 & -1 & & & \\ -1 & 2 & \ddots & & \\ & \ddots & \ddots & \ddots & \\ & & \ddots & \ddots & -1 \\ & & & -1 & 2 \end{bmatrix} \in \mathbb{R}^{n\times n}$$

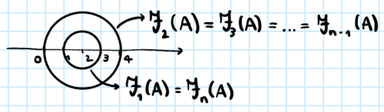

se $\emptyset$ fosse autovalore di A, apparterrebbe al bordo dell'unione dei cerchi, ma questo violerebbe il III° teorema di Gershgorin, perché non sta sul bordo di $\mathcal{G}_n$ e $\mathcal{G}_n$ $\Longrightarrow$ ci assicura che A è non singolare

definizione: $A \in \mathbb{C}^{n\times n}$ si dice a "predominanza diagonale debole" se $|a_{ii}| \ge \sum_{\substack{j=1 \\ j\neq i}}^{n} |a_{ij}|$ ed esiste almeno un indice k, per cui $|a_{kk}| > \sum_{\substack{j=1 \\ j\neq k}}^{n} |a_{kj}|$

corollario: $A \in \mathbb{C}^{n\times n}$ a predominanza diagonale debole ed irriducibile, allora A non singolare

esempio: (continuo quello di prima)

$$A = \begin{bmatrix} * & * & & & \\ * & * & \ddots & & \\ & \ddots & \ddots & \ddots & \\ & & \ddots & \ddots & * \\ & & & * & * \end{bmatrix} \in \mathbb{C}^{n\times n}$$

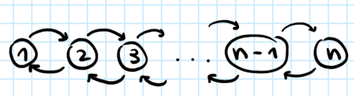

$\rightsquigarrow$ è fortemente connesso

MATRICI A BLOCCHI

talvolta (per descrivere/analizzare algoritmi) è comodo scriversi le matrici in termini delle loro sottomatrici, al posto delle entrate scalari

esempi:

(1)

$$A = \left[\begin{array}{ccc|c} * & * & * & * \\ * & * & * & * \\ \hline * & * & * & * \end{array}\right] \in \mathbb{C}^{3\times 4} \Longrightarrow A = \begin{bmatrix} B & C \\ D & E \end{bmatrix}$$

(B sopra le prime tre colonne, C sopra l'ultima; D sotto le prime tre colonne, E sotto l'ultima)

$B \in \mathbb{C}^{2\times 3}$
$C \in \mathbb{C}^{2\times 1}$
$D \in \mathbb{C}^{1\times 3}$
$E \in \mathbb{C}$

queste scritture si possono sempre fare, purché le sottomatrici che stanno sulla stessa riga abbiano lo stesso numero di righe, e le matrici che stanno sulla stessa colonna abbiano lo stesso numero di colonne

(2)

$$A = \left[\begin{array}{cc|ccc} 1 & 0 & 1 & 1 & 1 \\ 0 & 1 & 1 & 1 & 1 \\ \hline 1 & 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 & 1 \end{array}\right] = \begin{bmatrix} I_2 & E \\ E^T & I_3 \end{bmatrix}$$

definizione: $A \in \mathbb{C}^{m\times n}$ si dice a blocchi s x t se si scrive come:

$$A = \begin{bmatrix} A_{11} & \cdots & A_{1t} \\ \vdots & & \vdots \\ A_{s1} & \cdots & A_{st} \end{bmatrix}$$ dove $A_{ij} \in \mathbb{C}^{m_i \times m_j}$ con $\sum_{i=1}^{s} m_i = m$ e $\sum_{j=1}^{t} m_j = m$

NOTA: nei casi rilevanti si assume che i blocchi sulla diagonale siano quadrati e che la matrice A sia quadrata

↳ in questo caso si ha $m_i = n_i$ e $s = t$, $\forall i = 1, \dots, (s = t)$

definizione: A si dice triangolare inferiore o superiore a blocchi se è della forma:

$$A = \begin{bmatrix} A_{11} & & \emptyset \\ \vdots & \ddots & \\ A_{s1} & \cdots & A_{ss} \end{bmatrix}$$ oppure $$A = \begin{bmatrix} A_{11} & \cdots & A_{1s} \\ & \ddots & \vdots \\ \emptyset & & A_{ss} \end{bmatrix}$$ con A_{ii} quadrata $\forall i = 1, \dots, s$

A si dice diagonale a blocchi se valgono entrambe

$$A = \begin{bmatrix} A_{11} & & \emptyset \\ & \ddots & \\ \emptyset & & A_{ss} \end{bmatrix} \quad \forall i = 1, \dots, s$$

proprietà:

- $\det(A) = \prod_{j=1}^{s} \det(A_{ii})$
- le operazioni aritmetiche (somma e prodotto) tra matrici scritte a blocchi, con blocchi diagonali quadrati, si possono fare/scrivere in modo analogo alle operazioni scalari

$$A = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix}, \quad B = \begin{bmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{bmatrix}$$

$B_{ii} \in \mathbb{C}^{n_i \times n_i}$, $A_{ii} \in \mathbb{C}^{n_i \times n_i}$, $i = 1, 2$ $\Longrightarrow$ allora:

$$A + B = \begin{bmatrix} A_{11} + B_{11} & A_{12} + B_{12} \\ A_{21} + B_{21} & A_{22} + B_{22} \end{bmatrix}$$

$$A \cdot B = \begin{bmatrix} A_{11} \cdot B_{11} + A_{12} \cdot B_{21} & A_{11} \cdot B_{12} + A_{12} \cdot B_{22} \\ A_{21} \cdot B_{11} + A_{22} \cdot B_{21} & A_{21} \cdot B_{12} + A_{22} \cdot B_{22} \end{bmatrix}$$

MATRICI RIDUCIBILI

definizione: $A \in \mathbb{C}^{n\times n}$, $n \ge 2$, si dice "riducibile" se $\exists \Pi \in \mathbb{R}^{n\times n}$ (pi greco) matrice di permutazione tale che:

$$B = \Pi A \Pi^T = \begin{bmatrix} A_{11} & A_{12} \\ \emptyset & A_{22} \end{bmatrix}$$ $A_{11} \in \mathbb{C}^{k\times k}$, $A_{22} \in \mathbb{C}^{(n-k)\times(n-k)}$, $1 \le k < n$

osservazioni:

- ci possono essere più di una matrice Π che verifica questa relazione con un valore diverso di k (dim A_{11})
- se una matrice è riducibile, allora $\exists \tilde{\Pi}$ (tilde) matrice di permutazione tale che $\tilde{\Pi} A \tilde{\Pi}^T = \begin{bmatrix} \tilde{A}_{11} & \emptyset \\ \tilde{A}_{21} & \tilde{A}_{22} \end{bmatrix}$

(le due definizioni sono equivalenti)

risolvere un sistema lineare con matrice riducibile: $Ax = b$, $A \in \mathbb{C}^{n\times n}$, $b \in \mathbb{C}^n$ (termini noti), $x \in \mathbb{C}^n$ (vettore incognite)

$\Pi A \Pi^T = \begin{bmatrix} A_{11} & A_{12} \\ \emptyset & A_{22} \end{bmatrix} = B$ $\longrightarrow$ come si sfrutta la riducibilità?

$$Ax = b \Longleftrightarrow \underbrace{\Pi A x}_{\Pi^T \Pi = I} = \Pi b \Longleftrightarrow \underbrace{\Pi A \Pi^T}_{B} \cdot \underbrace{\Pi x}_{y} = \underbrace{\Pi b}_{c} \Longleftrightarrow By = c \Longleftrightarrow \begin{bmatrix} A_{11} & A_{12} \\ 0 & A_{22} \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} c_1 \\ c_2 \end{bmatrix} \Longleftrightarrow \begin{cases} A_{11} \cdot y_1 + A_{12} \cdot y_2 = c_1 \\ A_{22} \cdot y_2 = c_2 \end{cases}$$

$\rightsquigarrow$ sistema lineare di dimensione $(n-k)\times(n-k)$

↳ 1 risolvo per y_2 (sistema lineare associato alla seconda)

↳ 2 sostituisco nella prima riga ed ottengo $A_{11} y_1 = c_1 - A_{12} y_2$

↳ 3 risolvo per y_1 (sistema lineare $k \times k$)

y = permutazione delle incognite

c = permutazione dei termini noti

- ne vale la pena?

prendiamo per buono che risolvere $Ax = b$ in generale costa $O(n^3)$

↓

procedura diretta per $Ax = b$ $\rightsquigarrow$ $O(n^3)$

procedura vista sopra $\rightsquigarrow$ $O((n-k)^3 + k^3 +$ termine di ordine inferiore$)$

- $(n-k)^3$: risolvere un sistema $(n-k)\times(n-k)$
- k^3: risolvere sistema $k \times k$
- termine di ordine inferiore: prodotto matrice-vettore: genera un costo quadratico (più piccolo)

↓

caso migliore è $k = \frac{n}{2}$ in cui si ha:

$O(n^3)$ vs. $O\left((n - \frac{n}{2})^3 + (\frac{n}{2})^3\right) = O\left(\frac{n^3}{4}\right)$

↳ si guadagna un fattore 4 sul numero di operazioni

osservazione: questo algoritmo si può applicare ricorsivamente sui blocchi A_{11} e A_{22} nel caso fossero riducibili

esempio:

$$A = \begin{bmatrix} 1 & 0 & -1 & 0 \\ 2 & 3 & -2 & 1 \\ -1 & 0 & -2 & 0 \\ 1 & -1 & 1 & 4 \end{bmatrix}, \quad x = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix}, \quad b = \begin{bmatrix} 1 \\ -2 \\ -1 \\ -2 \end{bmatrix}, \quad \Pi = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 \end{bmatrix} \rightsquigarrow \Pi^T = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 \end{bmatrix}$$

$$\Pi A \Pi^T = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & -1 & 0 \\ 2 & 3 & -2 & 1 \\ -1 & 0 & -2 & 0 \\ 1 & -1 & 1 & 4 \end{bmatrix} \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 1 & -1 & 1 & 4 \\ 2 & 3 & -2 & 1 \\ -1 & 0 & -2 & 0 \\ 1 & 0 & -1 & 0 \end{bmatrix} \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 4 & -1 & 1 & 1 \\ 1 & 3 & -2 & 2 \\ 0 & 0 & -2 & -1 \\ 0 & 0 & -1 & 1 \end{bmatrix}$$

(A_{11}, A_{12}, A_{22}; forma a blocchi triangolare superiore)

$$y = \Pi x = \begin{bmatrix} x_4 \\ x_2 \\ x_3 \\ x_1 \end{bmatrix} \quad (y_1, y_2) \qquad c = \Pi b = \begin{bmatrix} -2 \\ -2 \\ -1 \\ 1 \end{bmatrix} \quad (c_1, c_2)$$

$$\begin{cases} \begin{bmatrix} 4 & -1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} x_4 \\ x_2 \end{bmatrix} + \begin{bmatrix} 1 & 1 \\ -2 & 2 \end{bmatrix} \begin{bmatrix} x_3 \\ x_1 \end{bmatrix} = \begin{bmatrix} -2 \\ -2 \end{bmatrix} \longrightarrow \begin{bmatrix} 4 & -1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} x_4 \\ x_2 \end{bmatrix} = \begin{bmatrix} -2 \\ -2 \end{bmatrix} - \begin{bmatrix} 1 & 1 \\ -2 & 2 \end{bmatrix} \begin{bmatrix} 0 \\ 1 \end{bmatrix} \longrightarrow \begin{cases} 4x_4 - x_2 = -3 \\ x_4 + 3x_2 = -4 \end{cases} \begin{cases} -16 - 12x_2 - x_2 = -3 \\ x_4 = -4 - 3x_2 \end{cases} \begin{cases} -13x_2 = 13 \\ x_4 = -4 - 3x_2 \end{cases} \begin{cases} x_2 = -1 \\ x_4 = -1 \end{cases} \Longrightarrow \begin{bmatrix} x_2 \\ x_4 \end{bmatrix} = \begin{bmatrix} -1 \\ -1 \end{bmatrix} \\ \begin{bmatrix} -2 & -1 \\ -1 & 1 \end{bmatrix} \begin{bmatrix} x_3 \\ x_1 \end{bmatrix} = \begin{bmatrix} -1 \\ 1 \end{bmatrix} \longrightarrow \begin{cases} -2x_3 - x_1 = -1 \\ -x_3 + x_1 = 1 \end{cases} \begin{cases} -2x_3 - 1 - x_3 = -1 \\ x_1 = 1 + x_3 \end{cases} \begin{cases} x_3 = 0 \\ x_1 = 1 \end{cases} \Longrightarrow \begin{bmatrix} x_3 \\ x_1 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \end{bmatrix} \end{cases}$$

(A_{11}, y_1, A_{22}, y_2, c_1; $\begin{bmatrix} 1 \\ 2 \end{bmatrix}$; A_{22}, y_2, c_2)

lezione 8 (22/03/2024)

22 March 2024 10:32

quando una matrice è riducibile?

teorema: $A \in \mathbb{C}^{n\times n}$ è riducibile $\iff$ $G(A)$ non è fortemente connesso

(matrice che ha tutti elementi diversi da zero è sicuramente irriducibile)

esempio: avere molti zeri non vuol dire per forza che la matrice è riducibile

$A = \begin{bmatrix} 0&1&0&0\\ 0&0&1&0\\ 0&0&0&1\\ 1&0&0&0 \end{bmatrix} \in \mathbb{R}^{4\times 4}$ ⟶ grafo associato 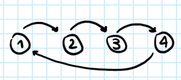 $\Rightarrow$ $G(A)$: fortemente connesso $\Rightarrow$ A irriducibile

dimostrazione: osservazione preliminare, data $\Pi \in \mathbb{R}^{n\times n}$ matrice di permutazione, si ha che $G(A)$ e $G(\Pi A \Pi^T)$ sono "uguali"

consideriamo Π che scambia riga i con riga j

$\Pi A = \begin{bmatrix} \cdots \\ \text{riga } j \\ \cdots \\ \text{riga } i \\ \cdots \end{bmatrix}$ ⟿ sto scambiando gli archi in uscita dal vertice (i), con quelli in uscita da (j), e viceversa

$A\Pi^T = \begin{bmatrix} \cdots & \text{col } j & \cdots & \text{col } i & \cdots \end{bmatrix}$ ⟿ commento analogo, ma per gli archi in entrata

$\Rightarrow$ $\Pi A \Pi^T$ ottengo lo stesso grafo, a meno di aver scambiato il nome di (i) con (j), e viceversa

$\Rightarrow$ $G(A)$ è fortemente connesso $\iff$ $G(\Pi A \Pi^T)$ è fortemente connesso $\quad \forall \Pi$ matrice di permutazione

↳ **dimostrazione**: $\Rightarrow$ A è riducibile $\Rightarrow \exists \Pi : B = \Pi A \Pi^T = \begin{bmatrix} A_{11} & A_{12} \\ 0 & A_{22} \end{bmatrix}$ k righe, $n-k$ righe

$G(B)$ non è fortemente connesso perché da un indice in $\{k+1, k+2, \dots, n\}$ non si può arrivare a nessun indice nell'insieme $\{1, \dots, k\}$ $\Rightarrow$ $G(A)$ non è fortemente connesso

$\Leftarrow$ $G(A)$ non fortemente connesso $\Rightarrow \exists j, h \in \{1, \dots, n\}$ $j \neq h$ tali per cui partendo da j non posso arrivare ad h

allora consideriamo: $P = \{x \in \{1, \dots, n\} : x \text{ raggiungibile da } j\}$, $Q = \{x \in \{1, \dots, n\} : x \text{ irraggiungibile da } j\}$ ⟶ $P \neq \emptyset$ (contiene j), $Q \neq \emptyset$ (contiene almeno h), $P \cup Q = \{1, \dots, n\}$

osservazione: non ci possono essere archi che partono da un elemento di P e raggiungono un elemento di Q

↳ allora consideriamo una permutazione Π tale che sposta in testa tutti gli elementi in Q e sposta in coda tutti gli elementi di P

$\Pi A \Pi^T = \begin{matrix} Q \\ P \end{matrix} \begin{bmatrix} \overset{Q}{A_{11}} & \overset{P}{A_{12}} \\ 0 & A_{22} \end{bmatrix}$ $\Rightarrow$ definizione di A riducibile

↳ deve essere necessariamente zero, altrimenti il grafo è fortemente connesso

osservazione: la dimostrazione fornisce un modo per trovare Π

esempio: $A = \begin{bmatrix} 3&0&6\\ 2&4&7\\ 3&0&0 \end{bmatrix}$ ⟶ grafo associato

nodi	nodi raggiungibili	nodi irraggiungibili
1	1 3	2
2	1 2 3	∅
3	1 3	2

↳ scegliamo $P = \{1\ 3\}$, $Q = \{2\}$ e la permutazione (per righe)

$2 \to 1$, $1 \to 2$, $3 \to 3$ $\Rightarrow$ $\Pi = \begin{bmatrix} 0&1&0\\ 1&0&0\\ 0&0&1 \end{bmatrix}$

$\Pi A \Pi^T = \left[\begin{array}{c|cc} 4 & 2 & 7 \\ \hline 0 & 3 & 6 \\ 0 & 3 & 0 \end{array}\right]$

osservazione: si può provare ad applicare il procedimento di riduzione a forma triangolare a blocchi in maniera ricorsiva

supponiamo di aver trovato Π:

$\Pi A \Pi^T = \begin{bmatrix} \overbrace{A_{11}}^{k} & \overbrace{A_{12}}^{n-k} \\ & A_{22} \end{bmatrix}$, si prova ad applicare lo stesso metodo ad A_{11} e A_{22} se sono riducibili

se sono entrambi riducibili si trovano $\Pi_1 \in \mathbb{R}^{k\times k}$, $\Pi_2 \in \mathbb{R}^{(n-k)\times(n-k)}$ matrici di permutazione tali che:

$\Pi_1 A_{11} \Pi_1^T = \begin{bmatrix} A_{11}^{(1)} & A_{12}^{(1)} \\ 0 & A_{22}^{(1)} \end{bmatrix}$ $\quad \Pi_2 A_{22} \Pi_2^T = \begin{bmatrix} A_{33}^{(1)} & A_{34}^{(1)} \\ 0 & A_{44}^{(1)} \end{bmatrix}$

$\begin{bmatrix} \Pi_1 & \\ & \Pi_2 \end{bmatrix} (\Pi A \Pi^T) \begin{bmatrix} \Pi_1^T & \\ & \Pi_2^T \end{bmatrix} = \left[\begin{array}{cc|cc} A_{11}^{(1)} & A_{12}^{(1)} & \multicolumn{2}{c}{*} \\ 0 & A_{22}^{(1)} & & \\ \hline \multicolumn{2}{c|}{0} & A_{33}^{(1)} & A_{34}^{(1)} \\ & & 0 & A_{44}^{(1)} \end{array}\right]$ ⟶ matrice txt triangolare a blocchi

(continuando ricorsivamente sui blocchi diagonali)

$\begin{bmatrix} A_{11} & & A_{1t} \\ & \ddots & \\ & & A_{tt} \end{bmatrix}$ ⟶ il sistema lineare associato è della forma $\Rightarrow$

$\begin{cases} A_{11}x_1 = c_1 - A_{12}x_2 - \dots - A_{1t}x_t \\ \vdots \\ A_{t-1\,t-1}x_{t-1} = c_{t-1} - A_{t-1\,t}x_t \\ A_{tt}x_t = c_t \end{cases}$

↖ metodo di sostituzione all'indietro (a blocchi)

$A_{t-1\,t-1}x_{t-1} = c_{t-1} - A_{t-1\,t}x_t$ ⟶ risolvo per x_{t-1} e sostituisco nella riga sopra

$A_{tt}x_t = c_t$ ↳ risolvo per x_t e sostituisco nella riga sopra

Sistemi con matrice triangolare: supponiamo $A = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ & \ddots & \vdots \\ 0 & & a_{nn} \end{bmatrix}$ e di voler risolvere $Ax = b$, $A \in \mathbb{C}^{n\times n}$, $b \in \mathbb{C}^n$

$\begin{cases} \vdots \\ a_{n-1\,n-1}x_{n-1} = b_{n-1} - a_{n-1\,n}x_n \\ a_{nn}x_n = b_n \end{cases}$ ⟿ $x_n = \frac{b_n}{a_{nn}}$ ↳ sostituisco

$\Rightarrow$ in formula, le componenti della soluzione sono: $x_j = \begin{cases} \frac{b_n}{a_{nn}} & \text{se } n = j \\ b_j - \sum_{i=j+1}^{n} \frac{a_{ji}x_i}{a_{jj}} \end{cases}$ ⟶ quanto costa calcolarla?

↳ $n-j$ moltiplicazioni

$n-j-1$ somme + 2 (somma + frazione)

↳ $2(n-j)+1$ operazioni per l'entrata j

$\sum_{j=1}^{n} 2(n-j)+1 = n + 2\sum_{j=1}^{n}(n-j) = n + 2\sum_{j=1}^{n-1} j = n + 2\frac{n(n-1)}{2} = n + n(n-1) = (n^2)$ ⟶ risolvere un sistema triangolare costa $O(n^2)$ operazioni

↳ (molto meglio del caso A generica che costa $O(n^3)$)

metodi per sistemi lineari: $Ax = b$, $A \in \mathbb{C}^{n\times n}$, $b \in \mathbb{C}^n$, A generica (no assunzioni particolari)

1. metodi diretti ⟶ se operassimo in aritmetica esatta calcolerebbero la soluzione (x) in un numero finito di passi (operazioni) es. metodo di sostituzione all'indietro del sistema triangolare
2. metodi iterativi ⟶ (non garantisce la soluzione in un numero finito di passi) generano una successione $\{x_n\}_{k\in\mathbb{N}}$ (di vettori x_n) tale che $\lim_{k\to+\infty} x_k = x$, però in genere x_N (con N ragionevole) è una buona approssimazione di x

↳ hanno un costo più basso ⟶ se converge abbastanza in fretta può essere più conveniente

metodi diretti per $Ax = b$:

esempi: (metodo di Cramer) ⟶ si usa poco perché costa tanto

$x_j = \frac{\begin{vmatrix} a_{11} & \cdots & a_{1\,j-1} & b_1 & a_{1\,j+1} & \cdots & a_{1n} \\ \vdots & & \vdots & \vdots & \vdots & & \vdots \\ a_{n1} & \cdots & a_{n\,j-1} & b_n & a_{n\,j+1} & \cdots & a_{nn} \end{vmatrix}}{\det(A)}$ ⟿ costa come calcolarsi $n+1$ determinanti (in genere è una cosa troppo costosa)

↳ con Laplace $O(n!)$

↳ con metodi migliori $O(n^3)$

(metodo di eliminazione di Gauss)

idea: portare $Ax = b$ in un sistema equivalente (che ha la stessa soluzione) $Ux = c$, in cui U è triangolare superiore

osservazione: nel contesto di matrici riducibili si cercava di fare una cosa simile (differenza era che la matrice era a blocchi) mediante matrici di permutazione

nell'algoritmo di Gauss si fa una cosa simile, ma con trasformazioni più costose delle permutazioni, ma che consentono di andare oltre al vincolo della riducibilità

osservazione: se ho un sistema lineare e sommo il multiplo di una certa equazione alla j-esima non cambio l'insieme delle soluzioni

1° passo: $\begin{cases} a_{11}x_1 + \dots + a_{1n}x_n = b_1 \\ a_{21}x_1 + \dots + a_{2n}x_n = b_2 \\ \vdots \\ a_{n1}x_1 + \dots + a_{nn}x_n = b_n \end{cases}$ ⟶ posso sommare un multiplo della 1ª riga a quelle sotto, in modo da annullare

↳ per avere una cosa triangolare devo liberarmi di questi termini

- sommo alla riga j la riga 1 moltiplicata per $-\frac{a_{j1}}{a_{11}}$, $j = 2, \dots, n$

↳ ottengo: $\begin{cases} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n = b_1 \\ 0 + a_{22}^{(2)}x_2 + \dots + a_{2n}^{(2)}x_n = b_2^{(2)} \\ \vdots \\ 0 + a_{n2}^{(2)}x_2 + \dots + a_{nn}^{(2)}x_n = b_n^{(2)} \end{cases}$

2° passo ⟶ si ripete sommando la 2ª riga moltiplicata per $-\frac{a_{j2}^{(2)}}{a_{22}^{(2)}}$ alla riga j per $j = 3, \dots, n$

$\begin{cases} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n = b_1 \\ a_{22}^{(2)}x_2 + \dots + a_{2n}^{(2)}x_n = b_2^{(2)} \\ a_{33}^{(3)}x_3 + \dots + a_{3n}^{(3)}x_n = b_3^{(3)} \\ \vdots \\ a_{n3}^{(3)}x_3 + \dots + a_{nn}^{(3)}x_n = b_n^{(3)} \end{cases}$

- al passo j (generico) sommo la riga j moltiplicata per $-\frac{a_{ij}^{(j)}}{a_{jj}^{(j)}}$ alla riga i per $i = j+1, \dots, n$
- dopo $n-1$ passi: $\begin{cases} a_{11}x_1 + \dots + a_{1n}x_n = b_1 \\ a_{22}^{(2)}x_2 + \dots + a_{2n}^{(2)}x_n = b_2^{(2)} \\ \ddots \\ a_{nn}^{(n)}x_n = b_n^{(n)} \end{cases}$ $\quad \begin{matrix} \to U \\ \to c \end{matrix}$

⟿ ed infine applicare il metodo di sostituzione all'indietro per trovare x (costa $O(n^2)$)

esempio:

$\begin{bmatrix} -2 & 1 & 1 \\ -1 & 3 & 1 \\ 1 & 1 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} -2 \\ -3 \\ 2 \end{bmatrix}$

moltiplico la riga per $\frac{-1}{-2}$ e sommo alla 2

$\left[\begin{array}{ccc|c} -2 & 1 & 1 & -2 \\ -1 & 3 & 1 & -3 \\ 1 & 1 & 2 & 2 \end{bmatrix} \xrightarrow{-\frac{1}{2}\text{riga}1+\text{riga}2} \left[\begin{array}{ccc|c} -2 & 1 & 1 & -2 \\ 0 & 5/2 & 1/2 & -2 \\ 0 & 3/2 & 5/2 & 1 \end{array}\right] \xrightarrow{-(\frac{3}{5}\ \frac{3}{2})} \left[\begin{array}{ccc|c} -2 & 1 & 1 & -2 \\ 0 & 5/2 & 1/2 & -2 \\ 0 & 0 & 11/5 & 11/5 \end{array}\right]$

$\begin{cases} -2x_1 + x_2 + x_3 = -2 \to x_1 = 1 \\ \frac{5}{2}x_2 + \frac{1}{2}x_3 = -2 \to x_2 = -1 \\ \frac{11}{5}x_3 = \frac{11}{5} \to x_3 = 1 \end{cases}$ $\quad x = \begin{bmatrix} 1 \\ -1 \\ 1 \end{bmatrix}$

(ii) per casa: $\begin{bmatrix} 1 & -1 & 2 \\ -2 & 1 & 1 \\ -1 & 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 4 \\ 3 \\ 3 \end{bmatrix} \longrightarrow \left[\begin{array}{ccc|c} 1 & -1 & 2 & 4 \\ -2 & 1 & 1 & 3 \\ -1 & 0 & 0 & 3 \end{array}\right] \xrightarrow[\text{riga}3+\text{riga}1]{2\text{riga}1+\text{riga}2} \left[\begin{array}{ccc|c} 1 & -1 & 2 & 4 \\ 0 & -1 & 5 & 11 \\ 0 & -1 & 2 & 7 \end{array}\right] \xrightarrow{\text{riga}3-\text{riga}2} \left[\begin{array}{ccc|c} 1 & -1 & 2 & 4 \\ 0 & -1 & 5 & 11 \\ 0 & 0 & 3 & 8 \end{array}\right] \to \begin{cases} x_1 - x_2 + 2x_3 = 4 \to x_1 - \frac{7}{3} + \frac{16}{3} = 4 \to x_1 = 4 - \frac{16}{3} + \frac{7}{3} \to x_1 = 1 \\ -x_2 + 5x_3 = 11 \to -x_2 + \frac{40}{3} = 11 \to -x_2 = 11 - \frac{40}{3} \to x_2 = \frac{7}{3} \\ +3x_3 = 8 \to x_3 = \frac{8}{3} \end{cases}$ $\quad x = \begin{bmatrix} 1 \\ 7/3 \\ 8/3 \end{bmatrix}$

osservazione: le quantità $l_{ij} = \frac{a_{ij}^{(j)}}{a_{jj}^{(j)}}$ $i > j$, sono dette moltiplicatori, e per essere eseguito, l'algoritmo di Gauss, necessita della condizione $a_{jj}^{(j)} \neq 0$ $\forall j = 1, \dots, n-1$, con la convenzione che $a_{11}^{(1)} = a_{11}$

si può dimostrare che questa condizione è equivalente a chiedere che tutti i minori principali di testa di A siano $\neq 0$ per i minori di ordine $\leq n-1$

ovvero: $a_{11} \neq 0$, $\begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} \neq 0$, $\dots$, $\begin{vmatrix} a_{11} & \cdots & a_{1\,n-1} \\ \vdots & & \vdots \\ a_{n-1\,1} & \cdots & a_{n-1\,n-1} \end{vmatrix} \neq 0$

↳ se questa ipotesi non è verificata c'è un rimedio (prox. volta)

FATTORIZZAZIONE LU:

l'algoritmo di Gauss si può vedere come moltiplicare l'equazione $Ax = b$ per opportune matrici a sinistra

ad esempio, il 1° passo lo possiamo scrivere come: $\overbrace{\begin{bmatrix} 1 & & & \\ -l_{21} & 1 & & \\ \vdots & & \ddots & \\ -l_{n1} & & & 1 \end{bmatrix}}^{H_1} A \cdot x = \begin{bmatrix} 1 & & & \\ -l_{21} & 1 & & \\ \vdots & & \ddots & \\ -l_{n1} & & & 1 \end{bmatrix} b$

↳ ha zeri dappertutto tranne che sulla diagonale e sulla prima colonna

al passo j, quello che faccio è moltiplicare per $H_j = \begin{bmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ & & -l_{j+1\,j} & \ddots & \\ & & -l_{nj} & & 1 \end{bmatrix}$

tutto il procedimento di triangolarizzazione è perciò: $\underbrace{H_{n-1} \cdot H_{n-2} \cdot \dots \cdot H_1 \cdot A}_{U\ (\triangle)} x = \underbrace{H_{n-1} \cdot \dots \cdot H_1 b}_{c}$

proprietà: le matrici H_j (matrici elementari di Gauss)

- si scrivono $(I - N_j) = H_j$ $\quad N_j = \begin{bmatrix} 0 & & \\ & \ddots & \\ & l_{ij} & 0 \end{bmatrix}$ e $N_i \cdot N_j = 0$ $\forall i, j$ anche per $i = j$
- $H_j^{-1} = (I + N_j)$
- $H_1^{-1} \cdot \dots \cdot H_{n-1}^{-1} = (I + N_1 + \dots + N_{n-1})$

$U = H_{n-1} \cdot \dots \cdot H_1 \cdot A \Rightarrow \underbrace{H_1^{-1} \cdot \dots \cdot H_{n-1}^{-1}}_{L} \cdot U = A \longrightarrow A = LU = (\triangle) \cdot (\triangle)$ $\quad L = \begin{bmatrix} 1 & & & \\ l_{21} & 1 & & \\ \vdots & & \ddots & \\ l_{n1} & \cdots & l_{n\,n-1} & 1 \end{bmatrix}$

se uno conosce L ed U dal principio può risolvere Ax in due step:

$Ax = b \iff LUx = b \longrightarrow \begin{cases} Lc = b & \text{prima } O(n^2) \\ Ux = c & \text{dopo } O(n^2) \end{cases}$

portare la matrice in forma triangolare costa $O(\frac{2}{3}n^3)$

lezione 9 (25/03/2024)

25 March 2024 12:25

scorsa lezione: metodo di eliminazione di Gauss per risolvere $Ax=b$ $\quad A\in\mathbb{C}^{n\times n}$, $b\in\mathbb{C}^n$

↳ al passo j si cerca di annullare gli elementi in posizione $(j+1,j)\dots(n,j)$

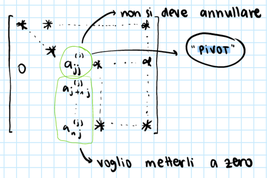

• possibili problemi se $a_{jj}^{(j)}=0$ oppure $a_{jj}^{(j)}\approx 0$ ⟹ per evitare questi casi (pivot piccoli rispetto agli altri elementi della colonna) si fa ricorso a delle matrici di permutazione (scambiando righe del sistema)

$a_{jj}^{(j)}=0$ → moltiplicatori $l_{ij}=\frac{a_{ij}^{(j)}}{a_{jj}^{(j)}}$ non risultano definiti

$a_{jj}^{(j)}\approx 0$ → moltiplicatori molto grandi in valore assoluto

Strategia di Pivoting

idea: al passo j scambio la riga j con la riga r, tale per cui si ha: $|a_{rj}^{(j)}|\geq \max_{i=j,j+1,\dots,n}|a_{ij}^{(j)}|$ ⟶ l'algoritmo con questa modifica si dice "eliminazione di Gauss con pivoting parziale (o per colonne)"

esempio:

$$A=\begin{bmatrix}1&2&3\\4&5&6\\7&8&0\end{bmatrix}\qquad b=\begin{bmatrix}1\\2\\3\end{bmatrix}$$

$$\left[\begin{array}{ccc|c}1&2&3&1\\4&5&6&2\\7&8&0&3\end{array}\right]\xrightarrow{1\leftrightarrow 3}\left[\begin{array}{ccc|c}7&8&0&3\\4&5&6&2\\1&2&3&1\end{array}\right]\xrightarrow[-\frac{1}{7}\text{riga}_1+\text{riga}_3]{-\frac{4}{7}\text{riga}_1+\text{riga}_2}\left[\begin{array}{ccc|c}7&8&0&3\\0&\frac{3}{7}&6&\frac{2}{7}\\0&\frac{6}{7}&3&\frac{6}{7}\end{array}\right]\xrightarrow{2\leftrightarrow 3}\left[\begin{array}{ccc|c}7&8&0&3\\0&\frac{6}{7}&3&\frac{6}{7}\\0&\frac{3}{7}&6&\frac{2}{7}\end{array}\right]\xrightarrow{-\frac{1}{2}\text{riga}_2+\text{riga}_3}\left[\begin{array}{ccc|c}7&8&0&3\\0&\frac{6}{7}&3&\frac{6}{7}\\0&0&\frac{9}{2}&0\end{array}\right]$$

(vedo che $6/7$ è il più grande, ripeto la riga al primo passo; $3/7$ più grande ⟶ scambio)

$$\Longrightarrow\begin{cases}7x_1+8x_2=3\longrightarrow 7x_1+8\cdot\frac{1}{3}=3\longrightarrow x_1=-\frac{1}{3}\\ \frac{6}{7}x_2+3x_3=\frac{6}{7}\longrightarrow x_2=\frac{1}{3}\\ \frac{9}{2}x_3=0\longrightarrow x_3=0\end{cases}\qquad x=\begin{bmatrix}-\frac{1}{3}\\\frac{1}{3}\\0\end{bmatrix}$$

osservazione: Gauss senza pivoting ⇝ $H_{n-1}\dots H_1Ax=H_{n-1}\dots H_1b$ ⟶ $A=LU$ (matrice triangolare superiore trovata in fondo all'algoritmo)

$H_j=\begin{bmatrix}1&&&\\&\ddots&&\\&&1&\\&&\vdots&\ddots\\&&-\ell_{n,j}&&1\end{bmatrix}=I-N_j$ con $N_j=\begin{bmatrix}0&&&\\&\ddots&&\\&&0&\\&&\ell_{j+1,j}&\ddots\\&&\vdots&&0\\&&\ell_{n,j}&&\end{bmatrix}$

$H_1^{-1}\dots H_{n-1}^{-1}=L=\begin{bmatrix}1&&&\\\ell_{21}&1&&\\\vdots&\ddots&\ddots&\\\ell_{n1}&\dots&\ell_{n,n-1}&1\end{bmatrix}$

fattorizzazione LU con pivoting parziale: ogni scambio di riga lo rappresentiamo con la moltiplicazione a sinistra per una matrice di permutazione

$A\to\Pi_1A\to H_1\Pi_1A\to\Pi_2H_1\Pi_1A\to\dots\to H_{n-1}\Pi_{n-1}\dots H_1\Pi_1A$ (un passo dell'algoritmo; Π_1A: scambio di righe; $H_1\Pi_1A$: seconda permutazione)

$H_{n-1}\Pi_{n-1}\dots H_1\Pi_1Ax=\underbrace{H_{n-1}\Pi_{n-1}\dots H_1\Pi_1b}_{c}$

$U=\begin{bmatrix}*&*&*\\&*&*\\0&&*\end{bmatrix}$

$U=H_{n-1}\Pi_{n-1}\dots H_1\Pi_1A$

proprietà: • $\Pi_jH_i=\Pi_j(I-N_i)=\underbrace{(I-\Pi_jN_i)}\Pi_j=\tilde{H}_i\Pi_j$ (matrice elementare di Gauss simile ad H_j, in cui si scambiano le righe secondo Π_j)

esempio:

$$A=\begin{bmatrix}1&2&3\\4&5&6\\7&8&0\end{bmatrix}\longrightarrow\begin{bmatrix}7&8&0\\4&5&6\\1&2&3\end{bmatrix}\longrightarrow\begin{bmatrix}7&8&0\\0&\frac{3}{7}&6\\0&\frac{6}{7}&3\end{bmatrix}\longrightarrow\begin{bmatrix}7&8&0\\0&\frac{6}{7}&3\\0&\frac{3}{7}&6\end{bmatrix}\longrightarrow\begin{bmatrix}7&8&0\\0&\frac{6}{7}&3\\0&0&\frac{9}{2}\end{bmatrix}=U=H_1\Pi_1H_1\Pi_1A=\underbrace{\tilde{H}_1\tilde{H}_1}_{L}\underbrace{\Pi_1\Pi_1}_{\Pi}A$$

Π_1A ($\Pi_1=\begin{bmatrix}0&0&1\\0&1&0\\1&0&0\end{bmatrix}$) $\quad H_1\Pi_1A$ $\quad\Pi_2H_1\Pi_1A$ ($\Pi_2=\begin{bmatrix}1&0&0\\0&0&1\\0&1&0\end{bmatrix}$) $\quad H_2\Pi_2H_1\Pi_1A$

$\Pi A=L\cdot U$, $L=\begin{bmatrix}1&&*&\ddots&*&*&1\end{bmatrix}$, $U=\begin{bmatrix}*&*&*\\&*&*\\&&*\end{bmatrix}$

osservazione: alla fine vogliamo scriverci una fattorizzazione del tipo $\Pi A=L\cdot U$; la U è quella trovata alla fine dell'algoritmo, la L si trova applicando gli scambi di righe agli elementi sottodiagonali di L, che avete trovato fino a quel dato passo

esempio:

$$\begin{bmatrix}1&2&3\\4&5&6\\7&8&0\end{bmatrix}\longrightarrow\begin{bmatrix}7&8&0\\4&5&6\\1&2&3\end{bmatrix}\longrightarrow\begin{bmatrix}7&8&0\\0&\frac{3}{7}&6\\0&\frac{6}{7}&3\end{bmatrix}\longrightarrow\begin{bmatrix}7&8&0\\0&\frac{6}{7}&3\\0&\frac{3}{7}&6\end{bmatrix}\longrightarrow\begin{bmatrix}7&8&0\\0&\frac{6}{7}&3\\0&0&\frac{9}{2}\end{bmatrix}=U$$

$L=\begin{bmatrix}1&&\\&1&\\&&1\end{bmatrix}\longrightarrow L=\begin{bmatrix}1&&\\1&1&\\&&1\end{bmatrix}\to L=\begin{bmatrix}1&&\\\frac{4}{7}&1&\\\frac{1}{7}&&1\end{bmatrix}\to L=\begin{bmatrix}1&0&0\\\frac{4}{7}&1&0\\\frac{1}{7}&0&1\end{bmatrix}\to L=\begin{bmatrix}1&0&0\\\frac{4}{7}&1&0\\\frac{1}{7}&\frac{1}{2}&1\end{bmatrix}$ *

$\Pi=\Pi_2\cdot\Pi_1$ possiamo calcolarla componendo le permutazioni fatte

$1\to 3\to 3$, $2\to 2\to 1$, $3\to 1\to 2$ (Π_1, Π_2) $\Longrightarrow\Pi=\begin{matrix}1\to 3\\2\to 1\\3\to 2\end{matrix}$ $\quad\Pi=\begin{bmatrix}0&0&1\\1&0&0\\0&1&0\end{bmatrix}$

fattorizzazione finale $\Pi A=L\cdot U$ *

(ii) per casa: trovare fattorizzazioni LU con e senza pivoting delle matrici

$$A=\begin{bmatrix}2&1&1\\2&2&0\\4&4&3\end{bmatrix}\qquad B=\begin{bmatrix}4&1&1&1\\-4&2&2&2\\4&-2&1&2\\0&3&0&0\end{bmatrix}$$

A con pivoting:

$$\begin{bmatrix}2&1&1\\2&2&0\\4&4&3\end{bmatrix}\to\begin{bmatrix}4&4&3\\2&2&0\\2&1&1\end{bmatrix}\to\begin{bmatrix}4&4&3\\0&0&\frac{3}{2}\\0&-1&\frac{1}{2}\end{bmatrix}\to\begin{bmatrix}4&4&3\\0&-1&\frac{1}{2}\\0&0&\frac{3}{2}\end{bmatrix}=U$$

$L=\begin{bmatrix}1&&\\&1&\\&&1\end{bmatrix}\to\begin{bmatrix}1&&\\&1&\\\frac{1}{2}&&1\end{bmatrix}\to\begin{bmatrix}1&&\\\frac{1}{2}&1&\\\frac{1}{2}&&1\end{bmatrix}\to\begin{bmatrix}1&&\\\frac{1}{2}&1&\\\frac{1}{2}&-1&1\end{bmatrix}=L$??

```
L =
    0.5000    1.0000         0
    0.5000         0    1.0000
    1.0000         0         0

U =
    4.0000    4.0000    3.0000
         0   -1.0000   -0.5000
         0         0   -1.5000
```

$1\to 3\to 3$, $2\to 2\to 1$, $3\to 1\to 2$ (Π_1, Π_2) $\quad\Pi=\begin{matrix}1\to 3\\2\to 1\\3\to 2\end{matrix}$ $\quad\Pi=\begin{bmatrix}0&0&1\\1&0&0\\0&1&0\end{bmatrix}$

calcolo del determinante: una conseguenza del teorema di binet-cauchy è che se $A=LU$ allora $\det(A)=\underbrace{\det(L)}_{1}\cdot\det(U)=\det(U)=\prod_{i=1}^{n}U_{ii}$ ⟹ possiamo calcolare $\det(A)$ con un costo pari all'eliminazione di Gauss $O(\frac{2}{3}n^3)$ (↳ coincide con il prodotto dei pivot nell'algoritmo)

nel caso si faccia LU con pivoting parziale $\det(\Pi)\det(A)=\det(\Pi A)=\det(L)\det(U)=\det(U)$ ⟹ per cui: $\det(A)=\det(U)\cdot(-1)^s$

↳ $\det(\Pi)=(-1)^s$ s = numero di scambi di righe fatti nell'algoritmo

condizionamento di un sistema lineare: $Ax=b$

$f:(A,b)\to x$

supponiamo di voler risolvere $Ax=b$, ma a causa di errori nei dati in realtà troviamo $x+\delta x$ (↳ errore) che risolve esattamente $(A+\delta A)(x+\delta x)=b+\delta b$

assumendo che δA e δb siano relativamente piccole, posso concludere che anche δx è (relativamente) piccolo? IN GENERALE NO!

esempi: $\delta A=0$

$$\begin{bmatrix}1&-1\\1&-1,0000_1\end{bmatrix}\begin{bmatrix}x_1\\x_2\end{bmatrix}=\begin{bmatrix}1\\1\end{bmatrix}\Longrightarrow x=\begin{bmatrix}1\\0\end{bmatrix}$$

$$\begin{bmatrix}1&-1\\1&-1,000001\end{bmatrix}\begin{bmatrix}x_1\\x_2\end{bmatrix}=\begin{bmatrix}0,999999\\1\end{bmatrix}\Longrightarrow x=\begin{bmatrix}-10^6\\-1\end{bmatrix}$$

$\delta A\neq 0$

$$\begin{bmatrix}3&4\\3&4,0000_1\end{bmatrix}\begin{bmatrix}x_1\\x_2\end{bmatrix}=\begin{bmatrix}7\\7,0000_1\end{bmatrix}\Longrightarrow x=\begin{bmatrix}1\\1\end{bmatrix}$$

$$\begin{bmatrix}3&4\\3&3,99999\end{bmatrix}\begin{bmatrix}x_1\\x_2\end{bmatrix}=\begin{bmatrix}7\\7,000014\end{bmatrix}\Longrightarrow x=\begin{bmatrix}\frac{25}{3}\\-4\end{bmatrix}$$

in entrambi i casi perturbazioni $10^{-5},10^{-6}$ su A e b che davano perturbazioni δx dell'ordine dell'unità

domanda: da cosa dipendono $\|\delta x\|$ e $\frac{\|\delta x\|}{\|x\|}$ ⟶ cerchiamo di limitarle dall'alto

assumiamo $\delta A=0$, $\det(A)\neq 0$ allora si ha: $A(x+\delta x)=b+\delta b\Longrightarrow A\delta x=\delta b\Longrightarrow\delta x=A^{-1}\delta b\Longrightarrow\|\delta x\|\leq\|A^{-1}\|\cdot\|\delta b\|$ (maggiorazione norma errore assoluto)

($Ax=b$ ↳ lo sottraiamo)

per l'errore relativo $\frac{\|\delta x\|}{\|x\|}$ ci serve una stima dal basso per $\|x\|$: $b=Ax\Longrightarrow\|b\|\leq\|A\|\cdot\|x\|\Longrightarrow\|x\|\geq\frac{\|b\|}{\|A\|}\Longrightarrow\frac{\|\delta x\|}{\|x\|}\leq\frac{\|A^{-1}\|\cdot\|\delta b\|\cdot\|A\|}{\|b\|}=\underbrace{\|A\|\cdot\|A^{-1}\|}\cdot\frac{\|\delta b\|}{\|b\|}$ (↳ errore relativo sul termine noto (quantità che mi aspetto sia piccola))

definizione: la quantità $\mu(A):=\|A\|\cdot\|A^{-1}\|$ (mu) si dice "numero di condizionamento" della matrice A rispetto alla norma $\|\cdot\|$

osservazione: $\mu(A)\geq 1\quad\forall A$ e $\forall\|\cdot\|$

$\|A\|\cdot\|A^{-1}\|\geq\|A\cdot A^{-1}\|=\|I\|\geq f(I)=1$

definizione: un sistema lineare si dice "mal condizionato" (HIRSCH) se $\mu(A)\gg 1$ (molto maggiore)

si dice "ben condizionato" se $\mu(A)\approx 1$

osservazione: se abbiamo t cifre significative (in base 10) sul termine noto, quando risolvo il sistema lineare, ho $t-\log_{10}(\mu(A))$ cifre significative su x

osservazione: la stima trovata $\frac{\|\delta x\|}{\|x\|}\leq\mu(A)\frac{\|\delta b\|}{\|b\|}$ è al caso pessimo, per una scelta specifica di δb le cose possono andare meglio

caso $\delta A\neq 0$

↳ teorema: se A e $A+\delta A$ sono non singolari (invertibili), allora vale $\frac{\|\delta x\|}{\|x\|}\leq\frac{\mu(A)}{1-\mu(A)\frac{\|\delta A\|}{\|A\|}}\cdot\left(\frac{\|\delta A\|}{\|A\|}+\frac{\|\delta b\|}{\|b\|}\right)$

osservazione: avere accesso a $\mu(A)$ non è facile, spesso si usano delle stime, oppure si possono fare delle stime a posteriori *

* stime a posteriori: supponiamo di aver trovato $\tilde{x}$ approssimazione di x, che verifica $Ax=b$, allora consideriamo:

* $b-A\tilde{x}=:r$ "vettore residuo"

↳ quando $x=\tilde{x}$ ⇝ $r=0$

sottraendo $Ax=b$ da * si ottiene: $A(\tilde{x}-x)=-r\Longrightarrow\tilde{x}-x=-A^{-1}r\Longrightarrow\|\tilde{x}-x\|\leq\|A^{-1}\|\cdot\|r\|$ ⟹ (usando $\|x\|\geq\frac{\|b\|}{\|A\|}$ si ottiene) $\frac{\|\tilde{x}-x\|}{\|x\|}\leq\mu(A)\cdot\frac{\|r\|}{\|b\|}$ ⟶ anche se il residuo è piccolo, la distanza dalla soluzione può essere grande, dipende dal condizionamento di A

esempio: se $A\in\mathbb{C}^{n\times n}$ è una matrice hermitiana, il numero di condizionamento in norma 2 si può riscrivere in termini degli autovalori: $\mu(A)=\|A\|_2\|A^{-1}\|_2=$ (↳ vale perché A hermitiana ed A^{-1} hermitiana) $\rho(A)\cdot\rho(A^{-1})=\max_{i=1,\dots,n}|\lambda_i|\cdot\max_{i=1,\dots,n}|\lambda_i^{-1}|=\frac{\max_{i=1,\dots,n}|\lambda_i|}{\min_{i=1,\dots,n}|\lambda_i|}$

lezione 10 (05/04/2024)

05 April 2024 23:06

l'ultima volta: $Ax=b$, $A\in\mathbb{C}^{n\times n}$, $b\in\mathbb{C}^n$

$\delta A, \delta b$ perturbazioni (sulla matrice o termine noto) $(A+\delta A)(x+\delta x)=b+\delta b$ ($Ax=b$)

$$\frac{\|\delta x\|}{\|x\|} \le \frac{\mathcal{N}(A)}{1-\mathcal{N}(A)\cdot\frac{\|\delta A\|}{\|A\|}}\cdot\left(\frac{\|\delta A\|}{\|A\|}+\frac{\|\delta b\|}{\|b\|}\right)$$ errore inerente

$\mathcal{N}(A)=\|A\|\cdot\|A^{-1}\|$

errore algoritmico nell'eliminazione di Gauss → pivoting: strategia per mitigare l'errore
↳ dipende dai moltiplicatori $\ell_{ij}=\frac{a_{ij}^{(i)}}{a_{ii}^{(i)}}$ → se $|\ell_{ij}|$ è grande (in senso relativo) allora errore algoritmico grande → la strategia di pivoting parziale serve a tenere sotto controllo l'errore algoritmico

REGOLA FONDAMENTALE DELL'ALGEBRA COMPUTAZIONALE:

per risolvere $Ax=b$ mai fare $A^{-1}\cdot b$ → più instabile dell'eliminazione di Gauss e costa di più
- trovarsi A^{-1} costa circa il doppio della fattorizzazione LU ($O(\frac{4}{3}n^3)$)
- in particolare su Matlab: `inv(A)*b` NO; `A\b` SI
- quando vediamo la descrizione di un algoritmo e vediamo dei passaggi della forma $A^{-1}b$, $A^{-1}B$ ($B\in\mathbb{C}^{n\times s}$) dobbiamo pensarli nell'implementazione come: sto risolvendo $Ax=b$, sto risolvendo $Ax=b^{(j)}$ $j=1,\dots,s$, $B=\left[b^{(1)}|\dots|b^{(s)}\right]$

⇑ **METODI DIRETTI**

- l'inversa di A [inv(A)] si usa quando serve A^{-1} da sola, non moltiplicata a sinistra o destra per altre cose (matrici)

METODI ITERATIVI per $Ax=b$

idea: generare una successione del tipo $x^{(k+1)}=Hx^{(k)}+c$ ("al passo successivo" = matrice · "al passo precedente" + vettore) dove moltiplicare per H è conveniente, almeno meglio di $O(n^2)$
- inoltre si deve arrivare vicino alla soluzione vera $x^{(\kappa)}\simeq x$ per un κ "piccolo"

=> si prova a riscrivere il problema come un problema di punto fisso, ovvero:

$Ax=b \iff x=Hx+c$

① come si trova $x=Hx+c$? → problema di punto fisso equivalente al sistema lineare

② il metodo associato $\begin{cases}x^{(0)} \text{ dato/generato casualmente}\\ x^{(k+1)}=Hx^{(k)}+c\end{cases}$ converge?

① • possibile strategia: $A=A_1+A_2$ con A_1 "facile da invertire"

$Ax=b \iff (A_1+A_2)x=b \iff A_1x=b-A_2x \iff x=\underbrace{-A_1^{-1}A_2}_{H}x+\underbrace{A_1^{-1}b}_{c}$

esempi: $A_1=\text{DIAG}(a_{11},\dots,a_{nn})=\begin{bmatrix}a_{11}&&0\\&\ddots&\\0&&a_{nn}\end{bmatrix}$ Jacobi

$A_1=\text{TRIL}(A)=\begin{bmatrix}a_{11}&&0\\\vdots&\ddots&\\a_{n1}&\cdots&a_{nn}\end{bmatrix}$ Gauss-Seidel

- altro modo: selezionare G matrice invertibile e scrivere

$Ax=b \iff x=x-G(Ax-b) \iff x=\underbrace{(I-GA)}_{H}x+\underbrace{Gb}_{c}$

② definizione: un metodo iterativo (di punto fisso) per $Ax=b$

$(*)\begin{cases}x^{(0)} \text{ dato}\\ x^{(k+1)}=Hx^{(k)}+c\end{cases}$ si dice convergente se $\lim_{k\to+\infty}x^{(k)}=x$ $\forall\, x^{(0)}\in\mathbb{C}^n$ (non importa dove partiamo, al limite bisogna sempre andare a x)

teorema: il metodo (*) è convergente $\iff \rho(H)<1$ (raggio spettrale)
↳ H è una matrice convergente

dimostrazione: $x=(Hx+c)$

$e^{(k+1)}\leftarrow x^{(k+1)}-x=Hx^{(k)}-x+c=Hx^{(k)}-Hx-\cancel{x}+\cancel{x}=\underbrace{H(x^{(k)}-x)}_{e^{(k)}}$ ⇝ $e^{(k+1)}=He^{(k)}=H^2e^{(k-1)}=\dots=H^ke^{(0)}$

↳ errore al passo k+1 = errore al passo precedente moltiplicato per H

$\lim_{k\to+\infty}e^{(k)}=\lim_{k\to+\infty}H^k\overset{0}{e^{(0)}}=0 \implies \lim_{k\to+\infty}x^{(k)}=x$

osservazione: se $\|H\|<1$ per una qualsiasi norma matriciale allora (*) è convergente → condizione sufficiente, ma non necessaria

se $|\det(H)|>1$ allora (*) non è convergente

$|\det(H)|<1$ è condizione necessaria alla convergenza, ma non è sufficiente

velocità di convergenza: dal teorema visto sopra sappiamo che $\frac{\|e^{(k)}\|}{\|e^{(0)}\|}\le\|H^k\|$ ($e^{(k)}=H^ke^{(0)}$)

inoltre, per un risultato di algebra lineare sappiamo che $\lim_{k\to+\infty}\sqrt[k]{\|H^k\|}=\rho(H) \implies \|H^k\|\simeq\rho(H)^k$

=> quindi se ho 2 metodi iterativi con matrici di iterazione H_1 e H_2 tali che $\rho(H_1)<\rho(H_2)$, allora ci aspettiamo che il più veloce a convergere sia il 1° metodo (H_1)
inoltre, come stima (non rigorosa) del numero di iterazioni che servono a ottenere $\|e^{(k)}\|\le\delta$ (es: $\delta=10^{-t}$) possiamo imporne la condizione

$\rho(H)^k\le\delta \implies k\log(\rho(H))\le\log(\delta)$

$\implies k\ge\frac{\log(\delta)}{\log(\rho(H))}$

esempio: $\delta=10^{-8}$ $k\ge\frac{\log_{10}(10^{-8})}{\log_{10}(\rho(H))}=-\frac{8}{\underbrace{\log_{10}(\rho(H))}_{\le 0}}$ → (numero positivo iterazioni)

criteri d'arresto:
- scegliere k iterazioni a priori se si conosce $\rho(H)$
- controllare il residuo $\frac{\|r^{(k)}\|}{\|b\|}=\frac{\|b-Ax^{(k)}\|}{\|b\|}\le\text{TOLLERANZA}=\delta>0$ → costo $O(n^2)$ (matrice · vettore)
- $\|x^{(k+1)}-x^{(k)}\|<\delta$ differenza fra due iterate piccola → costo $O(n)$

motivazione ulteriore per usare un metodo iterativo: se avete n molto grande e A molto sparsa (ci sono solo $O(n)$ entrate $\neq 0$) potete memorizzare A, ma non i fattori L ed U della fattorizzazione LU non sono sparsi quindi Gauss non è applicabile, ma Jacobi e Gauss-Seidel si

METODI DI JACOBI E GAUSS-SEIDEL:

$A=D-E-F$ $D=\text{DIAG}(a_{11},\dots,a_{nn})$

$E=\begin{bmatrix}0&&0\\-a_{21}&\ddots&\\\vdots&\ddots&0\\-a_{n1}&\cdots&-a_{n,n-1}\end{bmatrix}$, $F=\begin{bmatrix}0&-a_{12}&\cdots&-a_{1n}\\&\ddots&\ddots&\vdots\\&&\ddots&-a_{n-1,n}\\0&&&0\end{bmatrix}$

nel metodo di Jacobi:

$\begin{cases}x^{(k+1)}=\underbrace{D^{-1}(E+F)}_{H_J}x^{(k)}+\underbrace{D^{-1}b}_{c_J}\\ x^{(0)}=\text{random/scelto}\end{cases}$

osservazione: condizione necessaria per Jacobi è che A non abbia zeri sulla diagonale

$H_J=\begin{bmatrix}\frac{1}{a_{11}}&&\\&\ddots&\\&&\frac{1}{a_{nn}}\end{bmatrix}\cdot\begin{bmatrix}0&\cdots&a_{1j}&\cdots\\\vdots&&\vdots&\\a_{i1}&\cdots&0&\cdots\\\vdots&&\vdots&\end{bmatrix}=\begin{bmatrix}0&\frac{a_{12}}{a_{11}}&\cdots&\frac{a_{1n}}{a_{11}}\\\frac{a_{21}}{a_{22}}&0&\cdots&\frac{a_{2n}}{a_{22}}\\\vdots&&\ddots&\vdots\\\frac{a_{n1}}{a_{nn}}&\cdots&\frac{a_{n,n-1}}{a_{nn}}&0\end{bmatrix}$ (D^{-1})

$H_J=\begin{cases}\frac{a_{ij}}{a_{ii}} & \text{se } i\neq j\\ 0 & \text{se } i=j\end{cases}$

le equazioni del passo di Jacobi (modo in cui si aggiorna il vettore $x^{(k)}$) sono $x_i^{(k+1)}=\frac{1}{a_{ii}}\left(b_i-\sum_{\substack{j=1\\j\neq i}}^{n}a_{ij}\cdot x_j^{(k)}\right)$

osservazione: non si può sovrascrivere (cancellare) nessuna componente del vettore al passo precedente ($x^{(k)}$) finché non ho calcolato tutte le entrate del vettore al passo successivo ($x^{(k+1)}$)

nel metodo di Gauss-Seidel:

$\underbrace{(D-E-F)}_{A}x=b \iff (D-E)x=Fx+b$

$x=(D-E)^{-1}Fx+(D-E)^{-1}b$

→ permette di sovrascrivere le componenti di $x^{(k)}$ mentre si calcola (se manipolato)

$x^{(k+1)}=(D-E)^{-1}Fx^{(k)}+(D-E)^{-1}b$ → moltiplico per $(D-E)$

$(D-E)x^{(k+1)}=Fx^{(k)}+b \iff Dx^{(k+1)}=Ex^{(k+1)}+Fx^{(k)}+b$ → moltiplico per D^{-1}

$x^{(k+1)}=D^{-1}Ex^{(k+1)}+D^{-1}Fx^{(k)}+D^{-1}b$ → se ci andiamo a scrivere componente per componente questa relazione otteniamo: $x_i^{(k+1)}=\frac{1}{a_{ii}}\left(b_i-\sum_{j=1}^{i-1}a_{ij}x_j^{(k+1)}-\sum_{j=i+1}^{n}a_{ij}x_j^{(k)}\right)$ $i=1,\dots,n$

$\begin{cases}x^{(k+1)}=\underbrace{(D-E)^{-1}F}_{H_{GS}}x^{(k)}+\underbrace{(D-E)^{-1}b}_{c_{GS}} \longrightarrow x^{(k+1)}=H_{GS}x^{(k)}+c_{GS}\\ x^{(0)}=\text{random/dato}\end{cases}$

osservazione: quando calcolo $(D-E)^{-1}Fx^{(k)}$
① calcolo $Fx^{(k)}=y$ → $O(n^2)$ perché prodotto matrice vettore
② risolvo $(D-E)z=y$ → $O(n^2)$ perché sistema triangolare
↳ z è il risultato dell'operazione $(D-E)^{-1}Fx^{(k)}$

Jacobi: $O(n^2)$; $O(n)$ → matrice diagonale

osservazione: a differenza di Jacobi posso sovrascrivere $x^{(k)}$

osservazione: anche per Gauss-Seidel c'è bisogno di $a_{ii}\neq 0$ $\forall i=1,\dots,n$

teorema: $A\in\mathbb{C}^{n\times n}$, se soddisfa una di queste 2 condizioni (i) A a predominanza diagonale forte
(ii) A irriducibile e a predominanza diagonale debole

allora sia Jacobi che Gauss-Seidel per un sistema lineare $Ax=b$, risultano convergenti

dimostrazione: Jacobi dobbiamo far vedere che $\rho(H_J)<1$

nel caso (i) $H_J=\begin{cases}\frac{a_{ij}}{a_{ii}} & \text{se } i\neq j\\ 0 & \text{se } i=j\end{cases}$

$\|H_J\|_\infty=\max_{i=1,\dots,n}\sum_{\substack{j=1\\j\neq i}}^{n}\left|\frac{a_{ij}}{a_{ii}}\right|=\max_{i=1,\dots,n}\left(\sum_{i\neq j}^{n}\frac{|a_{ij}|}{|a_{ii}|}\right)<1 \implies 1>\|H_J\|_\infty\ge\rho(H_J)\implies H_J \text{ convergente}$

(matrice a predominanza diagonale forte → <1; massimo della somma sulle righe)

nel caso (ii) $\|H_J\|_\infty\le 1$, però sappiamo che ∃ almeno un cerchio di Gershgorin in H_J che ha raggio <1 → quindi se guardiamo i cerchi di Gershgorin di H_J, questi hanno tutti centro in zero e ce n'è almeno uno con raggio <1 e tutti gli altri con raggio ≤ 1

A irriducibile $\implies$ (H_J irriducibile, implica che anche) $\implies$ (per il 5° teorema di Gershgorin) se ho un autovalore sul bordo dell'unione dei cerchi, deve stare sul bordo di ogni cerchio $\implies$ non ci sono autovalori di modulo 1, ed in particolare sono tutti minori di 1 $\implies \rho(H_J)<1$

osservazione: le assunzioni (i) e (ii) implicano che $a_{ii}\neq 0$ $\forall i=1,\dots,n$

lezione 11 (08/04/2024)

09 April 2024 16:04

riassunto: metodi iterativi per $Ax=b$ $\rightsquigarrow$ genero $\{x_k\}_{k=1,2,\dots}$ tale che $\lim_{k\to+\infty} x_k = x$

$Ax=b \iff Hx+c=x \rightsquigarrow \begin{cases} x^{(0)} \\ x^{(k+1)} = Hx^{(k)}+c \end{cases}$

funziona (per ogni scelta di $x^{(0)}$) se e solo se $\rho(H)<1$

abbiamo visto un paio di scelte possibili per H : (i) Gauss-Seidel $\rightsquigarrow H=(D-E)^{-1}F$ $\quad A=\begin{bmatrix} D & F \\ E & D \end{bmatrix}$ $\quad A=D-E-F$

(ii) Jacobi $\rightsquigarrow H=D^{-1}(E+F)$

teorema: se $A\in\mathbb{C}^{n\times n}$ è tale per cui: (i) A è a predominanza diagonale forte

(ii) A è irriducibile e a predominanza diagonale debole

allora, $\forall b\in\mathbb{C}^n$ i metodi di Jacobi e Gauss-Seidel sono applicabili e forniscono successioni convergenti

dimostrazione: Gauss-Seidel

supponiamo per assurdo che $H_{GS}=(D-E)^{-1}F$ abbia un autovalore $\lambda\in\mathbb{C}$ tale che $|\lambda|\geq 1$, allora:

$0=\det(\lambda I-H_{GS})=\det(\lambda I-(D-E)^{-1}F)=\det((D-E)^{-1}\cdot[\lambda(D-E)-F])=\det(D-E)^{-1}\cdot\det(\lambda(D-E)-F)=\underbrace{\frac{\det(D-E)}{\neq 0}}^{-1}\cdot\underbrace{\det(\lambda D-\lambda E-F)}_{\neq 0} \implies 0=\det(D-E-\lambda^{-1}F)$ (*)

↘ dimostriamo che è un assurdo

$M_\lambda = D-E-\lambda^{-1}F = \begin{bmatrix} a_{11} & \frac{a_{12}}{\lambda} & \cdots & \frac{a_{1n}}{\lambda} \\ \frac{a_{21}}{\lambda} & a_{22} & \cdots & \frac{a_{2n}}{\lambda} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{a_{n1}}{\lambda} & \frac{a_{n2}}{\lambda} & \cdots & a_{nn} \end{bmatrix}$

se guardiamo i cerchi di Gershgorin di M_λ questi hanno gli stessi centri di quelli di A e raggi minori o uguali

in particolare: A dominante diagonale forte $\implies M_\lambda$ dominante diagonale forte

A dominante diagonale debole $\implies M_\lambda$ dominante diagonale debole

A irriducibile $\implies M_\lambda$ irriducibile (gli zeri della matrice sono nelle stesse posizioni)

quindi M_λ è non singolare per i teoremi di Gershgorin, e questo contraddice (*) $\implies H_{GS}$ non ha autovalori di modulo ≥ 1

teorema: se $A\in\mathbb{C}^{n\times n}$ è tridiagonale ($a_{ij}=0\ \ \forall(i,j)$ tale che $|i-j|>1$)

$A=\begin{bmatrix} \diagdown\!\diagdown & & 0 \\ & \diagdown\!\diagdown & \\ 0 & & \diagdown\!\diagdown \end{bmatrix}$

allora: $\rho(H_{GS})=\rho(H_J)^2$

in particolare i metodi convergono entrambi o divergono entrambi

osservazione: nel caso tridiagonale, se entrambi i metodi convergono, Gauss-Seidel è più veloce

esercizio: determinare i valori di α per cui il metodo di Jacobi converge

$A=\begin{bmatrix} 1 & \alpha & \alpha \\ \alpha & 1 & \alpha \\ \alpha & \alpha & 1 \end{bmatrix} \quad \alpha\in\mathbb{C}$

- cercare di trovare gli autovalori di A come funzioni di α

$H_J=D^{-1}(E+F)=\begin{bmatrix} 1 & & \\ & 1 & \\ & & 1 \end{bmatrix}^{-1}\cdot\begin{bmatrix} 0 & -\alpha & -\alpha \\ -\alpha & 0 & -\alpha \\ -\alpha & -\alpha & 0 \end{bmatrix}=\begin{bmatrix} 0 & -\alpha & -\alpha \\ -\alpha & 0 & -\alpha \\ -\alpha & -\alpha & 0 \end{bmatrix}$

$H_J=\begin{bmatrix} \alpha & \alpha & \alpha \\ \alpha & \alpha & \alpha \\ \alpha & \alpha & \alpha \end{bmatrix}+\begin{bmatrix} -\alpha & & \\ & -\alpha & \\ & & -\alpha \end{bmatrix}$ $\implies$ autovalori di H_J sono della forma $\lambda+\alpha$ con λ autovalore di $\begin{bmatrix} -\alpha & -\alpha & -\alpha \\ -\alpha & -\alpha & -\alpha \\ -\alpha & -\alpha & -\alpha \end{bmatrix}$ ($\alpha-1$)

$-\alpha\begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}\rightsquigarrow$ autovalori $=\begin{cases} \text{traccia}=3 \\ 0 \text{ con molteplicità } 2 \end{cases}$

↘ perché n numero di autovalori $\neq 0$

in conclusione gli autovalori di H_J sono: $\begin{cases} \alpha+(-\alpha)\cdot 3=-2\alpha \\ \alpha+(-\alpha)\cdot 0=\alpha \end{cases} \longrightarrow \rho(H_J)<1 \iff \begin{cases} |-2\alpha|<1 \\ |\alpha|<1 \end{cases} \iff \begin{cases} |\alpha|<\frac{1}{2} \\ |\alpha|<1 \end{cases} \iff$ Jacobi è convergente se e solo se $|\alpha|<\frac{1}{2}$

X casa: fare il caso Gauss-Seidel

esercizio: $A=\begin{bmatrix} 2 & 0 & 0 & \alpha \\ 1 & 2 & 0 & 0 \\ 0 & 1 & 2 & 0 \\ 0 & 0 & 1 & 2 \end{bmatrix}$ trovare gli $\alpha\in\mathbb{C}$ per cui Gauss-Seidel converge

dobbiamo studiare gli autovalori di $H_{GS}=(D-E)^{-1}F$

$H_{GS}=\begin{bmatrix} 2 & & & \\ 1 & 2 & & \\ & 1 & 2 & \\ & & 1 & 2 \end{bmatrix}^{-1}\cdot\begin{bmatrix} 0 & 0 & 0 & -\alpha \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}=\begin{bmatrix} 0 & 0 & 0 & \alpha \\ 0 & 0 & 0 & -\frac{\alpha}{2} \\ 0 & 0 & 0 & \frac{\alpha}{4} \\ 0 & 0 & 0 & -\frac{\alpha}{8} \end{bmatrix}$

↘ per trovare $\begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$ risolvo $\begin{bmatrix} 2 & & & \\ 1 & 2 & & \\ & 1 & 2 & \\ & & 1 & 2 \end{bmatrix}x=\begin{bmatrix} -\alpha \\ 0 \\ 0 \\ 0 \end{bmatrix} \iff \begin{cases} 2x_1-\alpha=0 \\ x_1+2x_2=0 \\ x_2+2x_3=0 \\ x_3+2x_4=0 \end{cases} \rightsquigarrow x=\begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix}=\begin{bmatrix} -\frac{\alpha}{2} \\ \frac{\alpha}{4} \\ -\frac{\alpha}{8} \\ \frac{\alpha}{16} \end{bmatrix} \implies H_{GS}=\begin{bmatrix} 0 & 0 & 0 & -\frac{\alpha}{2} \\ 0 & 0 & 0 & \frac{\alpha}{4} \\ 0 & 0 & 0 & -\frac{\alpha}{8} \\ 0 & 0 & 0 & \frac{\alpha}{16} \end{bmatrix}$ → gli autovalori di H_{GS} sono i suoi elementi diagonali perché è triangolare superiore

↘ sono 0 e $\frac{\alpha}{16}$ quindi, affinché $\rho(H_{GS})<1$ serve $|\alpha|<16$

X casa: fare il caso Jacobi

Sistemi lineari sovradeterminati

$Ax=b$

$A\in\mathbb{C}^{m\times n}$ (m equazioni, n incognite, $m\geq n$)

$b\in\mathbb{C}^m$

RANGO$(A)=n$ (rango massimo)

- si può provare ad applicare l'eliminazione di Gauss con pivoting e, dopo n passi si arriva ad una situazione del tipo: $\begin{matrix} \\ \\ \\ \\ m-n \text{ righe} \end{matrix}\begin{bmatrix} * & \cdots & * \\ 0 & \ddots & \vdots \\ \vdots & \ddots & * \\ 0 & \cdots & 0 \\ \vdots & & \vdots \\ 0 & \cdots & 0 \end{bmatrix}\begin{matrix} \\ \\ \\ \\ n \text{ righe} \end{matrix}\begin{bmatrix} * \\ \vdots \\ * \\ ? \\ \vdots \\ ? \end{bmatrix}$ se esiste anche un solo $?\neq 0$ allora non c'è soluzione

se invece $?=0$, allora si risolve il sistema quadrato $\begin{bmatrix} * & \cdots & * \\ & \ddots & \\ 0 & & * \end{bmatrix}x=\begin{bmatrix} * \\ \vdots \\ * \end{bmatrix}$ associato alle prime n righe

problema: molto spesso la soluzione non esiste, ovvero RANGO$(A|b)>$ RANGO(A) (Rouché-Capelli)

talvolta è di interesse cercare di rendere piccolo il vettore residuo $r(x)=b-Ax$, più formalmente si sostituisce il problema $Ax=b$ con il problema di ottimizzazione: $\min_{x\in\mathbb{C}^n}\|r(x)\|_2=\min_{x\in\mathbb{C}^n}\|b-Ax\|_2$ $\rightsquigarrow$ indichiamo con x^* il punto di minimo di (P)

↘ come si trova x^*? ci restringiamo al caso $A\in\mathbb{R}^{m\times n}$ e $b\in\mathbb{R}^m$, per cui il nostro problema è $\min_{x\in\mathbb{R}^n}\|Ax-b\|_2$

$\|b-Ax\|_2=\sqrt{\sum_{i=1}^m r_i(x)^2}$

- prima semplificazione: cerco il minimo di $\|b-Ax\|_2^2$

$\Psi(x)=\|b-Ax\|_2^2=(b-Ax)^T(b-Ax) : \mathbb{R}^n\to\mathbb{R}$

funzione convessa $\implies$ il suo punto di minimo x^* verifica $\nabla\Psi(x^*)=\begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}$ ← gradiente $\nabla\Psi(x)=\begin{bmatrix} \frac{\partial\Psi}{\partial x_1} \\ \vdots \\ \frac{\partial\Psi}{\partial x_n} \end{bmatrix}$

- $r(x)=b-Ax=\begin{bmatrix} r_1(x) \\ \vdots \\ r_m(x) \end{bmatrix}$

$[r_i(x)]^2=\left[b_i-\sum_{j=1}^n a_{ij}x_j\right]^2$

$\frac{\partial r_i^2(x)}{\partial x_j}=2\left[b_i-\sum_{j=1}^n a_{ij}x_j\right](-a_{ij})=2\left[\sum_{j=1}^n a_{ij}a_{ij}x_j-b_ia_{ij}\right]$

$\frac{\partial\Psi(x)}{\partial x_j}=2\left[\sum_{i=1}^m\sum_{j=1}^n a_{ij}a_{ij}x_j-\sum_{i=1}^m b_ia_{ij}\right]=2((A^TAx)_j-(A^Tb)_j) \implies \nabla\Psi(x)=2(A^TAx-A^Tb)$

osservazione: $\sum_{i=1}^m b_ia_{ij}=$ [riga $1\times m$ di A^T: $a_{1j}\ \cdots\ a_{mj}$] [colonna $m\times 1$ di b] $=(A^Tb)_j$

↘ colonna j di A

$\sum_{i=1}^n a_{ij}\sum_{j=1}^n a_{ij}x_j=\sum_{i=1}^n a_{ij}(Ax)_i=(A^TAx)_j$

in definitiva, abbiamo trovato che

$\nabla\Psi(x)=0 \iff A^TAx-A^Tb=0 \iff A^TAx=A^Tb$

↘ sistema lineare quadrato di dimensione $n\times n$

per cui, per trovare x^* ci basta risolvere un sistema lineare quadrato

definizione: il sistema $A^TAx=A^Tb$ prende il nome di sistema delle equazioni normali

osservazione: si ottiene da $Ax=b$ semplicemente moltiplicando a sinistra per A^T

definizione: il problema (P): $\min_{x\in\mathbb{R}^n}\|b-Ax\|_2$ viene detto problema lineare ai minimi quadrati

teorema: $A\in\mathbb{R}^{m\times n}$, $m\geq n$, il sistema $A^TAx=A^Tb$ ammette soluzione $\forall b\in\mathbb{R}^m$. la soluzione è unica se e solo se RANGO$(A)=n$

dimostrazione: per l'esistenza dobbiamo far vedere che $A^Tb\in I_m(A^TA)$

$I_m(A^TA)=\{y\in\mathbb{R}^n : y=A^Tx \text{ per un qualche } x\in\mathbb{R}^n\}$

poniamo decomporre $\mathbb{R}^n$ come $\mathbb{R}^n=I_m(A)\oplus I_m(A)^\perp$ $\longrightarrow$ ovvero possiamo scrivere $b=b_\parallel+b_\perp$ ($b_\parallel\in I_m(A)$, $b_\perp\in I_m(A)^\perp$)

- $I_m(A)=\{y=Ax\}$
- $I_m(A)^\perp=\{y : y^Tz=0 \ \ \forall z\in I_m(A)\}$ ↘ colonne di A

F/M

$A^Tb=\underbrace{A^Tb_\parallel}_{A^T(Ax)\in I_m(A^TA)}+\underbrace{A^Tb_\perp}_{0}$ $\quad A^Tb_\perp=\begin{bmatrix} -a_1- \\ \vdots \\ -a_n- \end{bmatrix}\cdot b_\perp=\begin{bmatrix} a_1^Tb_\perp \\ \vdots \\ a_n^Tb_\perp \end{bmatrix}=\begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}$

↘ perché le colonne di A stanno in $I_m(A)$ e $b_\perp\in I_m(A)^\perp$

$\implies A^Tb\in I_m(A^TA)$

↘ $[A^TA|A^Tb]$

unicità: studiamo quando $\det(A^TA)\neq 0$

$A^TA=$ [A^T] [A] $=$ [A^TA] per Binet-Cauchy (versione generale)

lezione 12 (12/04/2024)

12 Aprile 2024 10:32

Sistemi sovradeterminati $Ax=b$, $A\in\mathbb{R}^{m\times n}$, $b\in\mathbb{R}^m$

sistema: m equazioni, n incognite $\rightarrow x=\begin{bmatrix}x_1\\ \vdots\\ x_n\end{bmatrix}$

A rango massimo $\rightsquigarrow$ RANGO(A) = n

di solito non esiste la soluzione che verifica $Ax=b \iff b-Ax=0$ $\rightarrow$ in alternativa si cerca di risolvere il problema di ottimizzazione: $\min_{x\in\mathbb{R}^n}\|b-Ax\|_2 = \min_{x\in\mathbb{R}^n}\|Ax-b\|_2$ (P)

↑ ripasso

in genere si cerca il punto di minimo x^* di (P) e il valore ottimo $r^*=\|b-Ax^*\|_2$

$\Psi:\mathbb{R}^n\to\mathbb{R}$, $x\longrightarrow\|r(x)\|_2^2$ $\rightsquigarrow$ i punti di minimo sono le soluzioni di $A^TAx=A^Tb$ (sistema nxn)

teorema: le equazioni normali hanno SEMPRE almeno una soluzione, e se RANGO(A)=n allora la soluzione è unica

esempio:
$$\begin{cases}2x_1-x_2=1\\ -x_1+x_2=0\\ x_1+2x_2=1\end{cases}$$ (3 equazioni, 2 incognite) $\longrightarrow m=3, n=2$

risolviamo nel senso dei minimi quadrati:

$A=\begin{bmatrix}2&-1\\-1&1\\1&2\end{bmatrix}$ $b=\begin{bmatrix}1\\0\\1\end{bmatrix}$ $\longrightarrow$

- $A^TA=\begin{bmatrix}2&-1&1\\-1&1&2\end{bmatrix}\begin{bmatrix}2&-1\\-1&1\\1&2\end{bmatrix}=\begin{bmatrix}6&-1\\-1&6\end{bmatrix}\in\mathbb{R}^{2\times2}$ (sistema nxn)
- $A^Tb=\begin{bmatrix}3\\1\end{bmatrix}$
- $(A^TA)^{-1}A^Tb=\frac{1}{35}\begin{bmatrix}19\\9\end{bmatrix}=x^*$ ↳ risolvo $A^TAx=A^Tb$
- $\min_{x\in\mathbb{R}^2}\|b-Ax\|_2=\|r(x^*)\|_2=\sqrt{\frac{36+100+4}{35^2}}=\frac{\sqrt{140}}{35}=\frac{2\sqrt{35}}{35}$

$r(x^*)=\begin{bmatrix}1\\0\\1\end{bmatrix}-\begin{bmatrix}2&-1\\-1&1\\1&2\end{bmatrix}\cdot\begin{bmatrix}19\\9\end{bmatrix}\cdot\frac{1}{35}=\begin{bmatrix}6/35\\10/35\\-2/35\end{bmatrix}$ (b − A · x^*)

esempio: $Ax=b$, $A\in\mathbb{R}^{4\times3}$, $b\in\mathbb{R}^4$

$A=\begin{bmatrix}1&1&1\\1&\alpha&1\\0&0&\alpha\\\beta&0&0\end{bmatrix}$ per quali valori di $\alpha,\beta\in\mathbb{R}$ la soluzione del problema $\min_{x\in\mathbb{R}^3}\|b-Ax\|_2$ non è unica

↳ traduzione: per quali valori di α e β la matrice A ha RANGO < 3

- la matrice A ha RANGO < 3 $\iff$ tutte le sottomatrici 3x3 di A sono singolari (det = 0) $\rightarrow$ è sufficiente prendere i minori 3×3: $\begin{vmatrix}1&1&1\\1&\alpha&1\\0&0&\alpha\end{vmatrix}=\alpha(\alpha-1)$, $\begin{vmatrix}1&1&1\\1&\alpha&1\\\beta&0&0\end{vmatrix}=\beta(1-\alpha)$, $\begin{vmatrix}1&1&1\\0&0&\alpha\\\beta&0&0\end{vmatrix}=\alpha\cdot\beta$, $\begin{vmatrix}1&\alpha&1\\0&0&\alpha\\\beta&0&0\end{vmatrix}=\alpha^2\beta$
- imponiamo che: $\begin{cases}\alpha(\alpha-1)=0\\ \beta(1-\alpha)=0\\ \alpha\beta=0\\ \alpha^2\beta=0\end{cases}\Rightarrow$ $\boxed{\alpha=0,\ \beta=0}$ oppure $\boxed{\alpha=1,\ \beta=0}$

commento (caso complesso): al posto delle equazioni normali $A^TAx=A^Tb$ si hanno le equazioni normali $\boxed{A^*Ax=A^*b}$

commento (mal condizionamento): in molti casi la matrice A^TA risulta mal condizionata $\rightarrow$ (numero di condizionamento amplifica l'errore)

↳ ad esempio, nel caso quadrato m=n si ha $\mathcal{K}(A^TA)=\mathcal{K}(A)^2$

un metodo più sicuro dal punto di vista del condizionamento si basa su una fattorizzazione di A, chiamata fattorizzazione QR $\rightarrow$ **definizione**: $A\in\mathbb{C}^{m\times n}$, una fattorizzazione QR di A è una coppia di matrici (Q,R), $Q\in\mathbb{C}^{m\times n}$ e unitaria ($Q^*Q=QQ^*=I$) e $R\in\mathbb{C}^{m\times n}$ è triangolare superiore

$R=\begin{bmatrix}*&\cdots&*\\&\ddots&\vdots\\0&&*\end{bmatrix}\}$ n righe $=\begin{bmatrix}R_1\\0\end{bmatrix}$ $R_1\in\mathbb{C}^{n\times n}$ triangolare superiore

} m−n righe

teorema: $A\in\mathbb{C}^{m\times n}$, esiste sempre una fattorizzazione QR di A; in particolare non è mai unica

osservazione: se $A=Q_1R_1$ e prendo $D=\begin{bmatrix}\theta_1&&\\&\ddots&\\&&\theta_m\end{bmatrix}$ $|\theta_i|=1$, $\theta_i\in\mathbb{C}$

allora $A=Q_1R_1=\underbrace{Q_1D}_{\text{resta unitaria}}\cdot\underbrace{D^{-1}R}_{\text{resta triangolare superiore}}=Q_1R_1$

proprietà: • $x\in\mathbb{C}^m$, $Q\in\mathbb{C}^{m\times m}$, Q unitaria

$\|Qx\|_2=\|x\|_2$ $\rightsquigarrow$ $\|x\|_2^2=x^*x$, $\|Qx\|_2^2=(Qx)^*(Qx)=x^*\underbrace{Q^*Q}_{I}x=x^*x$ moltiplicare un vettore per una matrice unitaria non cambia la norma

• $A\in\mathbb{C}^{m\times n}$, $Q\in\mathbb{C}^{m\times m}$

$\|QA\|_F=\|A\|_F$ $\rightsquigarrow$ $\|A\|_F=\text{TRACCIA}(A^*A)$, $\|QA\|_F=\text{TRACCIA}(\underbrace{Q^*A^*AQ}_{\text{inversa}})$ è una trasformazione per similitudine

$A\in\mathbb{C}^{m\times m}$

$\|QA\|_2=\|A\|_2$ $\rightsquigarrow$ $\|A\|_2^2=\rho(A^*A)$, $\|QA\|_2^2=\rho(Q^*A^*AQ)$ } dato che le matrici A^*A e Q^*A^*AQ sono simili, allora hanno gli stessi autovalori ed in particolare lo stesso raggio spettrale

manca un pezzo ??

metodo QR per problemi ai minimi quadrati:

$\min_{x\in\mathbb{C}^n}\|Ax-b\|_2$ $A\in\mathbb{C}^{m\times n}$, $b\in\mathbb{C}^m$

supponiamo di sapere $A=QR$ $Q^*Q=QQ^*=I$, $R=\begin{bmatrix}R_1\\0\end{bmatrix}$

$\longrightarrow\|Ax-b\|_2^2=\underbrace{\|QRx-b\|_2^2}_{\text{vettore }\in\mathbb{C}^m}=\|Q^*(QRx-b)\|_2^2=\|Rx-\underbrace{Q^*b}_{c\in\mathbb{C}^m}\|_2^2=\|Rx-c\|_2^2=\left\|\begin{bmatrix}R_1\\0\end{bmatrix}\cdot x-\begin{bmatrix}c_1\\c_2\end{bmatrix}\right\|_2^2\ \begin{matrix}\}n\text{ righe}\\ \}m-n\text{ righe}\end{matrix}=\left\|\begin{bmatrix}R_1x-c_1\\-c_2\end{bmatrix}\right\|_2^2=$ (la scrivo a blocchi)

$=\|R_1x-c_1\|_2^2+\|c_2\|_2^2$

il nostro problema (P) è equivalente a $\min_{x\in\mathbb{C}^n}\|R_1x-c_1\|_2^2+\|c_2\|_2^2$

dato che non abbiamo controllo su $\|c_2\|_2^2$ (è una costante) si minimizza $\|R_1x-c_1\|_2^2$ $\rightsquigarrow$ residuo di un sistema lineare nxn (con matrice triangolare)

osservazione: se A ha rango massimo (n) $\Rightarrow$ R ha rango max $\longrightarrow$ perché $R=Q^*A\Rightarrow R$, è invertibile (le colonne di R_1 sono necessariamente linearmente indipendenti)

in questo caso RANGO(A) = n, la soluzione di (P) è quella del sistema $R_1x=c_1$

ALGORITMO DEL METODO QR

1. calcolo $A=QR$ $O(mn^2)$
2. calcolo $c=Q^*b$ $O(n^2)$ $O(mn)$
3. risolvo $R_1x=c_1$ $O(n^2)$
4. calcolo $\|c_2\|_2$ $O(m-n)$

osservazione: $\|c_2\|_2$ corrisponde al valore ottimo del problema ai minimi quadrati

$\min_x\|Ax-b\|_2=\sqrt{\min_x\|Ax-b\|_2^2}$

come si calcola la fattorizzazione QR?

osservazione: prodotto di 2 matrici unitarie è unitario

$Q_1\cdot Q_2$ $(Q_1\cdot Q_2)^*Q_1Q_2=Q_2^*\underbrace{Q_1^*Q_1}_{I}Q_2=Q_2^*Q_2=I$

idea: $A=\begin{bmatrix}*&\cdots&*\\\vdots&&\vdots*&\cdots&*\end{bmatrix}$ voglio moltiplicare a sinistra per H_1 in modo che $H_1\cdot A=\begin{bmatrix}*&\cdots&*\\0&*&\vdots\\\vdots&\vdots&*\\0&*&*\end{bmatrix}$ ed inoltre $H_1^*H_1=H_1H_1^*=I_m$

definizione: dato $v\in\mathbb{C}^m$ si definisce la trasformazione di Householder associata v, la matrice $H_v=I-\frac{2}{\|v\|_2^2}\cdot vv^*$ ↳ in particolare H_v è della forma "identità + rango 1"

proprietà: ① la matrice H_v è unitaria $\forall v\in\mathbb{C}^m$

② dato $x\in\mathbb{C}^m$ $\exists v\in\mathbb{C}^m$: $H_v\cdot x=\begin{bmatrix}*\\0\\\vdots\\0\end{bmatrix}=\alpha\cdot e_1$ ($\alpha\in\mathbb{C}$)

osservazione: dato che moltiplicare per matrici unitarie preserva la norma dei vettori, necessariamente $|\alpha|=\|x\|_2$

proprietà: per ottenere la trasformazione di householder che manda x in un multiplo di $e_1=\begin{bmatrix}1\\0\\\vdots\\0\end{bmatrix}$ si può scegliere $v=x+\theta\cdot\|x\|_2\cdot e_1$ $|\theta|=1$

ad esempio $v=x\pm\|x\|_2\cdot e_1=\begin{bmatrix}x_1\pm\theta\|x\|_2\\x_2\\\vdots\\x_n\end{bmatrix}$

morale della storia: si può calcolare H_v "facilmente", basta memorizzare v che si trova con $O(m)$ operazioni

metodo per calcolare la QR:

- al 1° passo

$A=\left[\begin{array}{c|ccc}a^1&*&\cdots&*\\\vdots&*&\cdots&*\\a^m&*&\cdots&*\end{array}\right]$ scelgo H_1 come una trasformazione di Householder che: $H_1\cdot a^1=\begin{bmatrix}*\\0\\\vdots\\0\end{bmatrix}$

- al 2° passo

$H_1A=\begin{bmatrix}*&*&\cdots&*\\0&*&\cdots&*\\\vdots&*&\cdots&*\\0&*&\cdots&*\end{bmatrix}$ scegliamo $\tilde{H}_2\in\mathbb{C}^{(m-1)\times(n-1)}$, $\tilde{H}_2\cdot a^2=\begin{bmatrix}*\\0\\\vdots\\0\end{bmatrix}\in\mathbb{C}^{m-1}$ ↳ $a^2\in\mathbb{C}^{m-1}$

$H_2=\left[\begin{array}{c|ccc}1&0&\cdots&0\\0&&&\\\vdots&&\tilde{H}_2&\\0&&&\end{array}\right]$ $\rightsquigarrow H_2\cdot(H_1A)=\begin{bmatrix}*&*&\cdots&*\\0&*&\cdots&*\\\vdots&0&*&\vdots\\0&0&*&*\end{bmatrix}$

- al passo k si guarda $a^k\in\mathbb{C}^{m-k+1}$

$H_{k-1}\cdots H_1A=\left[\begin{array}{ccc|c}*&\cdots&*&*\\&\ddots&\vdots&\vdots\\0&&*&*\\\hline&0&&*\\\vdots&&&\vdots\\0&&&*\end{array}\right]\}m-1$ righe $\rightsquigarrow$ seleziono $\tilde{H}_k\in\mathbb{C}^{(m-k+1)\times(n-k+1)}$, $\tilde{H}_k\cdot a^k=\begin{bmatrix}*\\0\\\vdots\\0\end{bmatrix}$

e si prende $H_k=\left[\begin{array}{c|c}I_{k-1}&0\\\hline0&\tilde{H}_k\end{array}\right]$

$H_k\cdot H_{k-1}\cdots H_1A=\begin{bmatrix}*&\cdots&*\\&\ddots&\vdots\\0&&*\\\vdots&&\vdots\\0&&*\end{bmatrix}$ (k)

dopo n passi si ottiene

$H_n\cdots H_1A=\begin{bmatrix}*&\cdots&*\\&\ddots&\vdots\\0&&*\end{bmatrix}=R$

per ottenere Q dobbiamo "liberarci" delle H_j a sinistra: $H_1^*\cdots H_{n-1}^*\underbrace{H_n^*\cdot H_n}_{I}\cdot H_{n-1}\cdots H_1A=H_1^*\cdots H_n^*R\iff A=\underbrace{H_1^*\cdots H_n^*}_{Q\text{ unitaria perché prodotto di unitarie}}R=QR$

costo computazionale del calcolo della QR: $O(mn^2)$

per arrivare a questo costo è cruciale che H_j sia della forma "identità + rango 1"

esempio:

$H_1\cdot A=(I-vv^*)\cdot A=A-v\underbrace{(v^*A)}_{O(mn)}$ $O(mn)$

nel caso generico sarebbe una matrice $m\times m$ per una $m\times n$ che costerebbe $O(m^2n)$

$v\cdot w^T$ $w\in\mathbb{C}^n$ $O(mn)$ (prendo il primo vettore della matrice $m\times n=m^2n$)

$O(mn)$

commento: nel caso $m=n$ si può considerare la fattorizzazione QR anche per risolvere $Ax=b$

$QRx=b\rightsquigarrow\begin{cases}c=Q^*b & O(n^2)\\ Rx=c & O(n^2)\end{cases}\longrightarrow$ costo della fattorizzazione QR $O(n^3)=O(\frac{4}{3}n^3)$

esempio:

$A=\begin{bmatrix}3&-6\\4&8\\0&1\end{bmatrix}$, $b=\begin{bmatrix}-1\\3\\2\end{bmatrix}$

$A=QR\longrightarrow Q=\begin{bmatrix}3/5&0&-4/5\\4/5&0&3/5\\0&1&0\end{bmatrix}$

$R=\begin{bmatrix}5&-10\\0&1\\0&0\end{bmatrix}$

$\min_{x\in\mathbb{R}^2}\|Ax-b\|_2$

$c=Q^*b=\begin{bmatrix}-3/5&4/5&0\\0&0&1\\-4/5&3/5&0\end{bmatrix}\begin{bmatrix}-1\\3\\2\end{bmatrix}=\begin{bmatrix}5\\2\\5\end{bmatrix}\Rightarrow$ $c_1=\begin{bmatrix}5\\2\end{bmatrix}$, $c_1=[5]$, $c_2=5=\min_{x\in\mathbb{R}^2}\|Ax-b\|_2$

$R_1=\begin{bmatrix}5&-10\\0&1\end{bmatrix}$

$x^*=\begin{bmatrix}5&-10\\0&1\end{bmatrix}\begin{bmatrix}5\\2\end{bmatrix}=\begin{bmatrix}-3\\2\end{bmatrix}$

lezione 13 (15/04/2024)

15 April 2024 08:32

APPROSSIMAZIONE FUNZIONE DI FUNZIONI

Supponiamo $f: \mathbb{R} \to \mathbb{R}$ che non conosciamo, ma abbiamo a disposizione $k+1$ punti in cui si conosce il valore di f: $(x_0, y_0), (x_1, y_1), \dots, (x_n, y_n)$ $\quad x_j \in \mathbb{R}$, $y_j \in \mathbb{R}$

e pensiamo a $y_j = f(x_j)$ o una sua approssimazione

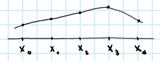

$\Rightarrow$ voglio trovare una funzione $P_k(x)$ tale che $P(x_j) = y_j \quad \forall j = 0, \dots, k$ $\longrightarrow$ questo si dice problema di **INTERPOLAZIONE**
oppure ci si può accontentare che la funzione "passi vicino" ai punti, dove "vicino" va specificato

esempio: (regressione lineare)

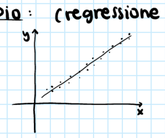

in genere si usa questo tipo di approssimazione quando si hanno molti punti, ma si pensa che $f(x)$ sia abbastanza semplice (pochi parametri) o che i dati siano affetti da rumore

commento: si cerca di costruire una funzione $P_k(x)$ interpolante o approssimante, che sia semplice (ovvero costruita come combinazioni di funzioni elementari, ad esempio polinomi)
↳ è conveniente perché una volta costruita P_k, la possiamo usare per valutare f lontano dai nodi di interpolazioni e per valutare altri tipi di informazioni relative ad f (ad esempio integrale)

interpolazione polinomiale: (aka parabolica)

dati $x_0, \dots, x_k \in \mathbb{R}$ $(x_i \neq x_j \ \forall i \neq j)$ e $k+1$ valori, vogliamo trovare $P_k(x)$ polinomio di grado al più k tale che $\boxed{P(x_j) = y_j \ \forall j = 0, \dots, k}$
$y_0, \dots, y_k \in \mathbb{R}$
$\|$
$R(x_0)$ $f(x_k)$

$P_k(x) = a_0 + a_1 x + a_2 x^2 + \dots + a_k x^k$ ← ciò che dobbiamo trovare $\longrightarrow$ ogni polinomio di grado k è univocamente determinato dai coefficienti $a_0, a_1, \dots, a_k$
$= \sum_{j=0}^{k} a_j x^j$

$P(x_0) = a_0 + a_1 x_0 + a_2 x_0^2 + \dots + a_k x_0^k = y_0$ equazione lineare nei coefficienti a_j
$P(x_1) = a_0 + a_1 x_1 + a_2 x_1^2 + \dots + a_k x_1^k = y_1$
$\vdots$ $\quad\quad\quad

lezione 14 (19/04/2024)

19 April 2024 10:27

problema di interpolazione polinomiale: abbiamo $k+1$ punti $(x_0, y_0) \dots (x_k, y_k)$

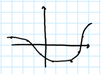

$y_j = f(x_j)$
vogliamo approssimare f con un polinomio di grado al più k

- abbiamo visto che se $x_i \neq x_j \quad \forall i \neq j$ la soluzione (ovvero $P_k(x)$, $P_k(x_i) = y_i \ \forall i$) esiste ed è unica (tra i polinomi di grado $\leq k$)
- trovare $P_k(x)$ equivale a risolvere un sistema $Va = y$ con $a = \begin{bmatrix} a_0 \\ \vdots \\ a_k \end{bmatrix}$ contenente i coefficienti di $P_k(x)$: $P_k(x) = \sum_{j=0}^{k} a_j x^j$
  - V è malcondizionata, quindi si evita di risolvere $Va = y$ → alternativa: si rappresenta $P_k(x)$ in un'altra base → $P_k(x) = \sum_{j=0}^{k} c_j q_j(x)$

1° possibilità: **base di Lagrange** ⇝ $q_j(x) = \ell_j(x) = \prod_{\substack{i=0 \\ i \neq j}}^{k} \frac{(x - x_i)}{(x_j - x_i)} = \frac{\prod_{i \neq j} (x - x_i)}{\prod_{i \neq j} (x_j - x_i)}$ (numeratore: polinomio; denominatore: costante) $\longrightarrow \ell_i(x_i) = \begin{cases} 1 & \text{se } i = j \\ 0 & \text{se } i \neq j \end{cases}$

$P_k(x) = \sum_{j=0}^{k} c_j \ell_j(x) \rightsquigarrow P_k(x_i) = \sum_{j=0}^{k} c_j \underbrace{\ell_j(x_i)}_{\text{si annullano tranne per } i=j} = c_i \Longrightarrow c_i = y_i \quad \forall i = 0, \dots, k$ (coefficienti sono "gratis")

2° possibilità: **base di Newton** ⇝ $P_k(x) = \sum_{j=0}^{k} f[x_0, \dots, x_j]\, n_j(x) \longrightarrow n_0(x) = 1$, $n_j(x) = (x - x_0) \cdot \dots \cdot (x - x_{j-1}) \quad j = 1, \dots, k$

dove $f[x_0, \dots, x_j]$ è definito per ricorrenza come segue:

definizione: $f : I \to \mathbb{R}$ con $x_0, \dots, x_{n-1} \in I$, $x_i \neq x_j \ \forall i \neq j$ (I intervallo aperto (a, b))

Si definisce **la differenza divisa di ordine k**, la funzione $f[x] = f(x)$ se $k = 0$

$f[x_0, x] = \frac{f(x) - f(x_0)}{x - x_0}$ se $k = 1$ (approssimazione di $f'(x)$)

$f[x_0, \dots, x_{k-1}, x] = \frac{f[x_0, \dots, x_{k-2}, x] - f[x_0, \dots, x_{k-1}]}{x - x_{k-1}}$ se $k > 1$

esempio: $f[x_0] = f(x_0)$

$f[x_0, x_1] = \frac{f(x_1) - f(x_0)}{x_1 - x_0}$

$f[x_0, x_1, x_2] = \frac{f[x_1, x_2] - f[x_0, x_1]}{x_2 - x_0}$

proprietà: se $f \in C^k(I)$ allora $\exists\, \xi \in \left[\min\{x_0, \dots, x_k, x\}, \max\{x_0, \dots, x_k, x\}\right]$ tale per cui $f[x_0, \dots, x_k, x] = \frac{f^{(k)}(\xi)}{k!}$

come si calcolano le differenze divise:

osservazione: non ci serve di conoscere f, ci bastano le valutazioni di f nei nodi d'interpolazione, ovvero $y_0, \dots, y_k$

$$A = \begin{bmatrix} f(x_0) & & & & 0 \\ f(x_1) & f[x_0, x_1] & & & \\ f(x_2) & f[x_0, x_2] & f[x_0, x_1, x_2] & & \\ \vdots & \vdots & f[x_0, x_1, x_3] & & \\ f(x_k) & f[x_0, x_k] & f[x_0, x_1, x_k] & \cdots & f[x_0, \dots, x_k] \end{bmatrix}$$

(coefficienti)

$P_k(x) = \sum_{j=0}^{k} f[x_0, \dots, x_j]\, n_j(x)$

- per calcolare un elemento in posizione (i, j) nella matrice A (con $i \geq j$) si usa la formula $a_{ij} = \frac{a_{ij-1} - a_{j-1\, j-1}}{x_i - x_{j-1}}$
  - in particolare si calcolano le entrate di A procedendo per righe dall'alto verso il basso e per colonne da sinistra verso destra

esempio:

x	0	1	2	4
$f(x)$	3	8	15	47

$P_3(x)$ interpolante di grado al più 3

x	$f(x)$	D.D.1	D.D.2	D.D.3
0	3			
1	8	5		
2	15	6	1	
4	47	11	2	$\frac{1}{2}$

$P_3(x) = 3 \cdot n_0(x) + 5 \cdot n_1(x) + 1 \cdot n_2(x) + \frac{1}{2} \cdot n_3(x) =$

$= 3 + 5x + x(x-1) + \frac{1}{2} x(x-1)(x-2) =$ → polinomio nella base di Newton

$= \frac{x^3}{2} - \frac{x^2}{2} + 5x + 3$ → polinomio nella base dei monomi

osservazione: nel caso si trovino tutti elementi uguali in una colonna del **quadro delle differenze divise** significa che le differenze divise di ordine superiore sono tutte nulle

in particolare $P_k(x)$ ha grado pari all'ordine dell'ultima differenza divisa $\neq 0$

↳ questa è conseguenza del fatto che $\deg(n_j(x)) = j$ se $f[x_0, \dots, x_{j+1}] = 0$ ... $f[x_0, \dots, x_{j+2}] = 0$ ... $f[x_0, \dots, x_k] = 0$ e $f[x_0, \dots, x_j] \neq 0$ $\Longrightarrow P_k(x) = \sum_{i=0}^{j} f[x_0, \dots, x_i]\, n_i(x)$ ha grado j

esempio:

x	0	-1	2	-2	3
y	5	3	3	-9	11

$P_4(x)$

x	y	D.D.1	D.D.2	D.D.3
0	5			
-1	3	2		
2	3	-1	-1	
-2	-9	3	-5	1
3	11	2	0	1

"colonna" di entrate uguali $\Longrightarrow$ D.D. 4 = 0 $\Longrightarrow \deg(P_4(x)) = 3$

$P_4(x) = \underbrace{5 + 2x - x(x+1) + x(x+1)(x-2)}_{\text{base di Newton}} = \underbrace{x^3 - 2x^2 - x + 5}_{\text{base monomiale}}$

osservazione: l'ordine dei nodi/punti di interpolazione $(x_0, y_0) \dots (x_k, y_k)$ non è determinante per $P_k(x)$

↳ questo può essere utile in alcune circostanze per semplificare i calcoli

esempio:

x	0	1	α	-1	3
y	2	1	4	$3\alpha+1$	11

$\alpha \in \mathbb{R}$

si determini per quali valori $\alpha \in \mathbb{R}$, $P_4(x)$ ha grado minimo

x	y	D.D.1	D.D.2	
0	2			2
1	1	-1		
3	11	3		$\frac{(3\alpha-3)}{2}$
-1	$3\alpha+1$	$1-3\alpha$		
α	4	$\frac{3}{\alpha}$		$\frac{(1+\alpha)}{\alpha(\alpha-1)}$

(metto α in fondo)

esiste un valore di α per cui questi 3 valori sono uguali?

$\begin{cases} \frac{3\alpha - 2}{2} = 2 \\ \frac{2 + \alpha}{\alpha(\alpha - 1)} = 2 \end{cases}$ se ha soluzione per un qualche α allora $P_4(x)$ ha grado 2

$\frac{3\alpha - 2}{2} = 2 \Longrightarrow \alpha = 2 \longrightarrow \frac{2+2}{2(2-1)} = \frac{4}{2} = 2$ ✓ $\Longrightarrow$ per $\alpha = 2$ $P_4(x)$ ha grado 2

per $\alpha = 2$ ⇝ $P_4(x) = \underbrace{2 - x + 2x(x-1)}_{\text{base di Newton}} = \underbrace{2x^2 - 3x + 2}_{\text{base monomiale}}$

errore dell'interpolazione polinomiale:

teorema: $I \subseteq \mathbb{R}$ intervallo tale che $x_0, \dots, x_k \in I$ e $f \in C^{k+1}(I)$

se $P_k(x)$ rappresenta il polinomio d'interpolazione di grado al più k nei punti $(x_0, f(x_0)) \dots (x_k, f(x_k))$ abbiamo che $\forall x \in I \ \exists\, \xi_x \in I$ tale che $f(x) - P_k(x) = \frac{f^{(k+1)}(\xi_x)}{(k+1)!} \cdot \pi(x)$, $\pi(x) = (x - x_0) \dots (x - x_k) = \prod_{j=0}^{k} (x - x_j)$

osservazione: se si conoscono/derivano maggiorazioni di $|f^{(k+1)}|$ e di $|\pi(x)|$ per $x \in I$, allora si può stimare l'errore d'interpolazione

ad esempio si può scrivere la disuguaglianza

$$\max_{x \in I} |f(x) - P_k(x)| \leq \frac{\max_{x \in I} |f^{(k+1)}(x)| \cdot \max_{x \in I} |\pi(x)|}{(k+1)!}$$

RECAP

	Newton	Lagrange
base	$n_j = (x - x_0) \dots (x - x_{j-1})$	$\prod_{i \neq j} \frac{(x - x_i)}{(x_j - x_i)} = \ell_j$
	$f[x_0, \dots, x_j]$ bisogna valutare una formula ricorsiva	$\ell(x_j) = y_j$ → costa ø trovarli
	posso vedere facilmente il grado di $P_k(x)$	per ottenere il grado di $P_k(x)$ devo espandere in un'altra base ad esempio monomiale
	se ho P_k e voglio P_{k+1} (ho un punto in più) mi devo calcolare solo $n_{k+1}(x)$ e $f[x_0, \dots, x_{k+1}]$	se ho P_k e voglio P_{k+1} mi devo ricalcolare tutti gli $\ell_j(x)$

indipendentemente da che base uso:

$f(x) - P_k(x) = \pi(x) \frac{f^{(k+1)}(\xi_x)}{(k+1)!}$

interpolazione osculatoria di Hermite:

$f : \mathbb{R} \to \mathbb{R}$ $f \in C^1$

supponiamo di avere $x_0, \dots, x_k \in \mathbb{R}$ e di conoscere $f(x_0) \dots f(x_k)$ e $f'(x_0) \dots f'(x_k)$

↳ vogliamo trovare un polinomio $P_{2k+1}(x)$ di grado al più $2k+1$ tale che: $P_{2k+1}(x_j) = f(x_j)$, $P'_{2k+1}(x_j) = f'(x_j)$ (*)

osservazione: le condizioni (*) viste come condizioni sui coefficienti del polinomio sono: $2k+2$ equazioni lineari

quindi ci aspettiamo che servano $2k+2$ gradi di libertà in $P_{2k+1}(x)$ per risolvere il problema → per questo motivo $P_{2k+1}(x)$ viene preso di grado $\leq 2k+1$ (infatti in questo modo è definito da $2k+2$ coefficienti)

teorema: se $x_i \neq x_j \ \forall i \neq j$ allora $\exists$ ed è unico $H_{2k+1}(x)$ che verifica (*) ⟶ questo viene detto polinomio di Hermite

dimostrazione: (dispense) analoga al caso standard, viene un sistema $(2k+2) \times (2k+2)$ con matrice invertibile

come si trova $H_{2k+1}(x)$?

si adotta un approccio simile all'interpolazione di Lagrange, si cercano 2 famiglie di polinomi $h_{0j}(x)$ e $h_{1j}(x)$, $j = 0, \dots, k$ che abbiano le seguenti proprietà:

- $h_{0j}(x_i) = \begin{cases} 1 & \text{se } i = j \\ 0 & \text{se } i \neq j \end{cases}$, $h'_{0j}(x_i) = 0 \quad \forall i$
- $h_{1j}(x_i) = 0 \ \forall i$, $h'_{1j}(x_i) = \begin{cases} 1 & \text{se } i = j \\ 0 & \text{se } i \neq j \end{cases}$

(**)

se conosciamo $h_{0j}(x)$ e $h_{1j}(x)$ con queste proprietà, scriverci $H_{2k+1}(x)$ è facile:

$H_{2k+1}(x) = \sum_{j=0}^{k} f(x_j) \cdot h_{0j}(x) + \sum_{j=0}^{k} f'(x_j) \cdot h_{1j}(x)$

$H_{2k+1}(x_i) = \sum f(x_j) \cdot \underbrace{h_{0j}(x_i)}_{\text{si annullano tutti tranne } h_{ii}(x_i)} + \sum f'(x_j) \cdot \underbrace{h_{1j}(x_i)}_{\text{tutti} = 0} = f(x_i) \cdot \underbrace{h_{0i}(x_i)}_{1} = f(x_i)$

$H'_{2k+1}(x_i) = \sum f(x_j) \cdot \underbrace{h'_{0j}(x_i)}_{0} + \sum f'(x_j) \cdot \underbrace{h'_{1j}(x_i)}_{\text{si annullano tutti tranne } h'_{1i}(x_i)} = f'(x_i) \cdot \underbrace{h'_{1i}(x_i)}_{1} = f'(x_i)$

come si trovano $h_{0j}(x)$ e $h_{1j}(x)$?

idea per trovarli: partire dai polinomi $\ell_j(x) = \prod_{i \neq j} \frac{(x - x_i)}{(x_j - x_i)}$ e li cerchiamo della forma: $h_{1j}(x) = (A_j \cdot x + B_j)\, \ell_j^2(x)$, $h_{1j}(x) = (C_j \cdot x + D_j)\, \ell_j^2(x)$ ⟶ si determinano A_j, B_j, C_j e D_j in modo che (**) siano verificate

per casa: dimostrare che

- $h_{0j}(x) = \left[1 - 2\ell'_j(x_j)(x - x_j)\right] \ell_j^2(x)$
- $h_{1j}(x) = (x - x_j)\, \ell_j^2(x)$

per cui: $H_{2k+1}(x) = \sum_{j=0}^{k} \left[1 - 2\ell'_j(x_j)(x - x_j)\right] \ell_j^2(x) \cdot f(x_j) + \sum_{j=0}^{k} (x - x_j)\, \ell_j^2(x) \cdot f'(x_j)$

esempio: supponiamo di avere 2 segmenti che vogliamo saldare in maniera C^1 con un polinomio

x	0	d
$f(x)$	0	L
$f'(x)$	0	S

$\ell_0(x) = \frac{d - x}{d}$ $\quad \ell_1(x) = \frac{x}{d}$

$h_{00}(x) = \left[1 + 2\frac{x}{d}\right] \frac{(x-d)^2}{d^2}$

$h_{01}(x) = \left[1 - 2\frac{(x-d)}{d}\right] \frac{x^2}{d^2}$ $\quad h_{10}(x) = \frac{x(x-d)^2}{d^2}$

$h_{11}(x) = (x - d)$

$H_3(x) = \left[1 - 2\frac{(x-d)}{d}\right] \frac{x^2}{d^2} L + (x - d) \frac{x^2}{d^2} \cdot S$

lezione 15 (22/04/2024)

23 April 2024 11:20

quando si considera l'interpolante polinomiale $P_k(x)$ di una certa f, come unico strumento per diminuire l'errore di approssimazione $\max_{x\in[a,b]} |P_k(x) - f(x)|$ usiamo il grado di P_k (cioè ci aspettiamo che se aumentiamo k, quindi aumentando i punti di interpolazione, l'errore vada a zero $\lim_{k\to+\infty} |P_k(x) - f(x)| = 0$)

esempio: $f(x) = \frac{1}{1+x^2}$ ⟶ fenomeno di Runge

curiosità: per qualunque strategia di scelta dei nodi di interpolazione su $[a,b]$ $\exists f \in C([a,b])$ tale che $\lim_{k\to+\infty} |P_k(x) - f(x)| \neq 0$ ⟹ teorema di Faber

conclusione: non esiste una scelta universale di punti di interpolazione che vada bene per ogni intervallo $[a,b]$ e per ogni funzione f definita su $[a,b]$, però ci sono scelte che funzionano meglio di altre, ad esempio i punti Chebyshev

interpolazione polinomiale a tratti: $(x_0,y_0) \dots (x_k,y_k)$. pensiamo a k grande

idea:
- si divide l'insieme dei nodi di interpolazione in sottoinsiemi di $s+1$ nodi consecutivi ($x_0 < x_1 < x_2 < \dots < x_k$)

$$\underbrace{x_0, __, x_s}_{\text{gruppo 1}} = \underbrace{x_s, __, x_{2s}}_{\text{gruppo 2}} = x_{2s} \dots$$

- su ogni sottoinsieme costruisco il polinomio interpolante di grado s $(q_1, __, q_{s+1}(x))$
- definisco la funzione interpolante $F(x)$ come $F(x) = q_j(x)$ se x appartiene al gruppo j

esempio: (interpolazione lineare a tratti)

gruppi: $[x_0,x_1], [x_1,x_2], \dots, [x_{k-1},x_k]$

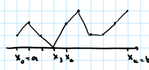

$$F(x) = \begin{cases} m_1 x + n_1 & \text{se } x \in [x_0,x_1] \\ m_2 x + n_2 & \text{se } x \in [x_1,x_2] \\ \vdots \end{cases}$$

osservazione: in questo contesto ci aspettiamo di migliorare l'errore di approssimazione $|f(x) - F(x)|$ sia aumentando il grado s usato nei sottointervalli, sia diminuendo l'ampiezza dei sottointervalli

il prezzo da pagare è il numero dei parametri per rappresentare $F(x)$ ⟶ in particolare, se uso polinomi di grado s e ho t sottointervalli, mi servono $t(s+1)$ parametri

funzioni spline: $x_0 < x_1 < \dots < x_k \in [a,b]$ $f: [a,b] \to \mathbb{R}$

si prendono i sottointervalli $[x_0,x_1], [x_1,x_2], \dots, [x_{k-1},x_k]$ ed in ciascuno di essi si prende un polinomio interpolante di grado 3 in modo tale che la funzione F definita a tratti sia derivabile 2 volte in $[a,b]$

definizione: si dice spline cubica, per f rispetto ai punti di interpolazione $(x_0, f(x_0)), \dots, (x_k, f(x_k))$ la funzione $S_3(x): [a,b] \to \mathbb{R}$ tale che:

(i) $S_3(x)\big|_{[x_{i-1},x_i]}$ è un polinomio di grado 3 ($\leftarrow$ ristretto a $[x_{i-1},x_i]$) $\quad i = 1, \dots, k$

(ii) $S_3(x_i) = f(x_i) \quad \forall i = 0, \dots, k$

(iii) $S_3(x) \in C^2([a,b])$

osservazione: se chiamiamo $p_i(x) = S_3(x)\big|_{[x_{i-1},x_i]}$ (iii) significa che $p_i'(x_i) = p_{i+1}'(x_i)$, $p_i''(x_i) = p_{i+1}''(x_i)$ $\quad i = 1, \dots, k-1$ (↳ gli estremi sono esclusi (0 e k))

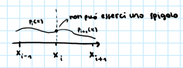

osservazione: si possono definire spline di grado d ($S_d(x)$) tali che in ogni intervallo $[x_{i-1}, x_i]$ corrispondano a un polinomio di grado d e che valga $S_d \in C^{d-1}([a,b])$

domanda: come si determina $S_3(x)$? Ovvero come determiniamo i $4\cdot k$ parametri che definiscono $p_1(x), \dots, p_k(x)$

imponendo le condizioni (i), (ii) e (iii)

$$\begin{cases} p_i(x_{i-1}) = f(x_{i-1}) & i = 1, \dots, k \quad \text{(condizioni di interpolazione)} \\ p_i(x_i) = f(x_i) & i = 1, \dots, k \\ \text{una volta imposte queste abbiamo automaticamente che la funzione è continua, perché } p_i \text{ e } p_{i+1} \text{ negli estremi dove si toccano devono "essere uguali"} \\ p_i'(x_i) = p_{i+1}'(x_i) & i = 1, \dots, k-1 \\ p_i''(x_i) = p_{i+1}''(x_i) & i = 1, \dots, k-1 \end{cases}$$

in totale abbiamo $4k-2$ condizioni (equazioni lineari nei coefficienti dei polinomi p_i) per determinare $4k$ parametri

le due condizioni mancanti riguardano gli estremi $x_0 = a$, $x_k = b$ e danno origine a Spline:
- Spline naturale ⟿ $p_1''(x_0) = p_k''(x_k) = 0$
- Spline periodica ⟿ $p_1'(x_0) = p_k'(x_k)$, $p_1''(x_0) = p_k''(x_k)$
- Spline vincolata ⟿ $p_1'(x_0) = c_1$, $p_k'(x_k) = c_2$ (con c_1, c_2 dati)

teorema: siano $x_0, __, x_k$ nodi equispaziati in $[a,b]$ (in particolare $x_i - x_{i+1} = \frac{b-a}{k} = h$ ↳ i punti distano h l'uno dall'altro, ↳ k intervalli), $f: [a,b] \to \mathbb{R}$ allora la Spline naturale $S_3(x)$ per i nodi x_j e la funzione f esiste ed è unica

inoltre, i polinomi $p_i(x)$ $(i = 1, \dots, k)$ che la costituiscono sono della forma: $y_i = f(x_i)$

$$p_i(x) = \left[y_{i-1} + \left(m_{i-1} + \frac{2y_{i-1}}{h}\right)(x - x_{i-1})\right]\left(\frac{x-x_i}{h}\right)^2 + \left[y_i + \left(m_i - \frac{2y_i}{h}\right)(x - x_i)\right]\left(\frac{x-x_{i-1}}{h}\right)^2$$

dove $m_0, __, m_k$ sono la soluzione del sistema lineare

$$\begin{bmatrix} 2 & 1 & & & \\ 1 & 4 & 1 & & \\ & \ddots & \ddots & \ddots & \\ & & 1 & 4 & 1 \\ & & & 1 & 2 \end{bmatrix} \begin{bmatrix} m_0 \\ m_1 \\ \vdots \\ m_k \end{bmatrix} = \begin{bmatrix} 3/h\,(y_1 - y_0) \\ 3/h\,(y_2 - y_1) \\ \vdots \\ 3/h\,(y_{k-1} - y_{k-2}) \\ 3/h\,(y_k - y_{k-1}) \end{bmatrix}$$

sistema $(k+1) \times (k+1)$

dimostrazione:

idea: in ogni intervallo $[x_{i-1}, x_i]$ si prende $p_i(x)$ come il polinomio di Hermite rispetto ai nodi d'interpolazione $(x_{i-1}, y_{i-1}), (x_i, y_i)$ $(x_{i-1}, m_{i-1}), (x_i, m_i)$ dove i valori m_i sono al momento da determinare

fatta questa scelta, in ogni intervallo ottengo una funzione definita a tratti continua e $C^1([a,b])$

imponendo la condizione $p_i''(x_i) = p_{i+1}''(x_i)$ si determinano i coefficienti m_i come le soluzioni del sistema lineare sopra citato

commento: risultati analoghi valgono per scelte diverse di nodi e Spline vincolate e periodiche

approssimazione ai minimi quadrati:

$f: \mathbb{R} \to \mathbb{R}$ $(x_0,y_0), __, (x_k,y_k)$ $y_i = f(x_i)$ (↳ k molto grande (es: 1000 punti))

cerchiamo un approccio che generalizza l'interpolazione in 2 direzioni: (i) non passare necessariamente dai punti, ma "sufficientemente vicino" (ii) non utilizzare necessariamente polinomi

cerchiamo $\Phi(x) \approx f(x)$ con $\Phi(x) = \sum_{j=0}^{m} c_j \cdot \varphi_j(x)$ con $m \leq k$, $\varphi_j(x)$ funzione MODELLO (funzione elementare non necessariamente un polinomio)

osservazione: l'interpolazione polinomiale è un caso particolare di quello che vedremo, in cui $m = k$ e $\varphi_j(x)$ polinomio di grado $\leq k$

esempio: $\varphi_0(x) = e^{2x}$, $\varphi_1(x) = \sin\left(\frac{x}{2}\right)$, $\varphi_2(x) = \frac{1}{3x^2+4}$

$\Phi(x) = c_0 e^{2x} + c_1 \sin\left(\frac{x}{2}\right) + \frac{c_2}{3x^2+4}$ (con c_0, c_1, c_2 scelti con un certo criterio)

esempio: (regressione lineare)

$m = 2$ k grande $k >> 2$

$\varphi_0(x) = 1$, $\varphi_1(x) = x$

$\Phi(x) = c_1 x + c_0$

come scegliamo i coefficienti c_i? li cerchiamo in modo tale che l'errore rispetto a f nei punti x_i $(i = 0, __, k)$ sia minimo/piccolo

definiamo una funzione che: dati $c_0, __, c_k$ misuri l'errore

↳ potremmo scegliere $\Psi(c_0, __, c_k) = \sum_{j=0}^{k} [\Phi(x_j) - f(x_j)]$ ⟶ somma di "scarti"

ma potrebbe essere piccola anche per approssimazioni non buone ↳ misuriamo quanti i punti distano dalla retta (a) ↳ se prendiamo $\Psi(c_0, __, c_k) = \sum_{j=0}^{k} |\Phi(x_j) - f(x_j)|$ non è più derivabile per il valore assoluto ⟶ non è differenziabile ⟶ più difficile trovare il minimo

$$\Psi(c) := \sum_{j=0}^{k} (\Phi(x_j) - f(x_j))^2 = \sum_{j=0}^{k} \left[\sum_{h=0}^{m} (c_h \cdot \varphi_h(x_j) - f(x_j))\right]^2$$

(c_h: variabili da determinare; sommiamo gli scarti quadratici dei nodi)

per determinare $c_0, __, c_m$ si risolve

$$\min_{c_0, __, c_m} \Psi(c_0, __, c_m) = \sum_{j=0}^{k} \left[\left(\sum_{h=0}^{m} c_h \cdot \varphi_h(x_j) - f(x_j)\right)\right]^2$$

e si prende il punto di minimo

se ci definiamo il vettore $r(c) := \begin{bmatrix} \Phi(x_0) - f(x_0) \\ \Phi(x_1) - f(x_1) \\ \vdots \\ \Phi(x_k) - f(x_k) \end{bmatrix} \in \mathbb{R}^{k+1}$ (per $j=0$) e $\Psi(c) = \sum_{j=0}^{k} (r_j(c))^2 = \|r_j(c)\|_2^2$

per cui abbiamo $r_j(c) = \sum_{h=0}^{m} c_h \varphi_h(x_j) - f(x_j) = c_0\varphi_0(x_j) + c_1\varphi_1(x_j) + \dots + c_h\varphi_h(x_j) - f(x_j) = \begin{bmatrix} \varphi_0(x_j) & \varphi_1(x_j) & \dots & \varphi_m(x_j) \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \\ \vdots \\ c_m \end{bmatrix} - f(x_j)$

$$A = \begin{bmatrix} \varphi_0(x_0) & \varphi_1(x_0) & \cdots & \varphi_m(x_0) \\ \varphi_0(x_1) & \varphi_1(x_1) & \cdots & \varphi_m(x_1) \\ \vdots & \vdots & & \vdots \\ \varphi_0(x_k) & \varphi_1(x_k) & \cdots & \varphi_m(x_k) \end{bmatrix} \in \mathbb{R}^{(k+1)\times(m+1)} \qquad b = \begin{bmatrix} f(x_0) \\ f(x_1) \\ \vdots \\ f(x_k) \end{bmatrix} \in \mathbb{R}^{(k+1)}$$

$r(c) = Ac - b \Rightarrow \min_c \Psi(c) = \min_c \|r(c)\|_2^2 = \min_c \|Ac - b\|_2^2$

il problema è equivalente a risolvere il sistema sovradeterminato $Ac = b$ nel senso dei minimi quadrati ⟶ quindi possiamo utilizzare le equazioni normali o il metodo QR per trovare c

esempio: calcolare l'equazione della retta e della parabola che approssimano nel senso dei minimi quadrati i valori

x	1	2	3	4	5
y	1.4	3.1	4.8	6.8	8.5

RETTA (↳ 1° caso)

$\Phi(x) = c_1 x + c_0$ $\varphi_0(x) = 1$, $\varphi_1(x) = x$

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{bmatrix} \qquad b = \begin{bmatrix} 1.4 \\ 3.1 \\ 4.8 \\ 6.8 \\ 8.5 \end{bmatrix}$$

le equazioni normali ci portano a considerare il sistema $A^TAc = A^Tb$

$$A^TA = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{bmatrix} = \begin{bmatrix} 5 & 15 \\ 15 & 55 \end{bmatrix} \qquad A^Tb = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{bmatrix} \begin{bmatrix} 1.4 \\ 3.1 \\ 4.8 \\ 6.8 \\ 8.5 \end{bmatrix} = \begin{bmatrix} 24.6 \\ 91.3 \end{bmatrix}$$

metto insieme e risolvo il sistema 2x2

$c = \begin{bmatrix} -0.45 \\ 1.79 \end{bmatrix}$ ⟶ $\Phi_1(x) = 1.79x - 0.45$ (↳ coefficiente angolare, ↳ termine noto)

PARABOLA (↳ caso 2)

$\Phi_2(x) = c_0 + c_1 x + c_2 x^2$ $\varphi_0(x) = 1$, $\varphi_1(x) = x$, $\varphi_2(x) = x^2$

$$A = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 4 \\ 1 & 3 & 9 \\ 1 & 4 & 16 \\ 1 & 5 & 25 \end{bmatrix} \rightsquigarrow A^TA = \begin{bmatrix} 5 & 15 & 55 \\ 15 & 55 & 225 \\ 55 & 225 & 979 \end{bmatrix}$$

$$b = \begin{bmatrix} 1.4 \\ 3.1 \\ 4.8 \\ 6.8 \\ 8.5 \end{bmatrix} \rightsquigarrow A^Tb = \begin{bmatrix} 24.6 \\ 91.3 \\ 378.3 \end{bmatrix}$$

risolvo il sistema 3x3 $A^TAc = A^Tb$

$c = \begin{bmatrix} -0.3 \\ 1.66 \\ 0.021\dots \end{bmatrix}$ ⟶ $\Phi_2(x) = -0.3 + 1.66x + 0.021\dots x^2$

lezione 16 (26/04/2024)

27 April 2024 15:56

integrazione numerica → si vogliono fornire metodi per approssimare quantità del tipo: $I(f;f) = \int_a^b f(x)\cdot f(x)\,dx$ dove $[a,b] \subset \mathbb{R}$ intervallo, $f(x) \in C([a,b])$, $f(x) \geq 0$ su $[a,b]$ tale che $m_k = \int_a^b |x|^k \cdot f(x)\,dx < +\infty$ $\forall k = 0,1,2,\dots$

- f: funzione peso
- le quantità m_k sono dette "momenti"

perché può servire?

- di molte funzioni non esiste una espressione esplicita della primitiva
- anche se la primitiva esiste, è o costosa da calcolare e/o da valutare
- a volte conosciamo $f(x)$ solo in qualche punto o è fornita come black-box (si può valutare, ma non si sa come è fatta f)
  - non conosco f, posso valutarla dove voglio, ma non so l'espressione esplicita
  - non posso ricavare la primitiva con carta e penna
- noi vediamo il caso $f: \mathbb{R} \to \mathbb{R}$, in più variabili i casi in cui si può considerare la primitiva di f sono ancora più rari

obbiettivo: vogliamo approssimare l'integrale con una combinazione lineare $\longrightarrow \int_a^b f(x)\cdot f(x)\,dx \approx \sum_{j=0}^{n} a_j \cdot f(x_j)$ con $a \leq x_0 < x_1 < x_2 < \dots < x_n \leq b$, $a_j \in \mathbb{R}$

definizione: una formula del tipo $J_n(f) := \sum_{j=0}^{n} a_j \cdot f(x_j)$ è detta FORMULA DI QUADRATURA
- nodi → abbiamo $(n+1)$ nodi
- pesi → abbiamo $(n+1)$ pesi

definizione: l'errore della formula di quadratura rispetto a una funzione f è definito come $E_n(f) := I(f;f) - J_n(f)$
- si può vedere come una mappa che va dalle funzioni (continue e non) in $\mathbb{R}$: $J_n(\cdot): C([a,b]) \to \mathbb{R}$, $f \to \sum_{j=0}^{n} a_j f(x_j)$
- $E_n(\cdot): C([a,b]) \to \mathbb{R}$, $f \to E_n(f) = I(f;f) - \sum_{j=0}^{n} a_j f(x_j)$

→ come si determina se una formula di quadratura è buona o accurata? **definizione**: una formula di quadratura con $(n+1)$ nodi $J_n(\cdot)$ si dice avere grado di precisione $m \in \mathbb{N}$ se verifica: $E_n(1) = E_n(x) = \dots = E_n(x^m) = 0$ e $E_n(x^{m+1}) \neq 0$ → integra perfettamente i monomi fino a potenza "m" e da "m+1" si comincia ad avere un certo errore

osservazione: per linearità, se $J_n(\cdot)$ ha grado di precisione m significa che integra esattamente ogni polinomio $q(x)$ che ha grado $\leq m$ ($E_n(q) = 0$)

dimostrazione: siano $f, g \in C([a,b])$, $c_1, c_2 \in \mathbb{R}$

$$I(c_1 f + c_2 g) = \int_a^b (c_1 f + c_2 g)\,f(x)\,dx = c_1 \int f \cdot f\,dx + c_2 \int g \cdot f\,dx = c_1 I(f;f) + c_2 I(f;g)$$

$$J_n(c_1 f + c_2 g) = \sum_{j=0}^{n} a_j \left(c_1 f + c_2 g\right)(x_j) = \sum_{j=0}^{n} a_j \left[c_1 f(x_j) + c_2 g(x_j)\right] = c_1 \sum_{j=0}^{n} a_j f(x_j) + c_2 \sum_{j=0}^{n} a_j g(x_j)$$

se prendo $q(x) = \sum_{j=0}^{n} q_j x^j$ è combinazione lineare di monomi su cui l'errore della formula di quadratura è esatta

esempio: supponiamo di voler calcolare $\int_{-1}^{1} f(x)\,dx$ ($f(x) = 1$) e di voler usare come nodi $x_0 = -1$, $x_1 = 1$

$J_1(f) = a_0 f(x_0) + a_1 f(x_1) = a_0 f(-1) + a_1 f(1)$

→ scelgo i pesi a_0, a_1 in modo tale che $J_1(\cdot)$ abbia grado di precisione massimo

$$E_1(1) = \int_{-1}^{1} 1\,dx - J_1(1) = 2 - (a_0 + a_1) = 0 \rightsquigarrow a_0 = 2 - a_1$$

$$E_1(x) = \int_{-1}^{1} x\,dx - J_1(x) = 0 - (-a_0 + a_1) = 0 \rightsquigarrow a_0 = a_1$$

$$\longrightarrow \begin{cases} a_0 = 1 \\ a_1 = 1 \end{cases}$$ con questa scelta il grado di precisione è almeno 1

→ ha grado 2? ($J_1(x^2)$)

$$E_1(x^2) = \int_{-1}^{1} x^2\,dx - (a_0 f(x_0) + a_1 f(x_1)) = \frac{2}{3} - (1+1) = \frac{2}{3} - 2 = -\frac{4}{3} \neq 0$$

x^2 non è integrato esattamente → il grado di precisione è esattamente 1

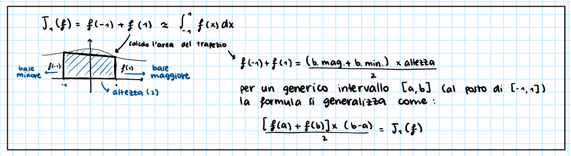

$\Rightarrow$ **definizione**: $J_1(f) = \left[f(a) + f(b)\right] \cdot \frac{b-a}{2}$ viene chiamata FORMULA DEI TRAPEZI
- $\frac{b-a}{2}$: formula di quadratura che utilizza solo due nodi (scelti come gli estremi dell'intervallo), che ottimizza/massimizza il grado di precisione

$$\text{per un generico intervallo } [a,b] \text{ (al posto di } [-1,1]\text{) la formula si generalizza come: } \frac{[f(a) + f(b)] \times (b-a)}{2} = J_1(f)$$

esempio: proviamo a raffinare la formula dei trapezi mettendoci un punto aggiuntivo, ci mettiamo il punto intermedio $\frac{a+b}{2}$

→ facciamo il caso $a = -1$, $b = 1$, quindi abbiamo come nodi $x_0 = -1$, $x_1 = 0$, $x_2 = 1$

→ cerchiamo i coefficienti di $J_2(f) = a_0 f(-1) + a_1 f(0) + a_2 f(1)$ in modo che il grado sia massimo

$$E_2(1) = \int_{-1}^{1} 1\,dx - J_2(1) = 2 - (a_0 + a_1 + a_2) = 2 - a_0 - a_1 - a_2 = 0 \rightsquigarrow a_0 = -a_1 - a_2 + 2$$

$$E_2(x) = \int_{-1}^{1} x\,dx - J_2(x) = 0 - (-a_0 + 0 + a_2) = a_0 - a_2 = 0 \rightsquigarrow a_0 = a_2$$

$$E_2(x^2) = \int_{-1}^{1} x^2\,dx - J_2(x^2) = \frac{2}{3} - (a_0 + 0 + a_2) = \frac{2}{3} - a_0 - a_2 = 0 \rightsquigarrow a_0 = -a_2 + \frac{2}{3}$$

$$\Rightarrow \begin{cases} a_0 = -a_1 - a_2 + 2 \\ a_0 = a_2 \\ a_0 = -a_2 + \frac{2}{3} \end{cases} \quad \begin{cases} a_2 = -2a_2 + 2 \\ a_0 = a_2 \\ a_2 = \frac{1}{3} \end{cases} \quad \begin{cases} a_2 = \frac{4}{3} \\ a_0 = \frac{1}{3} \\ a_2 = \frac{1}{3} \end{cases} \longrightarrow J_2(f) = \frac{1}{3} f(-1) + \frac{4}{3} f(0) + \frac{1}{3} f(1) = \frac{1}{3}\left[f(-1) + 4f(0) + f(1)\right]$$

→ il grado della formula è almeno 2

→ vediamo se il grado è più grande oppure esattamente 2:

$$E_2(x^3) = \int_{-1}^{1} x^3\,dx - J_2(x^3) = 0 - \left(a_0 f(x_0) + a_1 f(x_1) + a_2 f(x_2)\right) = \frac{1}{3} - 0 - \frac{1}{3} = 0 \quad \checkmark \longrightarrow \text{il grado è almeno 3!}$$

→ ha grado 4?

$$E_2(x^4) = \int_{-1}^{1} x^4\,dx - J_2(x^4) = \frac{2}{5} - \left(\frac{1}{3} f(-1) + \frac{4}{3} f(0) + \frac{1}{3} f(1)\right) = \frac{2}{5} - \frac{4}{3} - 0 - \frac{1}{3} = -\frac{4}{15} \neq 0 \quad \text{X condizione non verificata} \rightarrow \text{grado non è 4} \rightarrow \text{è esattamente 3}$$

- la formula trovata è detta FORMULA DI SIMPSON O DI CAVALIERI-SIMPSON, e per un generico intervallo $[a,b]$ prende la forma: $J_2(f) = \frac{b-a}{6}\left(f(a) + 4f\left(\frac{a+b}{2}\right) + f(b)\right)$

! se i nodi sono dati $(x_0, \dots, x_n)$ massimizzare il grado di precisione equivale a risolvere il sistema lineare: ($f(x) = 1$ per semplicità)

$$\begin{cases} a_0 + a_1 + \dots + a_n = \int_a^b 1\,dx = m_0 \\ a_0 x_0 + a_1 x_1 + \dots + a_n x_n = \int_a^b x\,dx = m_1 \\ a_0 x_0^2 + a_1 x_1^2 + \dots + a_n x_n^2 = \int_a^b x^2\,dx = m_2 \\ \vdots \\ a_0 x_0^n + a_1 x_1^n + \dots + a_n x_n^n = \int_a^b x^n\,dx = m_n \end{cases}$$

$J_n(f) = \sum_{j=0}^{n} a_j f(x_j)$ — a_j: incognite

→ sistema lineare di $(n+1)$ equazioni e $(n+1)$ incognite

lo possiamo scrivere come

$\forall \tilde{a} = b$ $\quad b = \begin{bmatrix} m_0 \\ \vdots \\ m_n \end{bmatrix} \in \mathbb{R}^{n+1}$ $\quad \tilde{a} = \begin{bmatrix} a_0 \\ \vdots \\ a_n \end{bmatrix} \in \mathbb{R}^{n+1}$ $\quad V = \begin{bmatrix} 1 & 1 & \dots & 1 \\ x_0 & x_1 & \dots & x_n \\ x_0^2 & x_1^2 & \dots & x_n^2 \\ \vdots & \vdots & & \vdots \\ x_0^n & x_1^n & \dots & x_n^n \end{bmatrix}$ → matrice di Vandermonde trasposta (vista ad interpolazione)?

$\Rightarrow \det(V) = \det(V^T) = \prod_{\substack{i,j \\ i,j=0,\dots,n}} (x_i - x_j)$ $\Rightarrow$ se $x_i \neq x_j$ il sistema ha un'unica soluzione $\Rightarrow$ fissati i nodi esiste ed è unica la formula di quadratura che ha grado di precisione ALMENO n

osservazione: se consideriamo le formule dei trapezi e di simpson, si nota che stiamo integrando al posto di f il polinomio (di grado 1 per i trapezi, di grado 2 per simpson) che interpola f nei nodi ((a,b) per i trapezi, $(a, b, \frac{a+b}{2})$ per simpson)

! se ho possibilità di scegliere sia i nodi che i pesi (ma n è dato), per massimizzare il grado devo risolvere un sistema non lineare → osserviamo che abbiamo $2n+2$ quantità/parametri da trovare $(a_0, \dots, a_n, x_0, \dots, x_n)$ quindi si impongono $2n+2$ equazioni:

$E_n(x^k) = 0 \quad k = 0, \dots, 2n+1$

$$\begin{cases} a_0 + a_1 + \dots + a_n = m_0 \\ a_0 x_0 + a_1 x_1 + \dots + a_n x_n = m_1 \\ \vdots \\ a_0 x_0^{2n+1} + \dots + a_n x_n^{2n+1} = m_{2n+1} \end{cases} \quad (*) \quad m_j = \int_a^b x^j\,dx$$

→ sistema non lineare di $(2n+2)$ equazioni, in $(2n+2)$ incognite
- m_{2n+1}: momento alla "$2n+1$"
- se lo risolviamo otteniamo una formula di quadratura che ha grado ALMENO $2n+1$

esempio: $\int_{-1}^{1} f(x)\,dx \approx a_0 f(x_0) + a_1 f(x_1)$ determinare a_0, a_1, x_0, x_1 in modo da massimizzare il grado

$$E_1(1) = E_1(x) = E_1(x^2) = E_1(x^3) = 0$$

$$E_1(1) = \int_{-1}^{1} 1\,dx - J_1(1) = 2 - (a_0 + a_1) = 2 - a_0 - a_1 = 0 \rightsquigarrow a_0 = -a_1 + 2$$

$$E_1(x) = \int_{-1}^{1} x\,dx - J_1(x) = 0 - (a_0 x_0 + a_1 x_1) = -a_0 x_0 - a_1 x_1 = 0 \rightsquigarrow a_0 x_0 = -a_1 x_1$$

$$E_1(x^2) = \int_{-1}^{1} x^2\,dx - J_1(x^2) = \frac{2}{3} - (a_0 x_0^2 + a_1 x_1^2) = \frac{2}{3} - a_0 x_0^2 - a_1 x_1^2 = 0 \rightsquigarrow a_0 x_0^2 = -a_1 x_1^2 + \frac{2}{3}$$

$$E_1(x^3) = \int_{-1}^{1} x^3\,dx - J_1(x^3) = 0 - (a_0 x_0^3 + a_1 x_1^3) = -a_0 x_0^3 - a_1 x_1^3 = 0 \rightsquigarrow a_0 x_0^3 = -a_1 x_1^3$$

$$\longrightarrow \begin{cases} a_0 = -a_1 + 2 \\ a_0 x_0 = -a_1 x_1 \\ a_0 x_0^2 = -a_1 x_1^2 + \frac{2}{3} \\ a_0 x_0^3 = -a_1 x_1^3 \end{cases} \quad \begin{cases} a_0 = -a_1 + 2 \\ -a_1 x_0 + 1 x_0 = -a_1 x_1 \\ a_1 x_0^3 = -a_1 x_1^3 + \frac{2}{3} \\ a_1 x_0^3 = -a_1 x_1^3 \end{cases} \quad \begin{cases} a_0 = -a_1 + 2 \rightarrow a_0 = \frac{2x_1}{x_1 - 1} \\ a_1 = \frac{-2x_0}{x_1 - x_0} \\ 2x_1 x_0^2 - 2x_1^2 x_0 = \frac{2}{3} x_1 - \frac{2}{3} x_0 \\ 2x_1 x_0^3 = 2x_0 x_1^3 \end{cases} \quad \begin{cases} a_0 = \frac{2x_1}{x_1 - 1} \\ a_1 = \frac{-2x_0}{x_1 - x_0} \\ x_1 = -\frac{x_0}{3} \\ x_0 = \frac{\sqrt{3}}{3} x_1 = -\frac{\sqrt{3}}{3} \end{cases} \quad \begin{cases} a_0 = 1 \\ a_1 = 1 \\ x_1 = \frac{\sqrt{3}}{3} \\ x_0 = -\frac{\sqrt{3}}{3} \end{cases}$$

$$\longrightarrow \boxed{J_1(f) = f\left(-\frac{\sqrt{3}}{3}\right) + f\left(\frac{\sqrt{3}}{3}\right)}$$

qual'è il grado di precisione?

$E_1(x^4) = \int_{-1}^{1} x^4\,dx - J_1(x^4) = \frac{2}{5} - \left(\frac{2}{9} + \frac{2}{9}\right) = \frac{2}{5} - \frac{4}{9} = \frac{2}{45} \neq 0 \Rightarrow$ il grado è esattamente 3

teorema: il sistema non lineare $(*)$ ammette sempre un unica soluzione per ogni intervallo $[a,b]$, peso $f(x)$ e numero di nodi $(n+1)$
- in particolare, c'è un'unica formula di quadratura con $(n+1)$ nodi che ha grado almeno $(2n+1)$ e tale formula viene detta FORMULA DI QUADRATURA GAUSSIANA

errore delle formule di quadratura

Studiamo come si comporta l'errore per formule in generale, non necessariamente Gaussiane (immaginiamo di essere in uno scenario dove gli x_j sono dati)

vale il seguente teorema di rappresentazione dell'errore:

teorema di Peano: $f(x) \in C^{m+1}([a,b])$, con $J_n(f)$ formula con grado di precisione $m \in \mathbb{N}$

allora: $E_n(f) = I(f;f) - J_n(f) = \frac{1}{m!} \int_a^b f^{(m+1)}(t) \cdot G(t)\,dt$

dove $G(t) = E_n(\Delta_m(x-t))$ è detta NUCLEO DI PEANO

$G(t): [a,b] \to \mathbb{R}$, $t \to \int_a^b \Delta_m(x-t) f(x)\,dx - J_n(\Delta_m(x-t)) = \int_t^b (x-t)^m f(x)\,dx - J_n(\Delta_m(x-t))$

$\Delta_m(x) = \begin{cases} x^m & x \geq 0 \\ 0 & x < 0 \end{cases}$ (*)

esempio: (nucleo di Peano per la formula dei trapezi)

$J_1(f) = f(-1) + f(1)$ $\quad (f(x) = 1, [a,b] = [-1,1])$

$\Delta_m(x-t) = \Delta_1(x-t) = \begin{cases} x-t & x \geq t \\ 0 & x < t \end{cases}$

$$G(t) = \int_t^1 (x-t)\,dx - \left[\Delta_m(-1-t) + \Delta_m(1-t)\right] = \frac{(x-t)^2}{2}\Big|_t^1 - \left[0 + 1 - t\right] = \frac{(1-t)^2}{2} - (1-t) = \boxed{\frac{t^2-1}{2}}$$

$\Delta_m(-1-t) = 0$ $\forall t \in [-1,1]$ (*)

(caso $f(x) = 1$)

errore dei trapezi $E_1(f) = \int_{-1}^{1} f''(t) \cdot \frac{t^2-1}{2}\,dt$

(*) $E_n(f) = \frac{1}{m!} \int_a^b f^{(m+1)}(t) \cdot G(t)\,dt$ → se $G(t)$ non cambia segno per $t \in [a,b]$, allora (per il teorema della media integrale) l'espressione (*) è uguale a $\frac{1}{m!} f^{(m+1)}(\xi) \cdot \int_a^b G(t)\,dt$ (per un certo $\xi \in [a,b]$)

questa parte non dipende da f e si può trovare con un "trucchetto" → se si valuta l'espressione precedente per $f = x^{m+1}$ si ottiene che $E_n(x^{m+1}) = \frac{1}{m!} \cdot ((m+1)!) \cdot \int_a^b G(t)\,dt = (m+1) \int_a^b G(t)\,dt \Longrightarrow \int_a^b G(t)\,dt = \frac{E_n(x^{m+1})}{m+1}$

per cui si ha: **corollario**: $f \in C^{m+1}([a,b])$, $J_n(f)$ con grado di precisione m e tale che il nucleo di Peano $G(t)$ non cambia segno per $t \in [a,b]$, allora:

$$E_n(f) = \frac{f^{(m+1)}(\xi)}{(m+1)!} \cdot E_n(x^{m+1}), \text{ per un certo } \xi \in [a,b]$$

lezione 17 (29/04/2024)

29 April 2024 08:31

approssimazione: $\int_a^b f(x)\cdot f(x)dx \approx \sum_{i=0}^{n} a_i f(x_i)$

$(n+1)$ nodi (punti dove è noto il valore di f) x_i

$(n+1)$ pesi $\rightsquigarrow a_i$ (definiti per ogni f, scelti in maniera tale che la formula sia accurata)

$f(x)$ funzione peso $\quad f(x)\geq 0 \quad \forall x\in[a,b]$

$\int_a^b x^k\cdot f(x) = m_k < +\infty \quad \forall k\in\mathbb{N}$ → momenti della funzione peso

il grado di precisione $m\in\mathbb{N}$ di una formula di quadratura ?? come l'intero positivo tale che: $E_n(1)=E_n(x)=\dots=E_n(x^m)=0$, $E_n(x^{m+1})\neq 0$

↳ $E_n(\cdot)=\int_a^b\cdot f(x)dx - J_n(\cdot)$

per quanto riguarda l'errore di una formula di quadratura, abbiamo visto che se il nucleo di Peano $G(t)$ non cambia mai segno in $[a,b]$ e $f\in C^{m+1}([a,b])$, allora: $E_n(f)=\int_a^b f\,f(x)dx - \underbrace{\sum_{i=0}^{n} a_i f(x_i)}_{J_n(f)} = \frac{f^{(m+1)}(\xi)}{(m+1)!}\cdot E_n(x^{m+1})$ con $\xi\in[a,b]$

esempio: (formula dei trapezi) partiamo con $[a,b]=[-1,1]$

$m=1 \quad E_1(f)=\frac{f''(\xi)}{2!}\cdot E_1(x^2)=\frac{f''(\xi)}{2}\cdot\left(\int_{-1}^{1}x^2dx - J_1(f)\right)=\frac{f''(\xi)}{2}\cdot\left(\frac{2}{3}-2\right)=\frac{f''(\xi)}{2}\cdot\left(-\frac{4}{3}\right)=-\frac{2}{3}f''(\xi)$

$J_1(f)=f(-1)+f(1)$ → da valutare in x^2

su $[a,b]$ cambia $E_1(x^2)=\int_a^b x^2dx-\left[\frac{b-a}{2}(f(a)+f(b))\right]=\frac{b^3-a^3}{3}-\frac{b-a}{2}(a^2+b^2)=\frac{2b^3-2a^3-3ba^2-3b^3+3a^3+3ab^2}{6}=\frac{-b^3+a^3-3ba^2+3ab^2}{6}=-\frac{(b-a)^3}{6}$ $\rightsquigarrow$ $E_1(f)=\frac{f''(\xi)}{2}\cdot\left[-\frac{(b-a)^3}{6}\right]=-\frac{f''(\xi)}{12}\cdot(b-a)^3$

→ nel caso dei trapezi il nucleo di Peano non cambia segno e si vede graficamente

$G(t)=E_n(\Delta_m(x-t))=\int_a^b\Delta_m(x-t)dx - J_n(\Delta_m(x-t))\leq 0$

↳ $\Delta_m(x)=\begin{cases}x^m & \text{se } x\geq 0\\ 0 & \text{se } x\leq 0\end{cases}$

possiamo spostare la t, ma l'area rimarrà sempre più piccola di quella del triangolo

↳ anche la formula di Simpson ha questa proprietà ($G(t)$ di segno costante) per cui si può usare la formula per il resto

→ nel caso di Simpson abbiamo $m=3$, per cui ci serve di calcolare $E_2(x^{m+1})=E_2(x^4)$ $\longrightarrow$ nel caso $[-1,1]$ si ha $E_2(x^4)=\frac{2}{5}-\frac{1}{3}\underbrace{\left[1+0+1\right]}_{\frac{1}{3}[f(a)+4f(\frac{a+b}{2})+f(b)]}=\frac{2}{5}-\frac{2}{3}=-\frac{4}{15}$

$E_2(f)=-\frac{4}{15}\cdot\frac{f^{(4)}(\xi)}{4!}=-\frac{1}{90}f^{(4)}(\xi)\qquad \xi\in[a,b]$

a casa, caso $[a,b]$ $\rightsquigarrow$ $-\frac{(b-a)^5}{2880}f^{(4)}(\xi)$

formule interpolatorie:

abbiamo $\int_a^b f(x)f(x)dx$, selezioniamo $(a\leq x_0<x_1<\dots<x_n\leq b)$ $n+1$ nodi di interpolazione in $[a,b]$

Si considera $P_n(x)$ polinomio di grado al più n, che interpola f nei nodi x_j: $f(x_j)=P_n(x_j)\quad \forall j=0,\dots,n$ (sappiamo che esiste ed è unico), e scriviamo $P(x)=P_n(x)+R_n(x)$ (funzione resto)

↳ sostituendo questa espressione nell'integrale, si ha: $\int_a^b f(x)f(x)dx=\int_a^b(P_n(x)+R_n(x))f(x)dx=\boxed{\int_a^b P_n(x)f(x)dx}+\int_a^b R_n(x)f(x)dx$ (parte che scegliamo come approssimazione dell'integrale)

sappiamo che $P_n(x)=\sum_{j=0}^{n} f(x_j)\cdot\ell_j(x)$ $\longrightarrow$ per cui: $\int_a^b P_n(x)f(x)dx=\int_a^b\sum_{j=0}^{n}\boxed{f(x_j)}\ell_j(x)\cdot f(x)dx=\sum_{j=0}^{n}f(x_j)\underbrace{\boxed{\int_a^b\ell_j(x)f(x)dx}}_{a_j}$ (valutazione della funzione nei nodi di interpolazione)

$\rightsquigarrow$ otteniamo una formula di quadratura in cui i nodi di interpolazione coincidono con i nodi della formula, e in cui i pesi a_j sono: $a_j=\int_a^b\ell_j(x)f(x)dx \qquad j=0,\dots,n$

↳ $\ell_j(x)=\prod_{\substack{i=0\\ i\neq j}}^{n}\frac{(x-x_i)}{(x_j-x_i)}$

per l'errore che si commette si ha: $E_n(f)=\int_a^b R_n(x)f(x)dx$

e per $f\in C^{n+1}([a,b])$ sappiamo che $R(x)=\frac{\pi(x)}{(n+1)!}\cdot f^{(n+1)}(\xi_x)$ (*) $\xi_x\in[a,b]$

↳ $\pi(x)=\prod_{j=0}^{n}(x-x_j)$

osservazione: se non si può usare il teorema di Peano ($G(t)$ cambia segno) si può utilizzare (*) per provare a stimare l'errore

osservazione: (grado di precisione) per costruzione, una formula interpolatoria su $n+1$ nodi è esatta su tutti i polinomi di grado n. quindi una tale formula ha grado di precisione $\geq n$. d'altro canto, fissati dei nodi (sempre $n+1$) esiste un'unica formula di quadratura che ha grado di precisione $\geq n$ (perché risolve un sistema lineare con matrice Vandermonde, trasposta)

quindi: fissati i nodi $x_0,\dots,x_n$, l'unica formula che ha grado di precisione almeno n è la formula interpolatoria su questi nodi

→ in base a come scegliamo i nodi, diamo nomi differenti alle formule interpolatorie; le più importanti sono: le formule di Newton-Cotes $\rightsquigarrow$ $x_0,\dots,x_n$ equispaziati in $[a,b]$

le formule Gaussiane $\rightsquigarrow$ $x_0,\dots,x_n$ scelti in modo da massimizzare il grado di precisione

formule di Newton-Cotes:

nodi: $x_0=a<x_1=a+h<x_2=x_1+h=a+2h<\dots<x_n=b$

$h=\frac{b-a}{n}$ ↳ numero di intervalli

↳ passo della formula di quadratura

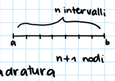

i pesi si trovano valutando $(f(x)=1)$ $a_i=I(\ell_i(x))=\int_a^b\ell_i(x)dx$, oppure risolvendo il sistema lineare derivante da $E_n(1)=E_n(x)=\dots=E_n(x^n)=0$

trapezi e Simpson sono i casi $n=2$ e $n=3$

↳ proprietà: fino ad $n=7$ (8 nodi) i pesi a_j risultano essere positivi e questa proprietà viene persa (ovvero si hanno segni alternanti) quando $n>7$ ↳ in questo ultimo caso, ho formule più instabili numericamente e di solito si considerano solo i casi $n\leq 7$

quando si vuole più accuratezza conviene quindi spezzare l'intervallo $[a,b]$ e fare stime degli integrali nei sottointervalli piuttosto che aumentare il numero di nodi della formula

proprietà: il nucleo di Peano delle formule di Newton-Cotes non cambia segno in $[a,b]$ $\rightsquigarrow$ formula di rappresentazione del resto $\rightsquigarrow$ $E_n(f)=\frac{f^{(m+1)}(\xi)}{(m+1)!}\cdot E_n(x^{m+1})$

in particolare è utile scriversi $E_n(f)$ come funzione di h: $E_n(f)=\begin{cases}c_n\cdot h^{n+2}\cdot f^{(n+2)}(\xi) & \text{quando } n \text{ è dispari}\\ c_n\cdot h^{n+3}f^{(n+3)}(\xi) & \text{quando } n \text{ è pari}\end{cases}$

↳ se il passo della formula (h) è piccolo, allora l'errore va a zero

esempi: trapezi $\xrightarrow{n=1,\ h=b-a}$ $-\frac{(b-a)^3}{12}f''(\xi)=-\underbrace{\frac{1}{12}}_{c_1}h^3f''(\xi)$

Simpson $\xrightarrow{n=2,\ h=\frac{b-a}{2}}$ $-\frac{(b-a)^5}{2880}f^{(4)}(\xi)=\underbrace{\frac{1}{90}}_{c_2}h^5f^{(4)}(\xi)$

stesso ordine (h^5)

• Newton-Cotes per $n=3$ si ottiene una formula detta "dei 3/8": $J_3(f)=\frac{b-a}{8}\left[f(x_0)+3f(x_1)+3f(x_2)+f(x_3)\right]$

$E_3(f)=-\frac{3}{80}h^5f^{(4)}(\xi)$

osservazione: le formule Newton-Cotes possono essere definite escludendo a e b, in quel caso si parla di formule di Newton-Cotes aperte

formule Gaussiane:

formule interpolatorie su nodi che ottimizzano il grado di precisione

i nodi $x_0,\dots,x_n$ si esprimono come zeri di polinomi ortogonali rispetto alla funzione $f(x)$

definizione: sia $\Pi=\{\text{polinomi con coefficienti reali}\}$ e consideriamo il prodotto scalare $p(x),q(x)\in\Pi$, $\langle p(x),q(x)\rangle=\int_a^b p(x)q(x)f(x)dx$ $\longrightarrow$ questo è uno spazio vettoriale, con prodotto scalare

definizione: $\Pi^*=\left\{q_i(x)\in\Pi_{i=0,1,2,\dots},\ \deg(q_i)=i,\ \langle q_i,q_j\rangle=\begin{cases}0 & i\neq j\\ c_i & i=j\end{cases}\right\}$ $\longrightarrow$ si dice famiglia di polinomi ortogonali su $[a,b]$ rispetto al peso $f(x)$

proprietà:
- gli elementi di Π^* sono univocamente determinati a meno di costanti
- i polinomi in Π^* di grado $\leq j$, generano tutti i polinomi di grado al più j
- $\langle p(x),q_n(x)\rangle=0$ $\forall p(x)$ di grado $\leq n-1$
- $q_n(x)$ ha n zeri semplici contenuti in $[a,b]$ $\forall n\in\mathbb{N}$, questi coincidono con i nodi della formula gaussiana a n nodi, per l'intervallo $[a,b]$ rispetto al peso $f(x)$

lemma: $q_n(x)$ polinomio ortogonale su $[a,b]$ con peso $f(x)$, allora $q_n(x)$ ha n zeri semplici in $[a,b]$

dimostrazione: supponiamo che ci siano $k<n$ zeri in $[a,b]$ e che siano $h\leq k$ di grado (/ molteplicità) dispari: $z_1,\dots,z_h$, allora consideriamo $p_h(x)=\prod_{j=1}^{h}(z-z_j)$ e osserviamo che $\langle p_h(x),q_n(x)\rangle=0$ perché $\deg(p_h)=h<\deg(q_n)$

$\int_a^b\underbrace{p_h(x)q_n(x)f(x)}_{\text{questa ha segno costante su }[a,b]}dx\neq 0$ $\quad\frac{1}{\downarrow}$ → contraddizione

esempi:
- polinomi di Chebyshev di 1° specie: su $[a,b]=[-1,1]$, $f(x)=\frac{1}{\sqrt{1-x^2}}$

$x_i=-\cos\left(\frac{2(i+1)\pi}{2(n+1)}\right)$, $a_i=\frac{\pi}{n+1}$

$T_0(x)=1$, $T_1(x)=x$, $T_{i+1}(x)=2xT_i(x)-T_{i-1}(x)$

- polinomi di Legendre: su $[a,b]=[-1,1]$, $f(x)=1$

$P_0(x)=1$, $P_1(x)=x$, $(i+1)P_{i+1}(x)=(2i+1)xP_i(x)-iP_{i-1}(x)$

→ è sufficiente che $f\in C([a,b])$ per avere $\lim_{n\to+\infty}J_n(f)=I(f,f)$ quando si usano formule gaussiane...

lezione 18 (03/05/2024)

03 May 2024 11:11

$\int_a^b f(x)\,dx \approx \sum_{i=0}^{n} a_i f(x_i)$ (nodi, pesi) → le formule di Newton-Cotes sono quelle che si ottengono sostituendo $f(x)$ con $P_n(x)$ (polinomio interpolante di grado al più n) che interpola f nei nodi equispaziati in $[a,b]$

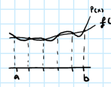

$\int_a^b f(x)\,dx \approx \int_a^b P_n(x)$

$n=1 \rightsquigarrow$ formula dei trapezi: $\int_a^b f(x)\,dx \approx \frac{b-a}{2}\cdot[f(a)+f(a)]$

$n=2 \rightsquigarrow$ formula di Simpson: $\int_a^b f(x)\,dx \approx \frac{b-a}{6}\left[f(a)+4f\left(\frac{a+b}{2}\right)+f(b)\right]$

errore delle formule di Newton-Cotes dipende dall'ampiezza: $b-a$ (quanto è "largo" l'intervallo)

$$E_n(f)=\begin{cases} C_n\cdot h^{n+2}\cdot f^{(n+1)}(\varepsilon) & n \text{ dispari} \\ C_n\cdot h^{n+3}\cdot f^{(n+2)}(\varepsilon) & n \text{ pari} \end{cases} \qquad \varepsilon\in[a,b]$$

$h=\frac{b-a}{n}$ (passo della formula)

ci aspettiamo che se h è "grande", l'errore non è assicurato essere piccolo

<u>domanda</u>: cosa si può fare per migliorare l'accuratezza?

abbiamo due possibilità: ① si aumentano i nodi nella formula di Newton-Cotes

② si spezza $[a,b]$ in sottointervalli più piccoli e si stimano gli integrali nei sottointervalli singolarmente

per quanto riguarda ①, quando si prende $n>7$ la formula di Newton-Cotes diventa instabile numericamente

↳ di solito si persegue la strada ②, l'idea è che se $c\in[a,b] \rightsquigarrow \int_a^b f(x)dx=\int_a^c f(x)dx+\int_c^b f(x)dx$

stima con una formula di Newton-Cotes; stima con un'altra

<u>formalmente</u>: se vogliamo L sottointervalli si scelgono $L+1$ punti equispaziati in $[a,b]$: $x_0=a<x_1=x_0+\tilde{h}<x_2=x_1+\tilde{h}<\dots<x_L=b$

↳ $\tilde{h}=\frac{b-a}{L}$ e si considera $\int_a^b f(x)\,dx=\sum_{i=1}^{L}\int_{x_{i-1}}^{x_i} f(x)dx \approx \sum_{i=1}^{L} J_n^{[x_{i-1},x_i]}(f)$ ← formula di N.C. con $n+1$ nodi in $[x_{i-1},x_i]$

fare questo procedimento ci "costringe" a valutare f nei punti $x_0,\dots,x_L$ ed inoltre in eventuali altri punti interni ai singoli intervalli

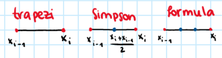

- punti compresi in $x_0,\dots,x_L$
- punti aggiuntivi

↳ quanti nodi servono in generale? Se usiamo una formula di N.C. con $n+1$ nodi ci servono $n+1-2=n-1$ punti aggiuntivi in ogni intervallo → quindi in totale abbiamo $(n-1)L+(L+1)=\boxed{nL+1}$

<u>osservazione</u>: per una formula di N.C. generalizzata sono necessarie $n\cdot L+1$ valutazioni di $f(x)$ dove L n° sottointervalli, n ordine della formula

<u>esempi</u>: formula dei trapezi generalizzata (o composita)

$$\int_a^b f(x)dx=\sum_{i=1}^{L}\int_{x_{i-1}}^{x_i} f(x)dx \approx \sum_{i=1}^{L}\left[\tfrac{x_i-x_{i-1}}{2}\cdot(f(x_{i-1})+f(x_i))\right]=\frac{b-a}{2L}\sum_{i=1}^{L}\left[f(x_{i-1})+f(x_i)\right]=\boxed{\frac{b-a}{2L}\left(f(x_0)+2\sum_{i=1}^{L-1}f(x_i)+f(x_L)\right)=:J_1^{(G)}(f)}$$

numero di nodi: $L+1$ ($x_0,\dots,x_L$)

formula di Cavalieri-Simpson generalizzata (o composita) (ogni intervallo è largo $\frac{b-a}{L}$)

$$\int_a^b f(x)dx=\sum_{i=1}^{L}\int_{x_{i-1}}^{x_i} f(x)dx \approx \sum_{i=1}^{L}\frac{x_i-x_{i-1}}{6}\left(f(x_i)+4f\left(\frac{x_i+x_{i-1}}{2}\right)+f(x_{i-1})\right)=\frac{b-a}{6L}\sum_{i=1}^{L}\left[f(x_i)+4f\left(\frac{x_i+x_{i-1}}{2}\right)+f(x_{i-1})\right]=\boxed{\frac{b-a}{6L}\left[f(x_0)+2\sum_{i=1}^{L-1}f(x_i)+4\sum_{i=1}^{L}f\left(\frac{x_i+x_{i-1}}{2}\right)+f(x_L)\right]=:T_2^{(G)}(f)}$$

numero dei nodi: $2L+1$

<u>errore delle formule generalizzate</u>:

in ogni intervallo $[x_{i-1},x_i]$ l'errore di una formula di N.C. è della forma: $c\cdot h^{\alpha}\cdot f^{(\alpha-1)}(\varepsilon)$, $\varepsilon\in[x_{i-1},x_i]$

se sommiamo su tutti gli intervalli si ottiene: $E^{(G)}(f)=\sum_{i=1}^{L} c\cdot h^{\alpha} f^{(\alpha-1)}(\varepsilon_i)=c\cdot h^{\alpha}\sum_{i=1}^{L} f^{(\alpha-1)}(\varepsilon_i)=c\cdot h^{\alpha}\cdot L\left(\frac{\sum f^{(\alpha-1)}(\varepsilon)}{L}\right)=\boxed{c\cdot h^{\alpha}\cdot L\cdot f^{(\alpha-1)}(\bar{\varepsilon})}$

media dei valori di $f^{(\alpha-1)}$ in vari punti in $[a,b]$; $h=\frac{b-a}{nL}$

per il teorema dei valori intermedi $\exists\,\bar{\varepsilon}\in[a,b]: f^{(\alpha-1)}(\bar{\varepsilon})=\frac{\sum f^{(\alpha-1)}(\varepsilon)}{L}$

$$E_n^{(G)}=\begin{cases} C_n\cdot\frac{(b-a)^{n+2}}{L^{n+1}}f^{(n+1)}(\varepsilon) & \text{se } n \text{ dispari} \\ C_n\cdot\frac{(b-a)^{n+3}}{L^{n+2}}f^{(n+2)}(\varepsilon) & \text{se } n \text{ pari} \end{cases}$$ (numero di nodi)

trapezi $\rightsquigarrow E_1^{(G)}=-\frac{(b-a)^3}{12L^2}f^{(2)}(\varepsilon)$ $\varepsilon\in[a,b]$

Simpson $\rightsquigarrow E_2^{(G)}=-\frac{(b-a)^5}{2880L^4}f^{(4)}(\varepsilon)$ $\varepsilon\in[a,b]$

<u>osservazione</u>: il grado di precisione delle formule generalizzate coincide con le formule base

---

<u>esercizio</u>: approssimare $\int_0^1 \frac{1}{1+x}\,dx$ con la formula dei trapezi generalizzata e supponiamo di voler commettere un errore in modulo minore di 10^{-4}

dare una stima del numero di sottointervalli L che ci servono

vogliamo $|E_1^{(G)}|\le 10^{-4}$ $f(x)=\frac{1}{1+x}$ è derivabile quante volte vogliamo su $[0,1]$

→ quindi $E_1^{(G)}=-\frac{1}{12L^2}\cdot f''(\varepsilon)$ $\varepsilon\in[0,1]$

idea: $|E_1^{(G)}|\le\frac{1}{12L^2}\max_{x\in[0,1]}|f''(x)|$

$f''(x)=\frac{2}{(1+x)^3} \rightsquigarrow \max_{[0,1]}|f''|\le\frac{2}{1+0}=2$

imponiamo che $\frac{1}{12L^2}\cdot 2\le 10^{-4} \Rightarrow L^2=\frac{10^4}{6} \Rightarrow L\ge\frac{10^2}{\sqrt{6}}=50\sqrt{\frac{2}{3}} \Rightarrow L\ge 40{,}82\dots \rightsquigarrow$ prendiamo $L=$

MANCA REGISTRAZIONE

<u>formule di quadratura che coinvolgono derivate di f</u>: niente vieta di generalizzare le formule di quadratura a espressioni del tipo: $\sum_{i=0}^{n_a} f(x_i)\cdot a_i+\sum_{i=0}^{n_b} f'(x_i)\cdot b_i+\sum_{i=0}^{n_d} f^{(n_{d,i})}(\bar{x}_i)\cdot c_i \approx \int_a^b f(x)dx$

dati i nodi in cui si conosce il valore della funzione e/o delle sue derivate, ci si può chiedere qual'è la scelta dei pesi che massimizzano il grado di precisione della formula

si procede nella maniera usuale determinando i pesi, in modo da avere $E(1)=E(x)=\dots=E(x^m)=0$ per m più grande possibile

→ il problema da risolvere è un sistema lineare dove le incognite sono i pesi della formula

<u>esempio</u>: $\int_0^1 f(x)dx \approx a_1 f(0)+a_2 f'(\frac{1}{3})+a_3 f'(\frac{2}{3})+a_4 f(1)$

determinare a_1,a_2,a_3,a_4 in modo da rendere massimo il grado di precisione e determinarlo

sistema lineare da risolvere:

$$\begin{cases} \int_0^1 1\,dx=1=a_1+a_4 \\ \int_0^1 x\,dx=\frac{1}{2}=\frac{1}{3}a_2+\frac{2}{3}a_3+a_4 \\ \int_0^1 x^2dx=\frac{1}{3}=\frac{2}{3}a_2+\frac{4}{3}a_3+a_4 \\ \int_0^1 x^3dx=\frac{1}{4}=\frac{1}{3}a_2+\frac{4}{3}a_3+a_4 \end{cases}$$

($f(x)=x^2 \rightarrow f'(x)=2x \rightarrow f'(\frac{1}{3})=\frac{2}{3}$)

$$\Rightarrow \begin{cases} 1=a_1+a_4 \\ \frac{1}{2}=a_2+a_3+a_4 \\ \frac{1}{3}=\frac{2}{3}a_2+\frac{4}{3}a_3+a_4 \\ \frac{1}{4}=\frac{1}{3}a_2+\frac{4}{3}a_3+a_4 \end{cases} \begin{cases} a_4=1-a_1 \\ \frac{1}{2}=a_2+a_3+1-a_1 \\ \frac{1}{3}=\frac{2}{3}a_2+\frac{4}{3}a_3+1-a_1 \\ \frac{1}{4}=\frac{1}{3}a_2+\frac{4}{3}a_3+1-a_1 \end{cases} \begin{cases} a_4=1-a_1 \\ a_3=-\frac{1}{2}-a_2+a_1 \rightarrow a_3=-\frac{1}{2}+a_2 \\ \cancel{1}=\cancel{2a_2}-\cancel{2}-\overset{2}{\cancel{4}}a_2+\cancel{4}a_1-\cancel{3}a_1 \rightarrow a_1=2a_2 \\ -\frac{3}{4}=\frac{4}{3}a_2-\frac{2}{3}+\frac{4}{3}a_2-2a_2 \rightarrow a_2=\frac{1}{4} \end{cases} \begin{cases} a_1=\frac{1}{2} \\ a_2=\frac{1}{4} \\ a_3=-\frac{1}{4} \\ a_4=\frac{1}{2} \end{cases}$$

$\int_0^1 f(x)dx \approx \boxed{\frac{1}{2}f(0)+\frac{1}{4}f'(\frac{1}{3})-\frac{1}{4}f'(\frac{2}{3})+\frac{1}{2}f(1)}$

→ grado di precisione? è almeno 3

$E_3(x^4)=\int_0^1 x^4dx-\left[\frac{1}{2}(0)+\frac{1}{\cancel{4}}\cdot(\frac{\cancel{4}}{27})-\frac{1}{\cancel{4}}\cdot(\frac{\cancel{8}}{27})+\frac{1}{2}(1)\right]=\frac{1}{5}-\frac{1}{27}+\frac{2}{27}-\frac{1}{2}=\frac{1}{5}+\frac{1}{27}-\frac{1}{2}=\frac{27+5}{135}-\frac{1}{2}=\frac{32}{135}-\frac{1}{2}\neq 0$ ✗ $\Rightarrow$ il grado di precisione è esattamente 3!

<u>esercizio</u>: $\int_{-c}^{c}|x|\cdot f(x)\,dx \approx a f(x_0)+b f(x_1)$ $\rho(x)=|x|$

determinare i valori dei parametri a,b,c,x_0,x_1 con $c\neq 0$ per cui il grado di precisione massimo

sistema non lineare:

$$\begin{cases} \int_{-c}^{c}1\cdot|x|dx=\int_{-c}^{0}-x\,dx+\int_0^c x\,dx=\frac{c^2}{2}+\frac{c^2}{2}=c^2=a+b \\ \int_{-c}^{c}x\cdot|x|dx=\int_{-c}^{0}-x^2dx+\int_0^c x^2dx=0=ax_0+bx_1 \\ \int_{-c}^{c}x^2\cdot|x|dx=\int_{-c}^{0}-x^3dx+\int_0^c x^3dx=\frac{c^4}{2}=ax_0^2+bx_1^2 \\ \int_{-c}^{c}x^3\cdot|x|dx=\int_{-c}^{0}-x^4dx+\int_0^c x^4dx=0=ax_0^3+bx_1^3 \end{cases}$$

$$\Rightarrow \begin{cases} a+b=c^2 \\ ax_0+bx_1=0 \\ ax_0^2+bx_1^2=\frac{c^4}{2} \\ ax_0^3+bx_1^3=0 \end{cases}$$ ($x_1=-x_0$)

$ax_0^3-bx_0^3=0$

$x_0^3(a-b)=0$

$x_0=0$ ↳ $\boxed{a=b}$ → sostituisco nella 1°: $a+a=c^2$, $2a=c^2$, $\boxed{a=\frac{c^2}{2}=b}$ → sostituisco nella 3°

$\frac{c^2}{2}x_0^2+\frac{c^2}{2}x_0^2=\frac{c^4}{2}$

$c^2x_0^2=\frac{c^4}{2} \rightsquigarrow x_0^2=\frac{c^2}{2} \rightsquigarrow x_0=-\frac{c}{\sqrt{2}}$, $x_1=\frac{c}{\sqrt{2}}$

moltiplico per $-x_0^2$ e sommo alla 4°: $-ax_0^3-bx_1x_0^2=0 \rightarrow bx_1(x_1^2-x_0^2)=0 \rightarrow bx_1(x_1+x_0)(x_1-x_0)=0$ ($\neq 0$ perché i nodi devono essere distinti $x_0\neq x_1$)

$x_1=0$ (la scartiamo perché porta ad un assurdo); $x_1=-x_0$

$$\Rightarrow \begin{cases} a=\frac{c^2}{2} \\ b=\frac{c^2}{2} \\ x_0=-\frac{c}{\sqrt{2}} \\ x_1=\frac{c}{\sqrt{2}} \end{cases}$$

Con queste scelte si ha grado di precisione ≥ 3 $\forall c\neq 0$

vediamo se scegliendo si può ottenere un grado di precisione maggiore

↳ vediamo com'è fatto l'errore per x^4: (idea: se posso scegliere "c" in modo tale che l'errore venga zero, allora quello sarà il "c" da scegliere)

$\int_{-c}^{c}x^4\cdot|x|dx=\int_{-c}^{0}-x^5dx+\int_0^c x^5dx=\frac{c^6}{3}\overset{?}{=}\frac{c^2}{2}\left(\frac{c^4}{4}+\frac{c^4}{4}\right)=\frac{c^2}{2}\left(\frac{c^4}{2}\right)=\frac{c^6}{4} \rightarrow \frac{c^6}{3}\overset{?}{=}\frac{c^6}{4}$ ("c" non è mai zero, non è verificata)

✗ ↳ per ogni scelta di $c\in\mathbb{R}\setminus\{0\}$ il grado di precisione è esattamente 3!

lezione 19 (06/05/2024)

06 May 2024 08:43

equazioni non lineari

problema di interesse: risolvere $f(x)=0$, $f:\mathbb{R}\to\mathbb{R}$, $f(x)\neq a_1x+a_0$ (non lineare)

↳ in generale non esiste una formula/metodo diretto che permette di calcolare una o tutte le soluzioni di $f(x)=0$

definizione: le soluzioni di $f(x)=0$ si dicono **RADICI o ZERI di f**

esempio: se f polinomio di grado ≥ 5, non esiste una formula che esprime le 5 radici del polinomio in termini di funzioni elementari dei coefficienti (teoria galois)

per trovare gli zeri di funzioni non lineari si usano metodi iterativi del tipo: $\begin{cases} x_0, x_1, \dots, x_{r-1} \text{ dati} \\ x_{n+1} = \phi_n(x_n, x_{n-1}, \dots, x_{n-r+1}) \quad n=0,1,2,\dots \end{cases}$

definizione: metodi iterativi di questo tipo vengono detti **a k punti**, se il metodo utilizza la stessa funzione ad ogni passo ($\phi_n = \phi \ \forall n \in \mathbb{N}$), il metodo si dice **stazionario**

definizione: $\{x_n\}_{n\in\mathbb{N}}$ non è detta convergente ad α radice di f se ($f(\alpha)=0$) $\lim_{n\to+\infty} x_n = \alpha$

definizione: data una successione convergente ad α e indicando con $e_n := x_n - \alpha$ (successione degli errori), se esistono $p\geq 1$ e $c\neq 0$ tali che $\lim_{n\to+\infty} \frac{|e_{n+1}|}{|e_n|^p} = \lim_{n\to+\infty} \frac{|x_{n+1}-\alpha|}{|x_n-\alpha|^p} = c$ ($c<+\infty$), allora si dice che la successione converge con ordine p

↳ nei casi $p=1$ e $p=2$ si parla di convergenza lineare e convergenza quadratica

osservazione: nel caso $p=1$ osserviamo che $0<c<1$ (è necessario per la convergenza della successione)

osservazione: in generale metodi iterativi per problemi non lineari convergono solo localmente, ovvero partendo sufficientemente vicini dalle radici, per cui è importante cercare di determinare intervalli che sappiamo contenere una radice → per questo scopo si possono utilizzare strumenti di analisi matematica, ad esempio:

① $f\in C^0([a,b])$ e $a,b\in\mathbb{R}$: $f(a)\cdot f(b)<0$ allora $\exists$ almeno una radice $\alpha\in[a,b]$

② studio del segno della derivata

$f(x) = x\log(x) + \frac{1}{3}$ (vogliamo far vedere che ci sono 2 soluzioni di $f(x)=0$ su $(0,+\infty)$

$\lim_{x\to 0^+} x\log(x) + \frac{1}{3} = \frac{1}{3}$

$f'(x) = \log(x) + 1 \Rightarrow \begin{cases} f'>0 & x>e^{-1} \\ f'\leq 0 & x\leq e^{-1} \end{cases}$

$f(e^{-1}) = -e^{-1} + \frac{1}{3} = -\frac{1}{e} + \frac{1}{3} < 0 \Rightarrow$ 2 radici $\alpha_1 < \alpha_2$

$\alpha_1 \in (0, e^{-1})$, $\alpha_2 \in (e^{-1}, +\infty)$

③ separazione grafica: se $f(x) = g(x) - h(x)$, dove $g(x)$ e $h(x)$ hanno grafici o proprietà note, potrebbe essere conveniente riscrivere $f(x)=0$ come $g(x) = h(x)$, ovvero cercare le intersezioni fra grafico di g e grafico di h

esempio: $f(x) = 5x^2 - 2e^x$ $\quad y = 5x^2$, $y = 2e^x$

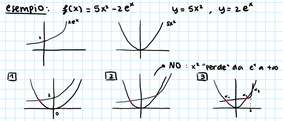

$g(2) = 2e^2 < 5\cdot 2^2$

$h(2) = 5\cdot 2^2 = 20$

$\alpha_1 \in (0,2)$

$\alpha_2 \in (2, +\infty)$

$\alpha < 0$ $\alpha \in (-\infty, 0)$

Supponiamo di aver identificato un intervallo $[a,b]$ in cui sappiamo esserci una sola radice α di $f(x)$

metodo di bisezione: (ricerca binaria)

Supponiamo che $f(a)\cdot f(b)<0$, $f\in C^0([a,b])$

$x_0 = a$, $x_1 = b$, $x_2 = \frac{a+b}{2}$

↳ se $f(x_1)\cdot f(x_2)<0 \Rightarrow \alpha\in[x_1, x_2] \Rightarrow x_3 = \frac{x_1+x_2}{2}$

altrimenti $f(x_2)\cdot f(x_1)<0 \Rightarrow \alpha\in[x_2, x_3] \Rightarrow x_3 = \frac{x_2+x_3}{2}$

→ per scriverlo in forma compatta consideriamo:

$\hat{x}_n = \begin{cases} \hat{x}_2 = \begin{cases} x_1 & \text{se } f(x_1)\cdot f(x_2)<0 \\ x_2 & \text{altrimenti} \end{cases} \\ \hat{x}_n = \begin{cases} x_{n-1} & \text{se } f(x_n)\cdot f(x_{n-1})<0 \\ \hat{x}_{n-1} & \text{altrimenti} \end{cases} \end{cases}$

$x_{n+1} = \frac{x_n + \hat{x}_n}{2}$ (in particolare è un metodo iterativo a 2 punti, non stazionario

osservazione: ad ogni passo si ha sicuramente $|x_{n+1}-\alpha| \leq \frac{b-a}{2^n} \Rightarrow \lim_{n\to+\infty} |x_n-\alpha| = 0$

come criterio d'arresto si può scegliere $\frac{b-a}{2^n} < \text{tol}$ (tolleranza) → che ci da immediatamente una stima del numero di iterazioni necessarie: $\frac{b-a}{2^n} < \text{tol} \Rightarrow n > \log_2\left(\frac{b-a}{\text{tol}}\right) \longrightarrow n = \left\lceil \log_2\left(\frac{b-a}{\text{tol}}\right)\right\rceil$

↳ la scegliamo noi

osservazione: l'ordine di convergenza è lineare ed in particolare $\lim_{n\to+\infty} \frac{|x_{n+1}-\alpha|}{|x_n-\alpha|} = \frac{1}{2}$, però è un po' lento, specialmente in contesti in cui valutare f è costoso ($$ o tempo)

metodo delle secanti:

metodo stazionario a 2 punti

$\begin{cases} x_{n+1} = x_n - f(x_n)\cdot \frac{x_n - x_{n-1}}{f(x_n)-f(x_{n-1})} \\ x_0, x_1 \Rightarrow \text{dati} \end{cases}$

teorema: $f\in C^2([a,b])$, e partite sufficientemente vicino a α, allora il metodo converge con ordine $p = \frac{1+\sqrt{5}}{2}$

metodi stazionari ad un punto:

$\begin{cases} x_0 \text{ dato/generato random} \\ x_{n+1} = \phi(x_n) \end{cases}$

↳ per scegliere $\phi(x)$ si può ad esempio considerare $\phi(x) = x - g(x)f(x)$ → con $g(x)$ funzione che non si annulla in intorno della radice

↳ se scegliamo una ϕ in questo modo, osserviamo che α radice di f è tale che $\phi(\alpha)=\alpha$ → $\phi(\alpha) = \alpha - g(\alpha)\underbrace{f(\alpha)}_{0} = \alpha$

cercare le radici di f è equivalente a cercare i **punti fissi di $\phi(x)$**

osservazione: se la successione (*) converge, allora necessariamente converge a un punto fisso di ϕ

$x_{n+1} = \phi(x_n) \iff \lim_{n\to+\infty} x_{n+1} = \lim_{n\to+\infty} \phi(x_n) \iff \alpha = \phi(\lim_{n\to+\infty} x_n) = \phi(\alpha)$

↓ supponiamo che $\lim_{n\to+\infty} x_n = \alpha$

↓

quando funziona?

teorema di convergenza locale: $I\subseteq\mathbb{R}$ intervallo, $\alpha\in I$, $\phi(\alpha)=\alpha$, $\phi\in C^1(I)$ e supponiamo che $\exists f\in\mathbb{R}^+$ e $k\in(0,1)$ tali che: $\forall x\in[\alpha-f, \alpha+f]$, $|\phi'(x)|\leq k$ allora: (i) $\forall x_0\in[\alpha-f,\alpha+f] \Rightarrow x_n\in[\alpha-f,\alpha+f] \ \forall n\in\mathbb{N}$

(ii) $\forall x_0\in[\alpha-f,\alpha+f]$, $\lim_{n\to+\infty} x_n = \alpha$

(iii) α è l'unico punto di ϕ in $[\alpha-f,\alpha+f]$

dimostrazione: (i) procediamo per induzione su n

$n=0$ → supponiamo la tesi vera per $x_0, x_1, \dots, x_n$

$|x_{n+1}-\alpha| = |\phi(x_n) - \phi(\alpha)| = |x_n-\alpha|\cdot|\phi'(\xi)| \leq k|x_n-\alpha| \leq \frac{k}{k}f \leq f \Rightarrow x_{n+1}\in[\alpha-f,\alpha+f]$

↳ teorema di lagrange ↳ $\xi\in(x_n,\alpha)$ in particolare $\xi\in[\alpha-f,\alpha+f]$ per ipotesi induttiva

(ii) $|x_{n+1}-\alpha| = |x_n-\alpha|\cdot|\phi'(\xi)| \leq k|x_n-\alpha| = k|\phi(x_n)-\phi(\alpha)| \leq k\underbrace{\phi'(\tilde{\xi})}_{\leq k}\cdot|x_{n-1}-\alpha| \leq k^2|x_{n-1}-\alpha| \leq \dots \leq k^n|x_0-\alpha| \leq k^n f$

$0 \leq \lim_{n\to+\infty} |x_{n+1}-\alpha| \leq \lim_{n\to+\infty} k^n f = 0 \Rightarrow \lim_{n\to+\infty} |x_n-\alpha| = 0$

(iii) supponiamo per assurdo che esistano $\alpha_1, \alpha_2 \in [\alpha-f,\alpha+f]$, $\phi(\alpha_1)=\alpha_1$, $\phi(\alpha_2)=\alpha_2$ allora:

$|\alpha_1-\alpha_2| = |\phi(\alpha_1)-\phi(\alpha_2)| = |\phi'(\xi)|\cdot|\alpha_1-\alpha_2| \leq k\cdot|\alpha_1-\alpha_2| < |\alpha_1-\alpha_2|$

$\xi\in[\alpha_1,\alpha_2]$, $\xi\in[\alpha-f,\alpha+f]$

lezione 20 (10/05/2024)

10 May 2024 10:46

$f(x)=0 \quad f:\mathbb{R}\to\mathbb{R}$ non lineare

metodi stazionari a un punto $\begin{cases} x_0 \text{ dato} \\ x_{n+1}=\phi(x_n) \quad n=1,2,3,\dots \end{cases}$

$\alpha: f(\alpha)=0 \iff \alpha=\phi(\alpha)$

teorema convergenza locale: se $\phi\in C^1$ e $|\phi'(\alpha)|<1$ allora partendo sufficientemente vicini a α il metodo di punto fisso converge

se prendo $x_0\in[\alpha-\rho,\alpha+\rho] \quad \rho>0 : |\phi'(x)|\le 1 \quad \forall x\in[\alpha-\rho,\alpha+\rho]$

osservazione: $x_{n+1}-\alpha=\phi(x_n)-\phi(\alpha)=(x_n-\alpha)\cdot\phi'(\varepsilon) \quad \varepsilon\in[x_n,\alpha]$ (↳ lagrange)

se $\phi'>0$ in $[x_n,\alpha]$ o $[\alpha,x_n]$

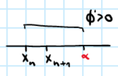

se la derivata ϕ' è >0 in un intorno destro o sinistro (o entrambi di α) allora la convergenza è monotona, ovvero:

$x_0<\alpha \implies x_0<x_1<x_2<\dots<\alpha$

$x_0>\alpha \implies x_0>x_1>x_2>\dots>\alpha$

se $\phi'<0$ intorno ad α

$(x_{n+1}-\alpha)=(x_n-\alpha)\cdot\phi'(\varepsilon)$ ($\phi'(\varepsilon)<0$) segno $x_{n+1}-\alpha$ è l'opposto di $x_n-\alpha$

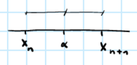

quindi qui è necessario che $|\phi'|<1$ in un intervallo simmetrico rispetto alla radice, per garantire la convergenza

$\phi'<0$ in $(\alpha-\rho,\alpha+\rho)$ allora $x_0<\alpha, x_1>\alpha, x_2<\alpha, x_3>\alpha,\dots$ ⇝ convergenza alternata

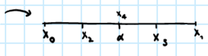

quanto in fretta converge un metodo di punto fisso?

teorema: sia $\phi(x)\in C^p(I)$, $\alpha\in I : \phi(\alpha)=\alpha$

allora $\exists\rho>0$ tale per cui se $x_0\in[\alpha-\rho,\alpha+\rho]$ la successione $\{x_n\}_{n\in\mathbb{N}}$ converge superlinearmente con ordine p se e solo se $\phi'(\alpha)=\phi''(\alpha)=\dots=\phi^{(p-1)}(\alpha)=0$, $\phi^{(p)}(\alpha)\neq 0$

$\{x_n\}$ converge superlinearmente con ordine $p>1$ se

$$\lim_{n\to+\infty}\frac{|x_{n+1}-\alpha|}{|x_n-\alpha|^p}=c<+\infty \qquad c\neq 0$$

quando $p=1$ si chiedeva $0<c<1$ ⇝ convergenza lineare

quando $p=1$ e $c=1$ (e sempre $\lim_{n\to+\infty}x_n=\alpha$) ⇝ convergenza sublineare

$|\phi'(\alpha)|=1$ e $|\phi'(x)|<1$ in $[\alpha-\rho,\alpha+\rho]-\{\alpha\}$

dimostrazione: $\Leftarrow$ se $\phi'(\alpha)=\phi''(\alpha)=\dots=\phi^{(r-1)}(\alpha)=0$, $\phi^{(r)}(\alpha)\neq 0$

consideriamo lo sviluppo di Taylor di ϕ in α

$$x_{n+1}=\phi(x_n)=\phi(\alpha)+(x_n-\alpha)\underbrace{\phi'(\alpha)}_{0}+\dots+\underbrace{\phi^{(p-1)}(\alpha)}_{0}\frac{(x_n-\alpha)^{p-1}}{(p-1)!}+\frac{(x_n-\alpha)^p}{p!}\phi^{(p)}(\varepsilon) \qquad \varepsilon\in[x_n,\alpha]$$

$$\implies x_{n+1}=\alpha+\frac{(x_n-\alpha)^p}{p!}\phi^{(p)}(\varepsilon) \implies x_{n+1}-\alpha=\frac{(x_n-\alpha)^p}{p!}\phi^{(p)}(\varepsilon)$$

$\varepsilon\in[x_n,\alpha] \xrightarrow{n\to+\infty}\alpha$

e quindi $\lim_{n\to+\infty}\frac{|x_{n+1}-\alpha|}{|x_n-\alpha|^p}=\lim_{n\to+\infty}\frac{\phi^{(p)}(\varepsilon)}{p!}=\frac{\phi^{(p)}(\alpha)}{p!}\neq 0$

$\implies$ prendiamo $1\le r\le p-1$ (r intero) facciamo vedere che $\phi^{(r)}(\alpha)=0$

per $r=1$ ($p=2$) $\lim_{n\to+\infty}\frac{|\phi(x_n)-\phi(\alpha)|}{|x_n-\alpha|}=\lim_{n\to+\infty}\frac{|x_n-\alpha|\,\phi'(\varepsilon)}{|x_n-\alpha|}=\lim_{n\to+\infty}\phi'(\varepsilon)=\phi'(\alpha)$ (0)

per induzione sappiamo che $\phi'(\alpha)=\phi''(\alpha)=\dots=\phi^{(r-1)}(\alpha)=0$

$$\phi(x_n)-\phi(\alpha)=\frac{(x_n-\alpha)\overbrace{\phi'(\alpha)}^{=0}}{1!}+\frac{(x_n-\alpha)^2\overbrace{\phi''(\alpha)}^{=0}}{2!}+\dots+\frac{(x_n-\alpha)^{r-1}\overbrace{\phi^{(r-1)}(\alpha)}^{=0}}{(r-1)!}+\frac{(x_n-\alpha)^r\overbrace{\phi^{(r)}(\alpha)}^{\neq 0}}{r!}=\frac{(x_n-\alpha)^r\phi^{(r)}(\alpha)}{r!}$$ ipotesi induttiva

$$0=\lim_{n\to+\infty}\frac{|x_{n+1}-\alpha|}{|x_n-\alpha|^r}=\lim_{n\to+\infty}\frac{|\phi(x_n)-\phi(\alpha)|}{|x_n-\alpha|^r}=\lim_{n\to+\infty}\frac{\phi^{(r)}(\varepsilon)}{r!}=\frac{\phi^{(r)}(\alpha)}{r!}\implies\phi^{(r)}(\alpha)=0$$

↳ perché la successione x_n converge con ordine $p>2$

commento: si possono avere ordine p non interi di convergenza solo se $\phi\notin C^1$

ad esempio la successione $\alpha=0$, $x_{n+1}=\sqrt{|x_n|^3}$ ha ordine di convergenza $\frac{3}{2}$

$$\lim_{n\to+\infty}\frac{|x_{n+1}-\alpha|}{|x_n-\alpha|^2}=c<+\infty \implies \lim_{n\to+\infty}\frac{|x_{n+1}-\alpha|}{|x_n-\alpha|}=0$$

esempio: ($\phi(x)=x-g(x)f(x)$, $f(x)=0$, $x=\phi(x)$, ma non solo)

$f(x)=x\log(x)-1$ $\alpha\in[1,e]$ si vede guardando ai punti di intersezione fra x e $\log(x)$

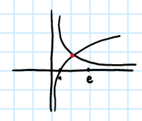

proviamo a vedere tre metodi di punto fisso: $x=\phi(x)$

$\phi_1(x)=\frac{1}{\log(x)}$, $\phi_2(x)=e^{1/x}$, $\phi_3(x)=\frac{x+1}{\log(x)+1}$

$x\log(x)-1=0 \rightsquigarrow \frac{1}{x}=\log(x) \rightsquigarrow e^{1/x}=x$

se $f(\alpha)=0$ (ovvero $\alpha\log(\alpha)-1=0 \rightsquigarrow \phi_3(\alpha)=\alpha$)

convergono? con quale ordine?

1) $\phi_1'(x)=\frac{1}{x}\left(-\frac{1}{\log^2(x)}\right)=-\frac{1}{x\log^2(x)}$ ($\alpha\log(\alpha)=1$)

$\phi_1'(\alpha)=-\frac{1}{\alpha\log^2(\alpha)}=-\frac{1}{\alpha\log(\alpha)\log(\alpha)}=\left|\frac{1}{\log(\alpha)}\right|>1$ ($\log(\alpha)\in(0,1)$) ⟶ metodo non converge

2) $\phi_2'(x)=-\frac{1}{x^2}e^{1/x}$

$\phi_2'(\alpha)=-\frac{1}{\alpha^2}e^{1/\alpha}=-\frac{1}{\alpha^2}\cdot\alpha=-\frac{1}{\alpha}$ ($\alpha=e^{1/\alpha}$, $\alpha\in(1,e)$) $\implies|\phi_2'(\alpha)|<1$ ⇝ metodo converge almeno linearmente poiché $|\phi'(\alpha)|\neq 0$

3) $\phi_3'(x)=\frac{\log(x)+1-(x+1)\cdot\frac{1}{x}}{(\log(x)+1)^2}=\frac{\log(x)-\frac{1}{x}}{(\log(x)+1)^2}=\frac{x\log(x)-1}{x(\log(x)+1)^2}$ ($f(x)$)

$\phi_3'(\alpha)=0$ ⇝ metodo converge almeno con ordine 2 ⟶ a casa $\phi_3''(x)=$

$\phi_3''(\alpha)=\frac{1}{\alpha(\log(\alpha)+1)}\neq 0$ ($\alpha\in(1,e)$, $\log(\alpha)+1>1$) ⟶ convergenza del metodo è quadratica

esercizio: $\phi(x)=1+a\log(x)+b\log^2(x)$ $a,b\in\mathbb{R}$

$\alpha=1$ è punto fisso di ϕ $\forall a,b\in\mathbb{R}$

Si discuta la convergenza di $x_n=\phi(x_{n-1})$ al variare di a,b, rispetto alla radice $\alpha=1$

(i) per quali valori la convergenza è monotona in un intorno di α?

(ii) se $a=0$ si dimostri che la convergenza è superlineare e si determini l'ordine. per quali b è monotona?

(i) $\phi'(x)=\frac{a}{x}+2b\frac{\log(x)}{x}$ ⇝ $\phi'(1)=a$

se $|a|<1$ il metodo converge, se $0<a<1$ converge in modo monotono

se $a=0$ converge in modo superlineare

(ii) $\phi(x)=1+b^2\log(x)$, $\phi'(x)=2b\frac{\log(x)}{x}$

$\phi''(x)=\frac{2b}{x^2}-\frac{2b\log(x)}{x^2}=2b\frac{(1-\log(x))}{x^2}\implies\phi''(1)=2b$ ⟶ convergenza quadratica se $b\neq 0$

se $b=0$ $\phi(x)=1$ convergenza in un passo (ordine ∞)

se $b>0$ $\phi'(x)>0$ su $(1,1+\rho)$ ⟶ si ha convergenza monotona se si parte a destra di α ($x_0\in(1,1+\rho)$)

se $b<0$ $\phi'(x)<0$ su $(1-\rho,1)$ ⟶ a sinistra di α ($x_0\in(1-\rho,1)$)

metodo di Newton o delle tangenti:

$f(x)=0 \rightsquigarrow x=\phi(x)$, $f\in C^1$

Scegliendo $\phi(x)=x-\frac{f(x)}{f'(x)}$ ⇝ $\begin{cases} x_0 \text{ dato} \\ x_{n+1}=x_n-\frac{f(x_n)}{f'(x_n)} \end{cases}$

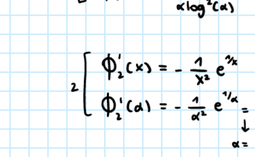

$x-g(x)\cdot f(x)$ ↳ $g(x)=\frac{1}{f'(x)}$

definizione: $f:[a,b]\to\mathbb{R}$ continua tale che $f(\alpha)=0$, $\alpha\in[a,b]$; α è detta radice di ordine o molteplicità r se vale: $\lim_{x\to\alpha}\frac{f(x)}{(x-\alpha)^r}=c<+\infty$ (con $c\neq 0$)

quando $r=1$ la radice viene detta semplice

teorema: se α è una radice semplice di $f(x)$ con $f\in C^2$, allora il metodo di Newton converge localmente in modo superlineare con ordine $p\ge 2$ ⟶ in particolare, vale: $\lim_{n\to+\infty}\frac{|x_{n+1}-\alpha|}{|x_n-\alpha|^2}=\frac{1}{2}\frac{f''(\alpha)}{f'(\alpha)}$ quindi $\begin{cases} f''(\alpha)\neq 0 \to p=2 \\ f''(\alpha)=0 \to p>2 \end{cases}$

dimostrazione: $\phi(x)=x-\frac{f(x)}{f'(x)}\implies\phi'(x)=1-\frac{[f'(x)]^2-f(x)f''(x)}{[f'(x)]^2}=\frac{f(x)f''(x)}{[f'(x)]^2}\implies\phi'(\alpha)=\frac{\overbrace{f(\alpha)}^{0}f''(\alpha)}{[f'(\alpha)]^2}=0$ ⇝ metodo converge superiormente

↳ se $f'(\alpha)\neq 0 \leftarrow \alpha$ radice semplice $\implies f'(\alpha)\neq 0$

per la seconda parte del teorema:

$$\phi''(x)=\frac{(f'\cdot f''+f\cdot f''')(f')^2-f\cdot f''\cdot 2f'\cdot f''}{(f')^4}\implies\phi''(\alpha)=\frac{[f'(\alpha)]^3\cdot f'(\alpha)}{[f'(\alpha)]^2}=\frac{f''(\alpha)}{f'(\alpha)\neq 0}$$

$$\frac{|x_{n+1}-\alpha|}{|x_n-\alpha|^2}=\frac{|\phi(x_n)-\phi(\alpha)|}{|x_n-\alpha|^2}=\left|\frac{\overbrace{\phi'(\alpha)}^{0}(x_n-\alpha)+\frac{\phi''(\varepsilon)(x_n-\alpha)^2}{2}}{|x_n-\alpha|^2}\right|=\frac{1}{2}|\phi''(\varepsilon)|\xrightarrow{n\to+\infty}\frac{1}{2}\phi''(\alpha)=\frac{1}{2}\left|\frac{f''(\alpha)}{f'(\alpha)}\right|$$

↳ Taylor

proprietà: se $f\in C^r([a,b])$, $\alpha\in[a,b]$ è radice di ordine r se e solo se $f(\alpha)=f'(\alpha)=f''(\alpha)=\dots=f^{(r-1)}(\alpha)=0$, $f^{(r)}(\alpha)\neq 0$

intuitivamente, α radice di ordine r significa che possiamo scrivere $f(x)=(x-\alpha)^r\cdot g(x)$ tale che $g(\alpha)\neq 0$, $f'(x)=r(x-\alpha)^{r-1}\cdot g(x)+(x-\alpha)^r\cdot g'(x) \rightsquigarrow f'(\alpha)=0+0$

$f^{(r-1)}(\alpha)=0$

in particolare, $f\in C^1$ e α radice semplice $\implies f'(\alpha)\neq 0$

esempio: supponiamo di voler calcolare t^{-1} con $t\in\mathbb{R}^+$ senza usare divisioni. è equivalente a cercare gli zeri di: $f(x)=x^{-1}-t$

$\phi(x)=x-\frac{f(x)}{f'(x)}=x-\frac{x^{-1}-t}{-x^{-2}}=x+x-tx^2=2x-tx^2$

$x_{n+1}=2x_n-tx_n^2$

come scelgo x_0 in modo da convergere?

$\phi'(x)=2-2xt=2(1-xt)$

↳ $|\phi'(x)|<1 \iff \begin{cases} 1-xt<\frac{1}{2} \\ 1-xt>-\frac{1}{2} \end{cases}\implies\begin{cases} x>\frac{t^{-1}}{2} \\ x<\frac{3}{2}t^{-1} \end{cases}$

$\implies$ Newton converge se parto da una stima non troppo sbagliata ovvero devo partire con $x_0\in\left[t^{-1}-\frac{t^{-1}}{2},t^{-1}+\frac{t^{-1}}{2}\right]$

esempio: (x casa)

calcolare la quantità $\sqrt[k]{t}$ senza usare estrazioni di radice con il metodo di Newton su $f(x)=x^k-t$

determinare per quali x_0 si ha convergenza

radici multiple: supponiamo α radice di molteplicità $s>1$, ovvero $f(x)=g(x)(x-\alpha)^s$ con $g(\alpha)\neq 0$, $f\in C^2$ (abbiamo $f'(\alpha)=0$), definiamo Newton in questo caso come $\phi(x)=\begin{cases} x-\frac{f(x)}{f'(x)} & \text{se } x\neq\alpha \\ \alpha & \text{se } x=\alpha \end{cases}$

↳ in questo caso si ha: $\phi'(x)=1-\frac{(f')^2-ff''}{(f')^2}=\frac{ff''}{(f')^2}$ (*)

sostituendo queste espressioni in (*) si ottiene ← $\begin{cases} f=g(x)(x-\alpha)^s \\ f'=g'(x)(x-\alpha)^s-sg(x)(x-\alpha)^{s-1} \\ f''=g''(x-\alpha)^s+sg'(x-\alpha)^{s-1}+sg'(x-\alpha)^{s-1}+s(s-1)g(x-\alpha)^{s-2} \end{cases}$

$\phi'(\alpha)=1-\frac{sg(\alpha)^2}{s^2g(\alpha)^2}=1-\frac{1}{s}<1$ ($\frac{1}{s}\in(0,1)$ $\forall s>1$) $\forall s\ge 1$

$\implies$ Newton converge in maniera lineare per $s>1$

commento: se si conosce s (la molteplicità della radice) si può modificare Newton in maniera minimale per riacquisire la convergenza quadratica: $x_{n+1}=x_n-s\frac{f(x_n)}{f'(x_n)}=:\tilde{\phi}(x_n)$

x casa: verificare che $\tilde{\phi}'(\alpha)=0$ con $\alpha: f(\alpha)=0$

lezione 21 (13/05/2024)

13 May 2024 12:11

ripasso della scorsa lezione: Metodo di Newton per la soluzione di equazioni non lineari $f(x)=0$ con $f:\mathbb{R}\to\mathbb{R}$

↳ consiste nel generare una successione del tipo: $\begin{cases} x_0 \text{ dato} \\ x_{n+1} = x_n - \dfrac{f(x_n)}{f'(x_n)} =: \phi(x_n) \quad n\geq 1 \end{cases}$

- f deve essere di classe C^1
- se f è di classe C^2 e α è radice semplice → si ha convergenza locale superlineare
- per avere convergenza di un metodo stazionario ad un punto si deve scegliere x_0 in un intorno $[\alpha-\rho,\alpha+\rho]$, $\rho\in\mathbb{R}^+$, in cui $|\phi'(x)|<1$

---

domanda: sia $[a,b]\subset\mathbb{R}$. quando possiamo assicurare che un metodo converge per ogni $x_0\in[a,b]$?

↳ teorema: se $\phi(x)\in C^1([a,b])$ e (1) $\phi(x)\in[a,b]$ $\forall x\in[a,b]$ [ipotesi in più rispetto al teorema di convergenza locale]

(2) $|\phi'(x)|<1$ $\forall x\in[a,b]$

allora esiste un unico punto fisso α di $\phi(x)$ in $[a,b]$ ed il metodo $x_{n+1}=\phi(x_n)$ per $n\geq 1$ converge $\forall x_0\in[a,b]$

=> per il metodo di Newton si possono garantire le ipotesi (1) e (2) sotto particolari assunzioni sul segno di f, f' e f''

teorema: sia $\alpha\in[a,b]\subset\mathbb{R}$ radice semplice di $f\in C^2([a,b])$

se f' e f'' hanno segno costante in $[a,b]$ allora il metodo di Newton converge per ogni x_0 tale che $f(x_0)f''(x_0)>0$

↳ se una funzione è crescente → tutto intervallo crescente (e viceversa)

osservazioni: (i) se la funzione f è concava, allora il metodo di Newton converge, partendo da x_0 in cui la funzione è negativa. viceversa, se f è convessa si ha convergenza partendo da un punto corrispondente ad un valore positivo di f

(ii) la condizione f' e f'' di segno costante comporta 4 casi possibili:

1) $f'>0$ e $f''>0$ f convessa crescente

2) $f'>0$, $f''<0$ f concava crescente 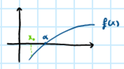

3) $f'<0$, $f''>0$ f convessa decrescente 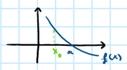

4) $f'<0$, $f''<0$ f concava decrescente 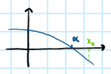

esempio: cerchiamo un intervallo di separazione (intervallo in cui esiste una sola radice della funzione f) per la radice di $f(x)=x+\log(x)$ si fornisca un punto di partenza x_0 che rende il metodo di Newton convergente

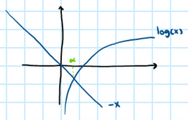

si dimostri che f ha una sola radice in $(e^{-1},1)$

$f'(x)=1+\frac{1}{x}$, $f''(x)=-\frac{1}{x^2}$

$f'>0$ in $[e^{-1},1]$

$f''<0$ in $[e^{-1},1]$

inoltre α è radice semplice ⟶ quindi scegliendo $x_0=e^{-1}$ il metodo di Newton converge

equazioni non lineari in $\mathbb{R}^n$:

la teoria vista fino ad adesso può essere estesa al caso $f:\mathbb{R}^n\to\mathbb{R}^n$ per il problema:

trovare $x\in\mathbb{R}^n$, $x=(x_1,\dots,x_n)$ tale che $\begin{cases} f_1(x_1,\dots,x_n)=0 \\ f_2(x_1,\dots,x_n)=0 \\ \vdots \\ f_n(x_1,\dots,x_n)=0 \end{cases}$ con $f_j:\mathbb{R}^n\to\mathbb{R}$ $j=1,\dots,n$

[nel caso di sistemi lineari $f(x)=Ax-b$]

l'idea è ancora una volta quella di riscrivere l'equazione $f(x)=0$ come un'equazione di punto fisso vettoriale ossia $x=\phi(x)$ $\phi:\mathbb{R}^n\to\mathbb{R}^n$

una scelta canonica consiste nel prendere $\phi(x)=x-\underbrace{G(x)}_{n\times n}\cdot\underbrace{f(x)}_{n}$ dove $G:\mathbb{R}^n\to\mathbb{R}^{n\times n}$

$G(x)=\begin{bmatrix} G_{11}(x) & \cdots & G_{1n}(x) \\ \vdots & & \vdots \\ G_{n1}(x) & \cdots & G_{nn}(x) \end{bmatrix}$ $f(x)=\begin{bmatrix} f_1(x) \\ \vdots \\ f_n(x) \end{bmatrix}$

e $G_{ij}:\mathbb{R}^n\to\mathbb{R}$ $\forall 1\leq i,j\leq n$. si assume che $G(x)$ sia non singolare in un intorno della radice $\alpha\in\mathbb{R}^n$

si considera infine l'iterazione $\underbrace{x^{(k+1)}}_{\mathbb{R}^n}=\phi(x^{(k)})$ $k=0,1,2,\dots$ a partire da $x^{(0)}\in\mathbb{R}^n$ dato

definizione: la successione $\{x^{(k)}\}_{k\in\mathbb{N}}$ converge a $\alpha\in\mathbb{R}^n$ se $\lim_{k\to+\infty}\|x^{(k)}-\alpha\|_2=0$

inoltre la convergenza si dice di ordine $p\geq 1$ se $\lim_{k\to+\infty}\frac{\|x^{(k+1)}-\alpha\|_2}{\|x^{(k)}-\alpha\|_2^p}=c$ con $c\neq 0$ e $c<+\infty$

nel caso in cui esistano e siano continue le derivate di ϕ rispetto alle variabili $x_1,\dots,x_n$ si considera la matrice jacobiana $J\phi:\mathbb{R}^n\to\mathbb{R}^{n\times n}$

$J\phi(x)=\begin{bmatrix} \frac{\partial\phi_1}{\partial x_1}(x) & \cdots & \frac{\partial\phi_1}{\partial x_n}(x) \\ \vdots & & \vdots \\ \frac{\partial\phi_n}{\partial x_1}(x) & \cdots & \frac{\partial\phi_n}{\partial x_n}(x) \end{bmatrix}$ $(J\phi(x))_{ij}=\frac{\partial\phi_i}{\partial x_j}(x)$ $\forall 1\leq i,j\leq n$

si generalizza il teorema di convergenza locale

teorema: sia $\phi\in C^1(\Omega)$ con $\Omega\subseteq\mathbb{R}^n$ e sia $\alpha\in\Omega$ tale che $\phi(\alpha)=\alpha$

se $\rho(J\phi(\alpha))<1$ allora $\exists J>0:\forall x^{(0)}$ con $\|x^{(0)}-\alpha\|_2<\delta$, la successione $\begin{cases} x^{(0)} \\ x^{(k+1)}=\phi(x^{(k)}) \quad k\geq 0 \end{cases}$ converge ad α

in particolare, se per una qualsiasi norma matriciale $\|\cdot\|$ si ha $\|J\phi(\alpha)\|\leq L\in(0,1)$ allora $\exists\delta>0:\forall x^{(0)}$ con $\|x^{(0)}-\alpha\|_2\leq\delta$ si ottiene una successione convergente e tale che $\lim_{k\to+\infty}\frac{\|x^{(k+1)}-\alpha\|}{\|x^{(k)}-\alpha\|}\leq L$

esempio: per $n=2$

$\begin{cases} x_1-\frac{1}{4}(x_1^2+x_2^2)=0 \\ x_2+x_1-2=0 \end{cases}\iff f(x)=0$

$f(x)=\begin{bmatrix} f_1(x) \\ f_2(x) \end{bmatrix}=\begin{bmatrix} x_1-\frac{1}{4}(x_1^2+x_2^2) \\ x_2+x_1-2 \end{bmatrix}$ $f(x)=0\iff\phi(x)=x$

$\phi(x)=\begin{bmatrix} \phi_1(x) \\ \phi_2(x) \end{bmatrix}=\begin{bmatrix} \frac{1}{4}(x_1^2+x_2^2) \\ 2-x_1 \end{bmatrix}$

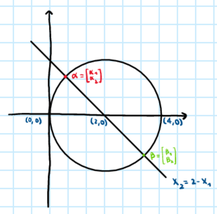

$f(x)=0$ ha 2 soluzioni che corrispondono all'intersezione del cerchio

$0=x_1-\frac{1}{4}(x_1^2+x_2^2)=-\frac{(x_1-2)^2}{4}-\frac{x_2^2}{4}+1$

con la retta $x_2=2-x_1$

la matrice jacobiana di ϕ è data $J\phi(x)=\begin{bmatrix} \frac{x_1}{2} & \frac{x_2}{2} \\ -1 & 0 \end{bmatrix}$

abbiamo $\|J\phi(x)\|_\infty\geq 1$ e $\|J\phi(x)\|_1\geq 1$ $\forall x$

consideriamo allora gli autovalori di $J\phi$ ⟶ $\left(\frac{x_1}{2}-\lambda\right)(-\lambda)+\frac{x_2}{2}=0\implies\lambda_{1,2}=\frac{\frac{x_1}{2}\pm\sqrt{\frac{x_1^2}{4}-2x_2}}{2}$

nel caso di α si ha che $\alpha_1<1$ e $2>\alpha_2>\alpha_1$, per cui $\frac{x_1^2}{4}-2x_2<0$ ovvero che $J\phi(\alpha)$ ha autovalori complessi coniugati di modulo $\rho(J\phi(\alpha))=\sqrt{\frac{\alpha_1^2}{16}-\frac{\alpha_1^2}{16}+\frac{\alpha_2}{2}}=\sqrt{\frac{\alpha_2}{2}}<1\implies$ il metodo è localmente convergente in α

metodo di Newton-Raphson in $\mathbb{R}^n$:

se le funzioni $f_j:\mathbb{R}^n\to\mathbb{R}$, $\forall j=1,\dots,n$, sono derivabili con continuità e la jacobiana di $f(x)$ è non singolare in un intorno Ω di una radice α di f, allora si può generalizzare il metodo di Newton $\phi(x)=x-\underbrace{(Jf(x))^{-1}}_{n\times n}\underbrace{f(x)}_{n}$

si genera quindi la successione $\begin{cases} x^{(0)} \text{ dato} \\ x^{(k+1)}=x^{(k)}-Jf(x^{(k)})^{-1}f(x^{(k)}) \quad k\geq 0 \end{cases}$

osservazione: nell'implementazione si forma $f(x^{(k)})\in\mathbb{R}^n$ e $Jf(x^{(k)})\in\mathbb{R}^{n\times n}$ e poi si risolve il sistema lineare $Jf(x^{(k)})\,y=f(x^{(k)})$ e infine $x^{(k+1)}=x^{(k)}-y$

per quanto riguarda la convergenza vale un risultato analogo al caso scalare che assicura convergenza locale quadratica

teorema: sia $f\in C^2(\Omega)$, con $\Omega\subseteq\mathbb{R}^n$, e sia $\alpha\in\Omega$ tale che $f(\alpha)=0$

se $Jf(x)$ è non singolare $\forall x\in\Omega$ allora $\exists\mathcal{B}\subseteq\Omega$ intorno di α e $\beta>0$ tale che $\forall x^{(0)}\in\mathcal{B}$ la successione $\{x^{(k)}\}_{k\in\mathbb{N}}$ del metodo di Newton-Raphson soddisfa $\|x^{(k+1)}-\alpha\|_2\leq\beta\|x^{(k)}-\alpha\|_2^2$ $k\geq 0$

osservazione: i risultati dati oggi si estendono facilmente a norme diverse da $\|\cdot\|_2$